ByteDance | Seed

AgentGym-RL：通过多轮强化学习训练大语言模型智能体进行长时程决策

Zhiheng Xi[1*†], Jixuan Huang[1*], Chenyang Liao[1*], Baodai Huang[1], Honglin Guo[1], Jiaqi Liu[1], Rui Zheng[1], Junjie Ye[1], Jiazheng Zhang[1], Wenxiang Chen[1], Wei He[1], Yiwen Ding[1], Guanyu Li[1], Zehui Chen[2], Zhengyin Du[2], Xuesong Yao[2], Yufei Xu[2], Jiecao Chen[2], Tao Gui[1,3†], Zuxuan Wu[1,3], Qi Zhang[1†], Xuanjing Huang[1], Yu-Gang Jiang[1]

[1] 复旦大学, [2] 字节跳动 Seed, [3] 上海创新研究院

摘要

开发能够通过一系列智能决策解决复杂现实任务的自主大语言模型智能体，是一个快速发展的前沿方向。与人类认知发展类似，智能体有望通过探索环境并与之交互来获取知识和技能。尽管已经取得诸多进展，研究社区仍缺乏一个统一的交互式强化学习（RL）框架，能够在多样且真实的环境中、不依赖监督微调（SFT）而从零开始有效训练此类智能体。为弥补这一空白，我们提出 AgentGym-RL，这是一个通过强化学习训练大语言模型智能体进行多轮交互式决策的新框架。该框架采用模块化、解耦式架构，具有高度灵活性和可扩展性；它涵盖丰富多样的现实场景，并支持主流强化学习算法。此外，我们提出 ScalingInter-RL，一种旨在平衡探索与利用并实现稳定强化学习优化的训练方法。在训练早期，该方法通过限制交互轮数来强调利用；随后逐步扩大交互时程并转向探索，以鼓励多样化的问题求解策略。由此，智能体能够发展出更加多样的行为，并且在长时程下不易发生训练崩溃。我们开展了大量实验，验证 AgentGym-RL 框架和 ScalingInter-RL 方法的稳定性与有效性。我们的智能体在多种环境的 27 项任务上达到或超越商业模型。我们给出了若干关键洞见，并将开源完整的 AgentGym-RL 框架（包括代码和数据集），助力研究社区开发下一代智能体。

通讯作者: zhxi22@m.fudan.edu.cn, tgui@fudan.edu.cn, qz@fudan.edu.cn

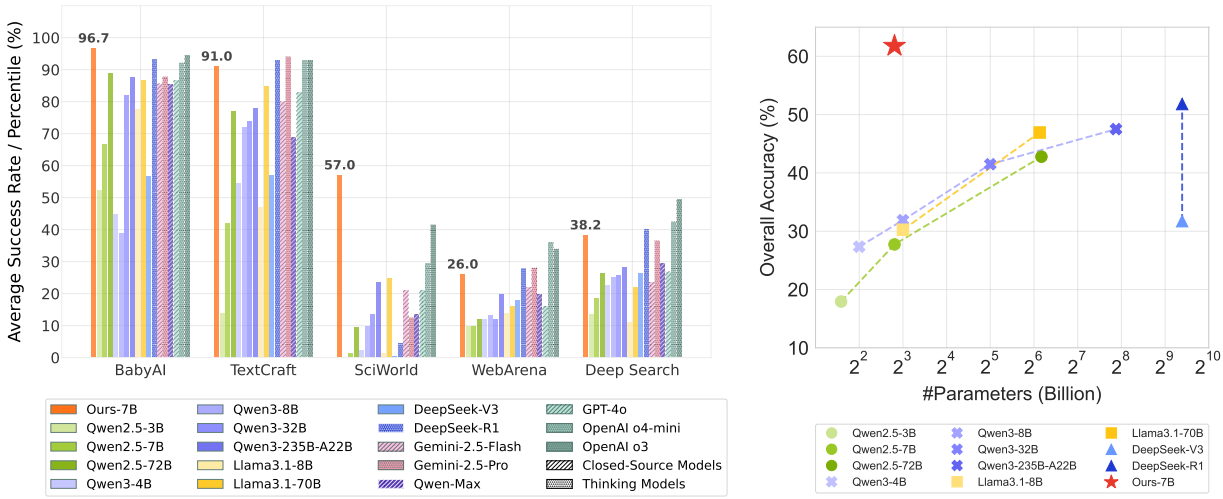
代码: https://github.com/woooodyy/AgentGym-RL

项目: https://AgentGym-RL.github.io

1 引言

随着大语言模型（LLM）的蓬勃发展 [2, 11, 41, 65, 84]，其应用已从聊天机器人扩展到能够处理长时程现实任务的自主智能体 [39, 79]。面对一项复杂任务，这些智能体会与环境交互，并通过一系列智能决策来实现目标 [95]。与人类认知发展类似，我们期望大语言模型智能体通过主动探索环境并与之交互来获取新知识与技能 [42, 77]。因此，一种自然的方法是使用强化学习（RL）训练这些智能体 [62]。

尽管强化学习在大语言模型推理等领域取得了进展 [12, 18, 23, 66, 68, 76]，但现有研究大多局限于单轮任务，模型无需与复杂环境进行多轮交互 [71]。近期虽有一些工作尝试扩展强化学习，以训练具备多轮能力的大语言模型智能体 [3, 26, 30, 47, 71, 95]，但这些工作在任务复杂度和环境多样性方面仍有限。此外，它们在优化



(a) (b)

图 1 **左图**：专有模型、开源模型以及我们的强化学习模型在不同智能体任务上的表现。**右图**：性能与模型规模的关系。我们的框架与方法协同作用，显著增强了开源 7B 规模模型的能力，使其达到可媲美甚至超越顶尖专有大模型的水平。

稳定性和效率方面存在困难，导致性能欠佳。尤其重要的是，研究社区目前仍缺少一个统一、端到端的交互式多轮强化学习框架；该框架应已被证明能够在广泛的现实场景和环境中有效训练大语言模型智能体，且无需将监督微调作为前置步骤 [12]。

为弥补这一空白，我们提出 AgentGym-RL，这是一个通过强化学习训练大语言模型智能体进行多轮交互式决策的新框架（图 2）。AgentGym-RL 采用模块化、解耦式架构，使智能体、环境与学习算法能够清晰分离，从而为多样化的研究需求提供高度可扩展性和灵活性。该框架支持 PPO [53]、GRPO [54] 和 REINFORCE++ [21] 等主流强化学习算法，并配备了广泛的现实场景，例如网页导航 [13, 87, 94]、深度搜索 [26, 72]、数字游戏 [15, 45]、具身任务 [7, 58] 和科学任务 [60, 69]。

此外，为应对探索与利用之间的权衡，并提高智能体强化学习训练的优化稳定性，我们提出 ScalingInter-RL，该方法在训练过程中逐步延长智能体与环境的交互时程。该方法的核心思想是让智能体分阶段适应环境：首先侧重利用，以可靠掌握基本技能和简单任务；随后延长交互时程，以促进探索、完善行为、摆脱捷径并应对更复杂的挑战。这种渐进式交互扩展策略使智能体能够发现更丰富的交互模式（例如规划与反思），并随着时间推移培养更广泛的技能与行为。

大量实验表明，AgentGym-RL 在横跨 5 类场景的 5 项任务上均为智能体带来了稳定且显著的性能提升（图 1a）。使用我们的框架与方法训练的开源模型（例如 Qwen-2.5-7B [83]）平均提升了 33.65 分，其表现可媲美甚至超越 OpenAI o3 [42] 和 Gemini-2.5-Pro [10] 等规模更大的商业闭源模型。我们还开展了大量分析实验，得出若干关键发现与洞见，表明扩展后训练计算量和测试时计算量在发展智能体智能方面具有巨大潜力（图 1b）。我们希望本工作能为研究社区的发展作出有价值的贡献。

总而言之，我们的主要贡献如下：

1. 我们提出并开源 AgentGym-RL，这是一个面向智能体多轮交互式决策的新型统一、模块化且灵活的端到端强化学习框架，涵盖多种场景和环境。
2. 我们提出 ScalingInter-RL，这是一个渐进式交互扩展框架，可使智能体逐步适应环境，促进交互模式的完善和技能习得。该框架提高了强化学习的优化稳定性，并实现探索与利用之间的平衡。
3. 大量实验表明，AgentGym-RL 和 ScalingInter-RL 能够带来显著且稳定的性能提升，达到或超越商业模型。此外，我们通过实证分析获得了关于智能体设计和运行范式的重要洞见，为未来研究提供了有价值的指导与资源。

2 预备知识

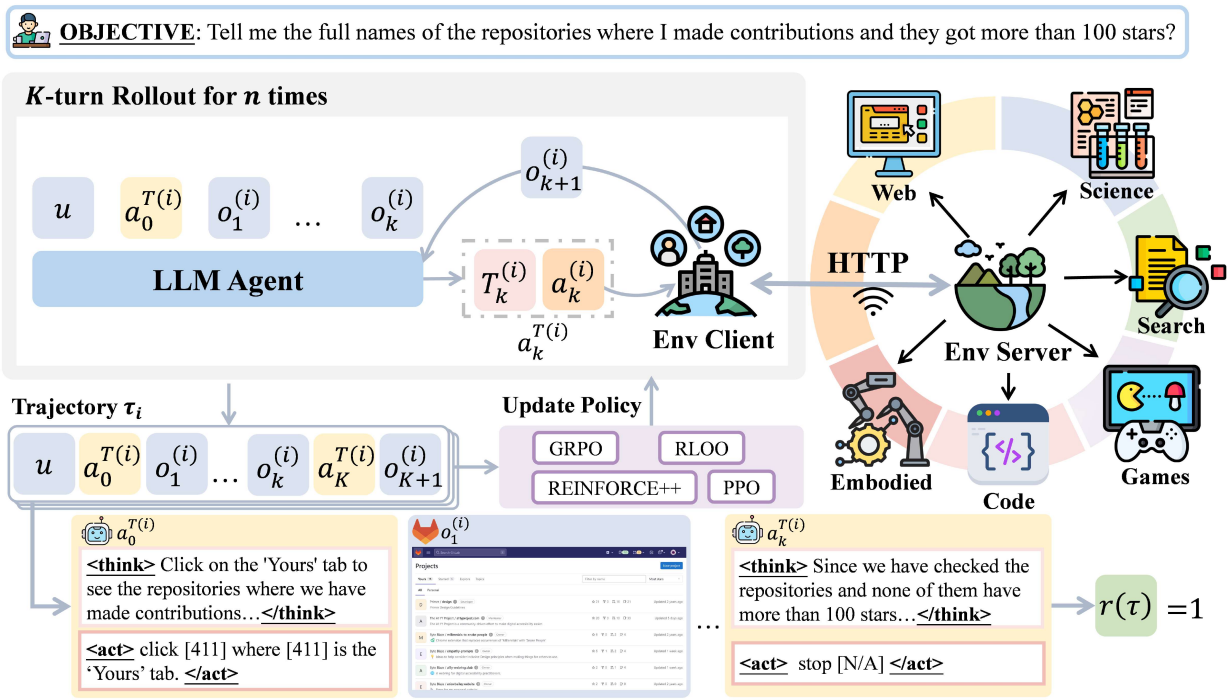


图 2 AgentGym-RL 框架概览。该框架采用解耦、灵活且可扩展的架构，由环境、智能体和训练三个主要模块组成，并支持多种场景、环境和算法。

2.1 形式化定义

本文研究多轮交互式决策任务，即智能体任务，并参照 Xi et al. [77], Zhou et al. [95] 将其建模为部分可观测马尔可夫决策过程（POMDP）$(\mathcal{U}, \mathcal{S}, \mathcal{A}, \mathcal{O}, \mathcal{T}, r)$，其中 $\mathcal{U}, \mathcal{S}, \mathcal{O}, \mathcal{T} : \mathcal{S} \times \mathcal{A} \to \mathcal{S}, r : \mathcal{U} \times \mathcal{S} \to \mathbb{R}$ 分别表示指令空间、状态空间、动作空间、观测空间、确定性状态转移函数和奖励函数。

给定任务指令 $u \in \mathcal{U}$，智能体任务要求大语言模型智能体根据由 θ 参数化的策略 π_θ 生成一系列动作 $a_k^T \sim \pi_\theta(\cdot|s_k)$，以完成给定任务，其中 $a_k \in \mathcal{A}$、$s_k \in \mathcal{S}$，而 T 为思考路径 [88]。随后，智能体从环境接收观测 $o_k \in O$，状态相应地转移为 $\mathcal{T}(s_k, a_k) = s_{k+1}$。最后，经过 N 轮交互后，环境 e 给出结果奖励 $r(\tau) \in [0, 1]$，用于描述多轮交互式决策任务的完成情况。

2.2 策略梯度

我们采用策略梯度方法 [63] 优化策略，以最大化期望累积奖励。基于价值的方法通过估计价值函数来导出策略，而策略梯度方法与之不同，它直接在策略参数空间中搜索最优策略。

策略梯度方法的核心思想是依据目标函数 $J(\theta)$ 执行梯度上升，其中该目标是策略参数 θ 的函数。具体而言，$J(\theta)$ 表示智能体遵循策略 π_θ 与环境交互时预期获得的累积奖励。在数学上，它表示由策略生成的轨迹 τ 上总奖励 $r(\tau)$ 的期望：

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [r(\tau)] \tag{1}$$

为了对 $J(\theta)$ 执行梯度上升，我们需要策略梯度 $\nabla_\theta J(\theta)$。在原始策略梯度方法中，策略梯度可估计为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[r(\tau) \sum_{k=0}^{K} \nabla_\theta \log \pi_\theta(a_k|s_k) \right] \tag{2}$$

其中，π_θ 是由 θ 参数化的策略，τ 表示由一系列状态和动作构成的轨迹，a_k 和 s_k 分别为时间步 k 的动作与状态，$r(\tau)$ 为轨迹 τ 的奖励。

得到策略梯度估计后，我们可以利用梯度下降法按如下方式优化策略 π_θ 的参数 θ，使其朝着最大化期望累积奖励的方向更新：

$$\theta_{new} = \theta_{old} - \alpha \nabla_\theta J(\theta) \tag{3}$$

其中，$\alpha \in [0,1]$ 为学习率。用于训练大语言模型的主流强化学习算法包括 PPO [53]、GRPO [54]、REINFORCE++ [21] 和 RLOO [30]，这些算法均已集成到我们的框架中。

3 AgentGym-RL 框架

3.1 架构概览

AgentGym-RL 框架构建于 AgentGym [77] 之上，后者为大语言模型智能体提供了若干基础交互环境。我们的主要扩展集中在三个方面：

1. 引入更多真实环境与任务（例如深度搜索任务），以促进更通用智能体的发展。
2. 纳入多种在线强化学习算法，涵盖经典方法和当前最先进的方法，从而与当前研究前沿保持一致，并为研究社区提供可继续拓展的基础。
3. 实施广泛的工程优化以及智能体与环境的协同设计，例如改进轨迹采样的并行化并缓解内存泄漏。

如图 2 所示，该框架由三个主要组件构成：

- **环境**模块通过采用统一 HTTP 协议的标准化服务器与客户端架构提供多种场景。
- **智能体**模块封装智能体在多轮交互中的推理和决策过程，并支持长时程规划、自我反思等高级机制。
- **训练**模块实现强化学习流程和其他训练方法，以优化智能体策略。

附录 A 对我们的架构作了更详细的说明。

给定一批用户查询和初始环境状态，我们的框架会并行初始化多个相互独立的环境客户端。每个客户端仅与一个智能体交互，确保不同执行过程彼此隔离、互不干扰。在每个客户端中，智能体生成一个在环境中执行的动作，随后环境返回更新后的状态和奖励，供下一步决策使用。框架跨客户端并发收集一批此类轨迹，再将其输入训练模块以更新智能体策略。框架的整体工作流程及相应伪代码如图 3 所示。

3.2 功能与特点

本节将重点介绍 AgentGym-RL 框架的主要特点，涵盖环境覆盖范围、算法支持、架构优势和开源贡献四个方面。

3.2.1 多样化的场景与环境。

为构建能够在现实环境中针对复杂任务进行多轮序列决策的大语言模型智能体，AgentGym-RL 覆盖广泛的场景，从而全面评估并培养智能体感知环境、围绕目标进行长期规划、通过深入推理作出智能决策，以及在遭遇挫折或犯错时进行反思与纠正的能力。

其中包括：

- **网页导航**：与动态网站交互，完成预订航班或提取结构化信息等任务；这要求智能体遵循指令、理解文本和视觉内容、操控动态界面并规划多步操作。
- **深度搜索**：借助浏览器或 Python 解释器等工具执行多步骤、目标导向的查询；这要求智能体具备强大的信息搜寻、多跳推理、长期记忆以及跨来源知识综合能力。
- **数字游戏**：在交互式游戏环境中探索并解决问题，侧重实时决策、策略制定以及对复杂动态情境的适应能力。

```
# Stage 1: Generate responses
task_ids = expand(task_ids, sample_num)
envs = create_env_clients(task_ids, "webarena", base_url)

Do in parallel:
    for (env, task_id) in zip(envs, task_ids):
        env.reset(task_id)

handlers =[
    RolloutHandler().add_user_message(env.observe())
    for env in envs]

for i in range(max_rounds)
    prompts = [h.get_prompt() for h in handlers]
    responses = actor.generate(prompts)

    results = thread_safe_list()
    Do in parallel:
        for (env, response) in zip (envs, responses):
            results.append(env.step(response))

    for (h, r, res) in zip(handlers, responses, results):
        h.add_assistant_message(r)
        h.add_user_message(res.state)
        h.score = res.score

    if all_done(handlers): break
```

```
# Stage 2: Prepare experience
batch = gen_batch_from_rollout_handlers(handlers)
batch = actor.compute_log_prob(batch)
batch = reference.compute_ref_log_prob(batch)
batch = compute_advantages(batch, method="grpo")

# Stage 3: Actor training
actor.update_actor(batch)
```

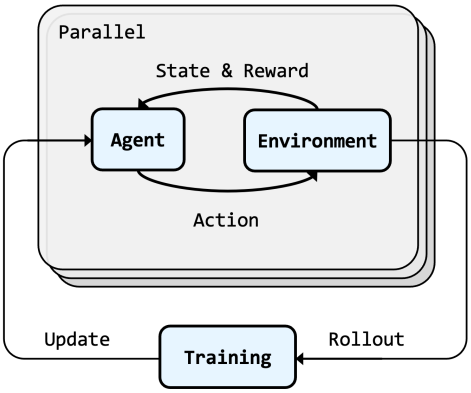


图 3 所提出框架的示例用法伪代码（框架提供的 API 以橙色标示），以及用于说明智能体与环境交互和训练流程的简化原理图。

- **具身任务**：控制虚拟或实体身体进行导航、操控和任务执行；这要求智能体具备目标导向的规划、空间推理以及稳健的感知与动作对齐能力。
- **科学任务**：在遵循物理规律、知识密集的情境中开展实验并解决问题；这要求智能体能够精确执行、动态解读反馈、基于证据推理并迭代完善假设。

3.2.2 全面支持强化学习算法。

原始 AgentGym 仅支持少量基于监督微调的训练方法，而 AgentGym-RL 则以在线强化学习为核心，使智能体能够通过与环境持续交互进行动态探索与适应。

AgentGym-RL 实现了一套主流在线强化学习算法：(1) **PPO**[53]，一种策略梯度方法，通过裁剪策略更新、防止步长过大来提高训练稳定性；它简化了 TRPO[52] 的信赖域概念，同时保持强劲的实证性能；(2) **GRPO**[54]，一种由 PPO 衍生的方法，它对每个状态下采样动作组内的奖励进行归一化，并采用 PPO 式裁剪，从而相对于其他动作强化表现更好的动作；(3) **RLOO**[30]，REINFORCE 的一种变体，它将同一批次中其他样本的平均奖励作为各样本的基线，从而降低策略梯度估计的方差；(4) **REINFORCE++**[21]，一种增强的 REINFORCE[73] 算法，集成 PPO 式裁剪和 KL 惩罚，无需评论家网络即可实现更稳定、更简洁且计算效率更高的训练。

除在线强化学习外，该框架还支持多种互补的训练范式：**SFT（监督微调）**[44] 是一种标准训练方法，智能体在其中逐步学习模仿专家示范或标准轨迹。**DPO（直接偏好优化）**[50] 是一种不涉及与环境在线交互的强化学习变体，它转而从预先收集的偏好对中学习。对于拒绝采样 [35]，我们支持 **AgentEvol**[77] 等方法：依据任务是否成功筛选智能体自行生成的轨迹，再利用这些轨迹迭代微调智能体。

3.2.3 可扩展性、可伸缩性与可靠性。

由于 AgentGym-RL 的主要设计目标是支持研究社区开展大规模强化学习研究与开发，我们进行了广泛的工程设计、实践和优化，以确保框架的可扩展性、可伸缩性与可靠性。

- **可扩展性**。可扩展性对于支持不断变化的研究需求至关重要，它使框架能够容纳新环境、新的智能体架构和训练策略，而不影响现有组件。我们的系统采用模块化、解耦式设计，环境、智能体和训练三个核心组件均可即插即用。因此，研究人员可以轻松引入新的强化学习目标、奖励函数或采样技术，从

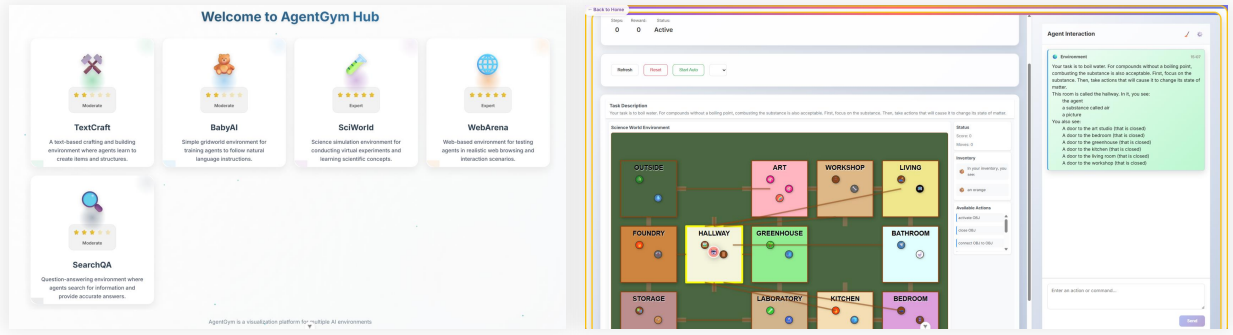


图 4 我们框架的可视化用户界面概览。

而促进可复现实验，并能够探索广泛的算法方向。例如，只需继承 `BaseEnvClient` 并实现 `reset()`、`step()` 和 `observe()` 等必要方法，即可引入一个新环境。实现后，新环境可与现有智能体架构和训练流程无缝配合，从而无需修改任何框架核心组件即可快速开展实验。

- **可伸缩性**。强化学习的最新进展越来越依赖大规模训练，这类训练涉及海量数据和更长的交互序列，给系统的可伸缩性带来了重大挑战。为应对这些挑战，框架必须同时具备扩展并行规模和交互时长的能力。为此，我们实施了一系列优化。例如，我们将 WebArena 默认的“每进程单浏览器”设计替换为基于子进程的架构，使单个服务器能够并发管理多个 Chromium 实例，从而增强并行能力。类似地，在 SciWorld 环境中，我们重新设计了环境的初始化与重置流程，以支持稳健地并行创建和重置多个实例，解决了以往并发实例化失败的问题。此外，我们通过 WebArena 中的 `full-reset` 接口支持更长的训练时程；该接口会在每个回合结束后将各网页服务器恢复至初始状态，从而缓解随时间累积的状态不一致问题。这些优化共同使我们的框架能够有效扩展，既促进大规模训练，也使研究社区能够开展广泛的实验。
- **可靠性**。大规模多轮智能体强化学习训练对系统可靠性提出了重大挑战，即系统能否在漫长的训练期间始终保持稳定可靠的运行。为实现可靠性，框架必须防止可能中断训练的故障，并确保关键资源得到妥善管理。例如，我们优化了 TextCraft 的内存管理实现。原环境的递归 `crafting_tree` 实现存在内存泄漏，其中列表结构冗余地自我复制，导致内存占用呈指数增长，最终在训练过程中崩溃。我们通过重构递归、消除冗余副本解决了这一问题。同样，SciWorld 内部时钟机制的内存泄漏会在长时间轨迹采样期间造成内存逐步累积和系统不稳定。我们通过重构时钟实现消除了这一泄漏。经过这些优化，该框架为长时程训练提供了可靠环境，确保系统在较长交互序列中持续且不间断地运行。

总体而言，这些设计与优化消除了主要工程瓶颈，使在异构环境中开展可复现的大规模强化学习实验成为可能。

3.2.4 开源可用性与社区可扩展性。

我们设计 AgentGym-RL，旨在构建一个协作生态系统，使社区贡献在维护可验证研究标准的同时，直接加速方法进步。AgentGym-RL 采用宽松许可证作为开源框架发布；它构建于 veRL[56] 和 AgentGym[77] 等成熟开源框架之上，并保持完全开源。该框架提供完备的文档、可复现的训练流程和标准化 API，以确保研究透明度并推动实际应用。其模块化架构包含明确定义的扩展点，能够无缝集成新环境和训练方法，使研究社区可在不干扰核心工作流程的情况下扩展功能。为了便于探查数据和模型行为，我们提供了交互式用户界面，以简化迭代开发中的实证分析。

易用性、可复现性与标准化评估。 AgentGym-RL 以方便研究社区使用为设计目标。为系统性解决基于大语言模型的强化学习所面临的可复现性挑战，AgentGym-RL 建立了标准化评估流程和可复现训练流程。该设计通过统一指标和一致的实验规程来确保公平比较。我们提供易于配置的复现脚本，可自动完成从环境配置到最终评估的整个工作流程。这一设计使研究人员能够高保真地复现既有发现，并显著降低在现有工作基础上进一步研究的门槛，从而促进可验证研究标准的形成。

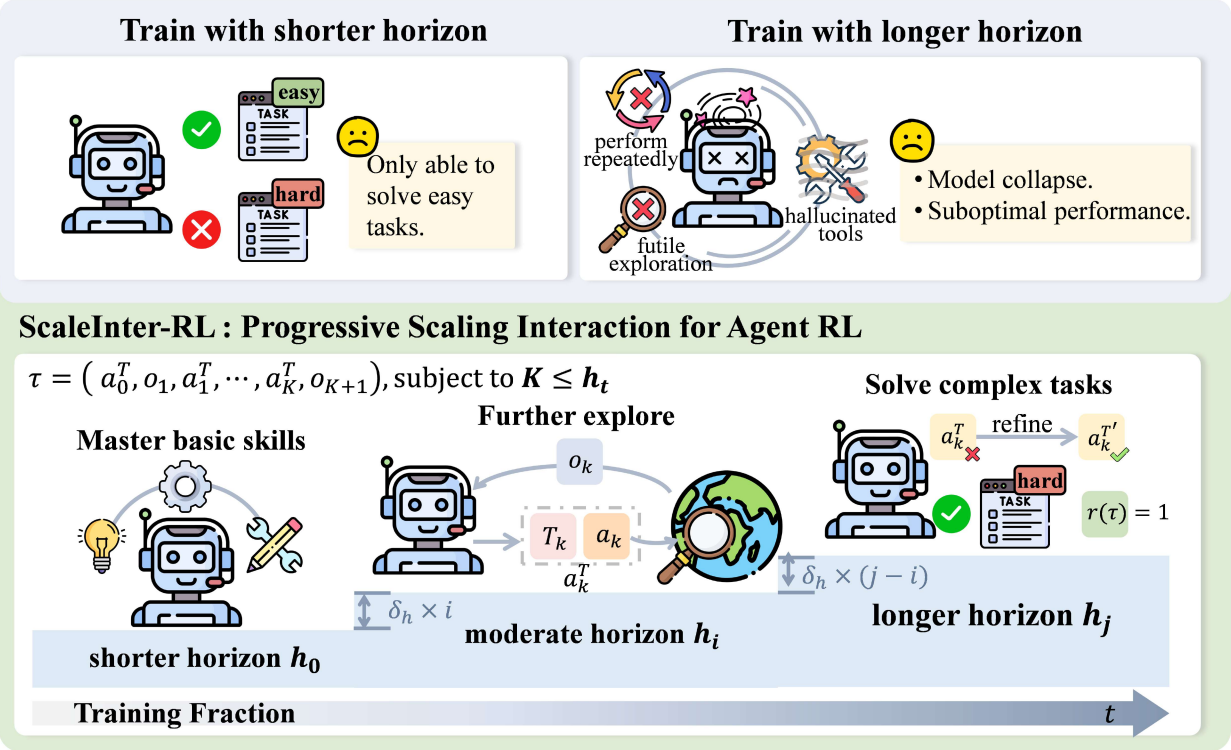


图 5 ScalingInter-RL 方法示意图。该方法使智能体能够分阶段适应：初期通过限制交互轮数，优先进行利用、掌握基本技能并解决简单任务；随后逐步增加交互轮数，以开展探索、避免走捷径、改进行为并应对更困难的问题。最终，这一过程能够训练出更强的智能体。

用于可观测性与分析的可视化用户界面。 如图 4 所示，AgentGym-RL 包含一个交互式用户界面，旨在方便探查数据与模型行为。该工具支持研究人员对智能体的决策过程进行细粒度、逐步检查，从而简化实证分析。它可以回放并检查完整交互轨迹，将环境观测、智能体内部推理及其最终动作之间的相互作用可视化。这项能力使研究人员能够直接洞察模型性能和失败模式，进而加快迭代开发与调试周期。

3.3 ScalingInter-RL：面向智能体强化学习的渐进式交互扩展

动机与核心洞见。 接到任务后，智能体会与环境进行迭代交互：观察变化、据此推理并执行后续动作。通过这一循环，智能体能够充分探索与尝试，最终到达目标状态。这一过程类似于 LLM 推理中的推理计算扩展（OpenAI o1 和 DeepSeek-R1 即为典型示例）：在测试时或 RL 轨迹采样过程中分配额外计算资源，使模型在给出最终答案前进行更深入的推理。

相比之下，我们认为，智能体除了依靠内部推理选择下一步动作外，还应增加与环境的外部交互，以确保充分探索并为实现最终目标积累更丰富的上下文，从而获得一种由实践驱动的洞见。然而，我们的初步实验表明，一开始就采用大量交互轮数往往会使模型陷入冗余推理和无效动作，最终导致训练崩溃、性能下降。反之，始终将交互轮数限制在较小范围内，又会缩窄探索空间，并限制智能体掌握多样化模式的能力。这促使我们提出如下方法。

方法。 受面向 LLM 推理的强化学习研究 [12, 18, 23, 66, 68, 76] 启发，我们提出 ScalingInter-RL，这是一种在保证优化稳定性的同时平衡探索与利用的训练方法。其核心是一种渐进式交互时程扩展策略，可在 RL 过程中自适应调整交互轮数。其目标是在受限交互预算下最大化期望终止奖励：

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [r(\tau)],$$

其中，每条轨迹 $\tau = (a_0^T, o_1, a_1^T, \ldots, a_{K-1}^T, o_K)$ 均从当前策略 π_θ 中采样，K 表示交互总轮数。为使智能体在有限交互资源下快速学会有效行为，我们从较短的交互时程开始训练。通过在初期约束交互时程，智能体

学会以最高效率利用其策略，较早熟练解决简单任务，并为更深入的长时程推理奠定基础。随着训练推进，我们引入单调调度序列 $\{h_1 < h_2 < \cdots < h_n\}$，其中 h_t 定义第 t 阶段允许的最大交互轮数：

$$\tau_t \sim \pi_\theta(\tau \mid h_t), \quad \text{subject to } K_t \leq h_t.$$

按照课程调度，每经过 Δ 个训练步更新一次交互时程 h_t：

$$h_{t+1} = h_t + \delta_h,$$

其中，δ_h 为自适应增量。随着交互时程延长，智能体会受到激励去探索更长的决策路径，从而促进规划、反思和策略性回溯等高阶认知行为的涌现；这与大型推理模型的 RLVR 中观察到的长度扩展现象相似 [3, 12, 37]。这种分阶段扩展使 ScalingInter-RL 能够让交互深度与智能体不断演进的策略能力相匹配，衔接高效的早期利用与长时程泛化。

4 实验

为验证 AgentGym-RL 框架的稳定性与有效性，我们在多种场景和环境中开展了广泛实验。结果表明，LLM 智能体仅依靠环境反馈，无需预先进行监督微调，即可从零开始探索和学习，最终达到与 OpenAI o3 等商业闭源模型相当、甚至更优的性能。

4.1 实验设置

场景、环境与任务。 如前所述，AgentGym-RL 包含五类场景。具体而言，在网页导航方面，我们纳入 WebArena [94]，这是一个真实且可复现的网页环境，涵盖互联网上常见的四个不同领域：在线购物、讨论论坛、协同开发和商业内容管理；在深度搜索方面，我们纳入基于 RAG 的环境 [19, 26, 28, 32, 38, 46, 67, 85]，使 LLM 能够与搜索引擎交互，并解决多轮检索与推理任务；在数字游戏方面，我们纳入 TextCraft [45]，这是一个基于文本的合成游戏环境，智能体通过自然语言交互和面向任务的规划来完成任务；在具身任务方面，我们纳入 BabyAI [7]，它提供一个带文本指令的可控网格世界，用于模拟环境中的具身推理；在科学任务方面，我们纳入 SciWorld [69]，它提供一个科学探索模拟器，智能体可通过文本驱动的推理循环开展科学实验。

基线与骨干模型。 我们采用 Qwen-2.5-3B 和 Qwen-2.5-7B [83] 作为主要骨干模型，并引入闭源模型 Gemini 2.5 Pro [10]、OpenAI o3 [42] 和 GPT-4o [22] 作为基线。此外，我们还纳入开源模型 DeepSeek-R1 [12]、Qwen-2.5-72B [83]、Llama-3.1-8B [14] 和 Llama-3.1-70B [14] 进行比较。

各环境的详细设置。 附录 B 详细介绍了各环境的工具、API 与实验设置。

4.2 总体结果、发现与洞见

主要结果见图 1、表 1、表 2、表 3、表 4 和表 5。本节将讨论总体发现与洞见。

强化学习通常能将开源 LLM 的智能体能力提升至专有模型水平。 如图 1 所示，AgentGym-RL-7B 不仅大幅优于其他开源模型，而且在五种不同场景的平均成功率上明显领先 GPT-4o 和 Gemini-2.5-Pro 等主流闭源模型。这一成果凸显了我们的框架在复杂交互任务中赋予模型学习与决策能力的有效性，成功缩小了开源模型与专有模型在高级智能任务上的性能差距。

ScalingInter-RL 能够显著且稳定地提升性能。 我们没有依赖大规模超参数调优，而是根据原始 RL 过程的总优化步数设置阶段之间的转换点。结果表明，ScalingInter-RL 在多种环境和任务中始终优于基线。尤其是在 WebArena 上，其性能提升超过 10%，已接近闭源商业模型；在 TextCraft 基准上，它比基础模型高出 30 分，取得了当前最佳结果。这些发现表明，我们的方法能够有效平衡强化学习中的探索与利用。如图 6 所示，在不同环境中的实验均表明，将 AgentGym-RL 框架与 ScalingInter-RL 算法结合，可带来稳定、持续且显著的奖励提升。

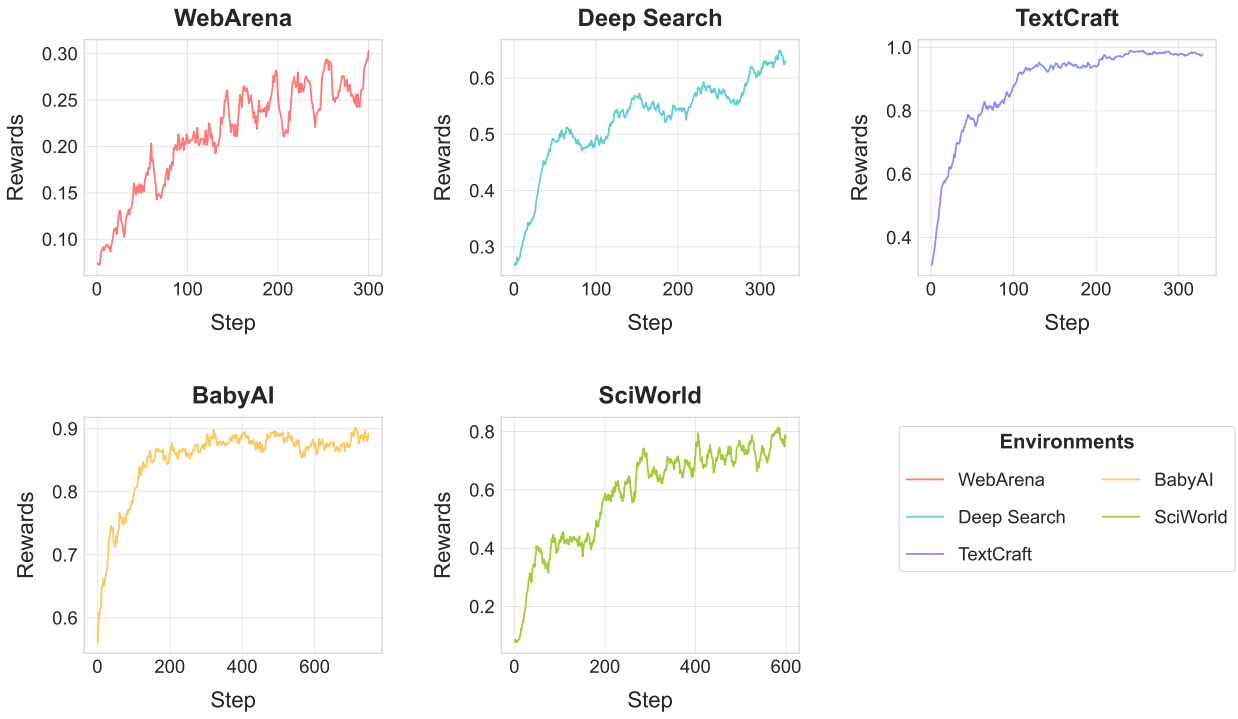


图 6 不同环境中的训练奖励。

较大的交互预算会加快早期性能提升，但最终导致训练不稳定。 如图 7 所示，我们观察到，与较少轮数的设置（如 5 轮）相比，采用更大的最大交互轮数（如 10 轮）会在早期取得更高性能，但随着训练推进会迅速崩溃。这说明在训练早期进行过度探索并不一定是好的选择。在尚未打下坚实基础时，智能体可能开展无效且低效的探索，从而增加训练不稳定的风险。相比之下，较少的轮数虽然限制了早期探索，却能提供更稳定的学习信号，从而带来更可靠的长期性能。综合来看，长、短交互轮数所呈现的不同动态促使我们提出 ScalingInter-RL，在训练过程中逐步延长交互时程。

ScalingInter-RL 在 RL 优化过程中表现出更稳定、更高效的训练动态。 如图 7 所示，我们的方法在初期受到交互轮数的约束。尽管一开始难以完全掌握困难任务，但通过利用基础技能和知识，奖励仍能明显提高；此后，随着智能体增加与环境交互和探索的轮数，它逐渐塑造自身的推理范式与交互行为，最终达到较高性能。相比之下，交互轮数较少的 RL 在后期收益递减并触及性能上限，而交互预算较大的 RL 则会迅速崩溃。此外，正如推理模型的 RL 研究中所观察到的现象 [3]，我们逐步扩展交互的策略显著减少了 RL 阶段所需的计算资源与时间，从而实现更高效的优化。

后训练与测试时计算展现出高于模型规模的扩展潜力。 实验带来的一个关键洞见是：有策略地投入后训练与测试时计算，比单纯增加模型参数量更具影响力。图 1（右）清楚说明了这一点：我们的 ScalingInter-RL 模型仅有 7B 参数，使用强化学习框架训练后，平均成功率约为 58.6%。这一性能不仅超过规模相近的其他开源模型，也显著优于 Llama3.1-70B（约 47%）和 Qwen2.5-72B（约 43%）等参数量接近其十倍的大型模型。这说明，与借助 AgentGym-RL 等框架开展有针对性的后训练和推理时计算所带来的增益相比，单纯扩大模型规模产生的性能提升有限，增长幅度也更小。

环境结构是决定强化学习效率的关键因素。 AgentGym-RL 的有效性会随环境及其反馈的性质而变化。在 TextCraft、BabyAI 和 SciWorld 等规则清晰、因果关系明确的模拟世界中，RL 带来的性能跃升最为显著。在 SciWorld 的复杂科学推理任务中，我们的方法将模型得分从 1.50 提高至 50.50，增幅接近惊人的 50 分。相比之下，在 WebArena 和深度搜索等更开放的环境中，RL 带来的性能增益较为温和，但仍为正向提升。在这些任务中，智能体必须应对真实网站的复杂性、处理多步合成计划，或处理来自搜索引擎的噪声信息，因此更难通过反复试错学到最优策略。这表明，尽管 RL 具有广泛适用性，但它在反馈明确、可通过探索较

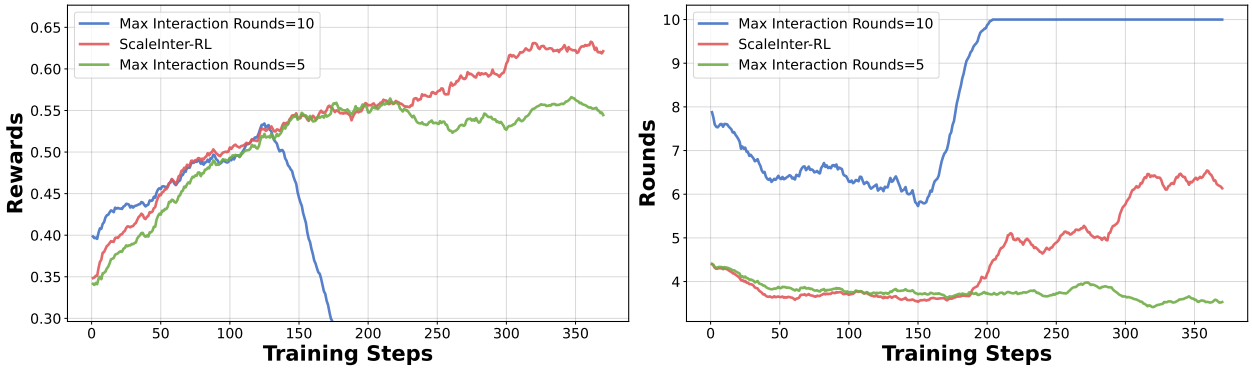


图 7 深度搜索环境中不同最大交互轮数下的训练动态。较长轮数的设置（如 10 轮）通过提供更充分的探索，初期能够取得更高奖励，但由于方差较大、信用分配困难以及对伪相关行为过拟合，性能会迅速崩溃。较短轮数的设置（如 5 轮）学习更稳定，但探索性较弱，因而会触及性能上限。我们提出的 ScalingInter-RL 方法逐步延长交互时程，最终取得更高且更高效的长期性能。

表 1 WebArena 基准上的评估结果。每组的最佳结果以**粗体**表示，次佳结果以下划线 表示。在首行中，G & R 表示 GitLab 和 Reddit。

模型	Shopping	CMS	Maps	G & R	Overall
专有模型					
GPT-4o	20.00	13.33	10.00	20.00	16.00
Qwen-Max	20.00	13.33	20.00	30.00	20.00
Gemini-2.5-Flash	26.67	20.00	10.00	30.00	22.00
OpenAI o4-mini	**33.33**	**26.67**	20.00	70.00	**36.00**
OpenAI o3	**33.33**	0.00	**40.00**	**80.00**	34.00
Gemini-2.5-Pro	26.67	**26.67**	0.00	60.00	28.00
开源模型≥ 100B					
Qwen3-235B-A22B	20.00	**20.00**	20.00	20.00	20.00
DeepSeek-V3-0324	20.00	13.33	10.00	30.00	18.00
DeepSeek-R1-0528	**33.33**	6.67	**30.00**	**50.00**	**28.00**
开源模型< 100B					
Qwen2.5-3B-Instruct	13.33	6.67	10.00	10.00	10.00
Qwen2.5-7B-Instruct	14.29	6.67	0.00	16.67	9.76
Qwen2.5-72B-Instruct	13.33	13.33	0.00	20.00	12.00
Qwen3-4B	13.33	6.67	10.00	20.00	12.00
Qwen3-8B	20.00	20.00	0.00	10.00	14.00
Qwen3-32B	20.00	6.67	**20.00**	0.00	12.00
Llama-3.1-8B-Instruct	13.33	0.00	**20.00**	**30.00**	14.00
Llama-3.1-70B-Instruct	26.67	6.67	**20.00**	10.00	16.00
我们的 RL 模型					
AgentGym-RL-3B	20.00	26.67	10.00	10.00	18.00
AgentGym-RL-7B	20.00	**33.33**	0.00	**30.00**	22.00
ScalingInter-7B	**33.33**	26.67	**20.00**	20.00	**26.00**

容易发现成功路径的环境中表现最佳。

4.3 各环境中的详细任务表现

网页导航。 如表 1 所示，我们的模型在 WebArena 基准上展现出极具竞争力的性能。其中，ScalingInter-7B 的总体准确率达到 26.00%，显著超过 GPT-4o（16.00%）等顶尖专有模型，并与 DeepSeek-R1-0528（28.00%）和 Gemini-2.5-Pro（28.00%）等更大模型相当。此外，我们的另一款 7B 模型 AgentGym-RL-7B 也取得了 16.00% 的总分，与 GPT-4o 持平。ScalingInter-7B 在结构化网页导航方面的当前最佳水平支撑了其强劲的总体表现：它在购物和 CMS 类别中分别取得 33.33% 和 26.67%，追平所有模型在这些类别中的最佳成绩。

表 2 深度搜索基准上的评估结果。每组的最佳结果以**粗体**表示，次佳结果以下划线 表示。SearchR1-it-v0.3 基线使用 Search-R1-v0.3 模型 [25]。

模型	NQ	TriviaQA	PopQA	HotpotQA	2Wiki	Musique	Bamboogle	Overall
专有模型								
GPT-4o	20.00	**70.00**	30.00	30.00	32.00	10.00	34.00	26.75
Qwen-Max	24.00	52.00	26.00	24.00	16.00	17.00	36.00	29.50
Gemini-2.5-Flash	8.00	60.00	30.00	24.00	16.00	8.00	34.00	23.50
OpenAI o4-mini	22.00	68.00	50.00	38.00	44.00	28.00	62.00	42.50
OpenAI o3	**28.00**	**70.00**	**56.00**	**46.00**	**64.00**	**29.00**	**74.00**	**49.50**
Gemini-2.5-Pro	22.00	62.00	38.00	28.00	48.00	19.00	56.00	36.50
开源模型≥ 100B								
Qwen3-235B-A22B	28.00	54.00	30.00	32.00	22.00	14.00	32.00	28.25
DeepSeek-V3-0324	28.00	60.00	24.00	28.00	18.00	11.00	34.00	26.50
DeepSeek-R1-0528	**32.00**	**68.00**	**42.00**	**44.00**	**50.00**	**21.00**	**44.00**	**40.25**
开源模型< 100B								
Qwen2.5-3B-Instruct	8.00	42.00	22.00	14.00	8.00	2.00	10.00	13.50
Qwen2.5-7B-Instruct	18.00	54.00	20.00	18.00	6.00	4.00	26.00	18.75
Qwen2.5-72B-Instruct	22.00	52.00	24.00	28.00	24.00	12.00	**38.00**	26.50
Qwen3-4B	18.00	58.00	26.00	24.00	26.00	5.00	20.00	22.75
Qwen3-8B	26.00	44.00	26.00	22.00	32.00	10.00	32.00	25.25
Qwen3-32B	24.00	54.00	22.00	36.00	28.00	11.00	20.00	25.75
Llama-3.1-8B-Instruct	16.00	26.00	12.00	6.00	2.00	4.00	18.00	11.00
Llama-3.1-70B-Instruct	20.00	44.00	22.00	22.00	18.00	9.00	32.00	22.00
SearchR1-it-3B-v0.3$_{\text{GRPO}}$	20.00	50.00	30.00	28.00	32.00	5.00	14.00	23.00
SearchR1-it-7B-v0.3$_{\text{GRPO}}$	24.00	52.00	30.00	22.00	34.00	6.00	26.00	25.00
我们的 RL 模型								
AgentGym-RL-3B	30.00	50.00	30.00	30.00	**46.00**	4.00	12.00	25.75
AgentGym-RL-7B	44.00	64.00	32.00	40.00	36.00	**15.00**	26.00	34.00
ScalingInter-7B	**52.00**	**70.00**	**46.00**	**42.00**	44.00	14.00	24.00	**38.25**

不过，与表现最好的 OpenAI o3（34.00%）和 o4-mini（36.00%）相比仍有显著差距，而这一差距几乎全部集中在“GitLab & Reddit”子任务上。

深度搜索。 表 2 的评估结果体现了复杂推理能力的重要性。目前，专有模型，尤其是 OpenAI “o”系列，树立了性能标杆，其中 OpenAI o3 以 49.50 获得最高总分。在这一竞争激烈的格局中，我们的模型表现出色。具体而言，ScalingInter-7B 的总分达到 38.25，不仅超过 GPT-4o（26.75）和 Gemini-2.5-Pro（36.50）等顶尖专有模型，也与最强的开源模型 DeepSeek-R1-0528（40.25）相当。它在关键领域的优势尤为突出：在 NQ 任务上取得所有模型中的最高分（52.00），并在 TriviaQA 上与 GPT-4o 并列第一（70.00）。此外，AgentGym-RL-7B（34.00）和 AgentGym-RL-3B（25.75）也取得了优异结果，均显著优于规模相近甚至更大的开源同类模型。这些结果有力证明，我们的强化学习方法能够有效释放模型内在的推理能力，使其在关键场景中达到甚至超过顶尖推理模型的性能；尤其重要的是，这不需要显式增加额外的长推理过程。

数字游戏。 如表 3 所详述，TextCraft 基准能够在广泛的难度范围内有效评估模型能力。在较浅深度（深度 1），顶尖模型基本都能解决任务；而在最高复杂度（深度 4），挑战几乎变得不可逾越，使大多数智能体遭遇性能断崖。正是在中等和最高难度下，我们模型的有效性尤为明显。ScalingInter-7B 取得了 91.00 的优异总分，稳居顶尖专有模型和大型开源模型之列（93.00–94.00）。更关键的是，它是少数几个在深度 4 上取得非零分数的模型之一，得分为 33.33，展现出在最高复杂度下独特的鲁棒性。AgentGym-RL-7B 同样表现出色，得分为 89.00，超过 GPT-4o（83.00）等知名模型。我们的 RL 训练对小型模型的提升尤其显著：AgentGym-RL-3B 得分为 75.00，远超 Qwen2.5-3B-Instruct（14.00）等规模相近的模型。这些结果表明，我们的 RL 方法能够提升模型，使其在复杂的序列决策任务上取得有竞争力的性能。

具身任务。 如表 4 所示，我们的 RL 模型在 BabyAI 基准上取得了当前最佳性能，总分达到 96.67，可与 o3 和 o4-mini 等领先的专有模型相媲美。值得注意的是，ScalingInter-7B 以 96.67% 取得最高总体准确率，超过 OpenAI o3（94.44%）和 GPT-4o（86.67%）等顶尖模型。这一优异表现源于 ScalingInter-7B 对多种子

表 3 TextCraft 基准上的评估结果。每组的最佳结果以**粗体**表示，次佳结果以下划线 表示。

模型	Depth 1	Depth 2	Depth 3	Depth 4	Overall
专有模型					
GPT-4o	**100.00**	87.80	64.00	0.00	83.00
Qwen-Max	93.55	75.61	36.00	0.00	69.00
Gemini-2.5-Flash	**100.00**	95.12	40.00	0.00	80.00
OpenAI o4-mini	**100.00**	**100.00**	**84.00**	0.00	93.00
OpenAI o3	**100.00**	**100.00**	**84.00**	0.00	93.00
Gemini-2.5-Pro	**100.00**	**100.00**	**84.00**	**33.33**	**94.00**
开源模型≥ 100B					
Qwen3-235B-A22B	**100.00**	**100.00**	**84.00**	0.00	**93.00**
DeepSeek-V3-0324	80.65	53.66	40.00	0.00	57.00
DeepSeek-R1-0528	**100.00**	**100.00**	**84.00**	0.00	**93.00**
开源模型< 100B					
Qwen2.5-3B-Instruct	35.48	7.32	0.00	0.00	14.00
Qwen2.5-7B-Instruct	80.65	41.46	0.00	0.00	42.00
Qwen2.5-72B-Instruct	96.77	85.37	48.00	0.00	77.00
Qwen3-4B	87.10	36.59	12.00	0.00	45.00
Qwen3-8B	**100.00**	78.05	40.00	**33.33**	74.00
Qwen3-32B	90.32	92.68	72.00	**33.33**	85.00
Llama-3.1-8B-Instruct	74.19	56.10	4.00	0.00	47.00
Llama-3.1-70B-Instruct	**100.00**	**100.00**	**84.00**	0.00	**93.00**
我们的 RL 模型					
AgentGym-RL-3B	**100.00**	90.24	28.00	0.00	75.00
AgentGym-RL-7B	**100.00**	97.56	72.00	0.00	89.00
ScalingInter-7B	**100.00**	97.56	76.00	**33.33**	91.00

任务的稳定掌握：在 GoTo、ActionObjDoor（AOD）和 SynthLoc 上均获得 100% 的满分，并在 FindObjS7（Find）和 OneRoomS20（Room）上均取得 80% 的优异成绩。同样，AgentGym-RL-7B 和 AgentGym-RL-3B 也展现出稳健能力，总体准确率分别达到 92.22% 和 93.33%，并在 GoTo 和 AOD 任务上取得满分。与 Qwen3-235B-A22B（87.78%）和 DeepSeek-R1-0528（93.33%）等其他开源模型相比，我们基于 RL 的模型始终保持较高性能，同时也能有效处理 Room 和 Find 等更具挑战的子任务；许多 LLM 在这些任务上的表现波动明显。总体而言，这些结果凸显了基于 RL 的方法，尤其是 ScalingInter-7B，在 BabyAI 基准的结构化导航与对象交互任务上取得当前最佳性能的优势。

科学场景。 表 5 总结了我们在 SciWorld 基准上的实验，展现出经 RL 训练的模型的先进性能。ScalingInter-7B 以 57.00 的总分创下新的当前最佳结果，显著超过所有开源和专有模型，包括成绩次优的专有模型 OpenAI o3（41.50）。这一卓越表现主要得益于其在“Find”（88.64）和“Test-Cond”（55.42）子任务上的高分。此外，AgentGym-RL-7B 也展现出强劲能力，以 50.50 获得第二高的总分，并在“Test-Cond”上取得最高分（59.04）。这些结果凸显了我们的 RL 方法在训练智能体执行探索和程序化操作任务方面的有效性。然而，我们的发现也揭示了所有被评估模型共有的一项关键局限：“Chem-Mix”子任务难以解决，包括我们最佳模型在内的所有模型得分均为零。这一一致结果表明，当前语言模型在需要复杂科学推理和多步化学模拟的任务中面临系统性挑战，也说明这是未来研究的一个关键方向。

5 讨论

5.1 智能体的测试时扩展

本小节研究智能体性能如何随推理计算量增加而变化。

扩展串行交互。 首先，我们研究提高模型可用的最大交互轮数时，性能如何变化。如图 8 所示，所有模型均随轮数增加而明显提升，这验证了 ScalingInter-RL 方法背后的洞见：智能体必须充分探索环境，才能塑造其交互与行为模式。此外，经过训练的智能体始终以显著优势超过基线，进一步证明了我们方法的有效性。

表 4 BabyAI 基准上的评估结果。每组的最佳结果以**粗体**表示，次佳结果以下划线 表示。在首行中，AOD 表示 ActionObjDoor，Find 表示 FindObjS7，Room 表示 OneRoomS20，SLoc 表示 SynthLoc。

模型	GoTo	Pickup	AOD	Find	Room	SLoc	Overall
专有模型							
GPT-4o	92.73	80.00	**100.00**	**80.00**	**60.00**	60.00	86.67
Qwen-Max	92.73	80.00	80.00	60.00	**60.00**	80.00	85.56
Gemini-2.5-Flash	92.73	86.67	80.00	20.00	**60.00**	**100.00**	85.56
OpenAI o4-mini	96.36	**100.00**	**100.00**	**80.00**	40.00	80.00	92.22
OpenAI o3	**98.18**	93.33	100.00	**80.00**	**60.00**	**100.00**	**94.44**
Gemini-2.5-Pro	94.55	93.33	**100.00**	40.00	**60.00**	60.00	87.77
开源模型							
Qwen3-235B-A22B	89.09	**86.67**	**100.00**	**80.00**	60.00	**100.00**	87.78
DeepSeek-V3-0324	67.27	53.33	0.00	20.00	40.00	60.00	56.67
DeepSeek-R1-0528	**98.18**	**86.67**	**100.00**	60.00	**80.00**	**100.00**	**93.33**
开源模型							
Qwen2.5-3B-Instruct	61.82	40.00	20.00	60.00	40.00	20.00	52.22
Qwen2.5-7B-Instruct	70.91	66.67	60.00	**80.00**	60.00	20.00	66.67
Qwen2.5-72B-Instruct	92.73	93.33	**100.00**	60.00	60.00	80.00	88.89
Qwen3-4B	60.00	60.00	40.00	40.00	40.00	20.00	54.44
Qwen3-8B	43.64	20.00	40.00	40.00	40.00	40.00	38.89
Qwen3-32B	87.27	80.00	**100.00**	60.00	40.00	80.00	82.22
Llama-3.1-8B-Instruct	85.45	60.00	**100.00**	**80.00**	60.00	40.00	77.78
Llama-3.1-70B-Instruct	89.09	86.67	**100.00**	60.00	60.00	**100.00**	86.67
我们的 RL 模型							
AgentGym-RL-3B	**100.00**	**100.00**	**100.00**	60.00	60.00	60.00	93.33
AgentGym-RL-7B	**100.00**	93.33	**100.00**	60.00	60.00	60.00	92.22
ScalingInter-7B	**100.00**	93.33	**100.00**	**80.00**	**80.00**	**100.00**	**96.67**

扩展并行采样。 如图 9 所示，增加样本数量会显著提高 Pass@K 性能，体现出各模型的下游优化潜力。即使采样预算较小，我们的模型也优于基线；随着采样次数增加，它仍能稳定且显著地领先基线。例如，在进行 64 次采样时，我们的 RL 模型相较未经训练的基础模型，在深度搜索环境中提升 5.5%，在 SciWorld 环境中提升 7.05%，展现出更强的优化能力。

5.2 不同 RL 算法的性能

我们比较了两种用于 LLM 后训练的主流 RL 算法，即 GRPO 与 REINFORCE++。如表 6 所示，实验发现，在 TextCraft、BabyAI 和深度搜索基准上，GRPO 始终大幅优于 REINFORCE++。尽管将模型参数规模从 3B 扩展至 7B 会改善两种算法的结果，但 GRPO 的优势尤为显著：其 3B 版本的得分高于 7B 的 REINFORCE++ 模型。这一发现表明，基础性的算法优势比单纯的模型规模更具影响力。

这种性能差异可以从两种算法处理任务核心难点（巨大探索空间与稀疏奖励）的不同方式来解释。REINFORCE++ 的学习信号来自完整回合的蒙特卡洛回报，这通常会产生高方差梯度，且对长轨迹中的随机成功与失败十分敏感。相比之下，GRPO 通过相对于学得的基线评估动作的相对优劣，缓解了这种不稳定性。对动作优势的关注可提供更稳定、更鲁棒的梯度，从而在复杂、低信号环境中促进更高效的探索与信用分配。

5.3 案例研究

本节给出一系列案例研究，既展示基础智能体的不足，也呈现强化学习模型带来的改进。在导航、组合式问题求解和网页交互场景中，经 RL 训练的智能体始终能够摆脱无效的行为循环，展现自适应恢复策略，并以更系统的方式执行任务。为提供均衡视角，我们还纳入了科学推理和高效网页交互中的两个代表性失败案例，以凸显仍需进一步改进之处。正文展示了 WebArena 轨迹示意图及其对应的可视化，其他环境的更多轨迹示意图见附录 C。

表 5 SciWorld 基准上的评估结果。每组的最佳结果以**粗体**表示，次佳结果以下划线 表示。在首行中，Test-Cond. 表示电导率测试，Chem-Mix 表示化学混合。

模型	Measure	Test-Cond.	Find	Chem-Mix	Lifespan	Overall
专有模型						
GPT-4o	15.09	6.02	38.64	20.00	73.33	21.00
Qwen-Max	9.43	0.00	34.09	20.00	40.00	13.50
Gemini-2.5-Flash	11.32	0.00	54.55	0.00	80.00	21.00
OpenAI o4-mini	20.75	14.46	47.73	0.00	**100.00**	29.50
OpenAI o3	**47.17**	**25.30**	**56.82**	**40.00**	66.67	**41.50**
Gemini-2.5-Pro	9.43	0.00	29.55	0.00	46.67	12.50
开源模型≥ 100B						
Qwen3-235B-A22B	**11.32**	**4.82**	**59.09**	**20.00**	**66.67**	**23.50**
DeepSeek-V3-0324	0.00	0.00	2.27	0.00	0.00	0.50
DeepSeek-R1-0528	1.89	0.00	11.36	0.00	20.00	4.50
开源模型< 100B						
Qwen2.5-3B-Instruct	3.77	0.00	0.00	0.00	0.00	1.00
Qwen2.5-7B-Instruct	1.89	0.00	0.00	0.00	13.33	1.50
Qwen2.5-72B-Instruct	7.55	1.20	15.91	20.00	40.00	9.50
Qwen3-4B	0.00	0.00	0.00	0.00	33.33	2.50
Qwen3-8B	9.43	0.00	18.18	0.00	46.67	10.00
Qwen3-32B	5.66	1.20	31.82	0.00	66.67	14.00
Llama-3.1-8B-Instruct	9.43	0.00	4.55	20.00	0.00	4.00
Llama-3.1-70B-Instruct	24.53	4.82	40.91	**40.00**	**86.67**	25.00
我们的 RL 模型						
AgentGym-RL-3B	20.75	28.92	0.00	0.00	66.67	22.50
AgentGym-RL-7B	24.53	**59.04**	65.91	0.00	66.67	50.50
ScalingInter-7B	**33.96**	55.42	**88.64**	0.00	73.33	**57.00**

导航能力增强。 图 12 展示了 BabyAI 环境中导航能力的显著提升。基础智能体表现出次优行为，其特征是反复移动：不断经过已经探索过的位置，却未能形成有效的任务完成搜索策略；而经强化学习训练的模型则展现出更有效的探索策略。RL 智能体具备策略性回溯能力：先有条理地退出门口，再选择其他路径，最终到达一扇可直通目标蓝色盒子的绿色门。这凸显了 RL 模型更强的空间推理能力，以及避开无效行为循环的能力。

组合式任务掌握。 图 14 展示了强化学习成功应用于复杂科学任务执行的案例。基础智能体在任务理解上存在根本性缺陷，会误用不可交互对象并生成无效动作。相比之下，经 RL 优化的智能体通过系统化方法展现出全面的任务理解：正确识别并操纵一个生物（香蕉树），执行恰当的物品栏管理操作，在多房间环境中导航并排除障碍，最终将树放入指定的紫色盒子，成功完成目标。这凸显了 RL 智能体在组合式问题空间中推理、规划和顺序执行任务方面得到增强的能力。

自适应网页导航策略。 图 10 和图 11 展示了通过强化学习优化而涌现出的网页导航能力。基础智能体会持续与无响应的界面元素交互，具体表现为反复点击无效目标，却未意识到这些动作毫无作用。经 RL 训练的智能体则展现出明显更优的自适应行为：遇到“页面未找到”错误时，它成功运用错误恢复机制；随后使用搜索框定位“pittsburgh”论坛，在热门帖子中识别与上下文相关的内容，并成功完成订阅任务。这表明它在错误处理上更具鲁棒性，导航策略更有目的性，并能在避免无效行为模式的同时始终聚焦任务。

科学场景中的局限。 图 15 揭示了 SciWorld 任务完成过程中的根本性程序执行失败：尽管 RL 智能体能够到达与任务相关的游戏状态，这些失败仍然存在。相关案例体现出两种不同的失败模式：第一，面对需要系统调试的交互失败时，智能体错误地用直接回忆事实代替预期的实验过程；第二，智能体的系统性探索不足，表现为导航至室外环境后便过早终止任务，只关注变色龙蛋，而没有按照任务要求分析所有可用动物。这些失败共同表明，模型缺乏执行严谨科学比较分析所需的深层程序性理解。

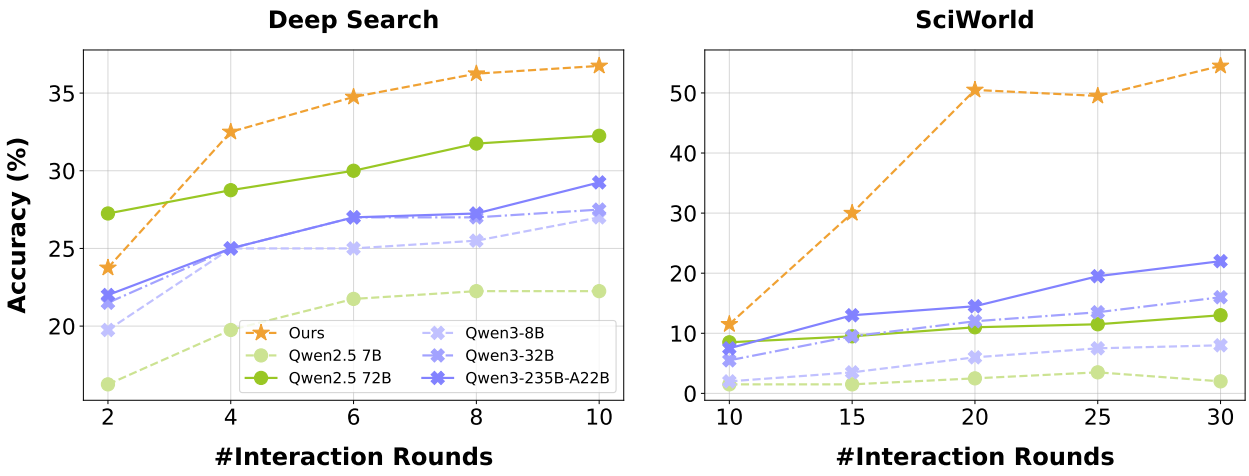


图 8 扩展测试时交互轮数。

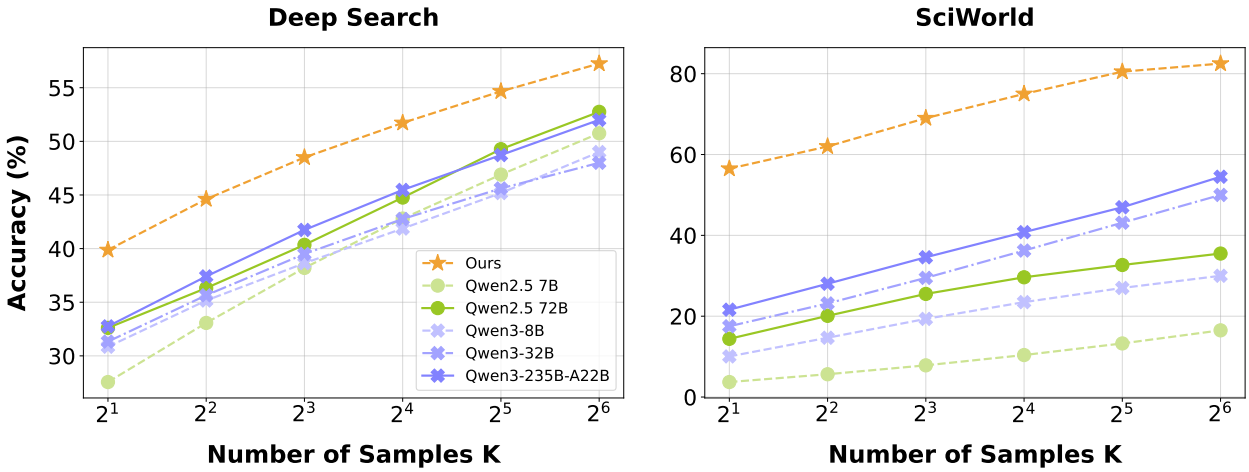


图 9 Pass@K 性能。

网页导航中的过度交互模式。 图 16 展示了网页导航任务中一种常见的失败模式，即交互序列过多且效率低下。在图示的两个案例中，尽管 RL 智能体均成功导航至正确的目标网站，却执行了多余的交互，包括重复点击、不必要的悬停和过度滚动，妨碍了从目标页面成功提取信息。这些行为模式说明，强化学习过程未能让模型形成最优完成任务所需的精确性与效率，反映出到达状态的能力与在该状态下有效选择动作的能力之间仍有差距。

6 相关工作

使用大语言模型开发智能体。 随着大语言模型的发展 [1, 2, 65]，研究人员开始使用它们构建能够进行多轮智能决策的智能体 [79, 86]。主流方法依靠提示来引导模型调用工具 [48, 90]，并辅以自我反思 [51, 57, 78, 82]、长时程规划 [36, 40, 45, 61] 和自我纠正 [29, 31] 等机制。部分工作构建工作流，为多个 LLM 分配不同角色 [17, 20, 34, 64, 74]，使其各自在任务完成过程中承担专门职责。然而，这些方法通常依赖强大的专有模型（如 OpenAI o3），且不会训练底层模型，使其演化为具备内在智能体能力的智能体。另一类工作收集大规模专家轨迹，并训练智能体逐步模仿专家 [4, 6, 91, 92]，从而获得 API 调用、规划和自我反思等能力。然而，这种方法成本高昂、难以扩展，并且模型难以通过与环境交互实现自我提升。

表 6 不同 RL 算法的评估结果。

RL 算法	TextCraft	BabyAI	SearchQA
Qwen2.5-3B-Instruct			
GRPO	**75.00**	**93.33**	**25.75**
REINFORCE++	28.00	70.00	13.25
Qwen2.5-7B-Instruct			
GRPO	**83.00**	**92.22**	**34.00**
REINFORCE++	73.00	84.44	24.00

面向大语言模型智能体的强化学习。 强化学习已成为大语言模型的一项关键后训练技术，可使模型与人类偏好对齐 [5, 24, 43, 80, 93]、增强推理能力 [12, 18, 23, 49, 68, 76]，并充当一种新的扩展维度 [12]。代表性算法包括 PPO [53]、GRPO [54]、REINFORCE++ [21] 和 RLOO [30] 等。然而，以 DeepSeek-R1 为代表的大多数现有工作局限于单轮静态任务，模型不会与复杂环境进行多轮交互。近期工作已使用 RL 训练智能体进行自我反思 [82]、使用工具 [89]，乃至开展长时程交互 [3, 26, 30, 47, 71, 95]。然而，由于任务复杂度和环境多样性有限，这些方法通常难以实现可扩展部署，并且频繁遭遇会妨碍性能的优化不稳定问题。为克服这些挑战，我们提出一个覆盖多种真实环境的统一端到端 RL 框架，无需将 SFT 作为预备步骤，即可训练模型进行多轮决策。我们还引入 ScalingInter-RL，这是一种能够稳定优化并提升智能体最终性能的交互扩展技术。

扩展语言模型的推理计算。 OpenAI o1 和 DeepSeek-R1 已表明，在推理期间（包括测试时和 RL 轨迹采样期间）增加计算量能够产生显著的扩展效应 [12, 23, 59, 75]。研究人员还探索了多种取得类似增益的方法，包括长思维链推理 [59, 78]、多数投票 [33, 70]、N 次采样择优 [9, 27]、束搜索 [81, 97] 和蒙特卡洛树搜索 [8, 16]。然而，在 LLM 智能体领域，很少有工作讨论如何扩展推理计算。Zhu et al. [96] 探索了智能体中的多种测试时扩展策略并取得显著增益，但没有研究 RL 中的推理扩展。最接近的工作可能是 TTI [55]，它利用拒绝采样，教会智能体在网页导航任务的交互而非思考过程中分配更多计算。相比之下，我们的方法采用 GRPO 和 REINFORCE++ 等主流在策略 RL 算法，并不限制智能体只能将计算用于思考或行动。我们只是扩展交互，让模型自行决定如何以最佳方式分配额外计算。我们的方法逐步赋予智能体更多探索能力，使其随时间推移更好地适应环境、习得更复杂的技能，并掌握更具挑战的任务。

7 结论与未来工作

本文介绍了 AgentGym-RL，这是一种新颖、统一的强化学习框架，旨在训练具备长时程、多轮决策能力的 LLM 智能体。该框架提供多样化的环境与任务，支持主流 RL 算法，并具有高度可扩展性，为社区提供了一套实用而强大的工具。此外，我们还提出 ScalingInter-RL 方法，以分阶段方式逐步增强智能体的交互智能。大量实验证明了框架与方法的有效性。不过，未来仍有若干重要方向值得探索：

开发具备泛化与迁移能力的智能体。 目前，我们训练的智能体在域内设置下表现良好。未来的一项关键挑战，是让智能体在保持高性能的同时，无缝适应新环境与陌生工具。

将 RL 训练扩展至时程更长、更真实且以物理世界为基础的任务。 包括本文在内的大多数现有研究都聚焦于相对简单的数字任务。然而，现实世界任务通常时程更长、更加复杂，并以物理世界为基础。这些任务要求智能体处理更丰富的感知输入，并在大得多的动作空间上进行推理，从而给强化学习训练和测试时交互带来新的挑战。

推进多智能体强化学习。 当前框架主要面向单智能体训练。然而，多智能体架构带来了新的可能性，并有望取得更强的性能。与此同时，它们也会引入额外的不确定性，对基础设施与算法设计提出更高要求。

致谢

本研究得到了 Huawei Ascend AI 处理器的支持。我们衷心感谢 Huawei 提供计算资源，使本研究得以完成。

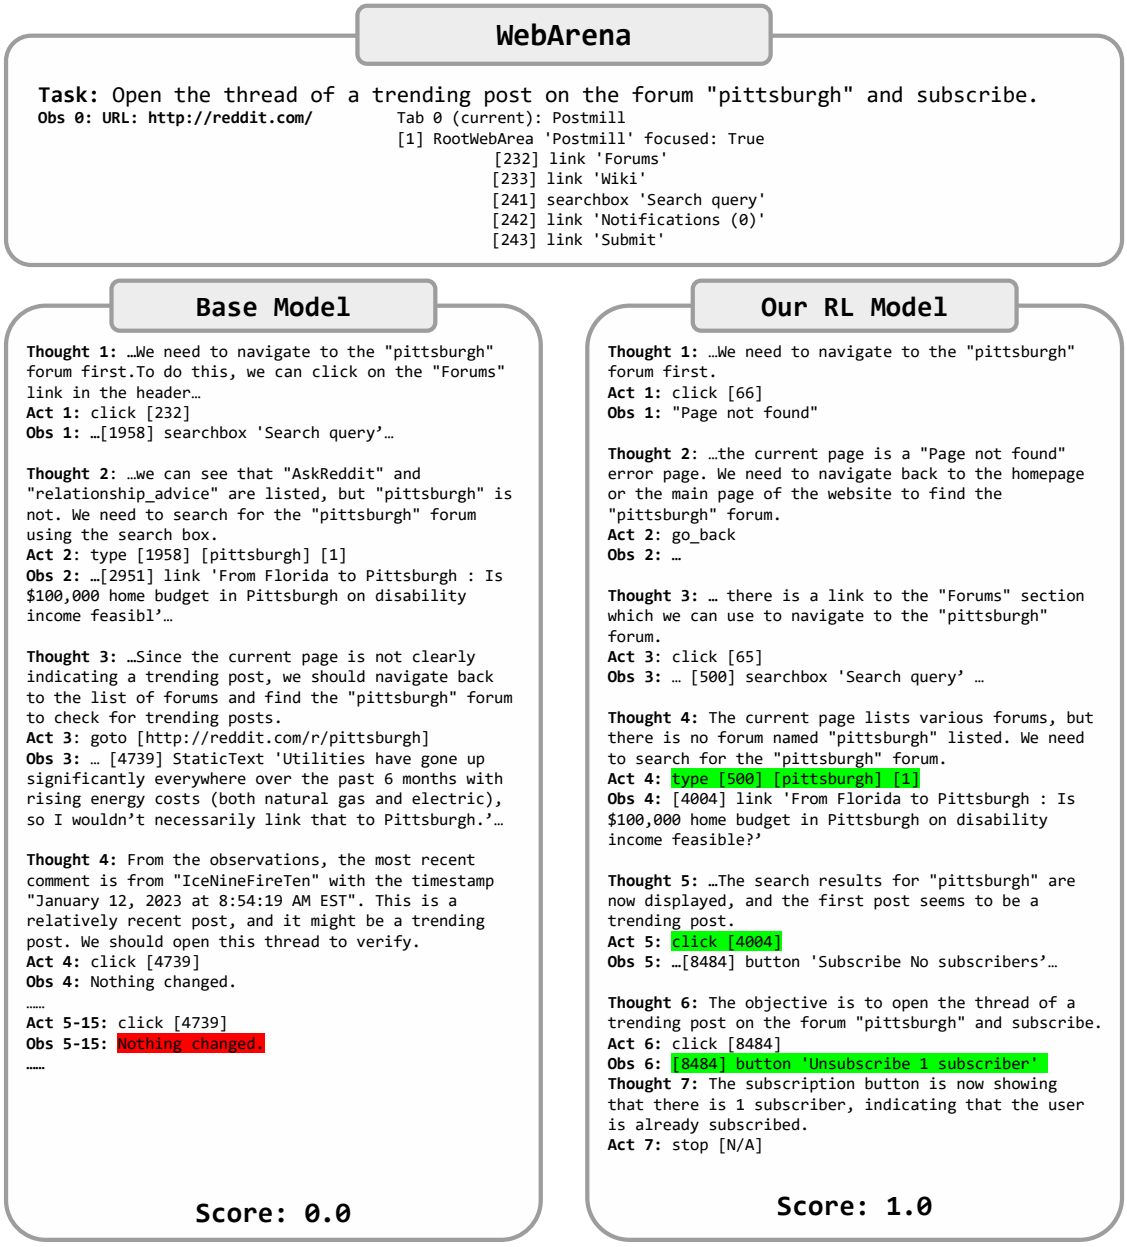


图 **10** 在 WebArena 任务上，我们的 RL 智能体相较基础模型的一个出色案例。

参考文献

[1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 技术报告。arXiv 预印本 arXiv:2303.08774, 2023.

[2] AI Anthropic. Claude 3 模型家族：Opus、sonnet、haiku。Claude-3 模型卡, 1(1):4, 2024.

[3] Shiyi Cao, Sumanth Hegde, Dacheng Li, Tyler Griggs, Shu Liu, Eric Tang, Jiayi Pan, Xingyao Wang, Akshay Malik, Graham Neubig, Kourosh Hakhamaneshi, Richard Liaw, Philipp Moritz, Matei Zaharia, Joseph E. Gonzalez, and Ion Stoica. Skyrl-v0：通过强化学习训练面向现实世界的长时程智能体，2025。

[4] Baian Chen, Chang Shu, Ehsan Shareghi, Nigel Collier, Karthik Narasimhan, and Shunyu Yao. Fireact：迈向语

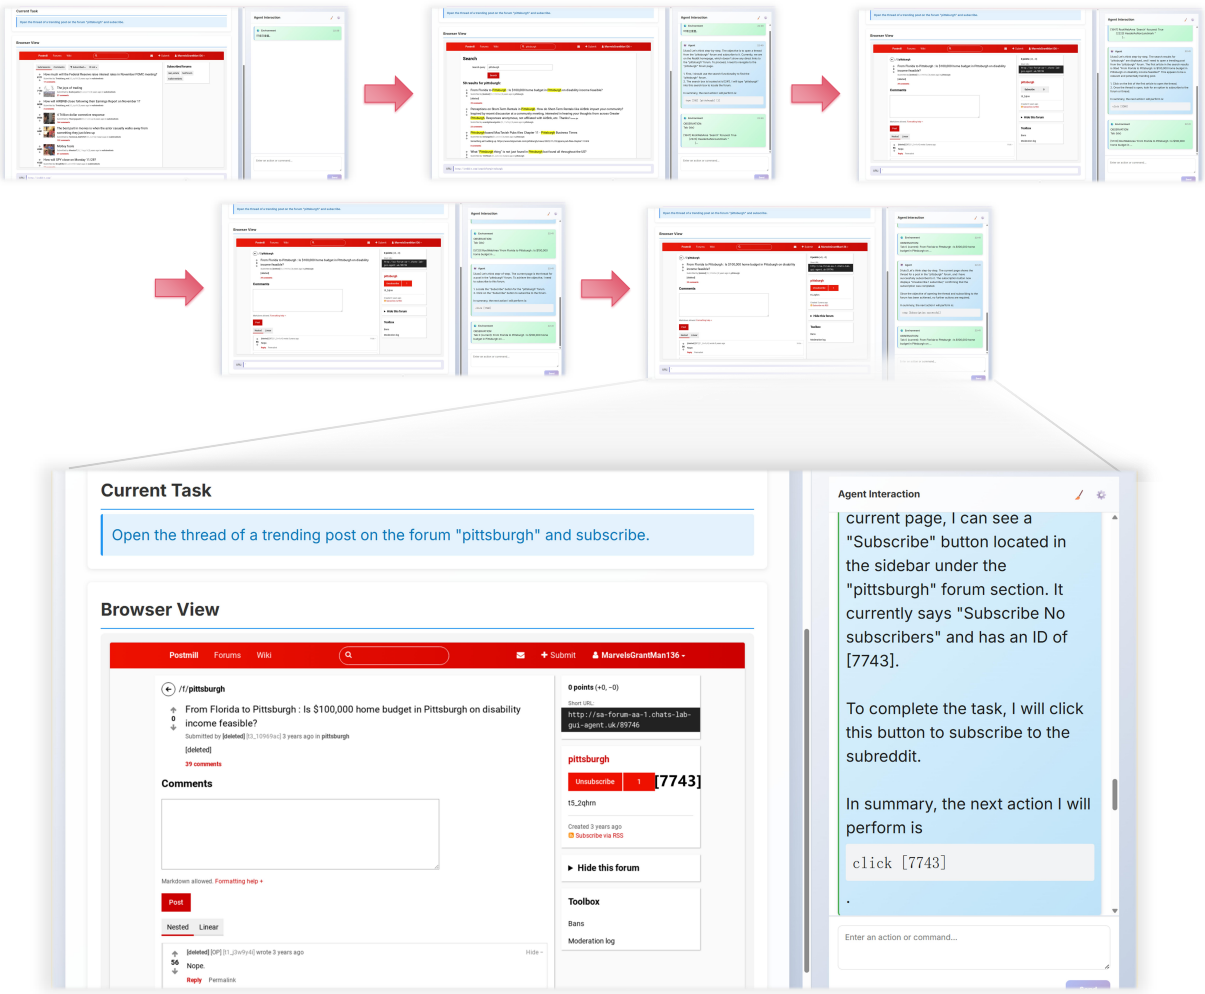


图 11 我们的 RL 智能体在 WebArena 任务上的轨迹可视化。

言智能体微调。CoRR, abs/2310.05915, 2023. doi: 10.48550/ARXIV.2310.05915. 网址：https://doi.org/10.48550/arXiv.2310.05915.

[5] Lu Chen, Rui Zheng, Binghai Wang, Senjie Jin, Caishuang Huang, Junjie Ye, Zhihao Zhang, Yuhao Zhou, Zhiheng Xi, Tao Gui, Qi Zhang, and Xuanjing Huang. 使用对比学习提升 RLHF 奖励模型的判别能力。收录于 Yaser Al-Onaizan、Mohit Bansal 和 Yun-Nung Chen 编，2024 年自然语言处理实证方法会议论文集，EMNLP 2024，美国佛罗里达州迈阿密，2024 年 11 月 12–16 日，第 15270–15283 页。计算语言学协会，2024。doi: 10.18653/V1/2024.EMNLP-MAIN.852. 网址：https://doi.org/10.18653/v1/2024.emnlp-main.852.

[6] Zehui Chen, Kuikun Liu, Qiuchen Wang, Wenwei Zhang, Jiangning Liu, Dahua Lin, Kai Chen, and Feng Zhao. Agent-flan：面向大语言模型有效智能体调优的数据与方法设计。收录于 Lun-Wei Ku、Andre Martins 和 Vivek Srikumar 编，计算语言学协会会议论文精选，ACL 2024，泰国曼谷及线上会议，2024 年 8 月 11–16 日，第 9354–9366 页。计算语言学协会，2024。doi: 10.18653/V1/2024.FINDINGS-ACL.557. 网址：https://doi.org/10.18653/v1/2024.findings-acl.557.

[7] Maxime Chevalier-Boisvert, Dzmitry Bahdanau, Salem Lahlou, Lucas Willems, Chitwan Saharia, Thien Huu Nguyen, and Yoshua Bengio. Babyai：研究具身语言学习样本效率的平台。收录于第 7 届国际学习表征会议，ICLR 2019，美国路易斯安那州新奥尔良，2019 年 5 月 6–9 日。OpenReview.net，2019。网址：https://openreview.net/forum?id=rJeXCo0cYX.

[8] Yizhou Chi, Yizhang Lin, Sirui Hong, Duyi Pan, Yaying Fei, Guanghao Mei, Bangbang Liu, Tianqi Pang, Jacky

Kwok, Ceyao Zhang, Bang Liu, and Chenglin Wu. SELA：树搜索增强的自动化机器学习大语言模型智能体。CoRR, abs/2410.17238, 2024. doi: 10.48550/ARXIV.2410.17238. 网址：https://doi.org/10.48550/arXiv.2410.17238.

[9] Yinlam Chow, Guy Tennenholtz, Izzeddin Gur, Vincent Zhuang, Bo Dai, Aviral Kumar, Rishabh Agarwal, Sridhar Thiagarajan, Craig Boutilier, and Aleksandra Faust. 面向大语言模型多样本择优采样的推理感知微调。收录于第十三届国际学习表征会议，ICLR 2025，新加坡，2025 年 4 月 24–28 日。OpenReview.net，2025。网址：https://openreview.net/forum?id=77gQUdQhE7.

[10] Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, et al. Gemini 2.5：以高级推理、多模态、长上下文和下一代智能体能力推进前沿。arXiv 预印本 arXiv:2507.06261, 2025.

[11] DeepSeek-AI, Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Daya Guo, Dejian Yang, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Haowei Zhang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Li, Hui Qu, J. L. Cai, Jian Liang, Jianzhong Guo, Jiaqi Ni, Jiashi Li, Jiawei Wang, Jin Chen, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, Junxiao Song, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Lei Xu, Leyi Xia, Liang Zhao, Litong Wang, Liyue Zhang, Meng Li, Miaojun Wang, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Mingming Li, Ning Tian, Panpan Huang, Peiyi Wang, Peng Zhang, Qiancheng Wang, Qihao Zhu, Qinyu Chen, Qiushi Du, R. J. Chen, R. L. Jin, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, Runxin Xu, Ruoyu Zhang, Ruyi Chen, S. S. Li, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shaoqing Wu, Shengfeng Ye, Shengfeng Ye, Shirong Ma, Shiyu Wang, Shuang Zhou, Shuiping Yu, Shunfeng Zhou, Shuting Pan, T. Wang, Tao Yun, Tian Pei, Tianyu Sun, W. L. Xiao, and Wangding Zeng. Deepseek-v3 技术报告。CoRR, abs/2412.19437, 2024. doi: 10.48550/ARXIV.2412.19437. 网址：https://doi.org/10.48550/arXiv.2412.19437.

[12] DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jiawei Wang, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qiushi Du, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, R. J. Chen, R. L. Jin, Ruyi Chen, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shengfeng Ye, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, and S. S. Li. Deepseek-r1：通过强化学习激发大语言模型的推理能力。CoRR, abs/2501.12948, 2025. doi: 10.48550/ARXIV.2501.12948. 网址：https://doi.org/10.48550/arXiv.2501.12948.

[13] Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Samual Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2web：迈向面向网页的通用智能体。收录于 Alice Oh、Tristan Naumann、Amir Globerson、Kate Saenko、Moritz Hardt 和 Sergey Levine 编，神经信息处理系统进展 36：2023 年神经信息处理系统年会，NeurIPS 2023，美国路易斯安那州新奥尔良，2023 年 12 月 10–16 日，2023。网址：http://papers.nips.cc/paper_files/paper/2023/hash/5950bf290a1570ea401bf98882128160-Abstract-Datasets_and_Benchmarks.html.

[14] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurélien Rodriguez, Austen Gregerson, Ava Spataru, Baptiste Rozière, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song, Danielle Pintz, Danny Livshits, David Esiobu, Dhruv Choudhary, Dhruv Mahajan, Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Frank Zhang, Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Graeme Nail, Grégoire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel M. Kloumann, Ishan Misra, Ivan Evtimov, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah, Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca, Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Kartikeya Upasani, Kate

Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, and et al. Llama 3 模型群。CoRR, abs/2407.21783, 2024. doi: 10.48550/ARXIV.2407.21783. 网址：https://doi.org/10.48550/arXiv.2407.21783.

[15] Linxi Fan, Guanzhi Wang, Yunfan Jiang, Ajay Mandlekar, Yuncong Yang, Haoyi Zhu, Andrew Tang, De-An Huang, Yuke Zhu, and Anima Anandkumar. Minedojo：利用互联网规模的知识构建开放式具身智能体。收录于 Sanmi Koyejo、S. Mohamed、A. Agarwal、Danielle Belgrave、K. Cho 和 A. Oh 编，神经信息处理系统进展 35：2022 年神经信息处理系统年会，NeurIPS 2022，美国路易斯安那州新奥尔良，2022 年 11 月 28 日–12 月 9 日，2022。网址：http://papers.nips.cc/paper_files/paper/2022/hash/74a67268c5cc5910f64938cac4526a90-Abstract-Datasets_and_Benchmarks.html.

[16] Bingzheng Gan, Yufan Zhao, Tianyi Zhang, Jing Huang, Yusu Li, Shu Xian Teo, Changwang Zhang, and Wei Shi. MASTER：采用大语言模型专用 MCTS 的多智能体系统。收录于 Luis Chiruzzo、Alan Ritter 和 Lu Wang 编，2025 年计算语言学协会美洲分会人类语言技术会议论文集，NAACL 2025——第 1 卷：长文，美国新墨西哥州阿尔伯克基，2025 年 4 月 29 日–5 月 4 日，第 9409–9426 页。计算语言学协会，2025。doi: 10.18653/V1/2025.NAACL-LONG.476. 网址：https://doi.org/10.18653/v1/2025.naacl-long.476.

[17] Honglin Guo, Kai Lv, Qipeng Guo, Tianyi Liang, Zhiheng Xi, Demin Song, Qi Zhang, Yu Sun, Kai Chen, Xipeng Qiu, and Tao Gui. Critiq：从人类偏好中挖掘数据质量标准。CoRR, abs/2502.19279, 2025. doi: 10.48550/ARXIV.2502.19279. 网址：https://doi.org/10.48550/arXiv.2502.19279.

[18] Jujie He, Jiacai Liu, Chris Yuhao Liu, Rui Yan, Chaojie Wang, Peng Cheng, Xiaoyu Zhang, Fuxiang Zhang, Jiacheng Xu, Wei Shen, Siyuan Li, Liang Zeng, Tianwen Wei, Cheng Cheng, Bo An, Yang Liu, and Yahui Zhou. Skywork open reasoner 1 技术报告。CoRR, abs/2505.22312, 2025. doi: 10.48550/ARXIV.2505.22312. 网址：https://doi.org/10.48550/arXiv.2505.22312.

[19] Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, and Akiko Aizawa. 构建用于全面评估推理步骤的多跳问答数据集。收录于 Donia Scott、Núria Bel 和 Chengqing Zong 编，第 28 届国际计算语言学会议论文集，COLING 2020，西班牙巴塞罗那（线上），2020 年 12 月 8–13 日，第 6609–6625 页。国际计算语言学委员会，2020。doi: 10.18653/V1/2020.COLING-MAIN.580. 网址：https://doi.org/10.18653/v1/2020.coling-main.580.

[20] Sirui Hong, Mingchen Zhuge, Jonathan Chen, Xiawu Zheng, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, Chenyu Ran, Lingfeng Xiao, Chenglin Wu, and Jürgen Schmidhuber. Metagpt：面向多智能体协作框架的元编程。收录于第十二届国际学习表征会议，ICLR 2024，奥地利维也纳，2024 年 5 月 7–11 日。OpenReview.net，2024。网址：https://openreview.net/forum?id=VtmBAGCN7o.

[21] Jian Hu. REINFORCE++：一种简单高效的大语言模型对齐方法。CoRR, abs/2501.03262, 2025. doi: 10.48550/ARXIV.2501.03262. 网址：https://doi.org/10.48550/arXiv.2501.03262.

[22] Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. Gpt-4o 系统卡。arXiv 预印本 arXiv:2410.21276, 2024.

[23] Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. Openai o1 系统卡。arXiv 预印本 arXiv:2412.16720, 2024.

[24] Jiaming Ji, Tianyi Qiu, Boyuan Chen, Borong Zhang, Hantao Lou, Kaile Wang, Yawen Duan, Zhonghao He, Jiayi Zhou, Zhaowei Zhang, Fanzhi Zeng, Kwan Yee Ng, Juntao Dai, Xuehai Pan, Aidan O'Gara, Yingshan Lei, Hua Xu, Brian Tse, Jie Fu, Stephen McAleer, Yaodong Yang, Yizhou Wang, Song-Chun Zhu, Yike Guo, and Wen Gao. 人工智能对齐：一项全面综述。CoRR, abs/2310.19852, 2023. doi: 10.48550/ARXIV.2310.19852. 网址：https://doi.org/10.48550/arXiv.2310.19852.

[25] Bowen Jin, Jinsung Yoon, Priyanka Kargupta, Sercan Ö. Arik, and Jiawei Han. 面向推理与搜索交错式大语言模型智能体的强化学习实证研究。CoRR, abs/2505.15117, 2025. doi: 10.48550/ARXIV.2505.15117. 网址：https://doi.org/10.48550/arXiv.2505.15117.

[26] Bowen Jin, Hansi Zeng, Zhenrui Yue, Dong Wang, Hamed Zamani, and Jiawei Han. Search-r1：通过强化学习训练大语言模型进行推理并利用搜索引擎。CoRR, abs/2503.09516, 2025. doi: 10.48550/ARXIV.2503.09516. 网址：https://doi.org/10.48550/arXiv.2503.09516.

[27] Yuu Jinnai, Tetsuro Morimura, Kaito Ariu, and Kenshi Abe. 用于缓解语言模型对齐中奖励劫持的正则化多样本择优采样。CoRR, abs/2404.01054, 2024. doi: 10.48550/ARXIV.2404.01054. 网址：https://doi.org/10.48550/arXiv.2404.01054.

[28] Mandar Joshi, Eunsol Choi, Daniel S. Weld, and Luke Zettlemoyer. Triviaqa：用于阅读理解的大规模远程监督挑战数据集。收录于 Regina Barzilay 和 Min-Yen Kan 编，计算语言学协会第 55 届年会论文集，ACL

2017，加拿大温哥华，2017 年 7 月 30 日–8 月 4 日，第 1 卷：长文，第 1601–1611 页。计算语言学协会，2017。doi: 10.18653/V1/P17-1147. 网址：https://doi.org/10.18653/v1/P17-1147.

[29] Ryo Kamoi, Yusen Zhang, Nan Zhang, Jiawei Han, and Rui Zhang. 大语言模型何时真正能够纠正自身错误?一项关于大语言模型自我纠错的批判性综述。计算语言学协会汇刊, 12:1417–1440, 2024. doi: 10.1162/TACL_A_00713. 网址：https://doi.org/10.1162/tacl_a_00713.

[30] Wouter Kool, Herke van Hoof, and Max Welling. 购买 4 个 REINFORCE 样本，免费获得一个基线！ 收录于深度强化学习与结构化预测，ICLR 2019 研讨会，美国路易斯安那州新奥尔良，2019 年 5 月 6 日。OpenReview.net，2019。网址：https://openreview.net/forum?id=r1lgTGL5DE.

[31] Aviral Kumar, Vincent Zhuang, Rishabh Agarwal, Yi Su, John D. Co-Reyes, Avi Singh, Kate Baumli, Shariq Iqbal, Colton Bishop, Rebecca Roelofs, Lei M. Zhang, Kay McKinney, Disha Shrivastava, Cosmin Paduraru, George Tucker, Doina Precup, Feryal M. P. Behbahani, and Aleksandra Faust. 通过强化学习训练语言模型进行自我纠错。收录于第十三届国际学习表征会议，ICLR 2025，新加坡，2025 年 4 月 24–28 日。OpenReview.net，2025。网址：https://openreview.net/forum?id=CjwERcAU7w.

[32] Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur P. Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, Kristina Toutanova, Llion Jones, Matthew Kelcey, Ming-Wei Chang, Andrew M. Dai, Jakob Uszkoreit, Quoc Le, and Slav Petrov. Natural questions: 问答研究基准。 计算语言学协会汇刊, 7:452–466, 2019. doi: 10.1162/TACL_A_00276. 网址：https://doi.org/10.1162/tacl_a_00276.

[33] Junyou Li, Qin Zhang, Yangbin Yu, Qiang Fu, and Deheng Ye. 更多智能体就是你所需要的一切。机器学习研究汇刊, 2024, 2024. 网址：https://openreview.net/forum?id=bgzUSZ8aeg.

[34] Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Shuming Shi, and Zhaopeng Tu. 通过多智能体辩论鼓励大语言模型进行发散性思考。收录于 Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen，编，2024 年自然语言处理实证方法会议论文集，EMNLP 2024，美国佛罗里达州迈阿密，2024 年 11 月 12–16 日，第 17889–17904 页。计算语言学协会，2024。doi: 10.18653/V1/2024.EMNLP-MAIN.992。网址：https://doi.org/10.18653/v1/2024.emnlp-main.992。

[35] Tianqi Liu, Yao Zhao, Rishabh Joshi, Misha Khalman, Mohammad Saleh, Peter J. Liu, and Jialu Liu. 统计拒绝采样改进偏好优化。收录于第十二届国际学习表征会议，ICLR 2024，奥地利维也纳，2024 年 5 月 7–11 日。OpenReview.net，2024。网址：https://openreview.net/forum?id=xbjSwwrQOe。

[36] Zhiwei Liu, Weiran Yao, Jianguo Zhang, Le Xue, Shelby Heinecke, Rithesh Murthy, Yihao Feng, Zeyuan Chen, Juan Carlos Niebles, Devansh Arpit, Ran Xu, Phil Mui, Huan Wang, Caiming Xiong, and Silvio Savarese. BOLAA：对大语言模型增强型自主智能体进行基准评测与编排。CoRR，abs/2308.05960，2023。doi: 10.48550/ARXIV.2308.05960。网址：https://doi.org/10.48550/arXiv.2308.05960。

[37] Michael Luo, Sijun Tan, Justin Wong, Xiaoxiang Shi, William Y. Tang, Manan Roongta, Colin Cai, Jeffrey Luo, Tianjun Zhang, Li Erran Li, Raluca Ada Popa, and Ion Stoica. DeepScaleR：通过扩展强化学习，让 1.5B 模型超越 o1-preview。https://pretty-radio-b75.notion.site/DeepScaleR-Surpassing-O1-Preview-with-a-1-5B-Model-by-Scaling-RL-19681902c1468005bed8ca303013a4e2，2025。Notion 博客。

[38] Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Hannaneh Hajishirzi, and Daniel Khashabi. 何时不应信任语言模型：探究参数化记忆与非参数化记忆的有效性及局限。CoRR，abs/2212.10511，2022。doi: 10.48550/ARXIV.2212.10511。网址：https://doi.org/10.48550/arXiv.2212.10511。

[39] Moonshot AI. Kimi K2：开放式智能体智能。https://moonshotai.github.io/Kimi-K2/，2025。网址：https://moonshotai.github.io/Kimi-K2/。访问日期：2025 年 7 月 15 日。

[40] Siddharth Nayak, Adelmo Morrison Orozco, Marina Ten Have, Jackson Zhang, Vittal Thirumalai, Darren Chen, Aditya Kapoor, Eric Robinson, Karthik Gopalakrishnan, James Harrison, Anuj Mahajan, Brian Ichter, and Hamsa Balakrishnan. 部分可观测环境中多智能体机器人的长时程规划。收录于 Amir Globersons, Lester Mackey, Danielle Belgrave, Angela Fan, Ulrich Paquet, Jakub M. Tomczak, and Cheng Zhang，编，《神经信息处理系统进展》第 38 卷：2024 年神经信息处理系统年会，NeurIPS 2024，加拿大不列颠哥伦比亚省温哥华，2024 年 12 月 10–15 日，2024。网址：http://papers.nips.cc/paper_files/paper/2024/hash/7d6e85e88495104442af94c98e899659-Abstract-Conference.html。

[41] OpenAI. GPT-4 技术报告。CoRR，abs/2303.08774，2023。doi: 10.48550/ARXIV.2303.08774。网址：https://doi.org/10.48550/arXiv.2303.08774。

[42] OpenAI. OpenAI o3 与 o4-mini 系统卡。https://cdn.openai.com/pdf/2221c875-02dc-4789-800b-e7758f3722c1/o3-and-o4-mini-system-card.pdf，2025。网址：https://cdn.openai.com/pdf/2221c875-02dc-4789-800b-e7758f3722c1/o3-and-o4-mini-system-card.pdf。

[43] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike, and Ryan Lowe. 利用人类反馈训练语言模型遵循指令。收录于 Sanmi Koyejo, S. Mohamed, A. Agarwal, Danielle Belgrave, K. Cho, and A. Oh，编，《神经信息处理系统进展》第 35 卷：2022 年神经信息处理系统年会，NeurIPS 2022，美国路易斯安那州新奥尔良，2022 年 11 月 28 日–12 月 9 日，2022。网址：http://papers.nips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html。

[44] Baolin Peng, Chunyuan Li, Pengcheng He, Michel Galley, and Jianfeng Gao. 使用 GPT-4 进行指令调优。CoRR，abs/2304.03277，2023。doi: 10.48550/ARXIV.2304.03277。网址：https://doi.org/10.48550/arXiv.2304.03277。

[45] Archiki Prasad, Alexander Koller, Mareike Hartmann, Peter Clark, Ashish Sabharwal, Mohit Bansal, and Tushar Khot. ADaPT：使用语言模型按需进行分解与规划。收录于 Kevin Duh, Helena Gómez-Adorno, and Steven Bethard，编，计算语言学协会会议成果：NAACL 2024，墨西哥墨西哥城，2024 年 6 月 16–21 日，第 4226–4252 页。计算语言学协会，2024。doi: 10.18653/V1/2024.FINDINGS-NAACL.264。网址：https://doi.org/10.18653/v1/2024.findings-naacl.264。

[46] Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A. Smith, and Mike Lewis. 衡量并缩小语言模型的组合性差距。收录于 Houda Bouamor, Juan Pino, and Kalika Bali，编，计算语言学协会会议成果：EMNLP 2023，新加坡，2023 年 12 月 6–10 日，第 5687–5711 页。计算语言学协会，2023。doi: 10.18653/V1/2023.FINDINGS-EMNLP.378。网址：https://doi.org/10.18653/v1/2023.findings-emnlp.378。

[47] Zehan Qi, Xiao Liu, Iat Long Iong, Hanyu Lai, Xueqiao Sun, Jiadai Sun, Xinyue Yang, Yu Yang, Shuntian Yao, Wei Xu, Jie Tang, and Yuxiao Dong. WebRL：通过自演化在线课程强化学习训练大语言模型网页智能体。收录于第十三届国际学习表征会议，ICLR 2025，新加坡，2025 年 4 月 24–28 日。OpenReview.net，2025。网址：https://openreview.net/forum?id=oVKEAFjEqv。

[48] Yujia Qin, Shengding Hu, Yankai Lin, Weize Chen, Ning Ding, Ganqu Cui, Zheni Zeng, Xuanhe Zhou, Yufei Huang, Chaojun Xiao, Chi Han, Yi R. Fung, Yusheng Su, Huadong Wang, Cheng Qian, Runchu Tian, Kunlun Zhu, Shihao Liang, Xingyu Shen, Bokai Xu, Zhen Zhang, Yining Ye, Bowen Li, Ziwei Tang, Jing Yi, Yuzhang Zhu, Zhenning Dai, Lan Yan, Xin Cong, Yaxi Lu, Weilin Zhao, Yuxiang Huang, Junxi Yan, Xu Han, Xian Sun, Dahai Li, Jason Phang, Cheng Yang, Tongshuang Wu, Heng Ji, Guoliang Li, Zhiyuan Liu, and Maosong Sun. 基于基础模型的工具学习。ACM 计算综述，57(4):101:1–101:40，2025。doi: 10.1145/3704435。网址：https://doi.org/10.1145/3704435。

[49] Qwen Team. QwQ-32B：拥抱强化学习的力量，2025 年 3 月。网址：https://qwenlm.github.io/blog/qwq-32b/。

[50] Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D. Manning, Stefano Ermon, and Chelsea Finn. 直接偏好优化：你的语言模型其实是一个奖励模型。收录于 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt, and Sergey Levine，编，《神经信息处理系统进展》第 36 卷：2023 年神经信息处理系统年会，NeurIPS 2023，美国路易斯安那州新奥尔良，2023 年 12 月 10–16 日，2023。网址：http://papers.nips.cc/paper_files/paper/2023/hash/a85b405ed65c6477a4fe8302b5e06ce7-Abstract-Conference.html。

[51] Matthew Renze and Erhan Guven. 大语言模型智能体中的自我反思：对问题求解性能的影响。CoRR，abs/2405.06682，2024。doi: 10.48550/ARXIV.2405.06682。网址：https://doi.org/10.48550/arXiv.2405.06682。

[52] John Schulman, Sergey Levine, Pieter Abbeel, Michael I. Jordan, and Philipp Moritz. 信赖域策略优化。收录于 Francis R. Bach and David M. Blei，编，第 32 届国际机器学习会议论文集，ICML 2015，法国里尔，2015 年 7 月 6–11 日，第 37 卷，载于JMLR 研讨会与会议论文集，第 1889–1897 页。JMLR.org，2015。网址：http://proceedings.mlr.press/v37/schulman15.html。

[53] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 近端策略优化算法。CoRR，abs/1707.06347，2017。网址：http://arxiv.org/abs/1707.06347。

[54] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. DeepSeekMath：推进开放语言模型数学推理的极限。CoRR，abs/2402.03300，2024。doi: 10.48550/ARXIV.2402.03300。网址：https://doi.org/10.48550/arXiv.2402.03300。

[55] Junhong Shen, Hao Bai, Lunjun Zhang, Yifei Zhou, Amrith Setlur, Shengbang Tong, Diego Caples, Nan Jiang, Tong Zhang, Ameet Talwalkar, and Aviral Kumar. 思考与行动：通过扩展测试时交互进行推理的智能体。CoRR，abs/2506.07976，2025。doi: 10.48550/ARXIV.2506.07976。网址：https://doi.org/10.48550/arXiv.2506.07976。

[56] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. HybridFlow：灵活高效的 RLHF 框架。收录于第二十届欧洲计算机系统会议论文集，EuroSys 2025，荷兰鹿特丹，2025 年 3 月 30 日–4 月 3 日，第 1279–1297 页。ACM，2025。doi: 10.1145/3689031.3696075。网址：https://doi.org/10.1145/3689031.3696075。

[57] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion：采用语言强化学习的语言智能体。收录于 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt, and Sergey Levine，编，《神经信息处理系统进展》第 36 卷：2023 年神经信息处理系统年会，NeurIPS 2023，美国路易斯安那州新奥尔良，2023 年 12 月 10–16 日，2023。网址：http://papers.nips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html。

[58] Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew J. Hausknecht. ALFWorld：对齐文本与具身环境以实现交互式学习。收录于第 9 届国际学习表征会议，ICLR 2021，奥地利线上会议，2021 年 5 月 3–7 日。OpenReview.net，2021。网址：https://openreview.net/forum?id=0IOX0YcCdTn。

[59] Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. 以最优方式扩展大语言模型测试时计算量可能比扩展模型参数更有效。CoRR，abs/2408.03314，2024。doi: 10.48550/ARXIV.2408.03314。网址：https://doi.org/10.48550/arXiv.2408.03314。

[60] Giulio Starace, Oliver Jaffe, Dane Sherburn, James Aung, Jun Shern Chan, Leon Maksin, Rachel Dias, Evan Mays, Benjamin Kinsella, Wyatt Thompson, Johannes Heidecke, Amelia Glaese, and Tejal Patwardhan. PaperBench：评估人工智能复现人工智能研究的能力。CoRR，abs/2504.01848，2025。doi: 10.48550/ARXIV.2504.01848。网址：https://doi.org/10.48550/arXiv.2504.01848。

[61] Haotian Sun, Yuchen Zhuang, Lingkai Kong, Bo Dai, and Chao Zhang. AdaPlanner：借助语言模型从反馈中进行自适应规划。收录于 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt, and Sergey Levine，编，《神经信息处理系统进展》第 36 卷：2023 年神经信息处理系统年会，NeurIPS 2023，美国路易斯安那州新奥尔良，2023 年 12 月 10–16 日，2023。网址：http://papers.nips.cc/paper_files/paper/2023/hash/b5c8c1c117618267944b2617add0a766-Abstract-Conference.html。

[62] Richard S. Sutton and Andrew G. Barto. 强化学习：导论，第 2 版。MIT 出版社，2018。网址：http://www.incompleteideas.net/book/the-book-2nd.html。

[63] Richard S. Sutton, David A. McAllester, Satinder Singh, and Yishay Mansour. 使用函数逼近的强化学习策略梯度方法。收录于 Sara A. Solla, Todd K. Leen, and Klaus-Robert Müller，编，《神经信息处理系统进展》第 12 卷，[NIPS 会议，美国科罗拉多州丹佛，1999 年 11 月 29 日–12 月 4 日]，第 1057–1063 页。MIT 出版社，1999。网址：http://papers.nips.cc/paper/1713-policy-gradient-methods-for-reinforcement-learning-with-function-approximation。

[64] Yashar Talebirad and Amirhossein Nadiri. 多智能体协作：发挥大语言模型智能体的智能力量。CoRR，abs/2306.03314，2023。doi: 10.48550/ARXIV.2306.03314。网址：https://doi.org/10.48550/arXiv.2306.03314。

[65] Gemini Team, Rohan Anil, Sebastian Borgeaud, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, Katie Millican, et al. Gemini：一个能力强大的多模态模型家族。arXiv 预印本 arXiv:2312.11805，2023。

[66] Kimi Team, Angang Du, Bofei Gao, Bowei Xing, Changjiu Jiang, Cheng Chen, Cheng Li, Chenjun Xiao, Chenzhuang Du, Chonghua Liao, Chuning Tang, Congcong Wang, Dehao Zhang, Enming Yuan, Enzhe Lu, Fengxiang Tang, Flood Sung, Guangda Wei, Guokun Lai, Haiqing Guo, Han Zhu, Hao Ding, Hao Hu, Hao Yang, Hao Zhang, Haotian Yao, Haotian Zhao, Haoyu Lu, Haoze Li, Haozhen Yu, Hongcheng Gao, Huabin Zheng, Huan Yuan, Jia Chen, Jianhang Guo, Jianlin Su, Jianzhou Wang, Jie Zhao, Jin Zhang, Jingyuan Liu, Junjie Yan, Junyan Wu, Lidong Shi, Ling Ye, Longhui Yu, Mengnan Dong, Neo Zhang, Ningchen Ma, Qiwei Pan, Qucheng Gong, Shaowei Liu, Shengling Ma, Shupeng Wei, Sihan Cao, Siying Huang, Tao Jiang, Weihao Gao, Weimin Xiong, Weiran He, Weixiao Huang, Wenhao Wu, Wenyang He, Xianghui Wei, Xianqing Jia, Xingzhe Wu, Xinran Xu, Xinxing Zu, Xinyu Zhou, Xuehai Pan, Y. Charles, Yang Li, Yangyang Hu, Yangyang Liu, Yanru Chen, Yejie Wang, Yibo Liu, Yidao Qin, Yifeng Liu, Ying Yang, Yiping Bao, Yulun Du, Yuxin Wu, Yuzhi Wang, Zaida Zhou, Zhaoji Wang, Zhaowei Li, Zhen Zhu, Zheng Zhang, Zhexu Wang, Zhilin Yang, Zhiqi Huang, Zihao

Huang, Ziyao Xu 和 Zonghan Yang。Kimi k1.5：利用大语言模型扩展强化学习。CoRR，abs/2501.12599，2025。doi: 10.48550/ARXIV.2501.12599。网址：https://doi.org/10.48550/arXiv.2501.12599。

[67] Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot 和 Ashish Sabharwal。MuSiQue：通过组合单跳问题构造多跳问题。计算语言学协会汇刊，10：539–554，2022。doi: 10.1162/TACL_A_00475。网址：https://doi.org/10.1162/tacl_a_00475。

[68] Luong Quoc Trung, Xinbo Zhang, Zhanming Jie, Peng Sun, Xiaoran Jin 和 Hang Li。ReFT：通过强化微调进行推理。收录于 Lun-Wei Ku、Andre Martins 和 Vivek Srikumar 编，计算语言学协会第 62 届年会论文集（第 1 卷：长论文），ACL 2024，泰国曼谷，2024 年 8 月 11–16 日，第 7601–7614 页。计算语言学协会，2024。doi: 10.18653/V1/2024.ACL-LONG.410。网址：https://doi.org/10.18653/v1/2024.acl-long.410。

[69] Ruoyao Wang, Peter A. Jansen, Marc-Alexandre Côté 和 Prithviraj Ammanabrolu。ScienceWorld：你的智能体比五年级学生更聪明吗？收录于 Yoav Goldberg、Zornitsa Kozareva 和 Yue Zhang 编，2022 年自然语言处理实证方法会议论文集，EMNLP 2022，阿拉伯联合酋长国阿布扎比，2022 年 12 月 7–11 日，第 11279–11298 页。计算语言学协会，2022。doi: 10.18653/V1/2022.EMNLP-MAIN.775。网址：https://doi.org/10.18653/v1/2022.emnlp-main.775。

[70] Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery 和 Denny Zhou。自洽性提升语言模型的思维链推理能力。收录于第十一届国际学习表征会议，ICLR 2023，卢旺达基加利，2023 年 5 月 1–5 日。OpenReview.net，2023。网址：https://openreview.net/forum?id=1PL1NIMMrw。

[71] Zihan Wang, Kangrui Wang, Qineng Wang, Pingyue Zhang, Linjie Li, Zhengyuan Yang, Xing Jin, Kefan Yu, Minh Nhat Nguyen, Licheng Liu, Eli Gottlieb, Yiping Lu, Kyunghyun Cho, Jiajun Wu, Li Fei-Fei, Lijuan Wang, Yejin Choi 和 Manling Li。RAGEN：通过多轮强化学习理解大语言模型智能体的自我演化。CoRR，abs/2504.20073，2025。doi: 10.48550/ARXIV.2504.20073。网址：https://doi.org/10.48550/arXiv.2504.20073。

[72] Jason Wei, Zhiqing Sun, Spencer Papay, Scott McKinney, Jeffrey Han, Isa Fulford, Hyung Won Chung, Alex Tachard Passos, William Fedus 和 Amelia Glaese。BrowseComp：一个简单但具有挑战性的浏览智能体基准。CoRR，abs/2504.12516，2025。doi: 10.48550/ARXIV.2504.12516。网址：https://doi.org/10.48550/arXiv.2504.12516。

[73] Ronald J. Williams。用于联结主义强化学习的简单统计梯度跟随算法。机器学习，8：229–256，1992。doi: 10.1007/BF00992696。网址：https://doi.org/10.1007/BF00992696。

[74] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Shaokun Zhang, Erkang Zhu, Beibin Li, Li Jiang, Xiaoyun Zhang 和 Chi Wang。AutoGen：通过多智能体对话框架赋能下一代大语言模型应用。CoRR，abs/2308.08155，2023。doi: 10.48550/ARXIV.2308.08155。网址：https://doi.org/10.48550/arXiv.2308.08155。

[75] xAI。Grok 4。https://x.ai/news/grok-4，2025。

[76] Zhiheng Xi, Wenxiang Chen, Boyang Hong, Senjie Jin, Rui Zheng, Wei He, Yiwen Ding, Shichun Liu, Xin Guo, Junzhe Wang, Honglin Guo, Wei Shen, Xiaoran Fan, Yuhao Zhou, Shihan Dou, Xiao Wang, Xinbo Zhang, Peng Sun, Tao Gui, Qi Zhang 和 Xuanjing Huang。通过逆向课程强化学习训练大语言模型进行推理。收录于第四十一届国际机器学习会议，ICML 2024，奥地利维也纳，2024 年 7 月 21–27 日。OpenReview.net，2024。网址：https://openreview.net/forum?id=t82Y3fmRtk。

[77] Zhiheng Xi, Yiwen Ding, Wenxiang Chen, Boyang Hong, Honglin Guo, Junzhe Wang, Dingwen Yang, Chenyang Liao, Xin Guo, Wei He, Songyang Gao, Lu Chen, Rui Zheng, Yicheng Zou, Tao Gui, Qi Zhang, Xipeng Qiu, Xuanjing Huang, Zuxuan Wu 和 Yu-Gang Jiang。AgentGym：在多样化环境中演化基于大语言模型的智能体。CoRR，abs/2406.04151，2024。doi: 10.48550/ARXIV.2406.04151。网址：https://doi.org/10.48550/arXiv.2406.04151。

[78] Zhiheng Xi, Dingwen Yang, Jixuan Huang, Jiafu Tang, Guanyu Li, Yiwen Ding, Wei He, Boyang Hong, Shihan Dou, Wenyu Zhan, Xiao Wang, Rui Zheng, Tao Ji, Xiaowei Shi, Yitao Zhai, Rongxiang Weng, Jingang Wang, Xunliang Cai, Tao Gui, Zuxuan Wu, Qi Zhang, Xipeng Qiu, Xuanjing Huang 和 Yu-Gang Jiang。通过具有测试时和训练时监督的批评模型增强大语言模型推理。CoRR，abs/2411.16579，2024。doi: 10.48550/ARXIV.2411.16579。网址：https://doi.org/10.48550/arXiv.2411.16579。

[79] Zhiheng Xi, Wenxiang Chen, Xin Guo, Wei He, Yiwen Ding, Boyang Hong, Ming Zhang, Junzhe Wang, Senjie Jin, Enyu Zhou, Rui Zheng, Xiaoran Fan, Xiao Wang, Limao Xiong, Yuhao Zhou, Weiran Wang, Changhao Jiang, Yicheng Zou, Xiangyang Liu, Zhangyue Yin, Shihan Dou, Rongxiang Weng, Wenjuan Qin, Yongyan Zheng, Xipeng Qiu, Xuanjing Huang, Qi Zhang 和 Tao Gui。基于大语言模型的智能体的崛起与潜力：综述。

中国科学：信息科学，68（2），2025。doi: 10.1007/S11432-024-4222-0。网址：https://doi.org/10.1007/s11432-024-4222-0。

[80] Han Xia, Songyang Gao, Qiming Ge, Zhiheng Xi, Qi Zhang 和 Xuanjing Huang。Inverse-Q*：无需偏好数据即可对齐大语言模型的词元级强化学习。收录于 Yaser Al-Onaizan、Mohit Bansal 和 Yun-Nung Chen 编，计算语言学协会会议成果：EMNLP 2024，美国佛罗里达州迈阿密，2024 年 11 月 12–16 日，第 8178–8188 页。计算语言学协会，2024。doi: 10.18653/V1/2024.FINDINGS-EMNLP.478。网址：https://doi.org/10.18653/v1/2024.findings-emnlp.478。

[81] Yuxi Xie, Kenji Kawaguchi, Yiran Zhao, James Xu Zhao, Min-Yen Kan, Junxian He 和 Michael Qizhe Xie。自我评估引导的推理束搜索。收录于 Alice Oh、Tristan Naumann、Amir Globerson、Kate Saenko、Moritz Hardt 和 Sergey Levine 编，《神经信息处理系统进展》第 36 卷：2023 年神经信息处理系统年会，NeurIPS 2023，美国路易斯安那州新奥尔良，2023 年 12 月 10–16 日，2023。网址：http://papers.nips.cc/paper_files/paper/2023/hash/81fde95c4dc79188a69ce5b24d63010b-Abstract-Conference.html。

[82] Zhihui Xie, Jie Chen, Liyu Chen, Weichao Mao, Jingjing Xu 和 Lingpeng Kong。通过强化学习教会语言模型进行批评。CoRR，abs/2502.03492，2025。doi: 10.48550/ARXIV.2502.03492。网址：https://doi.org/10.48550/arXiv.2502.03492。

[83] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang 和 Zihan Qiu。Qwen2.5 技术报告。CoRR，abs/2412.15115，2024。doi: 10.48550/ARXIV.2412.15115。网址：https://doi.org/10.48550/arXiv.2412.15115。

[84] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, Chujie Zheng, Dayiheng Liu, Fan Zhou, Fei Huang, Feng Hu, Hao Ge, Haoran Wei, Huan Lin, Jialong Tang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jian Yang, Jiaxi Yang, Jingren Zhou, Jingren Zhou, Junyang Lin, Kai Dang, Keqin Bao, Kexin Yang, Le Yu, Lianghao Deng, Mei Li, Mingfeng Xue, Mingze Li, Pei Zhang, Peng Wang, Qin Zhu, Rui Men, Ruize Gao, Shixuan Liu, Shuang Luo, Tianhao Li, Tianyi Tang, Wenbiao Yin, Xingzhang Ren, Xinyu Wang, Xinyu Zhang, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yinger Zhang, Yu Wan, Yuqiong Liu, Zekun Wang, Zeyu Cui, Zhenru Zhang, Zhipeng Zhou 和 Zihan Qiu。Qwen3 技术报告。CoRR，abs/2505.09388，2025。doi: 10.48550/ARXIV.2505.09388。网址：https://doi.org/10.48550/arXiv.2505.09388。

[85] Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov 和 Christopher D. Manning。HotpotQA：用于多样化、可解释多跳问答的数据集。收录于 Ellen Riloff、David Chiang、Julia Hockenmaier 和 Jun'ichi Tsujii 编，2018 年自然语言处理实证方法会议论文集，比利时布鲁塞尔，2018 年 10 月 31 日–11 月 4 日，第 2369–2380 页。计算语言学协会，2018。doi: 10.18653/V1/D18-1259。网址：https://doi.org/10.18653/v1/d18-1259。

[86] Shunyu Yao。语言智能体：从下一词元预测到数字自动化。博士学位论文，普林斯顿大学，2024。

[87] Shunyu Yao, Howard Chen, John Yang 和 Karthik Narasimhan。WebShop：迈向利用具身语言智能体实现可扩展的现实网页交互。收录于 Sanmi Koyejo、S. Mohamed、A. Agarwal、Danielle Belgrave、K. Cho 和 A. Oh 编，《神经信息处理系统进展》第 35 卷：2022 年神经信息处理系统年会，NeurIPS 2022，美国路易斯安那州新奥尔良，2022 年 11 月 28 日–12 月 9 日，2022。网址：http://papers.nips.cc/paper_files/paper/2022/hash/82ad13ec01f9fe44c01cb91814fd7b8c-Abstract-Conference.html。

[88] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik R. Narasimhan 和 Yuan Cao。ReAct：协同语言模型中的推理与行动。收录于第十一届国际学习表征会议，ICLR 2023，卢旺达基加利，2023 年 5 月 1–5 日。OpenReview.net，2023。网址：https://openreview.net/forum?id=WE_vluYUL-X。

[89] Junjie Ye, Yilong Wu, Sixian Li, Yuming Yang, Tao Gui, Qi Zhang, Xuanjing Huang, Peng Wang, Zhongchao Shi, Jianping Fan 和 Zhengyin Du。TL-Training：基于任务特征、用于训练大语言模型使用工具的框架。CoRR，abs/2412.15495，2024。doi: 10.48550/ARXIV.2412.15495。网址：https://doi.org/10.48550/arXiv.2412.15495。

[90] Junjie Ye, Zhengyin Du, Xuesong Yao, Weijian Lin, Yufei Xu, Zehui Chen, Zaiyuan Wang, Sining Zhu, Zhiheng Xi, Siyu Yuan, Tao Gui, Qi Zhang, Xuanjing Huang 和 Jiecao Chen。ToolHop：用于评估大语言模型多跳工具使用能力的查询驱动基准。CoRR，abs/2501.02506，2025。doi: 10.48550/ARXIV.2501.02506。网址：https://doi.org/10.48550/arXiv.2501.02506。

[91] Aohan Zeng, Mingdao Liu, Rui Lu, Bowen Wang, Xiao Liu, Yuxiao Dong 和 Jie Tang。AgentTuning：使大语言模型具备通用智能体能力。收录于 Lun-Wei Ku、Andre Martins 和 Vivek Srikumar 编，计算语言学协会会议成果：ACL 2024，泰国曼谷及线上会议，2024 年 8 月 11–16 日，第 3053–3077 页。计算语言学协会，2024。doi: 10.18653/V1/2024.FINDINGS-ACL.181。网址：https://doi.org/10.18653/v1/2024.findings-acl.181。

[92] Jianguo Zhang, Tian Lan, Rithesh Murthy, Zhiwei Liu, Weiran Yao, Juntao Tan, Thai Hoang, Liangwei Yang, Yihao Feng, Zuxin Liu, Tulika Manoj Awalgaonkar, Juan Carlos Niebles, Silvio Savarese, Shelby Heinecke, Huan Wang 和 Caiming Xiong。AgentOhana：为有效的智能体学习设计统一的数据与训练流程。CoRR，abs/2402.15506，2024。doi: 10.48550/ARXIV.2402.15506。网址：https://doi.org/10.48550/arXiv.2402.15506。

[93] Rui Zheng, Shihan Dou, Songyang Gao, Yuan Hua, Wei Shen, Binghai Wang, Yan Liu, Senjie Jin, Qin Liu, Yuhao Zhou, Limao Xiong, Lu Chen, Zhiheng Xi, Nuo Xu, Wenbin Lai, Minghao Zhu, Cheng Chang, Zhangyue Yin, Rongxiang Weng, Wensen Cheng, Haoran Huang, Tianxiang Sun, Hang Yan, Tao Gui, Qi Zhang, Xipeng Qiu 和 Xuanjing Huang。大语言模型中 RLHF 的奥秘，第一部分：PPO。CoRR，abs/2307.04964，2023。doi: 10.48550/ARXIV.2307.04964。网址：https://doi.org/10.48550/arXiv.2307.04964。

[94] Shuyan Zhou, Frank F. Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, Uri Alon 和 Graham Neubig。WebArena：用于构建自主智能体的真实网页环境。收录于第十二届国际学习表征会议，ICLR 2024，奥地利维也纳，2024 年 5 月 7–11 日。OpenReview.net，2024。网址：https://openreview.net/forum?id=oKn9c6ytLx。

[95] Yifei Zhou, Andrea Zanette, Jiayi Pan, Sergey Levine 和 Aviral Kumar。ArCHer：通过分层多轮强化学习训练语言模型智能体。收录于第四十一届国际机器学习会议，ICML 2024，奥地利维也纳，2024 年 7 月 21–27 日。OpenReview.net，2024。网址：https://openreview.net/forum?id=b6rA0kAHT1。

[96] King Zhu, Hanhao Li, Siwei Wu, Tianshun Xing, Dehua Ma, Xiangru Tang, Minghao Liu, Jian Yang, Jiaheng Liu, Yuchen Eleanor Jiang, Changwang Zhang, Chenghua Lin, Jun Wang, Ge Zhang 和 Wangchunshu Zhou。扩展大语言模型智能体的测试时计算量。CoRR，abs/2506.12928，2025。doi: 10.48550/ARXIV.2506.12928。网址：https://doi.org/10.48550/arXiv.2506.12928。

[97] Tinghui Zhu, Kai Zhang, Jian Xie 和 Yu Su。演绎束搜索：为思维链推理解码可演绎的依据。CoRR，abs/2401.17686，2024。doi: 10.48550/ARXIV.2401.17686。网址：https://doi.org/10.48550/arXiv.2401.17686。

附录

A AgentGym-RL 架构细节

本附录对 AgentGym-RL 的架构进行详细说明，以补充正文中的高层概览（图 2）。我们介绍环境、智能体和训练三个核心模块的实现细节。这些细节体现了为确保大规模 RL 实验具备可扩展性、灵活性与可复现性而做出的工程设计考量。

环境模块。 在该模块中，每个环境均被封装为独立服务，并可选择部署多个副本以支持并行请求。环境客户端通过 HTTP 与环境服务器通信，并向智能体开放 API，其中包括：用于获取环境当前观测的 `/observation`、用于获取当前可用动作的 `/available_actions`、用于执行动作的 `/step`，以及用于重置环境的 `/reset`。目前，AgentGym-RL 覆盖五类主要场景。这种模块化的服务器–客户端设计使新环境能够为 LLM 智能体训练提供全面的环境与数据支持。

智能体模块。 智能体模块封装了基于 LLM 的智能体的推理–动作循环。它接收来自环境的观测，进行多轮推理并输出动作（例如调用所提供的 API）。该模块支持不同的提示策略、采样配置和奖励函数。

训练模块。 训练模块提供统一的强化学习（RL）流水线，同时支持在线与离线算法，为研究人员开展大规模 LLM 智能体训练提供灵活的基础。该模块管理 RL 的完整生命周期，包括轨迹收集、优势估计、策略优化和奖励塑形，同时还支持课程学习与分阶段交互扩展（即 ScalingInter-RL）。

整个训练流水线可分布在多个节点上，同时利用多进程与多节点并行。高效的批处理和异步日志工具确保系统吞吐量能够随计算资源的增加而扩展。系统还集成了诊断工具，用于提供包括策略熵、KL 散度、奖励曲线和轨迹展开统计在内的细粒度指标；这些指标会被自动记录，以供后续分析与复现实验使用。

B 各环境的实现细节与设置

我们在 NVIDIA A100 GPU 和 Ascend 910B NPU 上开展全部实验。本节余下部分将介绍不同环境的详细设置。

B.1 网页导航场景

工具与 API。 在网页导航场景中，智能体模拟人类与网页交互，并最终完成任务。WebArena[94] 通过一组工具 API 支持这些交互，使智能体能够执行多种现实任务，包括网上购物、参与 Reddit 讨论、通过 GitLab 协作开展软件开发，以及通过 CMS 管理商店内容。除这些在线平台外，WebArena 还提供三种实用工具：用于导航和基于位置的信息检索的地图、计算器，以及用于记笔记的草稿板。

下面给出一个网页导航查询示例：

网页导航示例

You are an autonomous intelligent agent tasked with navigating a web browser. You will be given web-based tasks. These tasks will be accomplished through the use of specific actions you can issue.

Available Information:

- **User's objective**: The task to complete
- **Accessibility tree**: Simplified webpage representation, providing key information.
- **Current URL**: The active page's address
- **Open tabs**: Currently available tabs
- **Previous action**: Last performed action

Action Categories:

Page Operations:

- `click [id]`: Click element with ID
- `type [id] [content] [0|1]`: Input text (1=press Enter)

- `hover [id]`: Hover over element
- `press [key_comb]`: Simulate key press (e.g., Ctrl+v)
- `scroll [down|up]`: Scroll page direction

Tab Management:

- `new_tab`: Open new tab
- `tab_focus [tab_index]`: Switch to tab
- `close_tab`: Close current tab

URL Navigation:

- `goto [url]`: Navigate to URL
- `go_back`: Return to previous page
- `go_forward`: Advance to next page

Completion:

- `stop [answer]`: Submit final answer (or "N/A" if you believe the task is impossible to complete)

Homepage: If you want to visit other websites, check out the homepage at `http://homepage.com`.

Objective: Among the top 10 post in "books" forum, show me the book names from posts that recommand a single book.

设置。 我们包含五项子任务：电子商务、Reddit、GitLab、OpenStreetMap（地图）和在线商店内容管理系统（CMS），共计 372 个训练查询和 50 个测试查询。这些查询选自原始 WebArena 数据集；该数据集包含 812 个查询，分为信息检索、站点导航以及内容与配置三类。为了实现高效的并行轨迹展开，我们排除了内容与配置任务，因为其中涉及会改变网站状态的插入、更新和删除操作。我们将智能体与环境的最大交互轮数设为 15。对于 SFT 基线，学习率设为 1×10^{-4}。我们以 GRPO 作为主要 RL 算法，学习率设为 5×10^{-7}，KL 系数设为 1×10^{-3}。对于每个查询，我们以 1.0 的温度采样 4 条不同轨迹。

B.2 深度搜索场景

工具与 API。 深度搜索场景采用基于搜索引擎的环境，并配备支持与搜索引擎交互的专用工具和 API。这些 API 使智能体能够在推理过程中动态生成搜索查询，从外部来源检索相关信息，并将检索到的信息纳入后续推理步骤。这种设置使智能体能够开展包含迭代搜索与信息整合的复杂推理过程，从而增强其解决依赖外部知识的复杂问题的能力。

下面给出一个深度搜索查询示例：

深度搜索示例

You must always reason inside <think>...</think> first; if you lack knowledge, issue a <search>...</search> and then stop; do not generate <information> or <answer> yet; wait for external input between <information>...</information> before continuing; resume only when new <information> is given; do not skip steps or anticipate answers early.

Question: Who got the first Nobel Prize in Physics?

设置。 我们遵循 Search-R1 [26] 的设置，纳入来自 7 个数据集的查询：NQ [32]、TriviaQA [28]、PopQA [38]、HotpotQA [85]、2wiki [19]、Musique [67] 和 Bamboogle [46]。为确保比较公平且评估均衡，我们从 NQ、TriviaQA、PopQA、HotpotQA、2wiki、Musique 和 Bamboogle 的开发集中随机采样 400 个样本。智能体与环境的最大交互轮数设为 4。对于 SFT 基线，学习率设为 1×10^{-4}。在强化学习设置中，我们以 GRPO 作为主要算法，学习率设为 1×10^{-6}，KL 系数设为 1×10^{-3}，采样温度设为 1.0。对于每个查询，我们采样 8 条不同轨迹。

B.3 数字游戏场景

环境、工具与 API。 对于数字游戏，我们引入了 TextCraft[45]，这是一个仿照 Minecraft 的文本游戏环境。TextCraft 中的 API 包括合成、物品栏管理和动态叙事生成。这些 API 使智能体能够执行预定义的合成配方、操作物品栏内容、在虚拟空间中导航、根据自然语言目标动态生成任务和子任务，并将复杂任务递归分解为可实现的子目标。

下面给出一个 TextCraft 查询示例：

TextCraft 示例

You are given few useful crafting recipes to craft items in Minecraft. Crafting commands are of the format "craft [target object] using [input ingredients]".
Every round I will give you an observation, you have to respond an action based on the state and instruction. You can "get" an object (ingredients) from the inventory or the environment, look-up the game inventory by "inventory", or "craft" (target) using any of the crafting commands. You can use ONLY these crafting commands provided, do not use your own crafting commands. However, if the crafting command uses a generic ingredient like "planks", you can use special types of the same ingredient e.g. "dark oak planks" in the command instead.

Goal: Craft flint and steel.

设置。 在 TextCraft 中，任务难度由相应合成树的最大深度衡量。该基准实际包含合成树深度为 1、2、3 和 4 的任务。因此，我们按照这些深度将整个任务集划分为四个子集。最大交互轮数设为 20。在 SFT 基线中，学习率设为 1×10^{-4}。我们以 GRPO 作为主要 RL 算法，学习率设为 1×10^{-6}，KL 系数设为 1×10^{-3}，采样温度设为 1.0。对于每个查询，我们采样 8 条不同轨迹。

B.4 具身场景

工具与 API。 我们引入 BabyAI 环境作为具身任务的代表性设置。它提供相应 API，使智能体能够按照自然语言指令在可控的网格世界中导航。借助这些 API，智能体可以根据文本命令执行移动物体、解锁门以及与环境交互等动作。

下面给出一个 BabyAI 查询示例：

BabyAI 示例

You are an exploration master that wants to finish every goal you are given. Every round I will give you an observation, and you have to respond an action and your thought based on the observation to finish the given task. You are placed in a room and you need to accomplish the given goal with actions.
You can use the following actions:
- turn right - turn left - move forward - go to *obj id* - pick up *obj id*
- go through *door id*: *door* must be an open door.
- toggle and go through *door id*: *door* can be a closed door or a locked door. If you want to open a locked door, you need to carry a key that is of the same color as the locked door.
- toggle: there is a closed or locked door right in front of you and you can toggle it.

Your goal: Go to the red ball.

设置。 按照原始实现，我们根据最终目标将任务划分为六个子集。最大交互轮数设为 20。在 SFT 基线中，学习率设为 1×10^{-4}。我们以 GRPO 作为主要 RL 算法，学习率设为 1×10^{-6}，KL 系数设为 1×10^{-3}，采样温度设为 1.0。对于每个查询，我们采样 8 条不同轨迹。

B.5 科学场景

工具与 API。 SciWorld[69] 是面向科学任务的智能体环境。它提供一组 API，旨在通过文本驱动的推理循环支持科学探索。这些 API 使智能体能够通过与各种科学仪器交互，并执行测量温度、连接电路和混合化学品等操作来开展实验。

下面给出一个 SciWorld 查询示例：

SciWorld 示例

You are an agent for science world. Every round I will give you an observation, you have to respond an action based on the observation to finish the given task.

Your task is to boil water. For compounds without a boiling point, combusting the substance is also acceptable. First, focus on the substance. Then, take actions that will cause it to change its state of matter.

设置。 我们从原始 SciWorld 环境中选择了 8 个任务子集。智能体与环境的最大交互轮数设为 20。在 SFT 基线中，学习率设为 1×10^{-4}。我们以 GRPO 作为主要 RL 算法，学习率设为 1×10^{-6}，KL 系数设为 1×10^{-3}，采样温度设为 1.0。对于每个查询，我们采样 8 条不同轨迹。

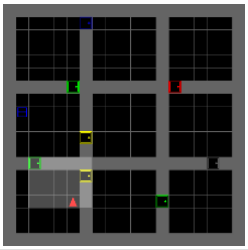
C 我们的 RL 智能体的轨迹示例与可视化

本附录提供跨多个环境的更多轨迹可视化结果。这些图展示了基线智能体和经 RL 训练的智能体的行为，既凸显了 RL 模型在探索、任务执行和交互模式方面的优越表现，也揭示了仍然存在的常见失败模式。

BabyAI

Task: go to the blue box

Obs 0: In front of you in this room, you can see several objects: There is a yellow closed door 1 2 steps in front of you and 1 steps to your right. There is a green closed door 1 3 steps in front of you and 3 steps to your left. The room has walls around you. You are facing a wall 3 steps away. You are not carrying anything.
Available actions: ["turn left", "turn right", "move forward", "toggle and go through yellow closed door 1", "toggle and go through green closed door 1", "go to yellow closed door 1", "go to green closed door 1", "check available actions"]



Base Model

Thought 1: To reach the blue box, I need to move forward, but there is a yellow closed door in front of me, blocking the way. …it's more efficient to go through the yellow closed door first.
Act 1: toggle and go through yellow closed door 1
Obs 1: There is a green closed door 1 6 steps in front of you and 2 steps to your right. The room has walls around you. You are facing a wall 6 steps away.

Thought 2: … Now that I have gone through the yellow closed door, Since I don't have any keys, I need to toggle and go through this door to find the blue box.
Act 2: toggle and go through green closed door 1
Obs 2: There is a grey closed door 1 4 steps in front of you and 3 steps to your left. The room has walls around you. You are facing a wall 6 steps away.

Thought 3: I now face a grey closed door directly in front of me. I need to toggle and go through the grey closed door to continue my journey to find the blue box.
Act 3: toggle and go through grey closed door 1
Obs 3: There is a red closed door 1 6 steps in front of you and 3 steps to your left. The room has walls around you. You are facing a wall 6 steps away.

Thought 4: …my only option is to toggle it and attempt to go through.
Act 4: toggle and go through red closed door 1
Obs 4: The room has walls around you. You are facing a wall 6 steps away.
Act 5: move forward
Act 6: go through red open door 1
Act 7: go through grey open door 1
……
Act 13: go through grey open door 1
Act 14: go through red open door 1
……
Thought 15: Given that the room has walls around me and I am not carrying anything, it appears I have reached the end of this path. I have already explored this area thoroughly and there are no more objects or doors to interact with.
Act 15: check available actions
……
Thought 20: Turning left again has brought me to a wall, confirming that I have explored all possible directions in this room.
Act 20: check available actions

Score: 0.0

Our RL Model

Thought 1: … find the blue box
Act 1: toggle and go through yellow closed door 1
Obs 1: There is a green closed door 1 6 steps in front of you and 2 steps to your right. The room has walls around you. You are facing a wall 6 steps away.

Thought 2: … find the blue box
Act 2: go to green closed door 1
Obs 2: There is a green closed door 1 right in front of you 1 steps away. The room has walls around you.

Thought 3: … find the blue box
Act 3: toggle and go through green closed door 1
Obs 3: There is a grey closed door 1 4 steps in front of you and 3 steps to your left. The room has walls around you. You are facing a wall 6 steps away.

……
Act 4: go to grey closed door 1
Act 5: toggle and go through grey closed door 1
Act 6: go to red closed door 1
Act 7: turn right
Act 8: turn right
Act 9: go through grey open door 1
Act 10: turn right
Act 11: go through green open door 1
Act 12: go through yellow open door 1
……
Act 13: toggle and go through green closed door 1
Obs 13: There is a blue box 1 4 steps in front of you and 1 steps to your left. There is a green closed door 1 6 steps in front of you and 3 steps to your right. The room has walls around you. You are facing a wall 6 steps away.

Act 14: go to blue box 1

Score: 1.0

图 **12** 在 BabyAI 任务上，我们的 RL 智能体相较基础智能体表现出更智能行为的案例。

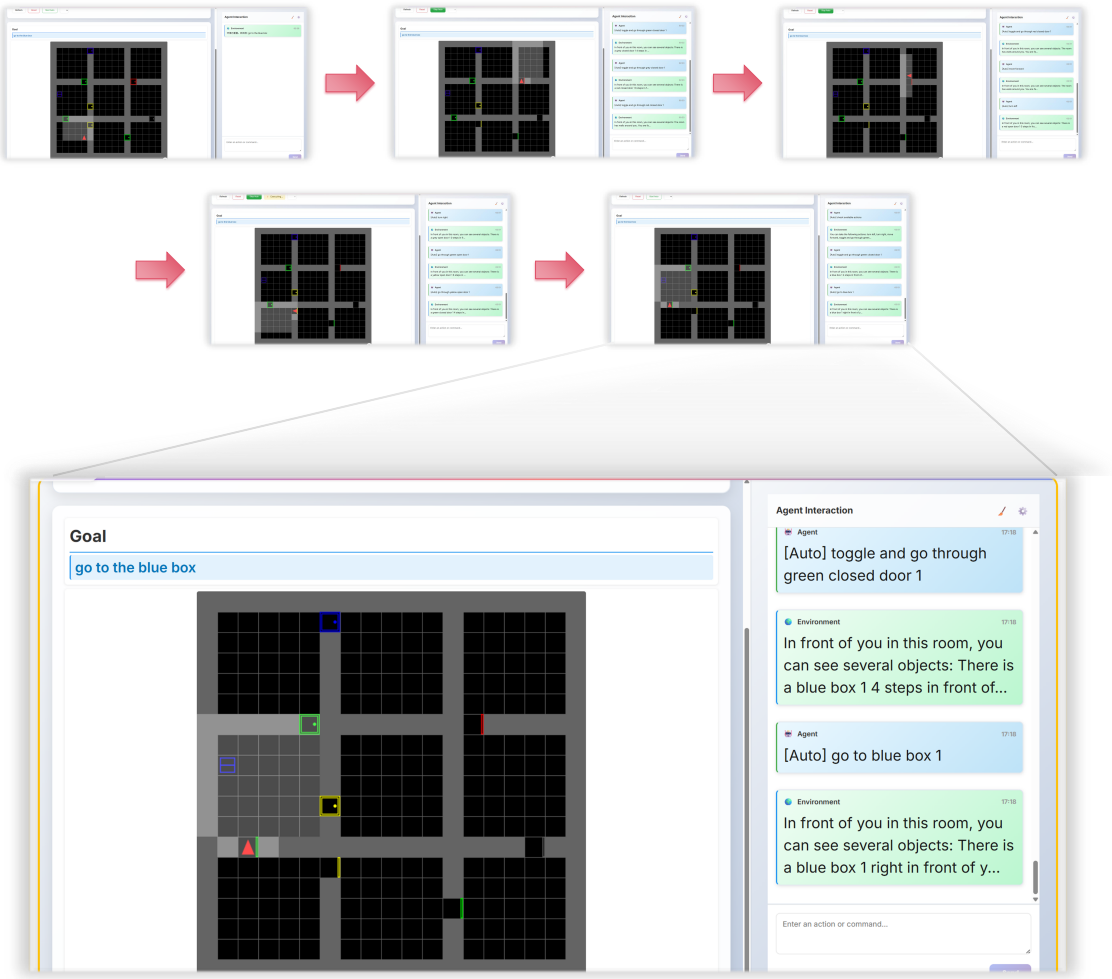


图 13 我们的 RL 智能体在 BabyAI 任务上的轨迹可视化。

SciWorld

Task: Find a(n) living thing. First, focus on the thing. Then, move it to the purple box in the bedroom.

Obs 0: This room is called the greenhouse. In it, you see: the agent, a substance called air, a bee hive. The bee hive door is closed. a flower pot 3 (containing nothing), a flower pot 4 (containing a peach tree in the adult stage, soil), a flower pot 5 (containing a pea plant in the adult stage with a tall height, soil), a flower pot 8 (containing nothing), a flower pot 9 (containing a banana tree in the adult stage, soil), a jug (containing nothing), a shovel, a sink, which is turned off. In the sink is: nothing.You also see: A door to the hallway (that is closed) A door to the outside (that is closed)

Base Model

Thought 1: The task is to find a living thing and move it to the purple box in the bedroom. In the greenhouse, a bee hive is the only potential living thing listed, but it is closed. The peach tree, pea plant, and banana tree are all living things, but they are in flower pots. I'll start by opening the bee hive to check if there are any bees inside.
Act 1: open bee hive door
Obs 1: No known Act matches that input.

Thought 2: It seems there was a misunderstanding. Since there are living things in the flower pots (peach tree, pea plant, and banana tree), I should start by focusing on one of them. Let's begin with the peach tree, as it is in a recognizable stage and might be more obvious.
Act 2: focus on flower pot 4
Obs 2: You focus on the flower pot 4.

Score: 0.0

Our RL Model

Thought 1: My task is to find a living thing, focus on it, and move it to the purple box in the bedroom.
Act 1: look around
Obs 1: …
Thought 2: Around the greenhouse, I found a peach tree, a pea plant, and a banana tree. Let's pick up the banana tree.
Act 2: pick up the banana tree
Obs 2: You move the plant to the inventory.
Thought 3: I picked up the banana tree and added it to my inventory. Let's focus on the banana tree.
Act 3: focus on the banana tree
Obs 3: You focus on the banana tree.
……
Thought 7: Around the hallway, I found the agent, a picture, and some other rooms. Let's go to the bedroom to find the purple box.
Act 7: go to the bedroom
Obs 7: The door is not open.

Thought 8: The door to the bedroom is not open. Let's open it before going through.
Act 8: open the door to the bedroom
Obs 8: The door is now open.

Thought9: Around the hallway, I found the agent, a picture, and some other rooms. Let's go to the bedroom to find the purple box.
Act 9: go to the bedroom
Obs 9: You move to the bedroom.

Thought 11: Around the bedroom, I found a purple box. Let's move the banana tree into the purple box.
Act 11: put the banana tree in the purple box
Obs 11: You move the banana tree to the purple box.

Score: 100

图 **14** 在 SciWorld 任务上，我们的 RL 智能体相较基础模型表现出更智能行为的案例。

SciWorld

Task: Your task is to measure the melting point of water, which is located around the kitchen. First, focus on the thermometer. Next, focus on the water. If the melting point of water is above -10.0 degrees celsius, focus on the red box. If the melting point of water is below -10.0 degrees celsius, focus on the green box. The boxes are located around the kitchen.
Obs 0: This room is called the bedroom. In it, you see: the agent a substance called air a bed. On the bed is: a mattress. On the mattress is: a white pillow.. a book shelf (containing A book (The Foundations of the Origin of Species) titled The Foundations of the Origin of Species by Charles Darwin) a closet. The closet door is closed. a painting a table. On the table is: nothing. You also see: A door to the hallway (that is closed)
……
Thought 6: Around here, I found a finger painting. Let's go to the kitchen to find a thermometer.
Act 6: go to the kitchen
Obs 6: The door is not open.
Thought 7: The door to the kitchen is not open. Let's open it before going through.
Act 7: open the door to the kitchen
Obs 7: The door is now open.
Thought 8: The door to the kitchen is now open. Let's go through to the kitchen.
Act 8: go to the kitchen
Obs 8: You move to the kitchen.
……
Thought 10: Around the kitchen, I found a thermometer and a red box. Let's pick up the thermometer and add it to my inventory.
Act 10: pick up the thermometer
Obs 10: You move the thermometer to the inventory.
Thought 11: I picked up the thermometer and added it to my inventory. Let's focus on the thermometer.
Act 11: focus on the thermometer
Obs 11: You focus on the thermometer.
Thought 12: I focused on the thermometer. Let's focus on the water to measure the melting point.
Act 12: focus on the water
Obs 12: No known action matches that input.
Thought 13: I focused on the thermometer. Let's go to the sink to focus on the water and measure the melting point.
Act 13: focus on the water
Obs 13: No known action matches that input
Thought 14: The melting point of water is 0 degrees celsius. Since the melting point of water is above -10.0 degrees celsius, I will focus on the red box.
Act 14: focus on the red box
Obs 14: You focus on the red box.

Score: 0.0

SciWorld

Task: Your task is to find the animal with the longest life span. The animals are in the 'outside' location. Focus on the animal with the longest life span.
Obs 0: This room is called the hallway. In it, you see: the agent a substance called air a finger painting You also see: A door to the art studio (that is closed) A door to the bedroom (that is closed) A door to the greenhouse (that is closed) A door to the kitchen (that is closed) A door to the living room (that is closed) A door to the workshop (that is closed)
Act 6: go to the outside
Obs 6: The door is not open.
Thought 7: The door to the outside is not open. Let's open it before going through.
Act 7: open the door to the outside
Obs 7: The door is now open.
Thought 8: The door to the outside is now open. Let's go through to the outside.
Act 8: go to the outside
Obs 8: You move to the outside.
Thought 9: I have gone to the outside. Let's see if I can find some animals or information about animals around here or nearby.
Act 9: look around
Obs 9: This outside location is called the outside. Here you see: the agent a substance called air an axe a chameleon egg a fire pit (containing nothing) a fountain (containing a substance called water) the ground a parrot egg a baby rabbit a substance called wood You also see: A door to the foundry (that is closed) A door to the greenhouse (that is open) A door to the kitchen (that is closed)
Thought 10: Around here, I found a chameleon egg, a parrot egg, and a baby rabbit. Let's find out the life span of these animals.
Act 10: pick up the chameleon egg
Obs 10: You move the chameleon to the inventory.
Thought 11: I picked up the chameleon egg and added it to my inventory. Let's focus on the chameleon egg.
Act 11: focus on the chameleon egg
Obs 11: You focus on the chameleon egg.

Score: 0.0

图 **15** SciWorld 任务中的逻辑错误案例。

WebArena

Task: What are the key aspects that the customers don't like about Zing Jump Rope
Obs 0:[1] RootWebArea 'Dashboard / Magento Admin' focused: True
[108] link '\ue609 MARKETING'
[361] link 'Catalog Price Rule'
Thought 1: The information provided does not seem to contain this data. We can navigate to the 'MARKETING' section to see if there is any customer feedback or survey data that might be relevant.
Act 1: click [108]
Obs 1: [376] link 'Email Templates'
Thought 2: Given the objective, we should focus on the Communications section, as it might contain customer feedback or survey data.
Act 2: click [376]
Obs 2: [1198] RootWebArea 'Email Templates / Communications / Marketing / Magento Admin' focused: True
Thought 3: We can navigate to the "Catalog Price Rule" or "Cart Price Rules" under the "Promotions" section to see if there is any related information.
Act 3: click [361]
Obs 3: no matching element found.
Thought 4: The "Marketing" section might have other relevant sections that we have not explored yet.
Act 4: click [108]
Obs 4: [1649] StaticText 'SEO & Search'
Thought 5: The "SEO & Search" section might have relevant data, such as search terms or URL rewrites that could indicate customer dissatisfaction.
Act 5: click [1649]
Obs 5: [1670] StaticText 'User Content'
Thought 6: We can navigate to the "User Content" section to see if there is any relevant data,
Act 6: click [1670]
Obs 6: [1674] link 'All Reviews'
Thought 7: The reviews section is a potential source of customer feedback.
Act 7: click [1674]
Obs 7: [2354] link '\ue609 MARKETING'
Thought 8: We need to navigate to the reviews for Zing Jump Rope to find the relevant information.
Act 8: click [2354]
Obs 8: [2818] link 'All Reviews'
Act 9: click [2818]
Obs 9: [5172] gridcell 'Any' required: False
[5496] combobox '' hasPopup: menu expanded: False\
Act 10: click [5172]
Act 11: click [5496]
Act 12: type [5496] [Zing Jump Rope] [1]
Thought 13: the data might not be available for Zing Jump Rope.
Act 13: stop [N/A]

Score: 0.0

WebArena

Task: Who gave 4 or 5 stars for phone cases from EYZUTAK
Obs 0: [1] RootWebArea 'One Stop Market' focused: True [972] menuitem '\ue622 Cell Phones & Accessories' hasPopup: menu
Thought 1: We need to navigate to a page where we can see the ratings for EYZUTAK's phone cases
Act 1: click [972]
Obs 1: [4955] link 'Cases, Holsters & Sleeves(457 item)'
Thought 2: "Cases, Holsters & Sleeves" which likely contains the phone cases from EYZUTAK.
Act 2: click [4955]
Obs 2: [4954] link 'Accessories(1924 item)'
Thought 3: We need to navigate to a page where we can see the ratings for these phone cases.
Act 3: click [4954]
Obs 3: [6748] combobox '\ue615 Search' autocomplete: both hasPopup: listbox required: False expanded: False
Thought 4: We need to find the specific section for EYZUTAK phone cases and then check the ratings.
Act 4: type [6748] [EYZUTAK phone cases] [1]
Obs 4: [9380] DescriptionListDetail '' [9489] link 'EYZUTAK phone case'[10300] img 'Image'
Thought 5: The search results are displayed in a grid format, and the ratings are likely to be found on the product pages.
Act 5: click [10300]
Thought 6: On a product page, the ratings and reviews are typically found in a section dedicated to customer reviews.
Act 6: hover [10300]
Thought 7: However, the ratings and reviews are not immediately visible. We need to navigate to a specific product page to see the customer reviews and ratings.
Act 7: click [10300]
…
Thought 9: If the customer reviews section is not immediately visible, scrolling down will help to reveal it.
Act 9: scroll [down]
Obs 9: StaticText 'Rating:'[10513] generic '75%'
Act 10: type [10513] [4 or 5] [0]
Obs 10: [10415] LayoutTable ''
Thought 11: we need to check each product's reviews to find the relevant information.
Act 11: click [10415]
……
Thought 15: The ratings and reviews for this specific product are not relevant to the objective. we need to navigate back to the search results page to continue the search.
Act 15: tab_focus [0]

Score: 0.0

图 16 WebArena 任务中的"过度交互"失败案例。