LongCat Interaction

SCOPE：信号校准的在策略蒸馏增强与双路径自适应加权

Binbin Zheng[1,2*†] **Xing Ma**[2*‡] **Yiheng Liang**[2,3] **Jingqing Ruan**[2]
Xiaoliang Fu[4] **Kepeng Lin**[5] **Benchang Zhu**[2‡] **Ke Zeng**[2] **Xunliang Cai**[2]
[1] 中国科学技术大学 [2] 美团 LongCat 交互团队
[3] 南京大学 [4] 复旦大学 [5] 华中科技大学
https://github.com/machine981/SCOPE

摘要

在策略强化学习已成为大语言模型推理对齐的主流范式，但其稀疏的结果级奖励使词元级信用分配尤为困难。在策略蒸馏（OPD）通过引入教师模型提供的稠密词元级 KL 监督来缓解这一问题，但通常会对所有采样轨迹统一施加这种监督，忽略了信号质量的根本差异。我们提出信号校准的在策略蒸馏增强框架（**SCOPE**）。该框架采用双路径自适应训练机制，依据正确性将在线采样轨迹分流至两条互补的监督路径。对于错误轨迹，SCOPE 进行以教师困惑度加权的 KL 蒸馏，优先关注教师确实具备纠错能力的样本，同时降低不可靠指导的权重。对于正确轨迹，该框架采用以学生困惑度加权的最大似然估计，将强化重点集中在能力边界附近的低置信度样本上，避免对已掌握样本进行过度强化。两条路径均采用组级归一化来自适应校准权重分布，以考虑不同提示之间固有的难度差异。在六个数学推理基准上的大量实验表明，相比有竞争力的基线，SCOPE 在 Avg@32 和 Pass@32 上分别取得了 11.42% 和 7.30% 的平均相对提升；扩展实验进一步证明了其更广泛的适用性。

1 引言

在大语言模型（LLM）的推理对齐中，在策略强化学习已成为主流范式：模型采样轨迹，并根据结果是否正确来更新策略 (Guo et al., 2025; Shao et al., 2024; Yu et al., 2025)。然而，这类奖励稀疏且仅作用于结果层面，使词元级信用分配异常困难，通常需要大量迭代才能收敛 (Peng et al., 2026; Wei et al., 2025)。在策略蒸馏（OPD）通过在学生模型自行采样的轨迹上引入来自教师模型的稠密词元级 KL 监督来缓解这一问题 (Min et al., 2024; Fu et al., 2026b)，从而在分布一致性与训练效率之间取得平衡。

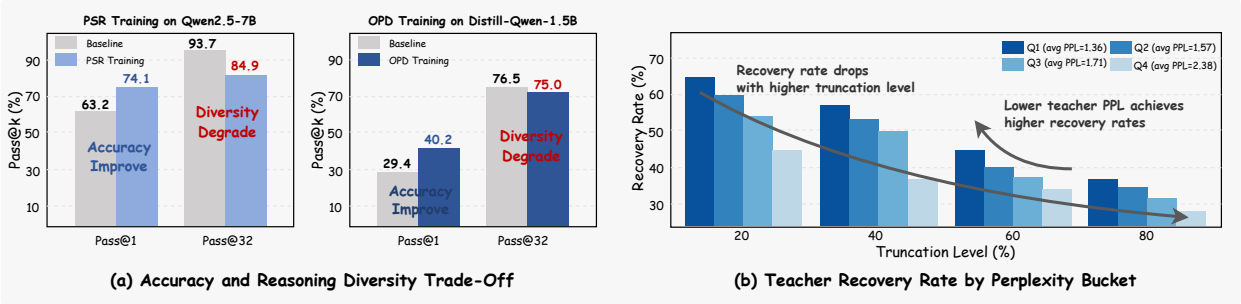
尽管 OPD 行之有效，但它假设教师的稠密监督在所有轨迹上都**同等可靠** (Ko et al., 2024; Agarwal et al., 2024; Fu et al., 2026b)，这会带来两方面问题。**(1) 对于错误轨迹**，较低的教师困惑度（PPL）意味着教师对相应推理掌握较好，因而能够在错误之后提供可靠指导。相反，较高的 PPL 表明教师不熟悉该轨迹，此时其词元级分布并非可靠信号。因此，蒸馏应优先考虑教师有信心的样本。如第 2 节所示，较低的教师 PPL 与成功的错误恢复高度相关 (Xiong et al., 2024; Kadavath et al., 2022)，证明该困惑度可以作为真实纠错能力的代理指标。**(2) 对于正确轨迹**，教师 KL 监督可能会压制学生偏离教师分布但仍然有效的非常规推理路径 (Agarwal et al., 2024)。最大似然估计（MLE）自强化虽是一种自然的替代方案，但等权 MLE 会过度强化已经稳定掌握的样本 (Zhu et al., 2025)，从而忽视位于能力边界的低置信度样本。因此，应依据学生模型的困惑度对正确轨迹进行自适应加权，以最大化学习价值。

上述分析揭示了标准 OPD 共有的一项结构性缺陷：**缺乏信号质量感知**。对于错误轨迹，OPD 无法区分可靠的教师指导与不可靠的监督。对于正确轨迹，它不考虑学习效用，将所有样本视为同等有价值。值得注意的是，这两条路径需要互补的加权视角：前者使用教师困惑度，后者使用学生困惑度。这促使我们构建一个统一框架，**依据正确性对轨迹进行路由**，并针对不同场景采用**定制的自适应加权**。

为此，我们提出信号校准的在策略蒸馏增强方法（**SCOPE**），这是一种双路径自适应训练框架。具体而言，SCOPE 根据正确性将在策略轨迹路由到两条监督路径。对于错误轨迹，它进行按教师困惑度加权的选择性 KL 蒸馏，提高教师展现真实纠错能力的样本权重。对于正确轨迹，它依据学生困惑度应用加权 MLE，将强化集中在能力边界样本上。最后，两条路径均采用归一化机制，对每组内的权重分布进行自适应校准。

我们的主要贡献如下：

*同等贡献。
†本工作于美团实习期间完成。
‡通讯作者。



(a) Accuracy and Reasoning Diversity Trade-Off (b) Teacher Recovery Rate by Perplexity Bucket

图 1: （a）在 AIME24 基准上训练前后的性能变化。PSR 和 OPD 训练都以牺牲 pass@32 为代价提升了 pass@1，体现出准确率与推理多样性之间的明显权衡。（b）在不同截断程度下，以截断后的学生错误轨迹作为前缀，并按困惑度分层后，教师模型的恢复率。

- **对 OPD 信号质量异质性的实证分析**。我们揭示了 OPD 中一项被忽视的质量差异：教师困惑度能够可靠预测错误轨迹上的纠错能力，而学生困惑度能够可靠识别正确轨迹中的能力边界样本。
- **双路径自适应框架**。 SCOPE 依据正确性路由轨迹，将错误轨迹交由教师困惑度加权的 OPD，将正确轨迹交由学生困惑度加权的 MLE，从而在统一目标中实现质量感知监督。
- **广泛的实验验证**。在数学基准上，相较有竞争力的基线，SCOPE 的 Avg@32 和 Pass@32 平均相对提升分别达到 11.42% 和 7.30%；扩展实验进一步证明了其广泛适用性。

2 预备分析

在介绍我们的框架之前，我们开展了两项实证研究，揭示现有在策略优化范式的根本局限：优化成功轨迹时推理多样性会下降，而纠正失败轨迹的效率较低。这些发现直接促成了 SCOPE 的双路径设计。

2.1 多样性退化

均匀强化学生自行生成的正确轨迹，会放大其主导推理路径，使有效但低概率的替代路径被边缘化 (Zhu et al., 2025; Li et al., 2025; Liang et al., 2025)。与此同时，施加稠密的教师信号会迫使学生严格匹配教师分布，从而抑制学生自身有效且多样的探索 (Yuan et al., 2025)。最终，这两种范式都不可避免地导致严重的模式坍缩。

Pass@k 悖论。 Zhu et al. (2025) 报告称，在 Qwen2.5-7B 上均匀强化模型自身的正确答案（正样本强化，PSR）会产生一个鲜明的悖论：Pass@1 有所提升，而 Pass@32 却从 93.7% 严重下降至 84.9%。为了研究稠密教师监督能否规避这一问题，我们对 DeepSeek-R1-Distill-Qwen-1.5B 生成的所有轨迹应用 OPD，并观察到同样显著的模式：Pass@1 上升，但 Pass@32 从 76.5% 降至 75.0%（图 1a）。这两项结果共同证实，均匀优化正确轨迹必然会使策略偏向主导推理模式，并以牺牲多样性为代价。其根本原因很直观：对于同一提示的正确轨迹，一部分遵循主导推理模式，另一些则通过罕见的非常规路径得出答案。均匀优化同等对待所有轨迹，过度强化前者并消除后者。因此，我们需要一**种能够区分已充分掌握解法与尚未充分探索解法的加权机制，并为后者赋予更高重要性，以保持推理多样性**。

2.2 纠错效率低下

当模型生成错误轨迹时，在复杂推理任务中仅依靠自我探索寻找正确路径效率极低 (Lu & Lab, 2025; Zhao et al., 2026)。虽然引入教师进行纠错监督很直观，但在策略特性带来了严重瓶颈：教师可能不得不以较弱学生生成的缺陷前缀为条件。如果这些前缀存在逻辑错误，教师的指导便可能退化为噪声，使纠错低效且不稳定。

缺陷前缀陷阱。 为了研究针对存在缺陷的在策略学生前缀进行外部纠错的效率，我们开展了错误恢复实验。具体而言，我们从 DeepMath 数据集 (He et al., 2025b) 中采样 2,000 个问题，使用学生模型（Distill-R1-Deepseek-Qwen-1.5B）生成推理轨迹，并保留其中的错误轨迹。随后，我们使用教师模型（Skywork-OR1-7B）计算这些缺陷轨迹的困惑度，并根据困惑度分数将其划分到不同区间。最后，我们以不同的长度比例截断这些前缀，并在提示教师模型完成后续生成时评估其恢复准确率（更多细节与案例研究分别见附录 C.1 和附录 C.4）。

如图 1b 所示，在所有截断程度下，低 PPL 前缀（Q1）的恢复率始终显著高于高 PPL 前缀（Q4），最高领先幅度达到 **+19.4%**。此外，随着截断程度增加，所有组的恢复率都迅速下降；即使表现最佳的组，在截断比例为 80% 时也降至约 **35%**。这揭示了一项关键机制：较高的教师 PPL 意味着上下文严重退化，会干扰教师的推理过程并产生高熵噪声。从这些退化区域学习会使纠错效率极低。相反，较低的 PPL 可保证前缀在结构上保持连贯，使教师能够提供高质量纠错信号。这促使我们认为，**高效纠错需要降低高教师 PPL 样本的权重，以滤除误导性噪声**。

3 方法

为克服上述推理多样性退化和前缀纠错固有的低效问题，我们提出双路径训练框架 SCOPE。如图 2 所示，SCOPE 根据轨迹结果路由在策略轨迹，并通过困惑度校准的自适应加权滤除误导性的教师噪声。我们首先介绍结果驱动的组分支（第 3.1 节），随后详述双路径自适应加权机制（第 3.2 节），最后给出整体目标（第 3.3 节）。

3.1 结果驱动的组分支

在策略轨迹采样过程中，对于每个输入提示 x，学生模型生成一组 N 个响应，记为 $Y^x = \{y_1, y_2, \ldots, y_N\}$，其中每个响应都是词元序列 $y_i = (a_{i,1}, a_{i,2}, \ldots, a_{i,|y_i|})$。随后，验证器对每个响应 $y_i \in Y^x$ 进行评估，得到二元奖励 $R_i \in \{0, 1\}$。我们将这些二元奖励作为路由信号，把生成的轨迹显式划分为两个互不相交的子集：正确集合 $\Omega_c^x = \{y_i \in Y^x \mid R_i = 1\}$ 和错误集合 $\Omega_w^x = \{y_i \in Y^x \mid R_i = 0\}$。

在策略代理形式。 为了使用行为策略 π_{old} 生成的轨迹优化当前策略 π_θ，我们通过定义词元级重要性采样比率来考虑分布偏移：

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(a_{i,t} \mid x, a_{i,<t})}{\pi_{\text{old}}(a_{i,t} \mid x, a_{i,<t})} \tag{1}$$

在此基础上，我们为划分后的两个子集设计了不同的代理目标：

有效轨迹利用（$i \in \Omega_c^x$）：正确轨迹包含直接且有效的推理步骤。我们不依赖教师指导，而是显式利用这些自行生成的成功尝试。通过代理目标最大化其似然，强化模型的内在能力：

$$\mathcal{L}_{\text{MLE}}(x, y_i; \theta) = -\sum_{t=1}^{|y_i|} \rho_{i,t}(\theta) \tag{2}$$

缺陷轨迹纠错（$i \in \Omega_w^x$）：错误轨迹缺乏内在监督目标。为实现有效纠错，我们利用教师策略 π_T 提供外部指导。在策略蒸馏目标将词元级对数比率视为负优势，以最小化反向 KL 散度，从而得到以下代理损失：

$$\mathcal{L}_{\text{OPD}}(x, y_i; \theta) = \sum_{t=1}^{|y_i|} \rho_{i,t}(\theta) \Big(\log \pi_{\bar{\theta}}(a_{i,t} \mid x, a_{i,<t}) - \log \pi_T(a_{i,t} \mid x, a_{i,<t}) \Big), \tag{3}$$

其中，$\bar{\theta}$ 表示已从计算图中分离的参数。

3.2 双路径自适应加权

为缓解多样性退化并提高纠错效率，我们引入一种新机制，称为**双路径自适应加权（DPAW）**，该机制严格在每个提示的候选响应组内运行。令 $\log \pi(y_i \mid x) = \sum_{t=1}^{|y_i|} \log \pi(a_{i,t} \mid x, a_{i,<t})$ 表示序列级对数概率。为了直观量化轨迹的内在不确定性，我们使用序列困惑度构造加权机制，其中 $\text{PPL}(y_i|x) = \exp(-\frac{1}{|y_i|} \log \pi(y_i \mid x))$。

学生引导权重：放大“非常规有效路径”。 对于正确轨迹（$i \in \Omega_c^x$），我们希望学生模型关注那些通过低概率替代路径成功得到正确结果的样本。为了给这些低置信度轨迹赋予更高权重，我们对长度归一化的负对数概率应用组内相对 softmax。使用序列概率 $\pi_S(y_i \mid x)$，**学生引导权重** w_i^{stu} 计算如下：

$$w_i^{\text{stu}} = \frac{\exp\left(-\frac{1}{\tau|y_i|} \log \pi_S(y_i \mid x)\right)}{\sum_{j \in \Omega_c^x} \exp\left(-\frac{1}{\tau|y_j|} \log \pi_S(y_j \mid x)\right)} = \frac{\text{PPL}_S(y_i \mid x)^{1/\tau}}{\sum_{j \in \Omega_c^x} \text{PPL}_S(y_j \mid x)^{1/\tau}}, \quad \forall i \in \Omega_c^x. \tag{4}$$

如最右项所示，该形式可以简洁地表示为对学生困惑度直接进行组级归一化（由温度 τ 缩放）。因此，正确但高困惑度的样本自然会得到更强的监督。理论分析见附录 A.2。

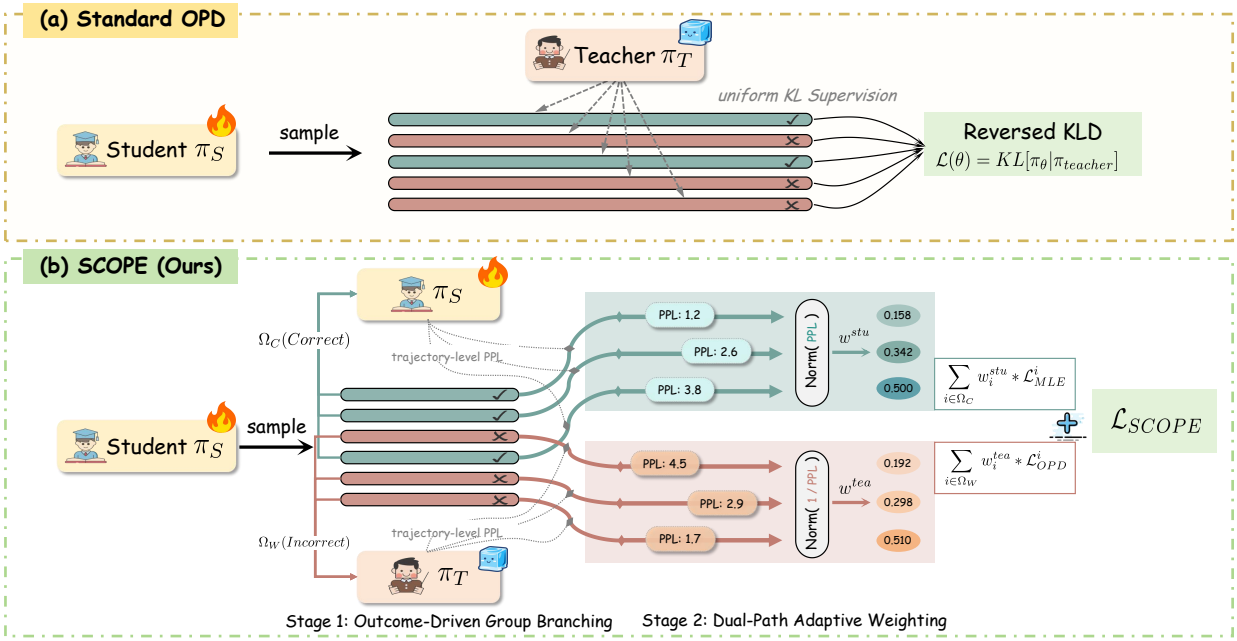


图 2: （a）标准 OPD 对所有样本施加均匀监督。（b）我们的 SCOPE 框架首先将轨迹划分为正确集合 Ω_C 和错误集合 Ω_W，然后应用基于困惑度的双路径加权，最后通过统一目标优化加权后的各分支，从而改进学习过程。

教师引导权重：滤除"前缀诱导噪声"。 对于错误轨迹（$i \in \Omega_w^x$），让教师以缺陷前缀为条件通常会产生高熵噪声（如第 2.2 节所示）。为了防止学生继承这类噪声，我们仅在教师提供高置信度纠正时才依赖教师。具体而言，我们直接对教师经长度归一化的对数概率应用 softmax：

$$w_i^{\text{tea}} = \frac{\exp\left(\frac{1}{\tau|y_i|}\log \pi_T(y_i \mid x)\right)}{\sum_{j\in\Omega_w^x}\exp\left(\frac{1}{\tau|y_j|}\log \pi_T(y_j \mid x)\right)} = \frac{\text{PPL}_T(y_i \mid x)^{-1/\tau}}{\sum_{j\in\Omega_w^x}\text{PPL}_T(y_j \mid x)^{-1/\tau}}, \quad \forall i \in \Omega_w^x. \tag{5}$$

该形式会有选择地降低教师呈现高困惑度样本的权重，从而有效滤除缺陷前缀引发的噪声。我们在附录 A.1 中对这一过滤准则进行了形式化说明。

3.3 SCOPE 整体目标

最后，我们将结果驱动的分支和自适应权重整合为数据集 $\mathcal{D}$ 上的整体目标。SCOPE 的整体损失 $\mathcal{J}_{\text{SCOPE}}$ 表示为：

$$\mathcal{J}_{\text{SCOPE}} = \mathbb{E}_{x\sim\mathcal{D}}\left[\sum_{i\in\Omega_c^x} w_i^{\text{stu}}\cdot\mathcal{L}_{\text{MLE}}(x,y_i) + \sum_{i\in\Omega_w^x} w_i^{\text{tea}}\cdot\mathcal{L}_{\text{OPD}}(x,y_i)\right]. \tag{6}$$

组级归一化使不同难度提示上的自适应更新更加稳定。形式化分析见附录 A.3。在该框架中，SCOPE 在组级别对监督信号进行自适应校准：一方面在有效路径上强化学生的边界能力，另一方面仅从教师针对缺陷路径的纠正中蒸馏有用信息。

4 实验

4.1 实验设置

训练设置与基线。 我们采用 DeepSeek-R1-Distill-Qwen-1.5B (Guo et al., 2025) 和 Qwen3-1.7B-Base (Yang et al., 2025) 作为学生模型，分别以 SkyWork-OR1-7B (He et al., 2025a) 和 Qwen3-8B-Instruct (Yang et al., 2025) 作为对应的教师模型，所有模型均在 DeepMath (He et al., 2025b) 上训练。我们将 SCOPE 与以下基线进行比较：

表 1：不同教师–学生配置下数学推理基准的主要结果。我们报告各基准的 Avg@32（A@32）和 Pass@32（P@32）。**粗体**表示最佳性能，下划线 表示次佳性能。

模型	AIME24		AIME25		AMC23		MATH500		Minerva		Olympiad		平均	
	A@32	P@32	A@32	P@32	A@32	P@32	A@32	P@32	A@32	P@32	A@32	P@32	A@32	P@32
教师：*SkyWork-OR1-7B* ⟶ 学生：*DeepSeek-R1-Distill-Qwen-1.5B*														
R1-Distill-Qwen-1.5B	29.4	76.5	23.9	46.9	72.7	94.7	84.6	97.3	32.3	**55.9**	44.2	67.5	47.9	73.1
使用 GRPO	35.5	68.3	24.5	45.1	75.1	95.0	87.0	96.7	35.1	53.5	40.5	67.7	49.6	71.1
使用 KD	26.6	71.4	22.2	45.6	69.1	96.3	84.1	97.4	30.7	54.1	39.7	66.9	45.4	72.0
使用 OPD	40.2	75.0	28.9	48.5	75.9	95.0	89.0	97.7	34.9	53.0	44.9	69.3	52.3	73.1
使用 **SCOPE**（本文）	**42.7**	**77.9**	**30.4**	**50.9**	**80.9**	**97.2**	**89.8**	**97.9**	**37.8**	55.1	**49.7**	**70.9**	**55.2**	**75.0**
相较 *OPD* 的 Δ%	+6.22%	+3.87%	+5.19%	+4.95%	+6.59%	+2.32%	+0.90%	+0.20%	+8.31%	+3.96%	+10.69%	+2.31%	+5.54%	+2.60%
教师：*Qwen3-8B-Instruct* ⟶ 学生：*Qwen3-1.7B-Base*														
Qwen3-1.7B-Base	3.7	26.7	3.2	20.7	24.6	69.4	54.8	88.6	11.2	41.6	16.3	48.0	19.0	49.2
使用 GRPO	7.5	27.2	4.2	24.5	33.1	60.0	62.9	89.8	25.3	49.8	**25.9**	50.9	26.5	50.4
使用 KD	4.6	18.9	5.8	24.8	29.8	66.1	50.2	86.2	16.6	43.2	13.3	41.4	20.1	46.8
使用 OPD	12.2	**31.5**	10.6	29.7	43.1	80.1	67.9	90.7	24.2	49.4	25.3	53.7	30.6	55.9
使用 **SCOPE**（本文）	**13.3**	**31.5**	**12.1**	**35.6**	**46.3**	**83.0**	**70.9**	**93.0**	**27.9**	**54.0**	24.6	**54.6**	**32.5**	**58.6**
相较 *OPD* 的 Δ%	+9.02%	+0.00%	+14.15%	+19.87%	+7.42%	+3.62%	+4.42%	+2.54%	+15.29%	+9.31%	-2.77%	+1.68%	+6.21%	+4.83%

- **组相对策略优化（GRPO）** (Shao et al., 2024)：根据多次采样响应的结果奖励计算组相对优势，并据此优化策略。
- **知识蒸馏（KD）** (Kim & Rush, 2016)：通过监督学习，使用离线数据集中由教师生成的静态序列训练学生模型。
- **在策略蒸馏（OPD）** (Lu & Lab, 2025)：在学生采样的轨迹上施加来自教师的稠密词元级 KL 散度监督。

评估基准与指标。 为了全面评估模型的推理能力，我们在广泛的数据集上测试其性能，包括 MATH500 (Hendrycks et al., 2021)、AIME24 (MAA, 2024)、AIME25 (MAA, 2025)、AMC 2023 (MAA, 2023)、Minerva (Lewkowycz et al., 2022) 和 OlympiadBench (He et al., 2024)。评估采用两个关键指标：Avg@32 反映模型的期望稳定性，Pass@32 则体现其能力上界。

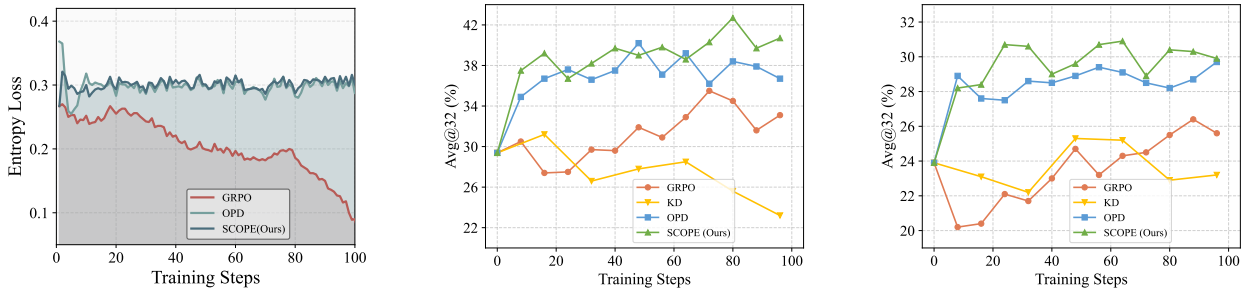
实现细节。 训练时，我们采用 256 的全局批大小、4,096 个词元的最大提示长度、12,288 个词元的补全长度、0.6 的轨迹采样温度，以及 1.0 的权重温度。评估时，我们报告轨迹采样温度为 0.6、采用 $p = 0.95$ 的 top-p 采样且最大响应长度为 32,768 个词元时的性能。更多细节见附录 B.1。

4.2 主要结果

数学推理性能。 表 1 展示了多个高难度数学推理基准上的评估结果。在主要配置（教师：SkyWork-OR1-7B，学生：Distill-Qwen-1.5B）下，SCOPE 始终取得最佳 Avg@32 性能。与强基线相比，SCOPE 相较标准 OPD 的平均相对提升为 +5.54%，其中在 Olympiad 和 AMC23 上分别显著提升 +10.69% 和 +6.59%。这些增益源于我们的教师引导加权：它自适应惩罚高困惑度的失败轨迹，以绕过“缺陷前缀陷阱”，进而提取精确的纠错信号。此外，Pass@32 结果体现了 SCOPE 保持推理多样性并克服 Pass@k 悖论的独特能力；在优化未经微调的基础模型时，这一挑战尤其严重。如表 1 下半部分所示，在 Qwen3-1.7B-Base 上的实验表明，标准范式（如 GRPO、KD）会显著削弱基础模型固有的探索能力，表现出严重的模式坍缩。相比之下，SCOPE 有效避免了这种退化，并显著提高多样本通过率。这一提升可归因于我们的学生引导加权：它为正确但高困惑度的轨迹赋予更高权重，从而主动放大“非常规有效路径”。

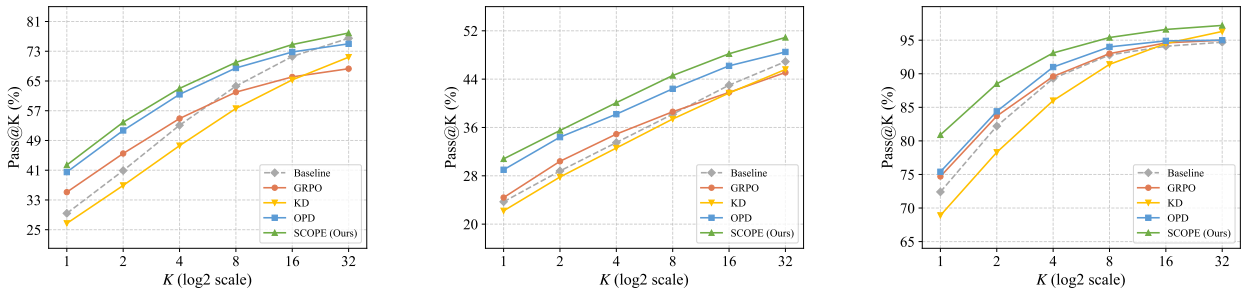
训练动态。 图 3 展示了 SCOPE、GRPO 和 OPD 的训练动态。图 3(a) 显示出熵演化的鲜明差异。GRPO 的熵持续下降（过早利用会直接导致 Pass@k 悖论），而 OPD 和 SCOPE 都能维持健康的策略熵。然而，标准 OPD 的均匀监督忽视信号质量，因此很快达到性能平台期。借助双路径自适应加权，SCOPE 始终取得更优的性能与样本效率（图 3b 和 c）。总体而言，GRPO 因探索坍缩而表现不佳，OPD 则受噪声蒸馏限制；SCOPE 将保持多样性的探索与质量感知纠错相结合，有效突破了这一瓶颈。

Pass@k 性能。 如图 4 所示，在 AIME24/25 和 AMC23 上，SCOPE 的 Pass@k 指标始终优于所有基线。值得注意的是，GRPO、OPD 等标准方法都受到 Pass@k 悖论影响，在 AIME24 评估中尤为明显。它们的多样性扩展能力受到限制：当 k 较大时，多样本带来的性能增益会减弱或进入平台期。相比之下，SCOPE 会放大学生能力边界附近的非常规有效轨迹，使模型能够保留多条互补推理路径。因此，随着样本数增加至



(a) 熵损失的动态变化　(b) AIME24 Avg@32 的动态变化　(c) AIME25 Avg@32 的动态变化

图 3: GRPO、OPD 与 SCOPE（本文）的训练动态对比：（a）不同训练步数下的熵损失；（b）AIME24 和（c）AIME25 上的 Avg@32（%）性能。



(a) AIME24 上的 Pass@k　(b) AIME25 上的 Pass@k　(c) AMC23 上的 Pass@k

图 4: 使用 DeepSeek-R1-Distill-Qwen-1.5B 模型时，GRPO、OPD 与 SCOPE（本文）在 AIME24、AIME25 和 AMC23 基准上的 Pass@k（%）性能对比。

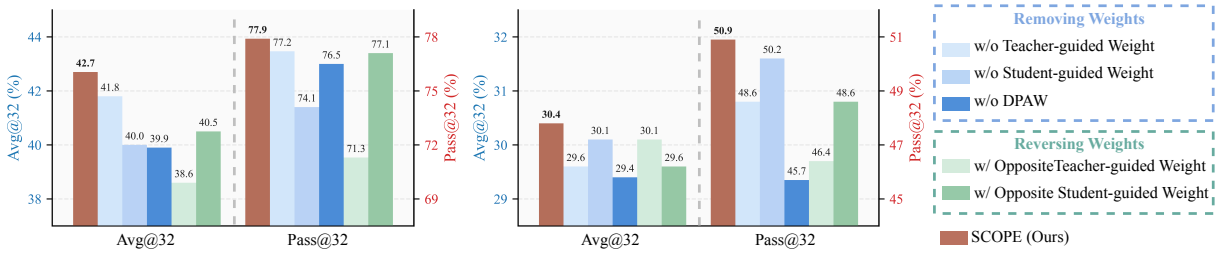
$k = 32$，其通过率仍持续提升，展现出更强的多样性扩展能力。这些结果表明，SCOPE 不仅提升了 Pass@1 性能，还扩大了对多样推理模式的覆盖，验证了信号质量感知监督在保持探索多样性方面的有效性。

4.3 消融研究

DPAW 机制的有效性。 为了验证 DPAW 机制的有效性，我们在 AIME24/25 基准上进行了消融研究，如图 5 所示。移除整个 DPAW 模块会导致性能严重下降。例如，AIME25 Pass@32 从 50.9% 显著降至 45.7%。这表明，从根本上忽略信号质量的标准均匀加权无法充分利用在策略轨迹。此外，移除学生引导权重会降低多样本通过率，例如 AIME24 Pass@32 从 77.9% 降至 74.1%；而反转其方向同样会损害性能。同样，移除或反转教师引导权重也会降低整体准确率。尤其是，反转教师引导权重会使 AIME24 Avg@32 从 42.7% 大幅降至 38.6%。这一结果从实证角度证明，动态惩罚不可靠的教师指导能够有效滤除前缀诱导的噪声蒸馏信号。总体而言，这些发现表明 DPAW 的两个组成部分高度互补：学生引导加权最大化成功轨迹上的探索多样性，教师引导加权则严格缓解失败轨迹上的蒸馏噪声。

4.4 扩展实验

表 2 进一步评估了 SCOPE 在代码生成任务上的通用性，其中包括 HumanEval (Chen et al., 2021)、LiveCodeBench (Jain et al., 2025) 和 Codeforces 问题。与标准 OPD 相比，SCOPE 在所有基准上均稳定提升 Avg@32，平均相对增益达到 +4.69%，同时平均优于 GRPO +4.21%。在 HumanEval 和 LiveCodeBench 上，相较 OPD 的增益尤为显著，SCOPE 的 Avg@32 分别提升 +4.51% 和 +6.95%。此外，SCOPE 将平均 Pass@32 从 59.2% 提升至 60.3%，进一步说明双路径自适应加权在数学推理之外仍然有效。这些结果表明，SCOPE 通过区分可靠的教师纠正与噪声纠正，并强化低置信度的成功轨迹，可为多种可验证任务提供广泛适用的监督信号。更多细节见附录 B.2。



(a) Performance on AIME24 (b) Performance on AIME25

图 5: SCOPE 双路径自适应加权机制（DPAW）的消融研究。我们报告 AIME24（a）和 AIME25（b）上的 Avg@32（%）与 Pass@32（%）性能。

表 2: 基于 1.5B 学生模型的代码生成基准结果。我们报告各基准的 Avg@32（A@32）和 Pass@32（P@32）。粗体表示最佳性能，下划线 表示次佳性能。

模型	HumanEval		Codeforces		LiveCodeBench		平均	
	A@32	P@32	A@32	P@32	A@32	P@32	A@32	P@32
教师：*SkyWork-OR1-7B* ⟶ 学生：*DeepSeek-R1-Distill-Qwen-1.5B*								
R1-Distill-Qwen-1.5B	57.8	74.1	20.3	39.4	21.2	35.2	33.1	49.6
使用 GRPO	61.5	75.2	32.4	45.3	**34.5**	45.7	42.8	55.4
使用 KD	49.5	73.2	12.9	22.9	17.1	25.1	26.5	40.4
使用 OPD	64.3	78.2	33.3	52.3	30.2	**47.0**	42.6	59.2
使用 **SCOPE（本文）**	**67.2**	**80.2**	**34.4**	**53.7**	32.3	**47.0**	**44.6**	**60.3**
相较 *OPD* 的 Δ%	+4.51%	+2.56%	+3.30%	+2.68%	+6.95%	+0.00%	+4.69%	+1.86%

5 相关工作

5.1 基于可验证奖励的强化学习

基于可验证奖励的强化学习（RLVR）近来显著推动了大语言模型推理能力的发展 (Guo et al., 2025; Fu et al., 2026a; Yu et al., 2025)。它利用客观领域（例如数学和代码生成）中的确定性结果验证器提供无歧义的信号，从而防止奖励作弊并激励自主探索 (Bin Tarek & Beheshti, 2025; Dong et al., 2025)。然而，GRPO (Shao et al., 2024) 等标准 RLVR 算法依赖稀疏的标量结果奖励，且仅在长推理轨迹的终止步骤发放，这会严重加剧信用分配问题 (Peng et al., 2026; Wei et al., 2025)，并使模型无法获得细粒度的过程监督 (Hübotter et al., 2026)。这一困难对于较小的大语言模型尤为突出，因为其有限的表征能力为自主信用传播留下的空间更小 (Xu et al., 2025; Ko et al., 2026)。尽管过程奖励模型（PRM）(Lightman et al., 2023; Cui et al., 2025) 可以提供逐步反馈，但它们需要高昂的人工标注成本，且跨领域泛化能力较差。这一瓶颈促使我们通过蒸馏，从能力更强的教师模型中寻求稠密的词元级监督。

5.2 知识蒸馏

知识蒸馏（KD）(Hinton et al., 2015) 已成为将教师模型能力迁移至紧凑型学生大语言模型的主要范式，其主要方式是进行词元级 logit 对齐 (Gu et al., 2023; Agarwal et al., 2024; Jung et al., 2025)。离策略知识蒸馏在教师生成的静态轨迹上训练 (Guo et al., 2025; Yang et al., 2025)，但其本质上会受到暴露偏差和分布失配的影响 (Agarwal et al., 2024; Hsieh et al., 2023)。在策略蒸馏（OPD）通过反向 KL 散度，利用教师反馈优化学生采样的展开轨迹，从而缓解上述问题并获得更强的收敛性 (Ko et al., 2024; Lu & Lab, 2025)。近期的 RL-KD 混合方法进一步在单一训练循环中统一可验证奖励和教师监督：KDRL (Xu et al., 2025) 联合优化奖励与 KL 目标，而 RLAD (Zhang et al., 2026) 和 REOPOLD (Ko et al., 2026) 则通过动态奖励塑形注入教师信号。尽管这些方法取得了进展，它们都隐式地假设教师监督在所有展开轨迹上都同等可靠，却忽视了教师可能在某些特定轨迹上自信地给出错误判断。因此，不加区分的蒸馏可能成为传播确认偏差的载体。这一局限要求构建一种**轨迹级自适应机制**，根据展开轨迹的正确性与信号可靠性来区分监督策略，这正是我们所提出框架的设计原则。

6 结论

本文提出了信号校准的在策略蒸馏增强方法（**SCOPE**），这是一种将信号质量感知融入在策略蒸馏的双路径自适应训练框架。SCOPE 根据正确性将展开轨迹路由至两条互补的监督路径：对于错误轨迹，采用教师困惑度加权的 KL 蒸馏，优先利用可靠的纠正性指导；对于正确轨迹，采用学生困惑度加权的 MLE，以强化能力边界上尚未充分探索的推理路径。统一的组级归一化机制可针对不同难度的提示，自适应地校准权重分布。在六个数学推理基准上的大量实验表明，相较于有竞争力的基线，SCOPE 在 Avg@32 和 Pass@32 上分别取得了 11.42% 和 7.30% 的平均相对提升。在三个代码生成基准上的补充结果进一步证明了其有效性，以及在多种任务上的广泛适用性。

局限性

我们承认当前研究主要存在两点局限。**第一，SCOPE 依赖可自动验证的结果信号，将轨迹划分为正确分支和错误分支**。因此，我们的实验在能够可靠检查正确性的领域中进行，包括数学推理和代码生成。若将 SCOPE 应用于反馈具有主观性、不完整性或受偏好驱动的任务，例如开放式对话或创意写作，则可能需要额外的奖励模型或更复杂的验证机制。**第二，我们的实证评估仍受到计算资源的限制**。尽管我们在多个基准和教师–学生配置上评估了 SCOPE，但在更大的基础模型、MoE 架构以及更多样的可验证领域上开展进一步实验，仍是未来的重要研究方向。

伦理考量

我们认识到大语言模型研究所伴随的伦理责任。我们的实验使用公开可用的数据集和基准，不涉及隐私、敏感信息或个人身份信息。所有数据集、基准和预训练模型均依照其原始许可证与使用条款使用，我们发布的资源也将遵守相应的许可要求。我们报告主要训练配置、评估设置和实现细节，以支持透明性与可复现性。尽管本方法旨在增强模型的推理能力，但其输出在某些情况下仍可能不可靠，不应作为高风险决策的唯一依据。所发布资源仅供研究使用，我们鼓励负责任地使用这些资源。

参考文献

Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos Garea, Matthieu Geist, and Olivier Bachem. 语言模型的在策略蒸馏：从自生成错误中学习. In *第十二届国际学习表征会议*, 2024.

Mirza Farhan Bin Tarek and Rahmatollah Beheshti. 使用可验证复合奖励缓解奖励欺骗. In *第 16 届 ACM 生物信息学、计算生物学与健康信息学国际会议论文集*, pp. 1–6, 2025.

Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde De Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. 评估在代码上训练的大型语言模型. *arXiv 预印本 arXiv:2107.03374*, 2021.

Ganqu Cui, Lifan Yuan, Zefan Wang, Hanbin Wang, Yuchen Zhang, Jiacheng Chen, Wendi Li, Bingxiang He, Yuchen Fan, Tianyu Yu, et al. 通过隐式奖励进行过程强化. *arXiv 预印本 arXiv:2502.01456*, 2025.

Guanting Dong, Licheng Bao, Zhongyuan Wang, Kangzhi Zhao, Xiaoxi Li, Jiajie Jin, Jinghan Yang, Hangyu Mao, Fuzheng Zhang, Kun Gai, et al. 智能体熵平衡策略优化. *arXiv 预印本 arXiv:2510.14545*, 2025.

Xiaoliang Fu, Jiaye Lin, Yangyi Fang, Binbin Zheng, Chaowen Hu, Zekai Shao, Cong Qin, Lu Pan, Ke Zeng, and Xunliang Cai. Maspo：统一梯度利用、概率质量与信号可靠性，实现鲁棒且样本高效的大型语言模型推理. *arXiv 预印本 arXiv:2602.17550*, 2026a.

Yuqian Fu, Haohuan Huang, Kaiwen Jiang, Yuanheng Zhu, and Dongbin Zhao. 重新审视在策略蒸馏：经验性失败模式与简单修复方法. *arXiv 预印本 arXiv:2603.25562*, 2026b.

Yuxian Gu, Li Dong, Furu Wei, and Minlie Huang. Minillm：大型语言模型的知识蒸馏. *arXiv 预印本 arXiv:2306.08543*, 2023.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, Runxin Xu, Ruoyu Zhang, Shirong Ma, Xiao Bi, et al. Deepseek-r1 通过强化学习激励大型语言模型推理. *Nature*, 645(8081):633–638, 2025.

Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Thai, Junhao Shen, Jinyi Hu, Xu Han, Yujie Huang, Yuxiang Zhang, et al. Olympiadbench：以奥林匹克竞赛级双语多模态科学问题推动 agi 的高难度基准. In *计算语言学协会第 62 届年会论文集（第 1 卷：长论文）*, pp. 3828–3850, 2024.

Jujie He, Jiacai Liu, Chris Yuhao Liu, Rui Yan, Chaojie Wang, Peng Cheng, Xiaoyu Zhang, Fuxiang Zhang, Jiacheng Xu, Wei Shen, et al. Skywork open reasoner 1 技术报告. *arXiv 预印本 arXiv:2505.22312*, 2025a.

Zhiwei He, Tian Liang, Jiahao Xu, Qiuzhi Liu, Xingyu Chen, Yue Wang, Linfeng Song, Dian Yu, Zhenwen Liang, Wenxuan Wang, et al. Deepmath-103k：用于推进推理的大规模、高难度、去污染且可验证的数学数据集. *arXiv 预印本 arXiv:2504.11456*, 2025b.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. 使用 math 数据集衡量数学问题求解能力. *arXiv 预印本 arXiv:2103.03874*, 2021.

Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 神经网络中的知识蒸馏. *arXiv 预印本 arXiv:1503.02531*, 2015.

Cheng-Yu Hsieh, Chun-Liang Li, Chih-Kuan Yeh, Hootan Nakhost, Yasuhisa Fujii, Alex Ratner, Ranjay Krishna, Chen-Yu Lee, and Tomas Pfister. 逐步蒸馏！以更少训练数据和更小模型超越更大的语言模型. In *计算语言学协会研究发现：ACL 2023*, pp. 8003–8017, 2023.

Jonas Hübotter, Frederike Lübeck, Lejs Behric, Anton Baumann, Marco Bagatella, Daniel Marta, Ido Hakimi, Idan Shenfeld, Thomas Kleine Buening, Carlos Guestrin, et al. 通过自蒸馏进行强化学习. *arXiv 预印本 arXiv:2601.20802*, 2026.

Naman Jain, Alex Gu, Wen-Ding Li, Fanjia Yan, Tianjun Zhang, Sida Wang, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. Livecodebench：对代码大型语言模型进行全面且无污染的评估. In *国际学习表征会议*, volume 2025, pp. 58791–58831, 2025.

Seongryong Jung, Suwan Yoon, DongGeon Kim, and Hwanhee Lee. Todi：通过细粒度散度控制进行逐词元蒸馏. In *2025 年自然语言处理经验方法会议论文集*, pp. 8089–8102, 2025.

Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, et al. 语言模型（大多）知道自己知道什么. *arXiv 预印本 arXiv:2207.05221*, 2022.

Yoon Kim and Alexander M Rush. 序列级知识蒸馏. In *2016 年自然语言处理经验方法会议论文集*, pp. 1317–1327, 2016.

Jongwoo Ko, Sungnyun Kim, Tianyi Chen, and Se-Young Yun. Distillm：迈向大型语言模型的精简蒸馏. *arXiv 预印本 arXiv:2402.03898*, 2024.

Jongwoo Ko, Sara Abdali, Young Jin Kim, Tianyi Chen, and Pashmina Cameron. 通过宽松在策略蒸馏高效扩展推理能力. *arXiv 预印本 arXiv:2603.11137*, 2026.

Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ramasesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, et al. 使用语言模型求解定量推理问题. *神经信息处理系统进展*, 35:3843–3857, 2022.

Long Li, Zhijian Zhou, Jiaran Hao, Jason Klein Liu, Yanting Miao, Wei Pang, Xiaoyu Tan, Wei Chu, Zhe Wang, Shirui Pan, et al. 散度的选择：缓解可验证奖励强化学习中多样性坍塌的一个被忽视的关键. *arXiv 预印本 arXiv:2509.07430*, 2025.

Rongao Li, Jie Fu, Bo-Wen Zhang, Tao Huang, Zhihong Sun, Chen Lyu, Guang Liu, Zhi Jin, and Ge Li. Taco：算法代码生成主题数据集. *arXiv 预印本 arXiv:2312.14852*, 2023.

Xiao Liang, Zhongzhi Li, Yeyun Gong, Yelong Shen, Ying Nian Wu, Zhijiang Guo, and Weizhu Chen. 超越 pass@1：通过变分问题合成自博弈维持 rlvr. *arXiv 预印本 arXiv:2508.14029*, 2025.

Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. 让我们逐步验证. In *第十二届国际学习表征会议*, 2023.

Kevin Lu and Thinking Machines Lab. 在策略蒸馏. *Thinking Machines Lab：联结主义*, 2025. doi: 10.64434/tml.20251026. https://thinkingmachines.ai/blog/on-policy-distillation.

MAA. 美国数学竞赛（amc）, 2023. 访问时间：2023.

MAA. 美国数学邀请赛（aime）, 2024. 访问时间：2024.

MAA. 美国数学邀请赛（aime）, 2025. 访问时间：2025.

Yingqian Min, Zhipeng Chen, Jinhao Jiang, Jie Chen, Jia Deng, Yiwen Hu, Yiru Tang, Jiapeng Wang, Xiaoxue Cheng, Huatong Song, et al. 模仿、探索与自我提升：慢思考推理系统复现报告. *arXiv 预印本 arXiv:2412.09413*, 2024.

Jiangweizhi Peng, Yuanxin Liu, Ruida Zhou, Charles Fleming, Zhaoran Wang, Alfredo Garcia, and Mingyi Hong. Hiper：面向大型语言模型智能体且具有显式信用分配的分层强化学习. *arXiv 预印本 arXiv:2602.16165*, 2026.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath：推动开放语言模型数学推理的极限. *arXiv 预印本 arXiv:2402.03300*, 2024.

Quan Wei, Siliang Zeng, Chenliang Li, William Brown, Oana Frunza, Wei Deng, Anderson Schneider, Yuriy Nevmyvaka, Yang Katie Zhao, Alfredo Garcia, et al. 通过轮次级奖励设计强化大型语言模型智能体的多轮推理. *arXiv 预印本 arXiv:2505.11821*, 2025.

Miao Xiong, Zhiyuan Hu, Xinyang Lu, Yifei Li, Jie Fu, Junxian He, and Bryan Hooi. 大型语言模型能表达不确定性吗？对其置信度引导方法的实证评估. In *国际学习表征会议*, volume 2024, pp. 23650–23678, 2024.

Hongling Xu, Qi Zhu, Heyuan Deng, Jinpeng Li, Lu Hou, Yasheng Wang, Lifeng Shang, Ruifeng Xu, and Fei Mi. Kdrl：通过统一知识蒸馏与强化学习对推理型大型语言模型进行后训练. *arXiv 预印本 arXiv:2506.02208*, 2025.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 技术报告. *arXiv 预印本 arXiv:2505.09388*, 2025.

Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. Dapo：大规模开源大型语言模型强化学习系统. *arXiv 预印本 arXiv:2503.14476*, 2025.

Xiaoyang Yuan, Yujuan Ding, Yi Bin, Wenqi Shao, Jinyu Cai, Jingkuan Song, Yang Yang, and Heng Tao Shen. 不止一个教师：面向多样化探索的自适应多引导策略优化. *arXiv 预印本 arXiv:2510.02227*, 2025.

Zhaoyang Zhang, Shuli Jiang, Yantao Shen, Yuting Zhang, Dhananjay Ram, Shuo Yang, Zhuowen Tu, Wei Xia, and Stefano Soatto. 面向大型语言模型推理的强化感知知识蒸馏. *arXiv 预印本 arXiv:2602.22495*, 2026.

Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. 自蒸馏推理器：大型语言模型的在策略自蒸馏. *arXiv 预印本 arXiv:2601.18734*, 2026.

Xinyu Zhu, Mengzhou Xia, Zhepei Wei, Wei-Lin Chen, Danqi Chen, and Yu Meng. 负强化在大型语言模型推理中的惊人有效性. *arXiv 预印本 arXiv:2506.01347*, 2025.

A 理论动机与推导

本节给出 SCOPE 的理论动机与推导。我们分析在有缺陷的前缀上进行均匀蒸馏为何可能放大教师信号中的噪声，解释学生引导的加权为何有助于保留低概率但有效的推理路径，并说明组级归一化如何稳定自适应更新。

A.1 有缺陷前缀上的困惑度感知过滤

我们首先分析均匀蒸馏为何会对错误轨迹产生不利影响。在策略蒸馏过程中，教师信号是在行为策略 π_{old} 所采样的轨迹上评估的，而非在完整教师分布的显式期望下评估。依照第 3 节中的代理目标形式，停止梯度的词元级对数比率充当类优势信号：

$$\mathcal{L}_{OPD}(\theta) = \mathbb{E}_{y\sim\pi_{old}}\left[\sum_{t=1}^{|y|}\rho_t(\theta)\Big(\log\pi_{\bar{\theta}}(a_t \mid x, a_{<t}) - \log\pi_T(a_t \mid x, a_{<t})\Big)\right], \tag{7}$$

其中，$\rho_t(\theta) = \pi_\theta(a_t \mid x, a_{<t})/\pi_{old}(a_t \mid x, a_{<t})$，$\bar{\theta}$ 表示从计算图中分离的参数。在行为策略附近（即 $\theta \approx \theta_{old}$）计算梯度，可得

$$\nabla_\theta\mathcal{L}_{OPD}(\theta) \approx \mathbb{E}_{y\sim\pi_{old}}\left[\sum_{t=1}^{|y|}\nabla_\theta\log\pi_\theta(a_t \mid x, a_{<t})\cdot\Big(\log\pi_{\bar{\theta}}(a_t \mid x, a_{<t}) - \log\pi_T(a_t \mid x, a_{<t})\Big)\right]. \tag{8}$$

令 $A_t = \log\pi_{\bar{\theta}}(a_t \mid x, a_{<t}) - \log\pi_T(a_t \mid x, a_{<t})$ 表示停止梯度的蒸馏信号。对于单条采样轨迹，相应的随机梯度估计量为

$$g_{OPD}(x, y) = \sum_{t=1}^{|y|}\nabla_\theta\log\pi_\theta(a_t \mid x, a_{<t})\cdot A_t. \tag{9}$$

当前缀 $a_{<t}$ 构成有缺陷的推理上下文时，教师对后续内容的判断可能变得不那么可靠。教师可能为采样词元分配较低的概率，或产生信息量更少的分布，从而增大 $-\log\pi_T(a_t \mid x, a_{<t})$ (Xiong et al., 2024)。因此，A_t 可能受低置信度评估主导，而非反映有意义的纠正方向。

为说明这一现象如何影响优化，我们考虑单轨迹梯度估计量的范数平方。根据 Cauchy 不等式，

$$\|g_{OPD}(x, y)\|^2 = \left\|\sum_{t=1}^{|y|}\nabla_\theta\log\pi_\theta(a_t \mid x, a_{<t})\cdot A_t\right\|^2 \le |y|\sum_{t=1}^{|y|}\|\nabla_\theta\log\pi_\theta(a_t \mid x, a_{<t})\|^2\cdot A_t^2. \tag{10}$$

若得分函数满足如下有界条件：$\|\nabla_\theta\log\pi_\theta(a_t \mid x, a_{<t})\| \le G$，则

$$\mathbb{E}\left[\|g_{OPD}(x, y)\|^2\right] \le |y|G^2\sum_{t=1}^{|y|}\mathbb{E}\left[A_t^2\right]. \tag{11}$$

该界表明，随机更新的二阶矩由停止梯度的蒸馏信号幅度所控制。因此，教师在有缺陷前缀上的低似然会增大更新尺度，并引入带噪梯度。

轨迹级教师困惑度概括了这种低置信度情形：

$$\mathrm{PPL}_T(y \mid x) = \exp\left(-\frac{1}{|y|}\log\pi_T(y \mid x)\right), \tag{12}$$

其中，$\log\pi_T(y \mid x) = \sum_{t=1}^{|y|}\log\pi_T(a_t \mid x, a_{<t})$. 较高的 $\mathrm{PPL}_T(y \mid x)$ 表明教师为采样轨迹分配的平均似然较低。对于错误轨迹，这通常意味着教师以退化的前缀为条件，从而使其词元级指导的可靠性降低。

基于这一解释，SCOPE 会降低教师困惑度较高的错误轨迹的权重：

$$w_i^{tea} = \frac{\mathrm{PPL}_T(y_i \mid x)^{-1/\tau}}{\sum_{j\in\Omega_w^x}\mathrm{PPL}_T(y_j \mid x)^{-1/\tau}}. \tag{13}$$

因此，教师似然较高的错误轨迹会得到强调，而更可能包含前缀诱发教师噪声的高困惑度轨迹则会受到抑制。这解释了教师引导的加权如何通过降低潜在带噪教师信号的影响来提高纠正效率。

A.2 有效轨迹的探索

接下来，我们分析学生引导的加权为何有助于缓解由均匀强化成功轨迹所引发的 Pass@k 悖论。对于正确轨迹 Ω_c^x，标准 MLE 会均匀强化所有成功样本：

$$\nabla_\theta \mathcal{L}_{MLE} \propto -\sum_{i\in\Omega_c^x} \nabla_\theta \log \pi_\theta(y_i \mid x). \tag{14}$$

然而，在策略采样下，正确轨迹并非得到同等程度的表示。占主导地位的推理路径被更频繁地采样，而罕见但有效的路径出现概率要低得多。因此，均匀强化可能会放大主导模式，并削弱低概率有效路径的贡献。

SCOPE 为学生困惑度更高的正确轨迹分配更大的权重，以抵消这一影响：

$$w_i^{stu} = \frac{\mathrm{PPL}_S(y_i \mid x)^{1/\tau}}{\sum_{j\in\Omega_c^x} \mathrm{PPL}_S(y_j \mid x)^{1/\tau}}. \tag{15}$$

忽略组内归一化常数并只关注相对权重时，这一机制的作用类似于逆概率形式的校正：

$$w_i^{stu} \propto \exp\left(-\frac{1}{\tau|y_i|}\log \pi_S(y_i \mid x)\right) = \pi_S(y_i \mid x)^{-\frac{1}{\tau|y_i|}}. \tag{16}$$

实现中保留了长度归一化，以免系统性地偏向较短或较长的轨迹。

在总体层面，仅为使符号表达更清晰而省略长度归一化时，加权梯度可写为

$$\mathbb{E}_{y\sim\pi_S}\left[w^{stu}(y)\nabla_\theta \log \pi_\theta(y \mid x)\right] \propto \sum_{y\in\Omega_c^x} \pi_S(y \mid x)^{1-\frac{1}{\tau|y|}} \cdot \nabla_\theta \log \pi_\theta(y \mid x). \tag{17}$$

该加权通过将 $\pi_S(y \mid x)$ 的指数从 1 降至 $1-\frac{1}{\tau|y|}$，部分抵消了在策略轨迹的采样频率偏差。较小的 τ 会增强这种补偿，而较大的 τ 则使加权更接近均匀情形。尽管无法保证罕见路径一定得到保留，但该加权降低了高频推理模式相对于低概率有效轨迹的支配程度。这解释了 SCOPE 如何在利用成功在策略样本的同时保留推理多样性。

A.3 组级归一化与稳定性

最后，我们分析组级归一化的稳定作用。由于难度、长度和推理结构各异，不同提示可能呈现不同的困惑度尺度。因此，直接使用基于原始困惑度的权重，可能会使更新尺度对特定提示的统计特征敏感。

SCOPE 在每个轨迹组内应用局部 softmax 归一化，以避免这一问题：

$$w_i = \frac{\exp(S_i/\tau)}{\sum_{j\in\Omega}\exp(S_j/\tau)}, \tag{18}$$

其中，S_i 表示路径特定的得分。对于正确轨迹，S_i 对应学生困惑度得分；对于错误轨迹，它对应教师困惑度的倒数得分。该归一化保证

$$\sum_{i\in\Omega} w_i = 1, \qquad 0 < w_i < 1. \tag{19}$$

对于给定提示 x，SCOPE 的梯度可写为

$$\nabla_\theta \mathcal{J}_{SCOPE}(x) = \sum_{i\in\Omega_c^x} w_i^{stu}\nabla_\theta \mathcal{L}_{MLE}(x, y_i) + \sum_{i\in\Omega_w^x} w_i^{tea}\nabla_\theta \mathcal{L}_{OPD}(x, y_i). \tag{20}$$

根据三角不等式，

$$\|\nabla_\theta \mathcal{J}_{SCOPE}(x)\| \le \sum_{i\in\Omega_c^x} w_i^{stu}\,\|\nabla_\theta \mathcal{L}_{MLE}(x, y_i)\| + \sum_{i\in\Omega_w^x} w_i^{tea}\,\|\nabla_\theta \mathcal{L}_{OPD}(x, y_i)\|\,. \tag{21}$$

由于权重在各组内归一化，每个分支都构成轨迹级梯度的凸组合，而非依据原始困惑度值进行无界缩放。具体而言，

$$\left\|\sum_{i\in\Omega} w_i g_i\right\| \le \sum_{i\in\Omega} w_i \|g_i\| \le \max_{i\in\Omega}\|g_i\|\,. \tag{22}$$

因此，组级归一化在保留预期自适应加权效果的同时控制了更新尺度。它不会使估计量无偏；相反，它引入了一种信号校准偏差，以强调有缺陷轨迹上的可靠教师纠正信号，以及正确轨迹上尚未充分探索的有效路径。

表 3: GRPO、OPD 和 SCOPE 的训练配置

参数	GRPO	OPD	SCOPE
优化参数			
学习率	5×10^{-5}	5×10^{-5}	5×10^{-5}
学习率调度器	常数	常数	常数
权重衰减	0.01	0.01	0.01
训练批大小（提示数）	256	256	256
小批量大小（提示数）	256	256	256
强化学习与生成参数			
最大提示长度	4096	4096	4096
最大补全长度	12288	12288	12288
生成数量（G）	8	1	8
温度	0.6	0.6	0.6
KL 系数（β）	0.0001	–	–
裁剪比例（ϵ）	0.2	–	–
每批次更新轮数	1	1	1

表 4: 所有模型的评估参数。

参数	取值
最大词元数	32768
温度	0.6
Top-p	0.95
Top-k	20
重复惩罚（Qwen3-1.7B）	1.08
重复惩罚（Distill-1.5B）	1.0
每个提示的样本数	32

B 实验细节

B.1 实现设置

训练基础设施。 所有实验均在高性能分布式集群上进行，共使用 20 块 NVIDIA A100（80GB）GPU。具体而言，其中 16 块 GPU（分布在两个节点上）用于训练学生模型，其余 4 块 GPU（位于单个节点上）专门用于部署教师模型。

超参数配置。 本研究的详细实验设置分为两部分。表 3 列出了 GRPO、OPD 和 SCOPE 的具体训练配置，包括优化和强化学习超参数。在评估阶段，我们对所有模型采用一致的生成参数，详见表 4。对于 Qwen3-1.7B-Base，由于评估期间观察到严重的重复问题，我们提高了重复惩罚以缓解该问题。

B.2 评估基准

数学推理实验。 为全面评估数学推理能力，我们在一系列广泛的基准上评估本方法，这些基准涵盖不同的问题来源、难度等级和推理模式。它们包括从标准高中竞赛题到具有挑战性的奥林匹克竞赛风格任务，详细特征见表 5。

代码生成实验。 在代码生成实验中，我们使用 TACO 数据集 (Li et al., 2023) 作为主要训练语料。该数据集包含来自 Codeforces、AtCoder、Aizu Online Judge 和 GeeksforGeeks 等不同竞赛编程平台的 25,202 道编程题。评估时，我们采用 LiveCodeBench（时间范围为 2024.08 至 2025.02）和 HumanEval 基准。此外，我们从 TACO 数据集中抽取 500 道代码竞赛题（Codeforces）作为评估集。为防止数据泄漏，我们明确地将这些抽样问题从训练语料中排除。数据集的详细说明见表 5。

表 5: 评估基准及其关键特征概览，涵盖数学推理和代码生成任务。

基准	评估重点与特征
AIME 2024	在严格的答案格式约束下评估精确的算术与代数推理，解答通常以整数形式给出。
AIME 2025	作为留出基准，用于评估模型能否处理未见过且具有挑战性的数学推理模式。
AMC 2023	包含代数、几何和组合数学方面的基础竞赛风格题目，用于衡量核心数学问题求解能力。
MATH-500	使用覆盖多个数学领域的 MATH 基准代表性子集，要求具备符号运算、公式理解和稳健的答案解析能力。
Minerva	由面向 STEM 的数学问题构成，强调技术符号、定量推理和多步解答构造。
OlympiadBench	收集高难度奥林匹克竞赛风格问题，侧重严谨的逻辑推理、高级数学概括以及复杂问题求解能力。
HumanEval	包含 164 道人工编写的 Python 编程题，并基于单元测试进行评估，要求生成语法正确的代码，且在隐藏测试断言下功能正确。
Codeforces	来源于竞赛编程平台，共有 500 道题；其测试覆盖各不相同（每题包含 1–343 组输入/输出对），要求具备稳健的算法推理与边界情况处理能力。
LiveCodeBench	从近期竞赛编程比赛中整理而来，包含 279 道采用一致多用例评估的问题，强调解答在多样输入条件下的可靠性。

表 6: 错误学生轨迹各困惑度桶中的教师 PPL 与 NLL 统计量。

桶	PPL 均值	NLL 均值
Q1（最低 PPL）	1.361	0.305
Q2	1.565	0.448
Q3	1.710	0.536
Q4（最高 PPL）	2.383	0.688
总体	1.755	0.494

C 补充实验分析

C.1 初步实验

我们从 DeepMath 数据集中抽取 2,000 道问题，并使用学生模型（DeepSeek-R1-Distill-Qwen-1.5B）为每道问题生成 4 条推理轨迹，其中温度 $\tau = 0.6$、top-$k = 20$、top-$p = 0.95$，最大响应长度为 32,768 个词元。

对于每条错误轨迹，我们仅在响应词元（不包括提示）上计算其在教师模型（SkyWork-OR1-7B）下的困惑度得分，定义如下：

$$PPL(y_w \mid x) = \exp(-\frac{1}{|y_w|}\sum_{t=1}^{|y_w|}\log P_T(y_t \mid x)) \tag{23}$$

其中，y_w 表示错误样本。根据其 PPL 得分，采用四分位数划分将这些样本分层为四个大小相等的桶（Q1–Q4）。表 6 报告了每个桶的 PPL 和负对数似然（NLL）统计量。

在前缀截断实验中，每条错误轨迹均在最接近目标截断比例 $r \in \{0.2, 0.4, 0.6, 0.8\}$ 的换行边界处截断，从而得到有缺陷的前缀 y_{prefix}。随后，以温度 $\tau = 0.6$ 调用补全 API，提示教师从 y_{prefix} 继续完成生成。每个前缀补全 $n = 4$ 次，恢复率计算为这些补全结果的平均准确率。表 7 给出了所有截断比例和 PPL 桶下的完整错误恢复率。

C.2 权重温度的影响

为考察权重分布的尖锐程度如何影响优化，我们将温度参数 τ 分别设为 0.5、1.0 和 2.0。图 6 展示了 τ 在 DPAW 组内 softmax 归一化中的影响（式 4 和式 5）。我们采用 $\tau = 1.0$ 作为默认设置。较小的温度会使权重分布过于尖锐，导致模型集中关注困惑度取值极端的轨迹。这种激进的加权可能会放大离群噪声，而非提取可靠的纠正信号，从而使训练不稳定。相比之下，较大的温度会使分布变得平坦，并使 DPAW 退化至接近标准 OPD 所使用的均匀加权。如第 2 节所述，均匀加权缺乏信号质量感知：它既不能过滤失败轨迹上带噪的教师指导，也无法充分强调成功轨迹上尚未充分探索的有效路径。这可能进一步引发 Pass@k 悖论和多样性坍塌。总体而言，$\tau = 1.0$ 能够对信号质量的方差进行均衡校准，在有效过滤错误路径噪声的同时，保留正确路径的推理多样性。

表 7: 不同截断比例与 PPL 桶下的教师错误恢复率（%）。每个单元格报告每个样本 $n = 4$ 次补全的平均准确率。Q1–Q4 差距（最右列）量化了同一截断水平内由 PPL 分层产生的差异。

截断比例	Q1	Q2	Q3	Q4	Q1–Q4 差距
0.2	64.9	59.7	54.0	45.4	+19.4
0.4	55.8	53.2	50.1	40.2	+15.6
0.6	44.8	43.1	41.0	34.5	+10.3
0.8	35.8	35.3	32.6	28.6	+7.2

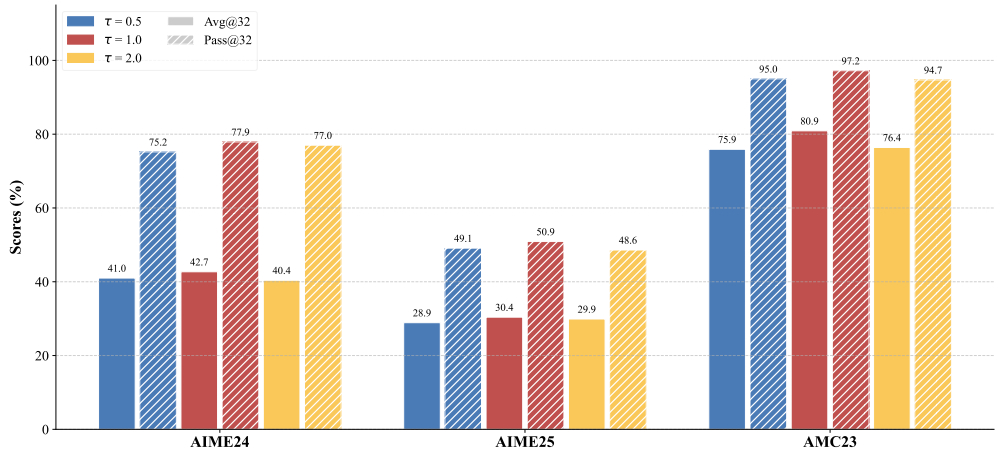


图 6: 温度超参数 τ 对模型在 AIME24、AIME25 和 AMC23 上性能的影响。结果表明，相较于 $\tau = 0.5$ 和 $\tau = 2.0$，默认配置 $\tau = 1.0$ 在所有基准上均能稳定取得最佳性能。

C.3 计算成本

如表 8 所示，我们将 SCOPE 与两个主要基线 GRPO 和 OPD 的单步实际耗时进行比较，以刻画本方法引入的额外开销。所有实验均采用相同配置，计时统计量收集自稳定训练阶段。

尽管展开轨迹的生成时间与 GRPO 相当，但本方法会产生额外的时间开销，主要来自对教师模型的查询。需要指出的是，我们使用了一种朴素的同步训练架构，其中展开轨迹生成与教师对数概率获取在时间上不重叠。通过实现异步策略，预计训练效率可与 GRPO 相当。此外，权重计算本身引入的计算开销很小。

C.4 案例研究

我们展示最高 PPL 桶中具有代表性的错误学生轨迹，以说明高困惑度错误的定性特征。表 9–12 中的案例展示了高困惑度（PPL ≥ 1.80）错误中的“缺陷轨迹陷阱”，既包括结构性坍塌（例如案例 1 中的数值溢出、案例 2 中的无限循环），也包括逻辑幻觉（例如案例 3 中的错误前提、案例 4 中的自相矛盾）。在所有这类情况中，严重退化的推理上下文都会干扰教师模型，使其预测分布趋于平坦，并迫使其输出高熵且无信息的噪声。在这些样本上进行标准在策略蒸馏，会导致学生灾难性地模仿这种混乱。我们的双路径自适应加权（DPAW）显式地规避了这一陷阱。DPAW 按照教师困惑度的倒数缩放蒸馏权重，从而为这些有害轨迹分配接近于零的权重。该机制能够自然地滤除上下文诱发的幻觉，确保学生仅从结构连贯、能够引出精确纠正信号的前缀中学习。

表 8: 各训练方法单步实际耗时的分解（秒）。数值为稳定训练阶段的均值。GRPO 和 SCOPE 的展开轨迹数设为 8，OPD 则设为 1。

组成部分	GRPO	OPD	SCOPE（本文）
生成	264.5	164.5	247.7
旧策略对数概率	34.0	5.2	31.4
奖励计算	4.8	0.7	4.6
行动者更新	151.8	22.9	154.1
教师评分	—	31.2	200.0
总计（每步）	**459.0**	**227.5**	**641.9**

表 9: 案例 1：数值坍塌。

问题	设 $a_1, a_2, \ldots, a_{100}$ 为整数，且满足 $\frac{\sum a_i^2}{\sum a_i} = 100$. 求 a_1 的最大可能值。
标准答案	550
学生答案	100
错误类型	数值坍塌

关键摘录	$\ldots 10100m^2 + 202md + 2d^2 - 2000000m - 20000d +$
	`9999...9` *[数千个重复数字]*
	$\times 6999 \times$ `9999...9` *[持续溢出]*
	`That seems like I'm not doing this... The problem is just to be solved.`
	`...\boxed{100}`

表 10: 案例 2：无限推理循环。

问题	判断 Mandelbrot 集的周长是有限还是无限。
标准答案	无限
学生答案	有限
错误类型	重复推理循环；未能得出正确结论

关键摘录	`Okay, so I have this question... I remember that the Mandelbrot set is`
	`this intricate fractal...`
	[该段逐字重复 4 次]
	`But the question isn't about whether a point is in the set, it's about`
	`the perimeter. I know that fractals often have infinite perimeters, but`
	`I'm not entirely sure about the Mandelbrot set...`
	[循环继续，始终未得出结论]

表 11: 案例 3：错误应用定理。

问题	定义在 $[a, b]$ 上、具有有界变差和介值性质的实值函数 F 是否一定连续?
标准答案	是
学生答案	否
错误类型	错误地将 Cantor 函数用作反例

关键摘录	`...the Cantor function is constant on the middle-thirds Cantor set,`
	`so it's not continuous, but it's still of bounded variation.`
	`[...]`
	`Therefore, it's clear that such functions can be discontinuous.`
	`So, the answer is no, it's not guaranteed to be continuous.`

注	Cantor 函数不满足介值性质，因此这是一个有缺陷的反例。学生未能验证该前提。

表 12: 案例 4：积分近似中的差一算术错误。

问题	求 $K = \left\lfloor \sum_{r=1}^{80} \int_0^1 x^{\sqrt{r}-1}\, dx \right\rfloor$ 的整数值。
标准答案	16
学生答案	17
错误类型	Euler–Maclaurin 近似中的积分界错误

关键摘录	`Wait, that seems contradictory because 16 is greater than 16.888.`
	`That can't be. Wait, maybe I misapplied the bounds.`
	`[...]`
	`But in the initial manual addition, I had the sum as about 16.888,`
	`but in reality, it's about 17.28. Therefore, the answer is 17.`

注	学生曾正确计算出 $\sum \approx 16.888$，随后却通过错误的重新近似与这一结果相矛盾，最终报告 $\lfloor 17.28 \rfloor = 17$，而非 $\lfloor 16.888 \rfloor = 16$。