LongCat

# Skill0.5：面向智能体强化学习分布外泛化的技能内化与利用协同

**Jiapeng Zhu[1,2,*], Jianxiang Yu[1], Yibo Zhao[1], Chengcheng Han[2], Qi Gu[2,†], Xunliang Cai[2], Xiang Li [1,†], Weining Qian [1]**

[1]华东师范大学，[2]美团 LongCat 团队

jiapengzhu@stu.ecnu.edu.cn, xiangli@dase.ecnu.edu.cn, guqi03@meituan.com

## 摘要

为大语言模型配备显式技能，已成为使自主智能体能够解决复杂任务的一种很有前景的范式。智能体技能可自然划分为两类：用于广泛认知迁移的通用技能，以及用于动态执行的任务特定技能。然而，现有基于技能的强化学习（RL）方法通常迫使模型在两个极端之间作出僵化选择：完全外化会带来难以承受的上下文开销，而完全内化则面临过拟合与知识冲突的风险。为解决这一困境，我们提出 Skill0.5，这是一种新颖的智能体强化学习框架，通过结合通用技能内化与任务特定技能利用，显式区分不同技能的处理方式。在动态难度感知路由器的驱动下，Skill0.5 将任务分流到不同掌握层级，并采用针对性的优化策略：对困难任务，通过特权蒸馏内化通用技能以建立认知基础；对简单任务，则通过诊断性探测惩罚捷径行为并强化对特定技能的利用。在 ALFWorld 和 WebShop 上的实验表明，Skill0.5 优于基于记忆和基于技能的强化学习基线，在分布内与分布外场景中均取得性能提升。代码地址：`https://github.com/JasonZhujp/Skill0_5`。

## 1 引言

随着大语言模型（LLM）(Zeng et al., 2026; Singh et al., 2025; Team et al., 2026) 演化为自主问题求解者，人们日益将富有挑战性的智能体任务交由其完成 (Guan et al., 2026; Du et al., 2025; Ding et al., 2026)。为使智能体掌握现实任务中复杂的操作逻辑，智能体技能已成为突破性能瓶颈的一种有前景的方案 (Xu 和 Yan, 2026; Ling et al., 2026)。技能将程序性知识封装为模块化、可复用的文本指令，用以规范标准操作流程与启发式规则 (Li et al., 2026a)。在实践中，这些技能会被动态检索并注入智能体提示词，从而显式引导其完成复杂工作流 (Zhou et al., 2026b)。

尽管通过零样本提示引入技能能够立即发挥作用，但为了进一步增强智能体在复杂环境中的稳健行动能力 (Xia et al., 2026b)，近期研究已拓展到基于技能的训练方法。这些方法主要分化为两种极端范式。一种范式主张完全外化，即在训练和推理全过程中，将所有技能作为外部上下文指导保留下来 (Xia et al., 2026a; Shi et al., 2026)。另一类研究则探索完全内化，旨在将技能完整吸收到模型参数中 (Lu et al., 2026b; Wang et al., 2026b)。然而，在真实部署场景中，技能库会随着用户贡献不断动态扩展，智能体经常需要面对陌生任务及此前未见的分布外（OOD）任务特定技能 (Ma et al., 2026b)。

因此，两种范式都存在显著局限：完全外化对 LLM 的上下文学习（ICL）能力提出严峻挑战 (Liu et al., 2024; Zhou et al., 2026a)；当提示词随技能数量增加而膨胀时，过长的上下文会削弱推理和指令遵循能力，在长程任务中尤为明显 (Si et al., 2026; Hsieh et al., 2024)。另一方面，完全内化从根本上受模型容量限制 (Allen-Zhu 和 Li, 2025)，且可能引入知识冲突风险 (Xu et al., 2024; Wang et al., 2025a)。当陌生的外部技能与模型已内化的技能模式冲突时，智能体可能无法吸收和利用新指令，从而产生执行幻觉 (Liu et al., 2026b; Zhang et al., 2026a)。因此，现有基于技能的训练方法在动态真实环境中的有效性仍缺乏充分研究。

从根本上说，智能体技能可分为两类互补类别：通用技能与任务特定技能 (Xia et al., 2026a; Li et al., 2026b,c)。通用技能（例如元推理与错误恢复）与领域无关，但往往占用较长上下文 (Zhou et al., 2026a)。相对地，任务特定技能编码细粒度执行规则，会动态更新，也容易受到检索噪声影响 (Lu et al., 2026b)。然而，现有方法以相同方式处理这两类技能，从而形成关键困境：完全外化冗长的通用启发式规则会产生难以承受的上下文开销 (Wu 和 Zhang, 2026)，而完全内化易变的特定技能则会带来严重的过拟合与知识冲突风险 (Ma et al., 2026a; Alzubi et al., 2026)。为此，我们主张采用差异化处理：**内化通用技能以建立上下文高效的认知基础，同时动态利用即插即用的任务特定技能以增强适应性**，尤其面向技能增强的 OOD 场景。

* 本工作在美团实习期间完成。
† 通讯作者。

直观而言，智能体必须先掌握基础策略，才能有效运用细粒度规则。受此启发，我们提出统一的智能体强化学习框架 **Skill0.5**，根据实时任务掌握程度，对解耦后的通用技能与特定技能进行联合优化。具体而言，难度感知路由器将任务分流到三个层级并分别优化：困难任务通过特权蒸馏内化通用技能；中等任务采用标准强化学习以最大化成功率；简单任务则使用诊断性探测，确保模型忠实利用特定技能。在 ALFWorld 和 WebShop 上的评估表明，Skill0.5 相比最强的技能增强基线，在 ID 和 OOD 场景下分别提升 **+2.2%** 与 **+8.5%**。我们的贡献主要有三点：

- 我们指出智能体强化学习中有必要对技能进行差异化处理，主张内化通用技能并动态利用任务特定技能，尤其针对真实的 OOD 部署场景。
- 我们提出新颖的强化学习框架 Skill0.5，其自适应难度感知路由器会针对不同掌握层级应用相应优化目标，从而联合实现技能内化与利用。
- 我们在 ALFWorld 和 WebShop 的 ID 与 OOD 设置上进行了广泛评估，通过实验验证了基于技能功能解耦进行联合优化的有效性。

## 2 预备知识

### 2.1 任务形式化

我们考虑一个与文本环境 $\mathcal{E}$ 交互的智能体，并将该环境建模为部分可观测马尔可夫决策过程（POMDP），表示为元组 $\mathcal{M} = (\mathcal{S}_{\text{env}}, \mathcal{A}, \mathcal{O}, \mathcal{T}, \Omega, \mathcal{R}_{\text{step}}, \gamma)$。在每个观测轮次 $t$，智能体接收局部文本观测 $o_t \in \mathcal{O}$，该观测呈现环境状态 $s_t \in \mathcal{S}_{\text{env}}$ 的局部视图。随后，智能体选择自由形式的自然语言动作 $a_t \in \mathcal{A}$；该动作通过 $\mathcal{T}(s_{t+1} \mid s_t, a_t)$ 触发环境状态转移，并通过 $\Omega(o_{t+1} \mid s_{t+1}, a_t)$ 产生下一条观测。完整交互序列由幕轨迹 $\tau = (o_1, a_1, o_2, a_2, \ldots, o_T)$ 表示。

每个任务由从任务数据集 $\mathcal{D}$ 中采样的文本指令 $x$ 指定。基于 LLM 的智能体由 $\theta$ 参数化，并在交互历史、任务指令以及第 $t$ 轮注入提示词的附加上下文 $c_t$（例如技能）的条件下，生成动作 $a_t \sim \pi_\theta(\cdot \mid o_{\le t}, x, c_t)$。为简洁起见，我们将该执行历史记作 $h_t = (o_{\le t}, x_i)$。我们的目标是优化策略参数 $\theta$，使任务分布上的期望累积回报最大：

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D},\tau\sim\pi_\theta}\left[\sum_{t=1}^{T}\gamma^{t-1}\mathcal{R}_{\text{step}}(s_t, a_t)\right]$$

对于基于结果的智能体任务，该形式化可简化为稀疏的二元终止奖励 $R(\tau) \in \{0, 1\}$，相应的优化目标变为最大化期望成功率 $\max_\theta \mathbb{E}[R(\tau)]$。为提升任务成功率，程序性技能以运行时上下文 $c_t$ 的形式加入提示词；下一小节将对此进行形式化说明。

### 2.2 技能库与运行时上下文

沿用 Xia et al. (2026a) 的设定，我们假设一个层次化技能库 $\mathcal{S}$，其中包含通用技能 $\mathcal{S}_G$ 和特定技能 $\mathcal{S}_S$。$\mathcal{S}_G$ 提供普遍适用的策略性启发式规则，$\mathcal{S}_S$ 则存储与不同任务领域显式关联的细粒度执行规则。由于通用技能具有广泛适用性，在每个交互轮次 $t$ 都可以将其完整提供给智能体。对于数量众多且语义细粒度的特定技能，我们使用嵌入模型检索与任务最相关的子集。令 $e_x$ 和 $e_s$ 分别表示任务指令 $x$ 与候选技能 $s$ 的嵌入。在可用的特定技能池中，以余弦相似度衡量相关性，并通过 Top-$K$ 语义匹配检索选定的特定技能子集 $\mathcal{K}_t(x)$：

$$\mathcal{K}_t(x) = \text{TopK}_{s\in\mathcal{S}_S}\big(\cos(e_x, e_s),\ K\big) \quad (1)$$

检索得到的子集 $\mathcal{K}_t(x)$ 与通用技能 $\mathcal{S}_G$ 一起，构成辅助上下文 $c_t$ 的候选指导。不同的技能增强方法，在训练和推理阶段如何构造运行时上下文 $c_t$ 方面存在差异：

- **完全外化**（例如 SkillRL (Xia et al., 2026a)）：在训练与推理两个阶段，始终将通用技能和选中的特定技能共同纳入上下文，即 $c_t = \mathcal{S}_G \cup \mathcal{K}_t(x)$。
- **完全内化**（例如 SKILL0 (Lu et al., 2026b)）：在训练期间逐步将完整上下文 $c_t = \mathcal{S}_G \cup \mathcal{K}_t(x)$ 吸收到模型参数中，从而在部署时实现上下文为空，即 $c_t = \emptyset$。
- **混合范式**：SLIM (Shen et al., 2026) 在训练期间动态维护不断更新的活跃子集 $c_t \subset \mathcal{S}$，并在推理时使用最终活跃技能集 $c_T \subset \mathcal{S}$。对于我们的 Skill0.5，训练期间会针对不同难度的任务定制 $c_t$（详见第 3 节），而推理期间只依赖特定技能 $c_t = \mathcal{K}_t(x)$。

### 2.3 ID 与 OOD 设置

我们模拟真实的技能部署场景。完整的任务领域空间被划分为 ID 领域 $\mathcal{D}_{\text{id}}$ 与 OOD 领域 $\mathcal{D}_{\text{ood}}$，相应地，整个特定技能池也被划分为 $\mathcal{S}_S^{\text{id}}$ 和 $\mathcal{S}_S^{\text{ood}}$。ID 任务进一步分为训练集 $\mathcal{X}_{\text{train}}^{\text{id}}$ 与验证集 $\mathcal{X}_{\text{val}}^{\text{id}}$。需要注意的是，由于具备跨领域适用性，所有通用技能 $\mathcal{S}_G$ 在各阶段始终可以全局访问。

训练期间，智能体接触 ID 训练任务 $x \sim \mathcal{X}_{\text{train}}^{\text{id}}$ 及其对应的 ID 特定技能 $\mathcal{S}_S^{\text{id}}$，而 OOD 任务及其配对的特定技能 $\mathcal{S}_S^{\text{ood}}$ 则严格不可见。评估期间，我们在两种设置下测试智能体：ID 评

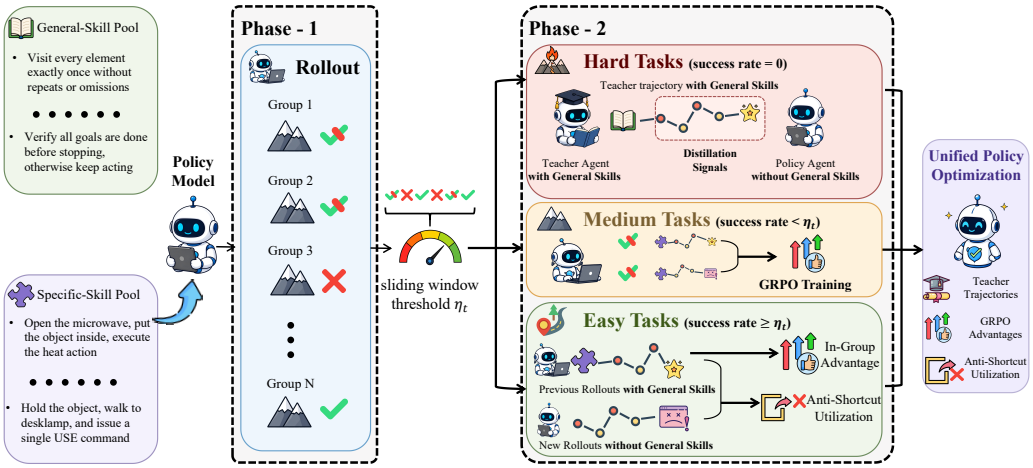



图 1: Skill0.5 框架的整体流程。技能被显式解耦为通用技能池与特定技能池。难度感知路由器将任务动态分流到三个层级并分别优化：困难任务蒸馏通用技能，中等任务采用标准 GRPO 提升成功率，简单任务使用反捷径探测以提供技能利用优势。

估从 $x \sim \mathcal{X}_{\text{val}}^{\text{id}}$ 中采样任务，并仅在 $\mathcal{S}_S^{\text{id}}$ 上检索 $\mathcal{K}_t(x)$；OOD 评估则从此前未见的 $x \sim \mathcal{X}^{\text{ood}}$ 中采样，并在同样未见过的 $\mathcal{S}_S^{\text{ood}}$ 上执行检索。

不同方法通过推理时如何暴露可访问技能来体现各自设计原则。我们的理念是在 ID 训练期间充分内化 $\mathcal{S}_G$ 的策略本质，并在评估时仅利用即插即用的特定技能 $\mathcal{K}_t(x)$，从而泛化到未见任务。

## 3 方法

实现技能内化与利用的协同需要有针对性的训练设计。在认知科学中 (Sweller, 1988)，专业能力的习得遵循循序渐进的过程：学习者必须先构建基础认知图式，而后才能高效处理特定领域的规则，以避免认知过载。类似地，智能体只有先将与环境交互所需的通用逻辑基础内化，才能有效利用特定于任务的指导。

受这一认知进程启发，我们提出 **Skill0.5**，这是一种智能体强化学习框架，可根据智能体对任务的实时掌握程度，动态解耦针对通用技能和特定技能的优化。为此，我们的框架采用精简的两阶段采样与优化范式，如图 1 所示。具体而言，**阶段一**（§3.1）执行基于经验通过率的难度感知路由器，将任务划分到三个掌握层级。随后，**阶段二**（§3.2）实施分层定制优化：困难任务需要内化通用启发式知识；中等任务以最大化通过率为先；简单任务则确保特定技能得到真正利用。通过为每个层级提供定制的优化目标，Skill0.5 促进了层次化技能的协同内化与利用。

### 3.1 阶段一：难度感知路由

我们使用任务的经验通过率衡量任务难度。在步骤 $t$，对于批次中的每个任务 $x_i$（该批次记为 $\mathcal{B}_t$），我们在标准提示下采样 $G$ 条独立轨迹 $\tau^{(1)} \sim \pi_\theta(\cdot \mid h_t, c_t^{\text{std}})$，其中 $c_t^{\text{std}} = \mathcal{K}_t(x_i)$ 确保仅使用检索到的特定技能。该推演配置与推理阶段采用完全相同的提示构造方式。随后，任务 $x_i$ 的难度通过 $p_i = \frac{1}{G}\sum_{g=1}^{G} R(\tau_i^{(1,g)})$ 进行评估，其中 $R \in \{0,1\}$ 是二元环境结果。我们严格遵循 §2.3 中定义的分布内（ID）训练设置，因此为简洁起见省略 “id” 上标。

关键在于，这些阶段一轨迹具有双重用途：既作为探测信号对任务进行动态路由，又被适时复用于支持阶段二的分层定制优化。

根据评估得到的通过率，完全失败的任务，即 $p_i = 0$，会被直接路由至困难层级。为进一步区分中等任务与简单任务，我们使用跨步骤滑动窗口均值作为动态阈值 $\eta_t$。与单个批次内有限数量的任务相比，该运行均值更加稳健。给定窗口大小 $W$ 以及批次级均值 $\bar{p}_t = \frac{1}{|\mathcal{B}_t|}\sum_{i\in\mathcal{B}_t} p_i$，阈值 $\eta_t$ 对过去窗口 $[t - \min(W,t) + 1, t]$ 内的这些均值取平均：

$$\eta_t = \frac{1}{\min(W,t)} \sum_{j=t-\min(W,t)+1}^{t} \bar{p}_j \qquad (2)$$

若任务 $x_i$ 满足 $p_i > \eta_t$，则将其视为简单任务，否则视为中等任务。我们将这一难度感知路由器 $\mathcal{M}(x_i)$ 形式化为：

$$\mathcal{M}(x_i) = \begin{cases} \text{Hard}, & \text{if } p_i = 0 \\ \text{Medium}, & \text{if } 0 < p_i \le \eta_t \\ \text{Easy}, & \text{if } p_i > \eta_t \end{cases} \qquad (3)$$

### 3.2 阶段二：分层定制优化

在阶段一所反映的实时掌握程度驱动下，智能体现在针对各层级的任务采用相应的优化目标。

#### 3.2.1 困难任务：通过特权蒸馏实现内化

当遇到困难任务时，智能体会暴露出基础推理逻辑的欠缺。为了教会智能体如何思考，我们引入特权提示，扩展运行时上下文以纳入通用启发式知识：$c_t^{\text{priv}} = \mathcal{S}_G \cup \mathcal{K}_t(x_i)$。具体而言，我们利用 $\mathcal{S}_G$ 作为特权信息，引导生成正确的推理轨迹。智能体在这一增强上下文下重新尝试每个困难任务 $G$ 次，并以教师身份执行阶段二推演：$\tau^{(2)} \sim \pi_\theta(\cdot \mid h_t, c_t^{\text{priv}})$。我们筛选这些推演中的成功轨迹，以构建黄金集合 $\mathcal{T} = \{\tau^{(2)} \mid R(\tau^{(2)}) = 1\}$。舍弃阶段一中零奖励的轨迹后，我们采用教师强制，将这一预言机行为蒸馏到学生模型中。具体而言，通过沿教师的成功推演轨迹 $\tau^{(2)} \in \mathcal{T}$ 计算学生模型的概率分布，我们迫使学生策略（仅给定 $c_t^{\text{std}}$）模仿教师（由 $c_t^{\text{priv}}$ 引导）的确切推理步骤。受 Ding (2026) 启发，该对齐过程通过词元级詹森–香农散度（JSD）进行优化：

$$\mathcal{L}_{\text{hard}} = \frac{1}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \frac{1}{|\tau|} \sum_{k=1}^{|\tau|} \text{JSD}\big(\text{sg}[\pi_\theta^{\text{t}}(k)] \,\big\|\, \pi_\theta^{\text{s}}(k)\big) \tag{4}$$

其中，$\pi_\theta^{\text{t}}(k) := \pi_\theta(\cdot \mid h_k, c_t^{\text{priv}})$，$\pi_\theta^{\text{s}}(k) := \pi_\theta(\cdot \mid h_k, c_t^{\text{std}})$。这里，$\text{sg}[\cdot]$ 表示停止梯度算子，保证学生策略主动与教师对齐。由此，智能体无需显式以 $\mathcal{S}_G$ 为条件，也能像接受其指导一样运用基础启发式知识，从而呈现出一种与推理过程兼容的自然内化过程。

#### 3.2.2 中等任务：能力强化

对于通过率低于路由阈值 $\eta_t$ 的中等任务，智能体虽已越过完全冷启动阶段，但其能力仍有较大的优化空间。我们直接复用路由阶段收集的阶段一轨迹，其中每个任务包含 $G$ 次推演。采用标准 GRPO (Shao et al., 2024) 来最大化智能体的成功率。

设轨迹 $\tau$ 在步骤 $k$ 的策略比率为 $\rho_k^{(g)} = \frac{\pi_\theta(a_k|h_k, c_t^{\text{std}})}{\pi_{\theta_{\text{old}}}(a_k|h_k, c_t^{\text{std}})}$。这些中等任务的强化学习目标 $\mathcal{L}_{\text{med}}$ 形式化为：

$$\mathcal{L}_{\text{medium}} = \frac{1}{G} \sum_{g=1}^{G} \sum_{k=1}^{|\tau^{(g)}|} \min\Big(\rho_k^{(g)} A_i^{(g)}, \; \text{clip}\big(\rho_k^{(g)}, 1-\epsilon, 1+\epsilon\big) A_i^{(g)}\Big) \tag{5}$$

其中，$\epsilon$ 是裁剪超参数。优势 $A_i^{(g)}$ 通过组内归一化计算：$A_i^{(g)} = \frac{R_i^{(g)} - \text{mean}(\mathbf{R}_i)}{\text{std}(\mathbf{R}_i)}$，其中 $\mathbf{R}_i = \{R_i^{(1)}, \ldots, R_i^{(G)}\}$ 表示 $G$ 条为任务 $x_i$ 采样的轨迹所对应的奖励。

该中等层级是优化的最佳区间 (Yu et al., 2026)。通过奖励信号驱动的试错，$\mathcal{L}_{\text{med}}$ 强化了智能体对特定技能的主动利用，提高了正确推理路径的采样效率，并最终最大化任务成功率。

#### 3.2.3 简单任务：反捷径利用

随着简单层级中的成功率持续上升，策略存在陷入捷径学习的风险 (Sun et al., 2025)。智能体并未真正利用检索到的特定技能 $\mathcal{K}_t(x_i)$，而是倾向于记忆从任务指令直接到动作的虚假映射。这种表面过拟合会严重损害真正的技能利用，并削弱分布外（OOD）泛化能力，而在 OOD 场景中，必须动态适应未见过的特定技能。

为了惩罚此类捷径行为，我们引入一种反事实诊断探针：无技能提示，其中有意消融特定技能，即 $c_t^{none} = \emptyset$。对于每个简单任务 $x_i$，我们迫使智能体在 $c_t^{\text{none}}$ 下执行阶段二推演，采样 $G$ 条轨迹，并测量组内经验通过率 $p_i^{\text{none}}$。关键在于，这些诊断轨迹仅作为隔离利用增益的反事实锚点，严格不参与策略梯度计算。

我们通过利用增益 $u_i = p_i - p_i^{\text{none}}$ 来量化智能体对特定技能的依赖程度，其中 $p_i$ 是同一任务 $x_i$ 在以 $c_t^{std}$ 为条件时的原始阶段一通过率。直观而言，该增益刻画了特定技能对任务成功的因果影响。配备必要技能的稳健智能体应当严格优于不受指导的对应智能体。当 $u_i$ 缩小或变为负值时，说明智能体存在绕过外部指导的行为。

为优化这种依赖性，我们使用滑动窗口跟踪最近 $W$ 个步骤内的平均利用增益，记为 $\bar{u}_t$。通过将 $\bar{u}_t$ 作为动态锚点，我们可以自然地为当前批次中的任务构造辅助的任务级利用优势 $A_i^u$：

$$A_i^u = \frac{u_i - \bar{u}_t}{\sigma_u} \tag{6}$$

其中，$\sigma_u$ 是 $(u_i - \bar{u}_t)$ 的批次级标准差。标准组内优势 $A_i^{(g)}$ 通过零均值归一化评估轨迹之间的相对质量，与之不同，$A_i^u$ 是一个全局任务级调制因子。它会平移该任务的整个优势分布。因此，第 $g$ 次推演（在阶段一中从 $c_t^{std}$ 下采样）的复合优势形式化为：

$$\hat{A}_i^{(g)} = \underbrace{A_i^{(g)}}_{\text{Trajectory-level quality}} + \underbrace{A_i^u}_{\text{Task-level utilization}} \tag{7}$$

如果某个任务暴露出捷径学习现象（$u_i < \bar{u}_t$），则负偏移 $A_i^u$ 会整体抑制该任务的优化梯度，从而惩罚绕过特定技能的动作分布。最后，将目标 $\mathcal{L}_{easy}$ 中的标准 $A_i^{(g)}$ 替换为复合优势 $\hat{A}_i^{(g)}$，并代入相同的 GRPO 框架进行优化。

| 方法 | ID | | | | | OOD | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | 拾取 | 冷却 | 清洁 | 平均 | 排名↓ | 查看 | 加热 | 拾取 2 | 平均 | 排名↓ |
| 基于提示的方法 | | | | | | | | | | |
| Zero-shot | 28.6 | 12.0 | 18.5 | 20.7 | 17.2 | 38.5 | 12.5 | 12.5 | 18.9 | 15.5 |
| Few-shot | 62.9 | 44.0 | 63.0 | 57.5 | 12.0 | 46.2 | 31.2 | 8.3 | 24.5 | 12.8 |
| ReAct | 71.4 | 28.0 | 33.3 | 47.1 | 13.3 | 46.2 | 18.8 | 12.5 | 22.6 | 12.8 |
| Reflexion | 85.7 | 44.0 | 44.4 | 60.9 | 10.3 | 46.2 | 31.3 | 29.2 | 34.0 | 8.7 |
| Mem0 | 54.3 | 4.0 | 18.5 | 28.7 | 17.5 | 38.5 | 18.8 | 4.2 | 17.0 | 15.7 |
| ExpeL | 80.0 | 44.0 | 66.7 | 65.5 | 9.5 | 46.2 | 18.8 | 20.8 | 18.9 | 11.2 |
| MemP | 65.7 | 12.0 | 33.3 | 40.2 | 15.3 | 46.2 | 37.5 | 12.5 | 28.3 | 11.0 |
| SimpleMem | 71.4 | 16.0 | 44.4 | 47.1 | 13.3 | 53.8 | 18.8 | 20.8 | 28.3 | 9.5 |
| 基于强化学习的方法 | | | | | | | | | | |
| RLOO | 91.4 | 80.0 | 81.5 | 85.1 | 4.3 | 61.5 | 56.3 | 20.8 | 41.5 | 5.8 |
| GRPO | 80.0 | 72.0 | 88.9 | 80.5 | 6.2 | **76.9** | 56.3 | 16.7 | 43.4 | 5.5 |
| 记忆增强的强化学习方法 | | | | | | | | | | |
| MemRL | 74.3 | 12.0 | 55.6 | 50.6 | 12.7 | 46.2 | 12.5 | 45.8 | 35.8 | 9.7 |
| EvolveR | 88.6 | 52.0 | 81.5 | 75.9 | 6.2 | 46.2 | 6.2 | **50.0** | 35.8 | 10.0 |
| Mem0+GRPO | 65.7 | 20.0 | 51.9 | 48.3 | 13.2 | 23.1 | 6.2 | 20.8 | 17.0 | 15.0 |
| SimpleMem+GRPO | 85.7 | 52.0 | 70.3 | 71.3 | 7.7 | 61.5 | 43.8 | 41.7 | 47.2 | 4.5 |
| 技能增强的强化学习方法 | | | | | | | | | | |
| SkillRL | 91.4 | 84.0 | **96.3** | 90.8 | 2.7 | 69.2 | 75.0 | 12.5 | 45.3 | 6.3 |
| SKILL0 | **94.3** | 76.0 | 81.5 | 85.1 | 3.8 | 46.2 | 50.0 | 29.2 | 39.6 | 7.5 |
| SLIM | 91.4 | 84.0 | 70.4 | 82.8 | 4.5 | 53.8 | 31.3 | 29.2 | 35.8 | 7.0 |
| **Skill0.5** | **94.3** | **88.0** | **96.3** | **93.1** | **1.3** | 69.2 | **87.5** | 33.3 | **58.5** | **2.5** |

表 1: ALFWorld 在 ID 与 OOD 任务设置下的性能比较。每列中的 最佳 结果与 次佳 结果分别以高亮标出。平均排名基于所有评测设置计算。

**总体目标。** 最终，Skill0.5 的全局优化目标由各层级损失联合聚合而成：

$$\mathcal{L} = \mathcal{L}_{hard} + \mathcal{L}_{medium} + \mathcal{L}_{easy} \tag{8}$$

对于训练批次内的任意单个任务 $x_i$，由于路由边界的存在，这些优化信号是互斥的。该动态路由机制建立了一套与智能体实时掌握程度变化同步的结构化课程。通过依据任务的实时掌握程度分配定制的学习目标，Skill0.5 在统一的强化学习框架内实现了基础推理内化与特定任务指导利用的联合优化。完整流程总结于算法 1。

## 4 实验

### 4.1 实验设置

**环境与 ID/OOD 划分。** 我们在两个具有明确领域划分的多轮交互式基准上评估所提出的框架，从而能够严格研究 OOD 泛化能力。

- **ALFWorld** (Shridhar et al., 2020) 是一个基于文本的具身环境，智能体通过自然语言动作完成家务任务。我们在其六种经典任务类型上进行评估。我们将 {Pick, Cool, Clean} 指定为 ID 领域，将 {Look, Heat, Pick2} 指定为 OOD 领域。
- **WebShop** (Yao et al., 2022a) 是一个基于网页的购物环境，智能体在其中搜索商品，并根据用户指令完成相符的购买。我们遵循附录 B 中详述的均衡方案，将商品类别划分为 ID = {Apparel, Electronics, Footwear, Other} 与 OOD = {Accessories, Beauty & Health, Home Decor} 两类领域。OOD 类别具有训练期间完全未出现的独特属性词汇和商品匹配启发式规则。

对于**智能体技能**，我们采用 Xia et al. (2026a) 提出的分层技能库作为基础技能集。该技能库分别为 ALFWorld 和 WebShop 提供 12 项和 15 项通用技能，同时每个任务领域都包含约 5 项任务特定技能。

**基线方法。** 我们将 Skill0.5 与多类方法进行比较：(1) **基于提示的方法**：零样本和少样本提示。(2) **基于提示的智能体方法或基于记忆的方法**：依赖上下文内提示进行多步推理的 ReAct (Yao et al., 2022b) 和 Reflexion (Shinn et al., 2023)，以及利用外部经验池在不更新参数的情况下指导行为的 Mem0 (Chhikara et al., 2025)、ExpeL (Zhao et al., 2024)、MemP (Fang et al., 2025) 和 SimpleMem (Liu et al., 2026a)。(3) **基于 RL 的方法**：RLOO (Ahmadian et al., 2024) 和 GRPO (Shao et al., 2024) 等基于组的 RL 算法。(4) **记忆增强 RL**：MemRL (Zhang et al., 2026c)、EvolveR (Wu et al., 2025)、Mem0+GRPO 和 SimpleMem+GRPO，这些方法将持久记忆直接整合到 RL 优化中。(5) **技能增强 RL**：

SkillRL (Xia et al., 2026a)、SKILL0 (Lu et al., 2026b) 和 SLIM (Shen et al., 2026)，它们代表了当前基于技能的智能体训练前沿。

实现细节与超参数配置见附录 D 和 F。

### 4.2 主要结果

表 1 和表 3 报告了 ALFWorld 与 WebShop 不同领域上的综合成功率，详细展示了各任务的性能以及汇总后的 ID 和 OOD 平均值。由此可得以下关键观察：

**Skill0.5 取得了最高的整体性能。**在所有设置下，Skill0.5 相较全部基线方法都展现出显著的性能优势。与最强的技能增强基线 SkillRL 相比，Skill0.5 在 ALFWorld 上的 ID 和 OOD 划分中分别实现了 **+2.3%** 和 **+13.2%** 的绝对提升，在 WebShop 对应划分中也分别稳定提升了 **+2.1%** 和 **+3.9%**。这些结果证实，我们的内化与利用联合框架既能确保 ID 性能稳步提升，又能在 OOD 场景中带来显著的泛化跃升。

**基于提示的方法构成了性能下限。**尽管借助技能或记忆进行提示（如少样本提示、ReAct）优于零样本基线，但这些方法仍显著落后于 Skill0.5，在 ALFWorld 和 WebShop 上的平均差距分别超过 45% 和 28%。这一巨大差距表明，仅依赖上下文学习不足以与外部技能形成有效协同 (Liu et al., 2026b)。

**基于记忆的方法受限于上下文噪声。**将轨迹存储整合进提示的方法对记忆质量高度敏感。例如，得益于复杂的记忆管理机制，SimpleMem+GRPO 在 ALFWorld OOD 上取得了 47.2% 的性能，而 Mem0+GRPO 则跌至 17.0%。然而，即便最强的记忆增强方法也未能超越技能增强方法。这一差异源于原始记忆检索往往会引入过于琐碎的上下文噪声，而有效的知识迁移需要高层次的程序性抽象和可复用的启发式规则 (Xia et al., 2026a)。

### 4.3 训练动态

本节研究训练动态，以阐明为何我们的方法能够持续超越现有技能增强 RL 基线。图 2 展示了 ALFWorld 训练集和验证集（ID 与 OOD）上成功率随训练步数变化的曲线。同时，图 3 跟踪了难度感知路由所分配的困难、中等和简单任务的动态占比。

**训练早期：克服零梯度困境，实现快速内化。**初始阶段，困难任务在任务分布中占据主导，造成奖励方差为零且优势消失，从而使梯度信号完全消失 (Yu et al., 2026)。我们的难度感知路由通过触发特权蒸馏作为替代梯度来源来解决这一问题，打破探索僵局并快速引导优化，使 Skill0.5 的初始提升速度显著快于基线方法。

**训练中后期：反捷径利用驱动稳健的 OOD 泛化。**随着训练推进，简单任务逐渐占据主导，进入容易产生捷径学习的阶段。得益于反捷径诊断探测，Skill0.5 在训练集和 ID 验证集上保持稳定增长，同时在 OOD 任务上取得持续且不衰减的提升。这表明，我们的方法确实学会了利用新技能，而不是通过过拟合绕开技能指导。

**基线方法的局限性。** SkillRL 表现出过拟合：尽管训练成功率快速上升，其在验证任务和 OOD 任务上的性能却在后期下降。这表明模型退化为捷径学习，即智能体以牺牲适应性为代价记忆领域特定动作。相比之下，SKILL0 依赖纯粹的内化，但在 OOD 任务上的性能始终受到抑制，这证实完全内化的策略过于僵化，难以整合新的任务–技能对。最后，由于动态退役机制过早丢弃通用技能，SLIM 出现了严重振荡。基础推理能力的丧失使困难任务上的进展停滞，而由此形成的割裂的活跃技能集也不可避免地与 OOD 任务失配。

### 4.4 消融实验

为单独考察分层定制优化各部分的贡献，我们在 ALFWorld 上评估了两个消融变体：**Internalize-Only**（保留面向困难任务的蒸馏，其余情况采用标准 GRPO）和 **Utilize-Only**（保留面向简单任务的对比利用，其余情况采用标准 GRPO）。

| Variant | ID Avg. | OOD Avg. |
|---|---|---|
| Internalize-Only | 89.6 | 52.8 |
| Utilize-Only | 85.1 | 50.9 |
| **Skill0.5** | **93.1** | **58.5** |

表 2: ALFWorld 上的消融实验。我们报告了 ID 和 OOD 任务划分上的平均成功率。

表 2 详述了实验结果，并揭示出两点关键结论：(1) **内化是获得整体能力的严格前提。***Utilize-Only* 变体在 ID 和 OOD 划分上都出现了灾难性下降。尽管自适应路由仍会根据相对性能将任务分配至简单层级，但对比利用目标已无法发挥作用：由于缺乏基本能力，无论是否提供特定技能，智能体都会失败，因而只能产生微不足道的对比优势，并严重阻滞整个训练过程。(2) **利用释放了最高水平的 OOD 适应能力。***Internalize-Only* 变体的性能出现了中等幅度的下降。尽管内化后的通用技能成功提供了稳健的推理基线（避免了彻底崩溃），但缺少对比利用损失使模型无法将其动作可靠地建立在新颖且任务特定的 OOD 指导之上，从而限制了其泛化上限。

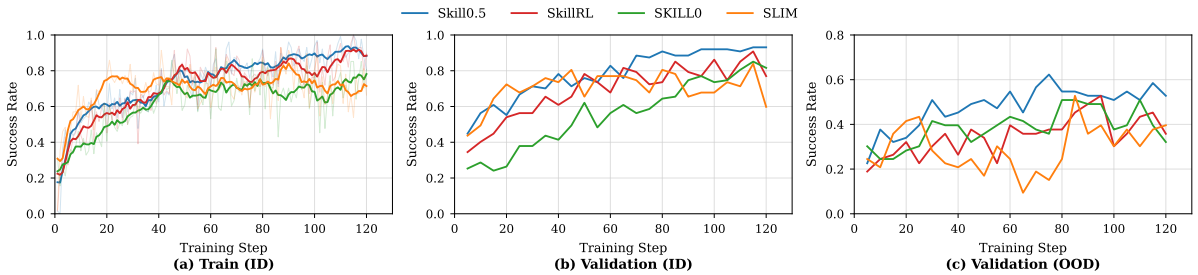



图 2: 与基于技能的 RL 基线相比，ALFWorld 训练集和验证集上的成功率。

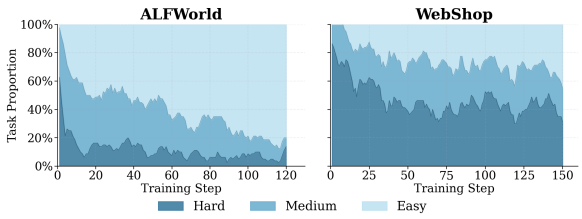



图 3: 难度感知路由所分配任务难度的动态分布。

综合来看，这些结果验证了联合设计的必要性：内化构建不可或缺的推理基础，并以此为基础，通过利用进一步最大化 OOD 适应能力。

### 4.5 案例分析

我们对 ALFWorld OOD 任务开展定性轨迹分析，以诊断各基线方法失败的原因（完整细节见附录 E）。我们识别出三种不同的失败机制：SkillRL 存在上下文干扰，即 OOD 特定技能被占主导地位的通用上下文中经 ID 训练形成的习惯性关联所覆盖；SKILL0 表现出参数化知识冲突，即尽管智能体在推理中引用了正确的技能，内化的 ID 模板仍会产生与 OOD 流程不兼容的动作；而 SLIM 则表现出行为崩溃，从成功状态逐步退化为任务幻觉，其原因在于过早退役了通用技能。在所有案例中，Skill0.5 都通过将通用推理内化到参数中，同时忠实执行新的 OOD 特定技能而取得成功，验证了我们的观点：两类技能需要采用差异化的处理方式。

## 5 结论

本文研究了 LLM 智能体面临的技能处理困境：现有强化学习方法通常不得不在完整上下文外化与无差别内化之间作出僵化选择。为解决这一问题，我们提出统一框架 Skill0.5，通过显式区分解耦后的通用技能与任务特定技能的处理方式，实现联合优化。在动态难度感知路由器的驱动下，Skill0.5 为不同任务层级组织相应的优化策略：通过特权蒸馏压缩通用技能，为困难任务建立认知基础；通过对比式优势探测强化简单任务中的特定技能利用。ALFWorld 与 WebShop 基准上的广泛实验表明，Skill0.5 显著优于基于提示、记忆和技能的基线；结果验证了本框架既能在 ID 任务上取得适度提升，又能在涉及未见 OOD 任务的实际部署场景中显著增强智能体的泛化能力。

## 局限性

尽管我们的框架是在文本交互环境上验证的，但差异化技能处理这一原则具有广泛适用性。未来，我们计划将 Skill0.5 扩展到代码生成、多模态环境、开放式网页导航等更复杂领域，以及交互时域更长、动作空间更大的设置。

## 伦理考量

本工作聚焦于提升基于 LLM 的智能体在模拟环境（ALFWorld 与 WebShop）中的推理和泛化能力。我们未发现本研究会直接带来伦理风险。所有实验均在受控的沙箱环境中进行，不涉及真实世界部署或与人类用户交互。所用基准均为公开资源，不包含个人身份信息或敏感内容。我们的方法未引入新的数据收集流程，所有训练数据均来自合成环境交互。我们承认，自主智能体能力的进步具有更广泛的社会影响；不过，本文研究的家居与电子商务模拟领域被滥用的风险很低。

## 参考文献


Arash Ahmadian, Chris Cremer, Matthias Gallé, Marzieh Fadaee, Julia Kreutzer, Olivier Pietquin, Ahmet Üstün, 和 Sara Hooker. 2024. 回归基础：重新审视用于从人类反馈中学习的 reinforce 式优化. 见第 *62* 届计算语言学协会年会论文集（第 *1* 卷：长论文）, 页 12248–12267.

Zeyuan Allen-Zhu 和 Yuanzhi Li. 2025. 语言模型物理学：第 3.3 部分，知识容量缩放定律. 见第 *13* 届国际学习表征会议论文集, ICLR '25. 完整版本见 https://ssrn.com/abstract=5250617.

Salaheddin Alzubi, Noah Provenzano, Jaydon Bingham, Weiyuan Chen, 和 Tu Vu. 2026. Evoskill：面向多智能体系统的自动化技能发现. *arXiv* 预印本 *arXiv:2603.02766*.

Shuzhen Bi, Mengsong Wu, Hao Hao, Keqian Li, Wentao Liu, Siyu Song, Hongbo Zhao, 和 Aimin Zhou. 2026. 通过大规模挖掘开源智能体仓库实现技能自动习得：多智能体程序性知识抽取框架. *arXiv* 预印本 *arXiv:2603.11808*.

Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, 和 Deshraj Yadav. 2025. Mem0：使用可扩展长期记忆构建生产就绪的 ai 智能体. *arXiv* 预印本 *arXiv:2504.19413*.

Ken Ding. 2026. Hdpo：通过特权自蒸馏实现混合蒸馏策略优化. *arXiv* 预印本 *arXiv:2603.23871*.

Shuangrui Ding, Xuanlang Dai, Long Xing, Shengyuan Ding, Ziyu Liu, Yang JingYi, Penghui Yang, Zhixiong Zhang, Xilin Wei, Xinyu Fang,, 另有 1 位作者. 2026. Wildclawbench：面向真实世界长时程智能体评估的基准. *arXiv* 预印本 *arXiv:2605.10912*.

Mingxuan Du, Benfeng Xu, Chiwei Zhu, Xiaorui Wang, 和 Zhendong Mao. 2025. Deepresearch bench：面向深度研究智能体的综合基准. *arXiv* 预印本 *arXiv:2506.11763*.

Runnan Fang, Yuan Liang, Xiaobin Wang, Jialong Wu, Shuofei Qiao, Pengjun Xie, Fei Huang, Huajun Chen, 和 Ningyu Zhang. 2025. Memp：探索智能体程序性记忆. *arXiv* 预印本 *arXiv:2508.06433*.

Lang Feng, Zhenghai Xue, Tingcong Liu, 和 Bo An. 2026a. 面向 llm 智能体训练的组中组策略优化. 神经信息处理系统进展, 38:46375–46408.

Lang Feng, Longtao Zheng, Shuo He, Fuxiang Zhang, 和 Bo An. 2026b. Dr. mas：面向多智能体 llm 系统的稳定强化学习. *arXiv* 预印本 *arXiv:2602.08847*.

Hao Guan, Lingyue Fu, Shao Zhang, Yaoming Zhu, Kangning Zhang, Lin Qiu, Xunliang Cai, Xuezhi Cao, Weiwen Liu, Weinan Zhang,, 另有 1 位作者. 2026. Swe-cycle：完整问题解决周期上的代码智能体基准评测. *arXiv* 预印本 *arXiv:2605.13139*.

Cheng-Ping Hsieh, Simeng Sun, Samuel Kriman, Shantanu Acharya, Dima Rekesh, Fei Jia, Yang Zhang, 和 Boris Ginsburg. 2024. Ruler：长上下文语言模型的真实上下文长度是多少？. *arXiv* 预印本 *arXiv:2404.06654*.

Chenliang Li, Adel Elmahdy, Alex Boyd, Zhongruo Wang, Alfredo Garcia, Parminder Bhatia, Taha Kass-Hout, Cao Xiao, 和 Mingyi Hong. 2025. St-ppo：面向多轮智能体训练的稳定化离策略近端策略优化. *arXiv* 预印本 *arXiv:2511.20718*.

Hao Li, Chunjiang Mu, Jianhao Chen, Siyue Ren, Zhiyao Cui, Yiqun Zhang, Lei Bai, 和 Shuyue Hu. 2026a. 生态系统规模的智能体技能组织、编排与基准评测. *arXiv* 预印本 *arXiv:2603.02176*.

Xiangyi Li, Wenbo Chen, Yimin Liu, Shenghan Zheng, Xiaokun Chen, Yifeng He, Yubo Li, Bingran You, Haotian Shen, Jiankai Sun,, 另有 1 位作者. 2026b. Skillsbench：评测智能体技能在多样化任务中的有效性. *arXiv* 预印本 *arXiv:2602.12670*.

Xiaoyuan Li, Moxin Li, Keqin Bao, Yubo Ma, Wenjie Wang, Dayiheng Liu, 和 Fuli Feng. 2026c. Skillgraph：通过进化技能图实现智能体技能增强强化学习. *arXiv* 预印本 *arXiv:2605.12039*.

Yu Li, Rui Miao, Zhengling Qi, 和 Tian Lan. 2026d. Arise：分层强化学习中通过内在技能进化进行智能体推理. *arXiv* 预印本 *arXiv:2603.16060*.

Qiliang Liang, Hansi Wang, Zhong Liang, 和 Yang Liu. 2026a. 从技能文本到技能结构：智能体技能的调度—结构—逻辑表示. *arXiv* 预印本 *arXiv:2604.24026*.

Zhenwen Liang, Yujun Zhou, Sidi Lu, Xiangliang Zhang, Haitao Mi, 和 Dong Yu. 2026b. 过于正确而无法学习：饱和推理数据上的强化学习. *arXiv* 预印本 *arXiv:2604.18493*.

George Ling, Shanshan Zhong, 和 Richard Huang. 2026. 智能体技能：用于扩展大语言模型功能的 claude skills 数据驱动分析. *arXiv* 预印本 *arXiv:2602.08004*.

Jiaqi Liu, Yaofeng Su, Peng Xia, Siwei Han, Zeyu Zheng, Cihang Xie, Mingyu Ding, 和 Huaxiu Yao. 2026a. Simplemem：面向 llm 智能体的高效终身记忆. *arXiv* 预印本 *arXiv:2601.02553*.

Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, 和 Percy Liang. 2024. 迷失在中间：语言模型如何利用长上下文. 计算语言学协会会刊, 12:157–173.

Yujian Liu, Jiabao Ji, Li An, Tommi Jaakkola, Yang Zhang, 和 Shiyu Chang. 2026b. 智能体技能在真实环境中的表现如何：真实场景下 llm 技能使用的基准评测. *arXiv* 预印本 *arXiv:2604.04323*.

Zhengxi Lu, Zhiyuan Yao, Zhuowen Han, Zi-Han Wang, Jinyang Wu, Qi Gu, Xunliang Cai, Weiming Lu, Jun Xiao, Yueting Zhuang,, 另有 1 位作者. 2026a. 自蒸馏智能体强化学习. *arXiv* 预印本 *arXiv:2605.15155*.

Zhengxi Lu, Zhiyuan Yao, Jinyang Wu, Chengcheng Han, Qi Gu, Xunliang Cai, Weiming Lu, Jun Xiao, Yueting Zhuang, 和 Yongliang Shen. 2026b. Skill0：用于技能内化的上下文智能体强化学习. *arXiv* 预印本 *arXiv:2604.02268*.

Yingwei Ma, Yue Liu, Xinlong Yang, Yanhao Li, Kelin Fu, Yibo Miao, Yuchong Xie, Zhexu Wang, 和 Shing-Chi Cheung. 2026a. 通过原子技能扩展编码智能体. *arXiv* 预印本 *arXiv:2604.05013*.

Ziyu Ma, Shidong Yang, Yuxiang Ji, Xucong Wang, Yong Wang, Yiming Hu, Tongwen Huang, 和 Xiangxiang Chu. 2026b. Skillclaw：借助智能体进化器让技能协同进化. *arXiv* 预印本 *arXiv:2604.08377*.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu,, 另有 1 位作者. 2024. Deepseekmath：推进开放语言模型数学推理的极限. *arXiv* 预印本 *arXiv:2402.03300*.

Junhao Shen, Teng Zhang, Xiaoyan Zhao, 和 Hong Cheng. 2026. 智能体强化学习的动态技能生命周期管理. *arXiv* 预印本 *arXiv:2605.10923*.

Yaorui Shi, Yuxin Chen, Zhengxi Lu, Yuchun Miao, Shugui Liu, Qi Gu, Xunliang Cai, Xiang Wang, 和 An Zhang. 2026. Skill1：通过强化学习统一进化技能增强智能体. *arXiv* 预印本 *arXiv:2605.06130*.

Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, 和 Shunyu Yao. 2023. Reflexion：使用言语强化学习的语言智能体. 神经信息处理系统进展, 36:8634–8652.

Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, 和 Matthew Hausknecht. 2020. Alfworld：对齐文本与具身环境以实现交互式学习. *arXiv* 预印本 *arXiv:2010.03768*.

Shuzheng Si, Haozhe Zhao, Yu Lei, Qingyi Wang, Dingwei Chen, Zhitong Wang, Zhenhailong Wang, Kangyang Luo, Zheng Wang, Gang Chen,, 另有 1 位作者. 2026. 从上下文到技能：语言模型能否熟练地从上下文中学习？. *arXiv* 预印本 *arXiv:2604.27660*.

Aaditya Singh, Adam Fry, Adam Perelman, Adam Tart, Adi Ganesh, Ahmed El-Kishky, Aidan McLaughlin, Aiden Low, AJ Ostrow, Akhila Ananthram,, 另有 1 位作者. 2025. Openai gpt-5 系统卡. *arXiv* 预印本 *arXiv:2601.03267*.

Xinyi Sun, Hongye Tan, Yaxin Guo, Pengpeng Qiang, Ru Li, 和 Hu Zhang. 2025. 通过基于大语言模型的智能数据增强缓解捷径学习. 见第 *31* 届国际计算语言学会议论文集, 页 8160–8172.

John Sweller. 1988. 问题解决过程中的认知负荷：对学习的影响. 认知科学, 12(2):257–285.

Meituan LongCat Team, Anchun Gui, Bei Li, Bingyang Tao, Bole Zhou, Borun Chen, Chao Zhang, Chen Gao, Chen Zhang, Chengcheng Han,, 另有 1 位作者. 2026. Longcat-flash-thinking-2601 技术报告. *arXiv* 预印本 *arXiv:2601.16725*.

Chenxi Wang, Zhuoyun Yu, Xin Xie, Wuguannan Yao, Runnan Fang, Shuofei Qiao, Kexin Cao, Guozhou Zheng, Xiang Qi, Peng Zhang,, 另有 1 位作者. 2026a. Skillx：为智能体自动构建技能知识库. *arXiv* 预印本 *arXiv:2604.04804*.

Fei Wang, Xingchen Wan, Ruoxi Sun, Jiefeng Chen, 和 Sercan O Arik. 2025a. Astute rag：克服大语言模型中不完美的检索增强与知识冲突. 见第 *63* 届计算语言学协会年会论文集（第 *1* 卷：长论文）, 页 30553–30571.

Hanlin Wang, Chak Tou Leong, Jiashuo Wang, Jian Wang, 和 Wenjie Li. 2025b. Spa-rl：通过逐步进展归因强化 llm 智能体. *arXiv* 预印本 *arXiv:2505.20732*.

Hao Wang, Guozhi Wang, Han Xiao, Yufeng Zhou, Yue Pan, Jichao Wang, Ke Xu, Yafei Wen, Xiaohu Ruan, Xiaoxin Chen,, 另有 1 位作者. 2026b. Skill-sd：面向多轮 llm 智能体的技能条件化自蒸馏. *arXiv* 预印本 *arXiv:2604.10674*.

Jiawei Wang, Jiacai Liu, Yuqian Fu, Yingru Li, Xintao Wang, Yuan Lin, Yu Yue, Lin Zhang, Yang Wang, 和 Ke Wang. 2025c. 利用不确定性：面向长时程 llm 智能体的熵调制策略梯度. *arXiv* 预印本 *arXiv:2509.09265*.

Zihan Wang, Chi Gui, Xing Jin, Qineng Wang, Licheng Liu, Kangrui Wang, Shiqi Chen, Linjie Li, Zhengyuan Yang, Pingyue Zhang,, 另有 1 位作者. 2026c. 理解多轮智能体强化学习中的推理崩溃. 见 *ICLR 2026* 终身智能体研讨会：学习、对齐与演化.

Zihan Wang, Kangrui Wang, Qineng Wang, Pingyue Zhang, Linjie Li, Zhengyuan Yang, Xing Jin, Kefan Yu, Minh Nhat Nguyen, Licheng Liu,, 另有 1 位作者. 2025d. Ragen：通过多轮强化学习理解 llm 智能体的自进化. *arXiv* 预印本 *arXiv:2504.20073*.

Quan Wei, Siliang Zeng, Chenliang Li, William Brown, Oana Frunza, Wei Deng, Anderson Schneider, Yuriy Nevmyvaka, Yang Katie Zhao, Alfredo Garcia,, 另有 1 位作者. 2025. 通过轮次级奖励设计强化 llm 智能体的多轮推理. *arXiv* 预印本 *arXiv:2505.11821*.

Rong Wu, Xiaoman Wang, Jianbiao Mei, Pinlong Cai, Daocheng Fu, Cheng Yang, Licheng Wen, Xuemeng Yang, Yufan Shen, Yuxin Wang,, 另有 1 位作者. 2025. Evolver：通过经验驱动的生命周期实现 llm 智能体自进化. *arXiv* 预印本 *arXiv:2510.16079*.

Yaxiong Wu 和 Yongyue Zhang. 2026. 从程序性记忆视角看智能体技能：综述. *Authorea* 预印本.

Peng Xia, Jianwen Chen, Hanyang Wang, Jiaqi Liu, Kaide Zeng, Yu Wang, Siwei Han, Yiyang Zhou, Xujiang Zhao, Haifeng Chen,, 另有 1 位作者. 2026a. Skillrl：通过递归技能增强强化学习进化智能体，2026. *URL https://arxiv. org/abs/2602.08234*.

Peng Xia, Jianwen Chen, Xinyu Yang, Haoqin Tu, Jiaqi Liu, Kaiwen Xiong, Siwei Han, Shi Qiu, Haonian Ji, Yuyin Zhou,, 另有 1 位作者. 2026b. Metaclaw：只需交谈——一个在真实环境中元学习并进化的智能体. *arXiv* 预印本 *arXiv:2603.17187*.

Renjun Xu 和 Yang Yan. 2026. 面向大语言模型的智能体技能：架构、习得、安全与未来道路. *arXiv* 预印本 *arXiv:2602.12430*.

Rongwu Xu, Zehan Qi, Zhijiang Guo, Cunxiang Wang, Hongru Wang, Yue Zhang, 和 Wei Xu. 2024. llms 的知识冲突：综述. 见 *2024* 年自然语言处理经验方法会议论文集, 页 8541–8565.

Shunyu Yao, Howard Chen, John Yang, 和 Karthik Narasimhan. 2022a. Webshop：迈向可扩展的真实世界网络交互与有据语言智能体. 神经信息处理系统进展, 35:20744–20757.

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, 和 Yuan Cao. 2022b. React：协同语言模型中的推理与行动. *arXiv* 预印本 *arXiv:2210.03629*.

Woongyeng Yeo, Yumin Choi, Taekyung Ki, 和 Sung Ju Hwang. 2026. Hint-sd：面向长时程智能体的定向后见自蒸馏. *arXiv* 预印本 *arXiv:2605.17873*.

Zhiqi Yu, Zhangquan Chen, Mengting Liu, Heye Zhang, 和 Liangqiong Qu. 2026. 揭示隐式优势对称性：grpo 为何难以进行探索与难度适应. *arXiv* 预印本 *arXiv:2602.05548*.

Aohan Zeng, Xin Lv, Zhenyu Hou, Zhengxiao Du, Qinkai Zheng, Bin Chen, Da Yin, Chendi Ge, Chenghua Huang, Chengxing Xie,, 另有 1 位作者. 2026. Glm-5：从氛围编程到智能体工程. *arXiv* 预印本 *arXiv:2602.15763*.

Genrui Zhang, Erle Zhu, Jinfeng Zhou, Caiyan Jia, 和 Hongning Wang. 2026a. Skillevolver：作为元技能的技能学习. *arXiv* 预印本 *arXiv:2605.10500*.

Hanrong Zhang, Shicheng Fan, Henry Peng Zou, Yankai Chen, Zhenting Wang, Jiayu Zhou, Chengze Li, Wei-Chieh Huang, Yifei Yao, Kening Zheng,, 另有 1 位作者. 2026b. Coevoskills：通过协同进化验证实现智能体技能自进化. *arXiv* 预印本 *arXiv:2604.01687*.

Shengtao Zhang, Jiaqian Wang, Ruiwen Zhou, Junwei Liao, Yuchen Feng, Zhuo Li, Yujie Zheng, Weinan Zhang, Ying Wen, Zhiyu Li,, 另有 1 位作者. 2026c. Memrl：通过基于情景记忆的运行时强化学习实现智能体自进化. *arXiv* 预印本 *arXiv:2601.03192*.

Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, 和 Gao Huang. 2024. Expel：llm 智能体是经验学习者. 见 *AAAI* 人工智能会议论文集, 卷 38, 页 19632–19642.

Chenyu Zhou, Huacan Chai, Wenteng Chen, Zihan Guo, Rong Shan, Yuanyi Song, Tianyi Xu, Yingxuan Yang, Aofan Yu, Weiming Zhang,, 另有 1 位作者. 2026a. llm 智能体中的外置化：记忆、技能、协议与智能体框架工程的统一综述. *arXiv* 预印本 *arXiv:2604.08224*.

Yifei Zhou, Andrea Zanette, Jiayi Pan, Sergey Levine, 和 Aviral Kumar. 2024. Archer：通过分层多轮强化学习训练语言模型智能体，2024. *URL https://arxiv. org/abs/2402.19446*.

Yingli Zhou, Wang Shu, Yaodong Su, Wenchuan Du, Yixiang Fang, 和 Xuemin Lin. 2026b. 智能体技能综合综述：分类体系、技术与应用. *arXiv* 预印本 *arXiv:2605.07358*.

# A 相关工作

## A.1 技能增强的智能体训练

早期的智能体技能研究主要将技能用作无需训练的上下文增强 (Wang et al., 2026a; Bi et al., 2026; Liang et al., 2026a; Zhang et al., 2026b)。然而，受模型容量与智能体任务复杂度持续增加的限制，近期研究已拓展到训练智能体有效运用技能；这些方法主要分为两种范式。一种范式主张完全外化 (Shi et al., 2026; Xia et al., 2026b; Li et al., 2026d,c)。例如，SkillRL (Xia et al., 2026a) 构建层次化技能库，将通用技能与任务特定技能拼接，并在训练和推理全过程中将所有指导持续保留在上下文窗口内。另一类研究探索完全内化，以消除运行时上下文开销 (Wang et al., 2026b; Lu et al., 2026a; Yeo et al., 2026)。例如，SKILL0 (Lu et al., 2026b) 利用动态课程逐步从上下文中撤去技能，直至智能体

无需任何外部输入即可运行，从而将全部指导效用完整吸收到模型参数中。

然而，技能内化与利用的联合研究仍不充分。一项密切相关的工作 SLIM (Shen et al., 2026) 会动态决定是保留技能以供主动利用，还是在其被内化后将其停用。不过，SLIM 仍以统一方式处理所有技能，其最终活跃技能集可能与配有未见特定技能的 OOD 任务不兼容。相比之下，我们显式解耦通用技能与任务特定技能，并分别针对基础内化和自适应利用进行联合优化。这样便能将基础推理逻辑参数化，并在真实 OOD 设置中主动运用量身定制的外部指导。

### A.2 智能体强化学习

强化学习，尤其是组相对策略优化（GRPO）(Shao et al., 2024)，已成为将 LLM 训练为交互式智能体的核心支柱。近期算法进展在此框架之上处理多轮环境中的关键挑战，包括时序信用分配 (Feng et al., 2026a; Wei et al., 2025; Wang et al., 2025b)、长程优化 (Zhou et al., 2024; Li et al., 2025; Wang et al., 2025c)，以及避免退化动作循环的训练稳定性 (Wang et al., 2025d; Feng et al., 2026b; Wang et al., 2026c)。尽管这些进展提供了坚实的优化基础，GRPO 的目标仍不感知难度——面对不可能完成的困难任务或过于简单的任务时，组内奖励方差都会坍缩为零，分别导致探索停滞 (Yu et al., 2026) 与饱和诱发的模式坍缩 (Liang et al., 2026b)。因此，我们动态感知任务难度，并专门为过难任务和近饱和任务分配针对性的辅助优化目标，以确保智能体强化学习训练有效进行。

## B WebShop 领域划分统计

我们使用 WebShop 中 12,087 条人工标注目标，并依据目标指令的关键词分类将其划分为七个领域。其中四个领域作为 ID 类别用于训练与 ID 评估，另外三个领域则被留作分布外 OOD 类别，仅用于 OOD 评估。为缓解杂项其他类别的严重不平衡（处理前占全部目标的 60% 以上），我们基于句子嵌入应用最远点采样（FPS）进行下采样，使其规模与其他领域相近。

各领域统计如下。**训练集（ID，3,320 个目标）**：服装 776，电子产品 938，鞋类 606，其他 1,000（通过 FPS 从约 ∼6,600 条下采样）。**ID 验证集（454 个目标）**：服装 113，电子产品 152，鞋类 89，其他 100（通过 FPS 从约 ∼940 条下采样）。**OOD 验证集（207 个目标）**：配饰 80，美妆与健康 54，家居装饰 73。

训练范围对应原始 WebShop 排序中索引 1,500 及之后的目标；验证池则合并原始测试集（0–499）与开发集（500–1,499），以保证每个领域具有足够覆盖。

## C 伪代码

**算法 1** Skill0.5：技能内化与利用协同

**Require:** Policy $\pi_\theta$, General Skills $\mathcal{S}_G$, Specific Skills $\mathcal{S}_S$

**for** each training step $t$ **do**
  Sample batch $\mathcal{B}_t \sim \mathcal{X}^{id}_{train}$. Initialize $\mathcal{L} \leftarrow 0$.
  **% 阶段 1：难度感知路由**
  **for** each $x_i \in \mathcal{B}_t$ **do**
    $c_t^{std} \leftarrow \mathcal{K}_t(x_i)$. Sample $G$ rollouts $\tau^{(1)} \sim \pi_\theta(\cdot|h_t, c_t^{std})$.
    Evaluate empirical pass rate $p_i$.
  **end for**
  Compute dynamic routing threshold $\eta_t$ (Eq. 2).
  **% 阶段 2：分层定制优化**
  **for** each $x_i \in \mathcal{B}_t$ **do**
    **if** $p_i == 0$ **then**
      % 困难层级
      Sample $\tau^{(2)}$ guided by $c_t^{priv} \leftarrow \mathcal{S}_G \cup \mathcal{K}_t(x_i)$.
      $\mathcal{L} \leftarrow \mathcal{L} + \mathcal{L}_{hard}$ via token-level JSD (Eq. 4).
    **else if** $p_i \le \eta_t$ **then**
      % 中等层级
      $\mathcal{L} \leftarrow \mathcal{L} + \mathcal{L}_{medium}$ via standard GRPO on $\tau^{(1)}$ (Eq. 5).
    **else**
      % 简单层级
      Sample diagnostic $\tau_{diag}$ using $c_t^{none} \leftarrow \emptyset$ to get $p_i^{none}$.
      $A_i^u \leftarrow$ offset derived from utilization gain $p_i - p_i^{none}$ (Eq. 6).
      $\mathcal{L} \leftarrow \mathcal{L} + \mathcal{L}_{easy}$ via GRPO using $\hat{A}_i^{(g)} = A_i^{(g)} + A_i^u$.
    **end if**
  **end for**
  Update policy parameters $\theta$ using $\nabla_\theta \mathcal{L}$.
**end for**

## D 实现细节

**推理协议。** 为确保公平比较，我们严格控制测试时的提示条件，使其符合各个基于技能的方法的设计原则与 OOD 设置约束。具体而言，**SkillRL** 同时接收通用技能，以及从技能集中检索得到的 ID 或 OOD 特定技能。由于采用完全内化，**SKILL0** 在 ID 任务上不接收技能上下文，在 OOD 任务上仅接收 OOD 特定技能。**SLIM** 在 ID 测试中接收训练结束时的活跃技能集（包含通用技能与 ID 特定技能的一个子集），而在 OOD 评估中，其 ID 特定技能会被 OOD 技能替换。由于通用技能已经内化，我们的 **Skill0.5** 在推理时仅接收 ID 或 OOD 特定技能。

**训练与实现细节。** 我们使用 Qwen2.5-7B-Instruct 作为基础模型。策略优化以 GRPO 为骨干，组大小为 $G = 8$，学习率为 $1 \times 10^{-6}$。训练在 4 张 H800 GPU 上进行，每次迭代的

| 方法 | ID | | | | | OOD | | | |
|---|---|---|---|---|---|---|---|---|---|
| | 服装 | 电子产品 | 鞋类 | 其他 | 平均 | 配饰 | 美妆 | 家居 | 平均 |
| 基于提示的方法 | | | | | | | | | |
| Zero-shot | 4.4 | 4.6 | 3.4 | 1.0 | 3.5 | 2.5 | 3.7 | 5.5 | 3.9 |
| Few-shot | 14.2 | 15.1 | 13.5 | 24.0 | 16.5 | 18.8 | 29.6 | 5.5 | 16.9 |
| 基于提示的智能体方法或基于记忆的方法 | | | | | | | | | |
| ReAct | 12.4 | 11.1 | 4.5 | 12.0 | 10.4 | 11.2 | 24.1 | 2.7 | 11.6 |
| Reflexion | 3.5 | 8.6 | 1.1 | 7.0 | 5.5 | 6.3 | 5.6 | 1.4 | 4.4 |
| Mem0 | 8.9 | 9.2 | 2.3 | 11.0 | 8.2 | 10.0 | 16.7 | 4.1 | 9.7 |
| ExpeL | 6.2 | 12.5 | 9.0 | 21.0 | 12.1 | 12.5 | 25.9 | 8.2 | 14.5 |
| MemP | 15.9 | 13.2 | 9.0 | 19.0 | 14.3 | 16.2 | 14.8 | 9.6 | 13.5 |
| SimpleMem | 11.5 | 13.8 | 6.7 | 13.0 | 11.7 | 10.0 | 20.4 | 5.5 | 11.1 |
| 基于强化学习的方法 | | | | | | | | | |
| RLOO | 34.9 | 23.9 | **41.5** | 32.1 | 31.1 | 31.4 | 46.5 | 22.5 | 32.9 |
| GRPO | 35.1 | 22.6 | 39.0 | 49.5 | 33.6 | 27.7 | 47.3 | 25.9 | 32.3 |
| 记忆增强的强化学习方法 | | | | | | | | | |
| MemRL | 22.2 | 15.2 | 25.0 | 48.3 | 26.2 | 13.2 | 17.9 | 27.8 | 19.6 |
| EvolveR | 32.5 | 31.1 | 25.0 | 20.9 | 28.0 | 20.8 | 28.6 | 18.2 | 21.9 |
| Mem0+GRPO | 36.5 | 22.0 | 40.6 | 23.1 | 29.5 | 10.2 | 32.1 | 30.2 | 23.0 |
| SimpleMem+GRPO | 25.4 | 28.0 | 26.6 | 25.1 | 26.4 | 16.2 | 32.1 | 29.4 | 25.0 |
| 技能增强的强化学习方法 | | | | | | | | | |
| SkillRL | 36.0 | 34.2 | 41.4 | 49.3 | 38.3 | 36.3 | 48.5 | 27.6 | 36.7 |
| SKILL0 | **39.2** | 33.0 | 38.1 | 37.9 | 35.2 | **42.1** | 38.6 | 26.5 | 35.4 |
| SLIM | 31.9 | 36.8 | 31.5 | 33.0 | 33.7 | 35.0 | 29.6 | **35.6** | 33.8 |
| **Skill0.5** | 39.1 | **37.3** | 41.1 | **50.9** | **40.4** | 36.6 | **54.2** | 31.4 | **40.6** |

表 3: WebShop 在 ID 与 OOD 任务设置下的性能比较。每列中的 最佳 结果与 次佳 结果均以高亮标出。

批大小为 16 个任务；ALFWorld 训练 120 步，WebShop 训练 150 步。ALFWorld 的最大交互时域设为 30 步，WebShop 设为 15 步。任务特定技能通过 Qwen3-Embedding-0.6B 检索，检索容量为 $K = 3$。维护大小为 $W = 5$ 的滑动窗口，以跟踪路由阈值与利用增益。对于特权蒸馏，沿用 Ding (2026)，在概率最高的 64 个词元上执行词元级 JSD 优化。

## E 案例研究

为了从定性角度说明差异化技能处理为何至关重要，我们给出了 ALFWorld 上各技能增强基线的代表性 OOD 失败案例，并将其与 Skill0.5 进行对比。表 4 总结了这些失败机制，图 4 则提供了详细的轨迹比较。

| 方法 | OOD 任务 | 步数 | 结果 | 失败诊断 |
|---|---|---|---|---|
| SkillRL | Heat & Place | 30 | ✗ | Contextual Interference |
| Skill0.5 | Heat & Place | 7 | ✓ | — |
| SKILL0 | Examine in Light | 20 | ✗ | Parametric Conflict |
| Skill0.5 | Examine in Light | 4 | ✓ | — |
| SLIM | Examine in Light | 30 | ✗ | Behavioral Collapse |
| Skill0.5 | Examine in Light | 3 | ✓ | — |

表 4: 代表性 OOD 失败案例汇总。各基线呈现出不同的失败机制，而 Skill0.5 始终能以显著更少的步数成功完成任务。

**案例 1：上下文干扰 (SkillRL)。** 在“加热并放置”任务中，SkillRL 的上下文窗口包含 ∼1,617 个 token，涵盖通用原则、常见错误和 OOD 特定技能，而后者仅占全部上下文的 ∼12%。成功加热土豆并导航至冰箱后，智能体执行了 `cool potato with fridge`—这与任务目标以及注入的技能“*Direct Post-Heat Placement: place the object once*”均直接矛盾。智能体的推理表明，在 ID 任务上训练得到的关联“fridge → cool”（来自冷却并放置任务）受到“尽早使用改变状态的工具”这一通用启发式的激活，从而压过了新的 OOD 指令。相比之下，Skill0.5 将通用技能内化到参数中，使上下文中仅保留 ∼214 个 token 的 OOD 特定指导。这确保了新的“place”指令能够获得不受稀释的注意力，从而在 7 步内正确完成任务。

**案例 2：参数知识冲突 (SKILL0)。** 对于“在灯光下检查”任务，SKILL0 会接收 OOD 特定技能“*Switch Lamp On: Issue 'use desklamp' as soon as you reach it*”。尽管指令十分明确，智能体仍激活了已内化的 ID 程序模板：它执行 `move bowl to sidetable`（拾取并放置的终止动作），并反复尝试 `take desklamp`（将其视

为可携带工具）。值得注意的是，智能体的推理甚至引用了该技能（“According to the Single Toggle Rule...”），却紧接着违背了它—这表明无上下文训练削弱了模型的指令遵循能力，使参数先验压过了新的文本指导。Skill0.5 完全避免了这一冲突：通用技能（领域无关、非程序性）被内化，而任务特定技能则保持外置。对比式利用训练（§3.2.3）显式构建了“读取指令 → 执行”的能力，从而能够忠实遵循新的 OOD 技能。

**案例 3：行为崩溃（SLIM）。** SLIM 的生命周期管理在第 5 步退役了“系统化探索”，其效用为 $\approx 0.001$；截至第 50 步，又有另外 7 项通用技能被退役（累计退役 66.7%）。在第 85 步，智能体仍能成功完成该任务。然而，到第 120 步时—此时已在缺少这些通用约束的情况下额外训练了 70 步—策略出现了灾难性退化：任务幻觉（任务指定“pillow”，推理却围绕“cd”展开）、思考—动作解耦（推理中说“fridge”，动作却前往“bed”），以及跨任务模式崩溃（5 个互不相关的任务均采用相同的退化模板）。这种不可逆的认知侵蚀源于将通用技能视为可退役的消耗品，而非永久性的认知基础。Skill0.5 通过 JSD 蒸馏将通用技能永久嵌入参数，使其不受退役决策影响，并确保整个长时间训练过程中的推理保持稳定。

**统一诊断。** 这些案例表明，在 OOD 设置下，每种统一的技能处理策略都会产生一种特征性的失败模式：完全外置会造成上下文层面的干扰（原则上可通过缩减上下文修复），完全内化会造成参数层面的冲突（推理时无法修复），而不加区分的生命周期管理会造成时间维度的退化（技能一旦退役便不可逆）。Skill0.5 通过按类型实施差异化处理，从设计上消除了这三种失败模式：将领域无关的通用技能永久内化，同时保持对动态任务特定技能的忠实利用。

## F 详细超参数

| **Hyperparameter** | **Value** |
|---|---|
| Policy Optimization Backbone | GRPO |
| Learning Rate | 1e-6 |
| KL Regularization Coeff. | 0.01 |
| Entropy Bonus Coeff. | 0.001 |
| Invalid Action Penalty Coeff. | 0.1 |
| GRPO Group Size | 8 |
| Batch size | 16 |
| Mini-Batch size | 128 |
| Token-level Top-k for JSD Loss | 64 |
| Maximum Prompt Token Length | 6000 |
| Maximum Response Token Length | 768 |
| Evaluation Sampling Temperature | 0.4 |

表 5: 训练超参数的详细配置。

**案例 1：SkillRL（完全外置）— "Put a hot potato in fridge" [失败，30 步]**

注入的 **OOD 技能**：*"Direct Post-Heat Placement: After heating, navigate straight to the destination and place the object once."*

关键轨迹片段：

```
Step 5: heat potato 2 with microwave 1                    ✓ 已加热
Step 6: go to fridge 1                                    ✓ 目标位置正确
Step 7: cool potato 2 with fridge 1                       ✗ 与目标矛盾！
think: ``need to cool it before placing...''              ← ID 习惯：fridge → cool
```

**Skill0.5 — 同一任务 [成功，7 步]**

```
Step 0: go to countertop → Step 1: take potato → Step 2: go to microwave →
Step 3: heat potato
→ Step 4: go to fridge → Step 5: open fridge → Step 6: move potato to fridge  ✓
think: ``heated the potato... next step is to place the hot potato in the
fridge.''                                                 无 "cool" 干扰
```

**案例 2：SKILL0（完全内化）— "Examine the bowl with the desklamp" [失败，20 步]**

注入的 **OOD 技能**：*"Switch Lamp On: Issue 'use desklamp' as soon as you reach it."*

关键轨迹片段：

```
Step 1: take bowl 1 from desk 1                           ✓ 手中持有碗，台灯可见
Step 2: go to sidetable 1                                 ✗ 离开台灯位置！
Step 3: move bowl 1 to sidetable 1                        ✗ 拾取并放置模板被激活
Step 5: take desklamp 1 from desk 1                       ✗ 尝试拿起固定装置
Step 6--8: take desklamp ×3 (repeated)                    ← 策略崩溃
```

**Skill0.5 — 同一任务 [成功，4 步]**

```
Step 0: go to desk → Step 1: take bowl → Step 2: go to desk → Step 3: use
desklamp 1                                                ✓
think: ``take the bowl and use the desklamp to examine it.''  直接遵循 "Switch Lamp On"
```

**案例 3：SLIM（生命周期管理）— "Look at pillow under desklamp" [第 85 步：成功 → 第 120 步：失败]**

已退役的通用技能：*gen_001 "Systematic Exploration"*（在第 *5* 步退役，效用 ≈ *0.001*）

第 **85** 步（成功）：`think: ``go to desk 1 to check if there is a desklamp''` ✓

第 **120** 步（崩溃）：

```
think: ``go to fridge or sink to find a cd''              ✗ 任务幻觉（任务对象为 "pillow"）
action: go to bed 1                                       ✗ 思考—动作解耦
```

在第 *120* 步，*5* 个不同任务均出现相同的退化模式。

**Skill0.5 — 第 120 步的 Examine 任务 [成功，3 步]**

```
Step 0: go to dresser → Step 1: take keychain → Step 2: use desklamp 1   ✓
think: ``find the desklamp and use it to examine the keychain under its light.''
```

第 120 步仍保持稳定推理

图 4: ALFWorld OOD 任务上的轨迹比较。Skill0.5 通过内化通用推理并忠实利用新颖的 OOD 特定技能，在所有案例中均成功完成任务。