OPID：用于智能体强化学习的在策略技能蒸馏

Shuo Yang[1]*, **Jinyang Wu**[1]*†, **Zhengxi Lu**[2], **Yuhao Shen**[2], **Fan Zhang**[3], **Lang Feng**[4], **Shuai Zhang**[1], **Haoran Luo**[4], **Zheng Lian**[5], **Zhengqi Wen**[1], **Jianhua Tao**[1]

[1] 清华大学 [2] 浙江大学 [3] 香港中文大学
[4] 南洋理工大学 [5] 同济大学
通讯邮箱：wu-jy23@mails.tsinghua.edu.cn

摘要

基于结果的强化学习为语言智能体提供了稳定的优化主干，但其稀疏的轨迹级奖励几乎无法指明应强化或抑制哪些中间决策。在策略自蒸馏能够提供稠密的词元级监督，但现有的技能条件化变体往往依赖外部技能记忆或检索得到的特权上下文；这些资源维护成本高昂，并且在多轮交互中可能与当前策略所诱导的状态分布不匹配。我们提出 **OPID**（在策略技能蒸馏），该框架直接从已经完成的在策略轨迹中提取技能监督。OPID 将轨迹的事后经验表示为层次化技能：回合级技能刻画全局工作流程或规避失败的规则，步骤级技能则捕捉关键时间步上的局部决策知识。关键步骤优先的路由机制在识别出关键决策时采用步骤级技能，否则回退到回合级技能作为默认指导。选定的技能会被注入交互历史，使旧策略能够分别在原始上下文和技能增强上下文下对同一个已采样响应重新评分。由此产生的对数概率变化构成词元级自蒸馏优势，并与结果优势结合以优化策略。因此，OPID 在保持强化学习作为主要训练目标的同时，引入了稠密且与分布匹配的事后监督。在 ALFWorld、WebShop 和基于搜索的问答任务上的实验表明，相较于仅基于结果的强化学习和现有技能蒸馏基线，OPID 总体上提升了智能体性能、样本效率和鲁棒性。代码见 https://github.com/jinyangwu/OPID/tree/main。

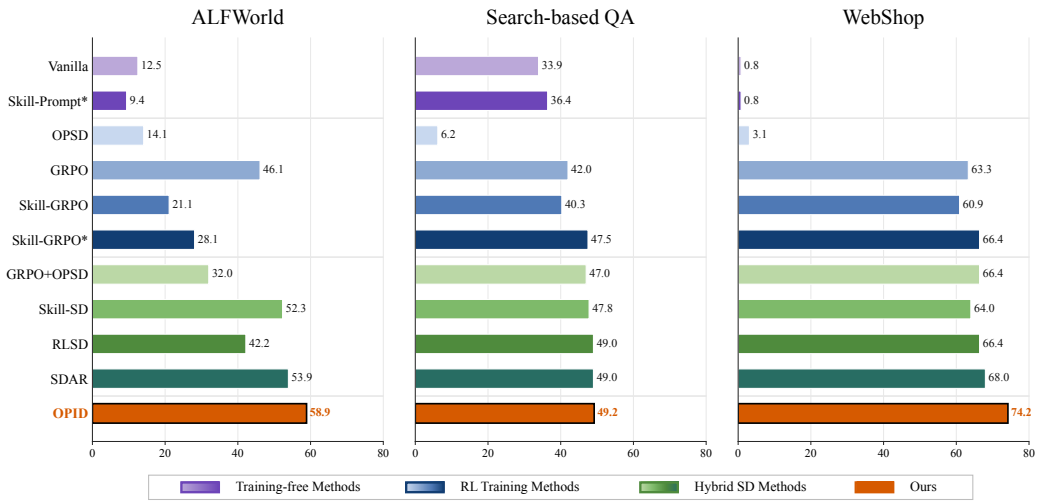


图 1: **总体性能对比**。我们在 ALFWorld、基于搜索的问答和 WebShop 上，将 OPID 与免训练提示方法、仅基于结果的强化学习以及技能蒸馏基线进行比较。OPID 在 ALFWorld 和 WebShop 上取得了最佳平均性能，同时在基于搜索的问答上保持了竞争力。

*同等贡献
†项目负责人

1 引言

大语言模型（LLM）正越来越多地被部署为交互式智能体；这类智能体需要在长时程中运行、调用工具、探索环境，并依据多轮观测调整自身行为 (Jimenez 等, 2024; Luo 等, 2025; Wu 等, 2026a; Lu 等, 2026a)。与单轮推理不同，智能体任务要求连续做出决策，而决策后果可能要经过许多交互步骤后才会显现。这一设定涵盖具身家庭环境、网页导航、搜索增强推理和软件工程智能体 (Shridhar 等, 2020; Yao 等, 2022; Jin 等, 2025; Jimenez 等, 2023)。强化学习（RL）利用来自环境或验证器的任务级反馈直接优化策略，因此已经成为此类智能体一种自然的后训练范式。尤其是，GRPO 等基于结果的方法 (Shao 等, 2024) 为在策略采样提供了稳定且无评论器的优化主干。

尽管行之有效，基于结果的智能体强化学习只能提供粗粒度监督 (Zhang 等, 2025)。环境奖励通常稀疏、延迟且方差较大：终止奖励可以说明一条轨迹是否成功，却无法指出哪些中间决策导致了这一结果。这个局限在长时程交互中尤为严重 (Chen 等, 2026; Xu 等, 2026)，因为早期的一次错误就可能使整个回合偏离目标，反复出现的无效动作会随时间累积，而局部决策的影响可能要到若干轮之后才会显现。因此，纯粹由结果驱动的优化虽然能提供稳定的任务级压力，却缺少细粒度的决策级信用分配。

在策略蒸馏和自蒸馏提供了互补的监督。与仅依赖轨迹级奖励不同，在策略蒸馏使用模型自身的采样输出进行训练，同时利用辅助教师信号产生词元级指导 (Gu 等, 2024a; Agarwal 等, 2024)。近期的自蒸馏方法通过比较同一策略在不同上下文下的表现，消除了对独立教师的需要，例如比较标准学生分支与具备特权信息的教师分支 (Zhao 等, 2026; He 等, 2026)。对于智能体强化学习，这启发了一种自然分工：强化学习仍作为主要优化主干，而自蒸馏则提供稠密的词元级塑形信号。SDAR 等近期工作遵循这一原则，将自蒸馏作为面向多轮智能体的受控辅助目标 (Lu 等, 2026a)。

自然语言技能是一种尤其有前景的特权上下文。技能条件化自蒸馏为教师分支补充程序性知识，例如子目标分解、动作模板或行为规则，再将由此产生的词元级偏好蒸馏到策略中 (Lu 等, 2026b; Wang 等, 2026; Lu 等, 2026a)。然而，现有基于技能的方法通常依赖外部技能库、检索得到的技能文件或持续维护的技能记忆。这种设计带来两个挑战。首先，技能记忆的维护并非易事，需要执行技能插入、完善、删除和检索。其次，检索到的技能可能与当前策略诱导出的状态分布不匹配。此类不匹配对多轮智能体尤为棘手，因为相对于预期轨迹的细微偏离就可能导致状态漂移，使本来有用的技能变得不可靠。

基于上述观察，我们提出 **OPID**（在策略技能蒸馏）框架：它从已经完成的在策略轨迹中提取事后技能，并将这些技能对行为的影响蒸馏回策略。OPID 将每条轨迹抽象为两个互补层级的自然语言技能：回合级技能总结贯穿整条轨迹的工作流程或规避失败的规则，步骤级技能则捕捉关键时间步上依赖状态的指导。这种层次结构体现了长时程决策中的粒度权衡。回合级技能覆盖面广且稳定，但对于关键状态可能过于粗略；步骤级技能精确，却较为稀疏并且依赖具体状态。OPID 通过关键步骤优先的技能路由解决这一权衡：在识别出的关键时间步使用步骤级技能，其余情况下则回退到回合级技能。路由得到的技能会被注入智能体的交互历史，使旧策略能够在原始上下文和技能增强上下文下对同一个在策略响应重新评分。由此诱导出的词元级对数概率变化构成基于技能的自蒸馏优势，并与回合优势结合以优化策略。因此，OPID 在保持基于结果的强化学习作为主要目标的同时，引入了稠密的在策略事后监督。推理时，OPID 无需分析器、外部技能检索或特权上下文。

我们使用不同规模的模型，在 ALFWorld (Shridhar 等, 2020)、WebShop (Yao 等, 2022) 和基于搜索的问答 (Jin 等, 2025) 上评估 OPID。在这些设定中，相较于仅基于结果的强化学习和技能蒸馏基线，OPID 均提升了长时程智能体的性能。这些结果表明，已经完成的在策略轨迹能够成为一种有用的、与分布匹配的事后监督来源，使策略可以将源自轨迹的技能内化，而不必在推理时依赖外部技能库或检索得到的特权上下文。

总体而言，本文的贡献如下：

- 我们提出**在策略事后技能提取**，将当前策略采样得到的完整轨迹视为与分布匹配的技能监督来源，从而避免依赖外部技能库或离策略检索。
- 我们引入**采用关键步骤优先路由的层次化事后技能**：回合级技能捕捉全局工作流程或规避失败的规则，步骤级技能捕捉关键的局部决策，而路由机制为轨迹的每一步选择可用的最具体技能。
- 我们将**基于技能的自蒸馏**融入智能体强化学习，把经过路由的事后技能转化为稠密的词元级塑形信号，同时仍将结果奖励优化作为主要训练目标。

- 我们在长时程智能体基准上对 OPID 进行了实证验证。结果表明，与仅基于结果的强化学习和技能蒸馏基线相比，OPID 持续取得更好的效果，同时提高了样本效率，并减少了重复或无效行为。

2 相关工作

面向智能体大语言模型的强化学习。 大语言模型正越来越多地被训练成交互式智能体，使其能够在长时程中运行、调用工具，并接收来自环境或验证器的反馈 (Shridhar 等, 2020; Yao 等, 2022; Jin 等, 2025; Jimenez 等, 2023; Wu 等, 2026c)。因此，强化学习已经成为一种自然的后训练范式，其中 GRPO 等基于结果的方法为在策略采样提供了稳定且无评论器的目标 (Shao 等, 2024)。然而，智能体环境通常只能提供稀疏且延迟的奖励。终止结果能够说明一条轨迹是否成功，却不能识别哪些中间决策导致了成功或失败。OPID 针对的正是这一缺失的信用分配信号：它保留基于结果的强化学习作为优化主干，并用从策略自身完整轨迹中提取的稠密决策级监督对其加以增强。

在策略自蒸馏。 在策略蒸馏使用模型自身的采样输出对其进行训练，同时利用辅助教师信号提供词元级学习目标 (Agarwal 等, 2024; Gu 等, 2024a)。近期的自蒸馏方法进一步通过比较同一策略在不同上下文或反馈条件下的表现，消除了对独立教师的需要 (Zhao 等, 2026; He 等, 2026)。对于多轮智能体，这启发了一种有效分工：强化学习负责任务级优化，自蒸馏则提供稠密的塑形信号 (Lu 等, 2026a)。其中的关键问题是特权信号应当来自何处。现有方法通常依赖通用修订上下文、外部提示或任务级反馈变换。OPID 则利用从在策略轨迹中提取的事后技能构造特权分支，使蒸馏信号与当前策略实际遇到的状态、动作和失败直接关联。

技能条件化智能体学习。 自然语言技能为智能体提供紧凑的程序性知识，包括子目标分解、动作模板和规避失败的规则 (Lu 等, 2026b; Wang 等, 2026; Lu 等, 2026a; Wu 等, 2026b)。现有基于技能的方法普遍依赖外部技能库、检索得到的技能文件或持久化技能记忆。这些设计可以改善智能体行为，但也会引入维护和检索成本，而且检索得到的技能可能与当前策略诱导出的状态分布不匹配。在长时程交互中，细微偏差就可能造成显著的状态漂移，从而使这种不匹配更加严重。OPID 采用了不同的设计：它直接从已经完成的在策略轨迹中提取层次化技能，依据决策关键程度进行路由，并在训练期间将技能对行为的影响蒸馏到策略中。因此，OPID 无需在推理时进行技能检索、调用分析器或使用特权上下文，即可提供与分布匹配的事后监督。

3 方法

我们将长时程智能体任务形式化为部分可观测决策过程，并提出 OPID：该框架将已完成的在策略轨迹转化为层次化技能，再把这些技能对行为的影响蒸馏回策略。OPID 分三个阶段进行在策略技能蒸馏。首先，从已完成的在策略轨迹中提取层次化技能。其次，将恰当的技能路由至每个决策步骤，并把技能的作用转化为词元级自蒸馏信号。最后，将这些词元级技能优势与组相对结果优势相结合，以优化策略。图 2 展示了整体流程。

3.1 问题形式化

我们将智能体任务建模为如下定义的部分可观测马尔可夫决策过程：

$$(\mathcal{S}, \mathcal{A}, \mathcal{O}, \mathcal{T}, \mathcal{R}, \gamma),$$

其中，$\mathcal{S}$ 是潜在状态空间，$\mathcal{A}$ 是动作空间，$\mathcal{O}$ 是观测空间，$\mathcal{T} : \mathcal{S} \times \mathcal{A} \to \mathcal{S}$ 是转移函数，$\mathcal{R} : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ 是奖励函数，$\gamma \in [0, 1)$ 是折扣因子。在时间步 t，环境处于隐藏状态 $s_t \in \mathcal{S}$，并给出观测 $o_t \in \mathcal{O}$。智能体维护如下交互历史：

$$h_t = (o_0, y_0, o_1, y_1, \ldots, o_t),$$

其中，y_i 表示在步骤 i 生成的文本响应或可执行动作。策略 π_θ 按如下方式生成下一响应：

$$y_t \sim \pi_\theta(\cdot \mid h_t).$$

执行 y_t 后，环境发生转移并返回下一观测。一条完整轨迹表示为

$$\tau = \{(o_t, y_t, r_t)\}_{t=0}^{T-1},$$

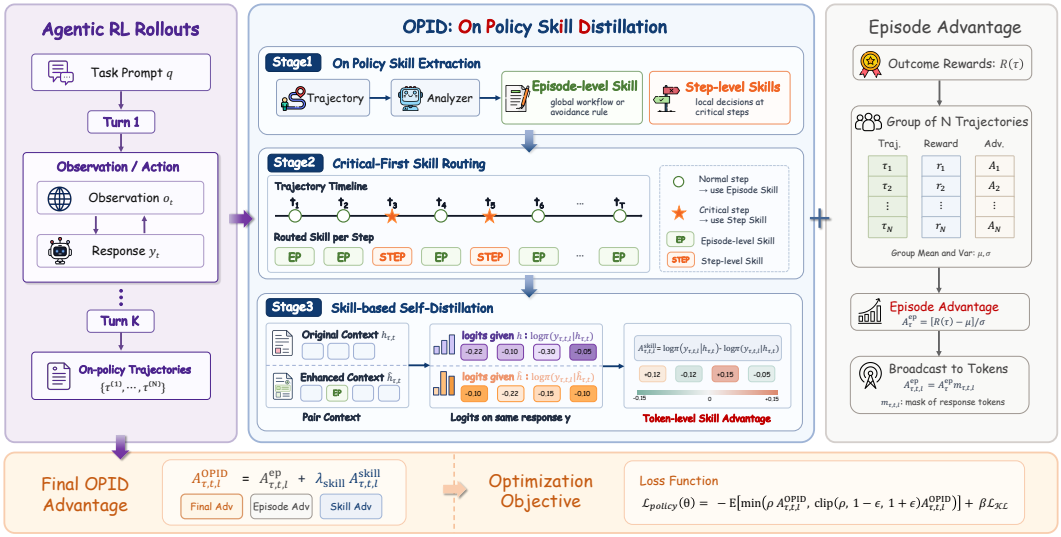


图 2: **OPID 概览**。OPID 从已完成的在策略轨迹出发，提取层次化事后技能，并将最相关的技能路由至每次决策，在关键状态下优先采用步骤级技能。随后，策略分别在有、无路由技能的条件下对同一采样响应重新评分，将逐词元的对数概率差转化为稠密的技能优势，以补充回合级强化学习信号。

其中，T 是回合长度。在大多数智能体基准中，奖励是稀疏且终止时给出的，因此我们将结果得分记为

$$R(\tau) \in \{0, 1\},$$

更一般地，当基准提供分级反馈时，有 $R(\tau) \in \mathbb{R}$。学习目标为

$$J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau)].$$

遵循 GRPO 风格的训练方式，对于每个任务提示 q，我们从当前策略中采样一组 N 条轨迹：

$$\mathcal{G}_q = \{\tau^{(1)}, \tau^{(2)}, \ldots, \tau^{(N)}\}.$$

3.2 在策略技能提取

结果奖励揭示轨迹是否成功，却不能说明其为何成功或失败。因此，OPID 将事后轨迹知识表示为从已完成的在策略采样轨迹中提取的层次化技能。该层次结构包含两个互补层级。

回合级技能。 回合级技能 s_τ^{ep} 概括完整轨迹 τ 的全局行为模式。对于成功轨迹，它提炼出可复用的工作流程，说明任务是如何解决的；对于失败轨迹，它提炼出失败规避规则，描述今后在类似情形下应当避免什么。回合级技能覆盖面广且较为稳定，适合作为大多数状态下的默认指导。

步骤级技能。 步骤级技能 $s_{\tau,t}^{\text{step}}$ 捕获时间步 t 的局部决策知识。它面向最终结果强烈依赖某项具体选择的关键状态，例如避免重复执行无效动作、选择下一个要检查的对象、纠正错误的子目标，或决定何时停止探索。步骤级技能比回合级技能更精确，但也更稀疏且依赖状态。

给定一条完整轨迹 τ，OPID 重建一份有序轨迹记录，其中包含任务提示、观测、模型响应、环境反馈、步骤索引和最终结果。基于大语言模型的分析器 $\mathcal{A}$ 将该记录映射为结构化自然语言技能：

$$\mathcal{A}(\tau) = \left(s_\tau^{\text{ep}}, \{s_{\tau,t}^{\text{step}}\}_{t \in \mathcal{C}_\tau}\right),$$

其中，$\mathcal{C}_\tau$ 是分析器识别出的稀疏关键时间步集合。

3.3 关键步骤优先的技能条件自蒸馏

对每一步都应用相同技能并非最优。回合级技能较为稳健，但在决定性状态下可能过于粗略；步骤级技能精确，却较为稀疏。因此，OPID 在进行技能条件自蒸馏之前，引入关键步骤优先的技能路由。对于轨迹 τ 和时间步 t，路由后的技能为

$$s_{\tau,t} = \begin{cases} s^{\text{step}}_{\tau,t}, & \text{if } t \in \mathcal{C}_\tau, \\ s^{\text{ep}}_{\tau}, & \text{otherwise.} \end{cases}$$

等价地，定义路由掩码

$$q^{\text{step}}_{\tau,t} = \mathbb{I}[t \in \mathcal{C}_\tau], \qquad q^{\text{ep}}_{\tau,t} = \mathbb{I}[t \notin \mathcal{C}_\tau].$$

关键步骤优先规则要求

$$q^{\text{step}}_{\tau,t} = 1 \Rightarrow q^{\text{ep}}_{\tau,t} = 0,$$

因而不会盲目合并两个技能层级。每个步骤都获得粒度最合适的技能。

路由完成后，OPID 将选定技能转化为词元级自蒸馏监督。令 $H(\cdot,\cdot)$ 表示确定性的技能注入函数：该函数在保留原始状态信息的同时，将路由后的技能添加到交互历史的开头或末尾。技能增强后的历史为

$$\tilde{h}_{\tau,t} = H(h_{\tau,t}, s_{\tau,t}).$$

原始响应 $y_{\tau,t}$ 不会重新生成。旧策略 $\pi_{\theta_{\text{old}}}$ 分别在原始历史与技能增强历史下，对同一采样响应进行评分。对于响应 $y_{\tau,t}$ 中的词元 ℓ，定义

$$\ell^{\text{old}}_{\tau,t,\ell} = \log \pi_{\theta_{\text{old}}}\left(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell}\right),$$

以及

$$\ell^{\text{skill}}_{\tau,t,\ell} = \log \pi_{\theta_{\text{old}}}\left(y_{\tau,t,\ell} \mid \tilde{h}_{\tau,t}, y_{\tau,t,<\ell}\right).$$

基于技能的自教师优势为

$$A^{\text{skill}}_{\tau,t,\ell} = \left(\ell^{\text{skill}}_{\tau,t,\ell} - \ell^{\text{old}}_{\tau,t,\ell}\right) m_{\tau,t,\ell},$$

其中，$m_{\tau,t,\ell} \in \{0,1\}$ 是有效响应词元掩码。

若 $A^{\text{skill}}_{\tau,t,\ell} > 0$，则选定技能使该词元在旧策略下出现的可能性更高，表明该词元与技能相符。若 $A^{\text{skill}}_{\tau,t,\ell} < 0$，则技能条件上下文为该词元赋予更低概率，表明该词元与路由后的事后技能不够一致。此过程无需外部专家动作，即可产生稠密的词元级指导。

3.4 基于技能优势的策略优化

对于每个采样轨迹组 $\mathcal{G}_q$，令 $\mathbf{r}_q = \{R(\tau') \mid \tau' \in \mathcal{G}_q\}$ 表示针对同一提示采样的所有轨迹的结果奖励集合。遵循 GRPO，组均值定义为

$$\mu_q = \text{mean}(\mathbf{r}_q) = \frac{1}{|\mathcal{G}_q|} \sum_{\tau' \in \mathcal{G}_q} R(\tau').$$

组标准差定义为组奖励方差的平方根：

$$\sigma_q = \text{std}(\mathbf{r}_q) = \sqrt{\frac{1}{|\mathcal{G}_q|} \sum_{\tau' \in \mathcal{G}_q} \left(R(\tau') - \mu_q\right)^2}.$$

随后，通过在对应提示组内对轨迹结果奖励进行归一化，计算 GRPO 风格的回合相对优势：

$$A^{\text{ep}}_{\tau} = \frac{R(\tau) - \mu_q}{\sigma_q}, \qquad \tau \in \mathcal{G}_q.$$

该标量被广播至所有有效响应词元：

$$A^{\text{ep}}_{\tau,t,\ell} = A^{\text{ep}}_{\tau} m_{\tau,t,\ell}.$$

最终的 OPID 优势将组相对结果反馈与词元级技能监督相结合：

$$A^{\text{OPID}}_{\tau,t,\ell} = A^{\text{ep}}_{\tau,t,\ell} + \lambda_{\text{skill}} A^{\text{skill}}_{\tau,t,\ell}.$$

该形式在保留结果奖励作为主要强化学习信号的同时，引入了词元级塑形。

我们优化标准的截断策略目标：

$$\mathcal{L}_{\text{policy}}(\theta) = -\mathbb{E}_{\tau,t,\ell}\left[\min\left(\rho_{\tau,t,\ell}(\theta)A^{\text{OPID}}_{\tau,t,\ell}, \text{clip}\left(\rho_{\tau,t,\ell}(\theta), 1-\epsilon, 1+\epsilon\right)A^{\text{OPID}}_{\tau,t,\ell}\right)\right] + \beta\mathcal{L}_{\text{KL}}(\theta).$$

其中，$\rho_{\tau,t,\ell}(\theta)$ 表示词元级重要性比率，定义为

$$\rho_{\tau,t,\ell}(\theta) = \exp\left(\log \pi_\theta(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell}) - \log \pi_{\theta_{\text{old}}}(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell})\right).$$

算子 $\text{clip}(x, 1-\epsilon, 1+\epsilon)$ 将 x 截断到区间 $[1-\epsilon, 1+\epsilon]$ 内，ϵ 是控制相对于旧策略最大允许偏差的截断超参数。

训练–推理边界。 分析器、路由后的技能和技能条件评分过程仅用于构造训练优势。在推理时，学得的策略仅依据普通交互历史 h_t 采取动作，不调用分析器、不检索技能，也不使用特权上下文。

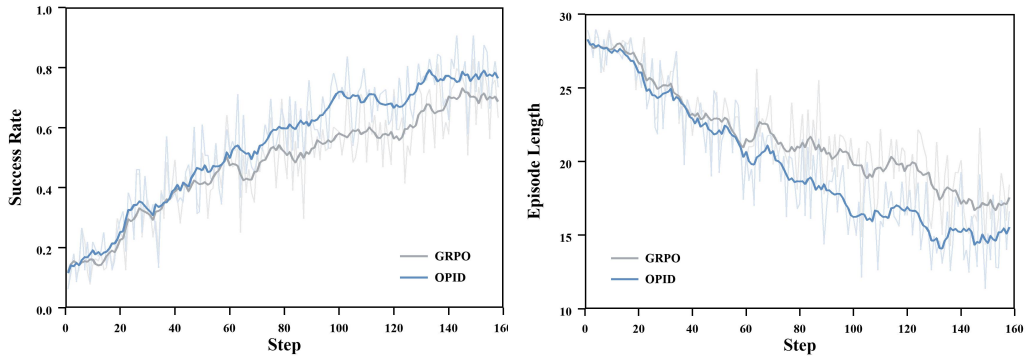
表 1: **代表性长时程基准（ALFWorld、基于搜索的问答和 WebShop）上的性能比较。**我们报告 ALFWorld 上的成功率（%）、基于搜索的问答准确率，以及 WebShop 上的任务完成得分/成功率。星号（*）表示验证时使用技能。**最佳**和次佳结果以高亮显示。

	ALFWorld							基于搜索的问答								WebShop	
方法	**拾取**	**查看**	**清洁**	**加热**	**冷却**	**拾取二物**	**平均**	**NQ**	**Triv**	**Pop**	**Hotp**	**2Wk**	**MuS**	**Bam**	**平均**	**得分**	**成功率**
Qwen2.5-3B-Instruct																	
Vanilla	44.4	11.1	6.2	15.4	28.6	12.5	21.9	24.6	48.1	31.0	26.3	25.3	7.2	59.7	31.7	6.7	0.8
Skill-Prompt*	51.7	66.7	48.4	0.0	4.3	10.0	28.9	23.7	46.2	30.6	24.4	22.1	7.5	12.5	23.9	0.2	0.8
OPSD	48.8	41.7	16.7	0.0	15.8	16.7	28.1	0.1	0.1	0.1	0.0	0.0	0.0	0.0	0.0	11.3	3.1
GRPO	91.2	62.5	96.2	61.9	65.0	47.4	75.0	39.3	60.6	41.1	37.4	34.6	15.4	26.4	36.4	79.8	63.3
Skill-GRPO	88.9	71.4	58.8	70.6	40.7	29.2	60.2	43.5	58.8	43.0	36.8	32.2	11.7	12.5	34.1	77.3	60.9
Skill-GRPO*	94.3	57.1	**100.0**	66.7	73.1	57.1	80.5	44.3	59.6	44.3	39.0	36.1	14.5	14.9	36.1	76.3	66.4
GRPO+OPSD	**100.0**	82.4	85.7	**75.0**	70.0	60.0	81.2	44.9	61.2	45.2	40.4	38.5	16.0	66.1	44.6	77.8	66.4
Skill-SD	88.2	50.0	96.2	52.4	65.0	57.9	73.4	44.4	60.4	44.0	39.5	**40.4**	15.4	64.9	44.1	75.9	64.0
RLSD	87.9	75.0	90.9	**75.0**	73.1	68.4	79.7	41.5	58.6	42.3	40.4	40.2	**16.8**	**66.9**	43.8	84.4	66.4
SDAR	97.1	62.5	**100.0**	61.9	75.0	**84.2**	**84.4**	44.8	58.1	44.3	38.6	36.2	15.7	66.1	43.4	**85.0**	68.0
OPID	92.7	**100.0**	88.9	70.0	**84.2**	70.0	84.3	**45.9**	**61.4**	**45.7**	**40.7**	38.8	16.4	66.1	**45.0**	**85.0**	**74.2**
Qwen2.5-7B-Instruct																	
Vanilla	36.1	22.2	3.1	0.0	0.0	0.0	12.5	25.2	50.8	29.5	29.0	29.0	10.4	63.7	33.9	5.9	1.6
Skill-Prompt*	51.7	50.0	32.3	5.3	4.3	0.0	23.4	30.9	52.1	32.7	32.7	27.9	12.7	66.1	36.4	1.7	0.8
OPSD	50.0	60.0	22.7	21.4	17.6	9.5	32.8	8.8	8.6	17.5	2.5	4.2	0.5	1.2	6.2	4.5	2.3
GRPO	91.2	87.5	96.2	81.0	65.0	57.9	81.2	45.1	63.7	44.0	43.6	43.2	16.8	37.6	42.0	80.9	72.6
Skill-GRPO	88.5	66.7	65.2	61.1	57.7	73.1	69.5	45.2	63.7	45.7	43.1	43.3	19.6	21.4	40.3	80.4	71.9
Skill-GRPO*	**100.0**	83.3	96.4	83.3	75.0	78.9	88.3	44.8	63.0	45.1	43.7	43.7	20.5	71.4	47.5	87.0	81.2
GRPO+OPSD	91.4	61.5	**100.0**	87.5	76.5	52.2	80.4	47.3	64.5	46.9	43.8	39.3	18.0	69.4	47.0	86.8	76.5
Skill-SD	93.9	**93.8**	90.9	**100.0**	69.2	68.4	85.1	47.1	64.5	47.8	44.2	42.1	20.2	69.0	47.8	86.1	76.5
RLSD	**100.0**	87.5	92.3	58.8	80.0	65.2	82.0	46.8	63.0	44.4	45.5	**48.9**	21.5	**73.0**	49.0	87.4	77.3
SDAR	94.7	75.0	**100.0**	86.7	68.2	78.9	85.9	46.3	63.5	**48.2**	43.8	48.4	19.6	**73.0**	49.0	**89.4**	**82.8**
OPID	**100.0**	81.8	97.1	**100.0**	**80.8**	**80.0**	**90.0**	**48.8**	**65.6**	46.8	**46.1**	42.7	**21.7**	72.6	**49.2**	85.3	79.7
Qwen3-1.7B-Instruct																	
Vanilla	25.0	22.2	3.1	0.0	21.4	4.2	12.5	29.4	46.9	37.0	23.5	19.6	6.4	10.5	24.8	46.5	4.7
Skill-Prompt*	10.3	50.0	16.1	0.0	0.0	5.0	9.4	29.4	46.5	36.2	22.9	20.8	4.3	10.1	24.3	23.0	2.3
OPSD	26.3	33.3	9.1	0.0	4.5	5.3	14.1	4.2	8.3	4.6	6.6	15.3	0.7	1.2	5.8	47.4	9.3
GRPO	71.1	41.7	36.4	40.0	31.8	31.6	46.1	40.0	**58.9**	43.5	35.4	30.3	12.0	65.7	40.8	67.3	38.3
Skill-GRPO	27.6	54.5	22.7	27.3	0.0	19.2	21.1	39.2	58.6	43.9	35.2	28.2	11.5	66.1	40.4	73.4	46.1
Skill-GRPO*	31.4	42.9	51.9	8.3	11.5	7.1	28.1	38.0	58.4	43.9	36.3	29.0	12.5	**66.9**	40.7	80.4	50.0
GRPO+OPSD	38.2	50.0	30.8	28.6	30.0	21.1	32.0	**40.7**	**58.9**	45.0	**37.0**	34.6	**13.3**	65.7	**42.2**	70.7	38.3
Skill-SD	52.9	37.5	69.2	**42.9**	60.0	36.8	52.3	39.1	57.5	**45.4**	34.8	34.1	10.7	64.1	40.8	**81.8**	53.9
RLSD	50.0	37.5	61.5	19.0	50.0	21.1	42.2	38.6	57.3	43.0	34.5	34.1	11.5	65.3	40.6	74.0	50.8
SDAR	**73.5**	25.0	**76.9**	33.3	40.0	36.8	53.9	39.7	**58.9**	45.3	35.9	**35.5**	12.6	65.3	41.9	76.8	58.6
OPID	65.9	**72.7**	66.7	40.0	**63.2**	**45.0**	**58.9**	38.1	58.1	43.4	35.5	31.7	11.7	64.5	40.4	79.6	**64.8**

4 实验

4.1 实验设置

基准。 我们在三个具有代表性的智能体基准上评估 OPID，这些基准需要多步交互或基于搜索的推理。首先，我们采用 ALFWorld (Shridhar 等, 2020)；这是一个具身家居基准，智能体必须通过一系列文本动作完成用自然语言指定的目标。我们报告六类任务上的性能：*拾取*、*查看*、*清洁*、*加热*、*冷却*和*拾取两个物体*。其次，我们在 WebShop (Yao 等, 2022) 上进行评估，其中智能体与电子商务网站交互，以寻找并购买满足用户自然语言要求的商品。遵循标准评估协议，我们报告 128 个测试任务上的结果。第三，我们考虑基于搜索的问答 (Jin 等, 2025)，其中智能体通过与搜索环境交互来回答问题；该基准包括 Natural Questions (Kwiatkowski 等, 2019)、TriviaQA (Joshi 等, 2017)、PopQA (Mallen 等, 2023)、HotpotQA (Yang 等, 2018)、2WikiMultiHopQA (Ho 等, 2020)、MuSiQue (Trivedi 等, 2022) 和 Bamboogle (Press 等, 2023)。



(a) 回合成功率　　(b) 回合长度

图 3: **OPID 与 GRPO 的训练动态**。图中给出了 Qwen2.5-3B-Instruct 在 ALFWorld 上的训练过程。半透明曲线表示原始测量值，实线表示平滑后的趋势。

基线。　我们将 OPID 与基于提示和基于训练的基线进行比较。*Vanilla* 表示原始提示基线。*Skill-Prompt* 在推理或验证时用技能描述增强模型。*GRPO* 是仅使用结果信号的在策略强化学习基线，其中利用组相对的轨迹级奖励优化策略 (Shao 等, 2024)。*Skill-GRPO* 将技能条件与 GRPO 式结果优化相结合。*OPSD* (Zhao 等, 2026)、*GRPO+OPSD*、*Skill-SD* (Wang 等, 2026)、*RLSD* (Yang 等, 2026) 和 *SDAR* (Lu 等, 2026a) 是自蒸馏或技能蒸馏基线，它们在训练过程中引入辅助的词元级或技能条件监督。标有 $*$ 的行表示按照相应基线所述设置，在验证时使用技能。

评估指标。　对于 ALFWorld，我们报告以百分比表示的任务成功率。对于 WebShop，我们按照基准协议，同时报告归一化任务得分和任务成功率。对于基于搜索的问答，我们报告各问答子集上以百分比表示的答案准确率，以及所有子集的平均准确率。

实现细节。　我们使用 Qwen2.5-3B/7B-Instruct (Yang 等, 2024) 和 Qwen3-1.7B-Instruct (Yang 等, 2025) 开展实验。ALFWorld 和 WebShop 的训练批大小设为 16，基于搜索的问答则设为 128。所有模型在各个环境中均训练 150 步。完整细节见附录 B。

4.2　主要结果

表 1 汇总了不同模型规模和智能体领域上的性能，并揭示了三个主要发现：

OPID 持续增强仅使用结果信号的强化学习。　在大多数模型–领域组合上，OPID 的表现均优于 GRPO。在 Qwen2.5-3B 上，ALFWorld 的提升为 +9.3 个百分点（84.3 对 75.0），基于搜索的问答为 +8.6 个百分点（45.0 对 36.4），WebShop 为 +10.9 个百分点（74.2 对 63.3）。在 Qwen2.5-7B 上，相应提升分别为 +8.8、+7.2 和 +7.1 个百分点。对于规模更小的 Qwen3-1.7B 主干模型，这种收益尤为显著：OPID 在 ALFWorld 和 WebShop 上分别提升 +12.8 和 +26.5 个百分点。唯一的例外是 Qwen3-1.7B 上的基于搜索的问答，此时 OPID 与 GRPO 的表现接近。总体而言，这些结果表明，相较仅使用结果信号的强化学习，OPID 通常能带来稳定提升，尤其是在长时程具身任务和网页购物任务上。

OPID 与强大的混合方法相比仍具竞争力。　除优于仅使用结果信号的强化学习外，OPID 在若干综合设置中也能媲美或超越强大的混合基线和自蒸馏基线。在 ALFWorld 上，OPID 使用 Qwen2.5-7B 和 Qwen3-1.7B 时均取得最佳平均成绩，分别比最强基线高 +1.7 个百分点（90.0 对 88.3）和 +5.0 个百分点（58.9 对 53.9）。在基于搜索的问答上，OPID 使用两个 Qwen2.5 主干模型时均取得最佳平均成绩：在 Qwen2.5-3B 上比最强基线高 +0.4 个百分点（45.0 对 44.6），在 Qwen2.5-7B 上高 +0.2 个百分点（49.2 对 49.0）。在 WebShop 上，OPID 使用 Qwen2.5-3B 和 Qwen3-1.7B 时均取得最佳成功率；在 Qwen3-1.7B 上比最强竞争方法高 +6.2 个百分点（64.8 对 58.6），在 Qwen2.5-7B 上也保持竞争力。这些结果表明，从轨迹中获得且与分布匹配的技能可以补充结果监督，并能与依赖混合训练信号或外部技能上下文的方法竞争。

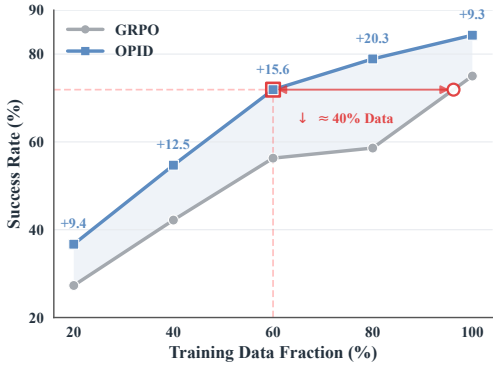


图 4: **样本效率分析**。在缩减训练数据的情况下，OPID 始终优于 GRPO；使用约 60% 的数据即可接近 GRPO 使用完整数据时的性能。

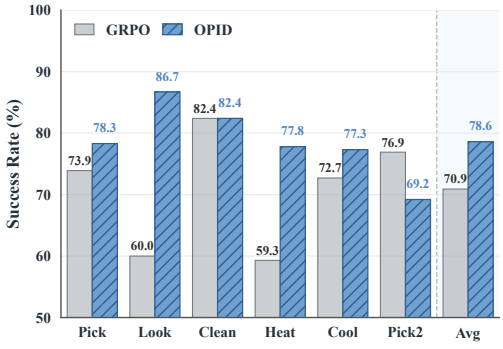


图 5: **在 ALFWorld 未见划分上的跨域泛化**。OPID 的平均成功率高于 GRPO，并且在查看和加热任务上取得尤为显著的提升。

OPID 将技能内化，而非在推理时依赖技能。 结果进一步表明，OPID 的收益来自将事后技能内化到策略之中，而不是依赖推理时的技能提示。直接使用检索到的技能进行训练会造成明显的训练–测试上下文失配：当移除验证时技能后，Skill-GRPO 在所有模型规模的 ALFWorld 上都不如普通 GRPO；Qwen2.5-3B 下降 -14.8 个百分点（60.2 对 75.0），Qwen2.5-7B 下降 -11.7 个百分点（69.5 对 81.2），Qwen3-1.7B 下降 -25.0 个百分点（21.1 对 46.1）。相比之下，OPID 同样是在不输入任何技能的条件下评估，却分别比 Skill-GRPO 高 +24.1、+20.5 和 +37.8 个百分点。在基于搜索的问答上，对于两个 Qwen2.5 模型，OPID 也同时优于 GRPO 和 Skill-GRPO，相较 GRPO 分别提升 +8.6 和 +7.2 个百分点；在 Qwen3-1.7B 上则保持相当的表现。此外，对于两个 Qwen2.5 主干模型，OPID 在 ALFWorld 和基于搜索的问答上均优于 Skill-GRPO*，尽管 Skill-GRPO* 在验证期间仍保留特权技能上下文。这些结果说明，OPID 将轨迹衍生的事后知识迁移进模型参数，使策略无需在推理时依赖外部技能提示，也能从技能中获益。

4.3 训练动态

图 3 展示了 ALFWorld 上的训练进程。两种方法在优化早期都有所改善，但 OPID 在中期开始与 GRPO 拉开差距，并在之后的整个训练过程中保持更优性能。这种分化模式表明，事后技能监督能够加速策略改进，超越单独使用结果奖励所能达到的效果。效率提升同样显著：OPID 将平均回合长度降至 15–16 步，而 GRPO 则稳定在 17–18 步。成功率上升与轨迹长度下降同时出现，揭示出一个关键的行为转变：OPID 智能体学会通过更直接的动作序列抵达目标，而不再进行探索性的绕行。

这些动态与分层监督的预期作用一致。回合级技能建立连贯的任务流程，减少回退与重复；步骤级技能则在关键决策点提供精确指导，避免会导致轨迹延长的无效动作和局部导航错误。这些机制共同使 OPID 能够同时内化全局任务结构和局部决策效率。

4.4 样本效率

图 4 比较了 OPID 和 GRPO 在使用不同比例 ALFWorld 训练数据时的表现。在所有数据规模下，OPID 均持续优于 GRPO，绝对提升范围为 +9.3 至 +20.3 个百分点。在低数据量和中等数据量区域，这一优势尤其明显，此时每条轨迹都承载着更高的训练价值。使用 60% 的数据时，OPID 达到 71.9，接近使用完整数据集训练的 GRPO（75.0）；使用 80% 的数据时，它已经超过完整数据上的 GRPO（78.9 对 75.0）。这些结果表明，OPID 式技能监督提高了基于结果的强化学习的数据效率。通过将已完成轨迹转化为稠密的词元级训练信号，OPID 从相同的环境交互中提取额外监督，而不只是依赖终止奖励。这使优化过程减少了对大量轨迹采样的依赖，并允许策略以更少样本习得有效行为。

4.5 跨域泛化

图 5 评估了向 ALFWorld 未见划分的跨域迁移。OPID 的平均成功率达到 78.6，比 GRPO 高 +7.7 个百分点。相较 GRPO，其提升主要集中在查看（+26.7）和加热（+18.5）等任务上，同时在其余任务类型上保持竞争力。这些结果表明，OPID 并非只是在记忆观察到的训练轨迹。相反，提取出的技能似乎捕捉到了可复用的行为结构，包括在未见环境配置下仍然有效的高层任务流程和局部决策规则。由于技能被蒸馏进策略，而不是在推理时检索，这一提升也说明 OPID 将可迁移的决策知识内化到了模型参数中。

表 2: **分层技能消融实验**。使用 Qwen2.5-3B-Instruct 主干模型时，我们报告 ALFWorld 上的成功率（%），以及 WebShop 上的得分/成功率（%）。

	ALFWorld							WebShop	
方法	**拾取**	**查看**	**清洁**	**加热**	**冷却**	**拾取二物**	**平均**	**得分**	**成功率**
OPID	92.7	**100.0**	**88.9**	**70.0**	**84.2**	70.0	**84.3**	**85.0**	**74.2**
不使用回合级技能	83.3	80.0	78.1	69.2	57.7	**76.5**	74.1	78.4	67.2
不使用步骤级技能	**95.1**	**81.8**	**88.9**	**70.0**	79.0	60.0	79.1	80.2	65.6

表 3: **关键优先技能路由消融实验**。使用 Qwen2.5-3B-Instruct 主干模型时，我们将 OPID 与移除关键优先路由策略的变体进行比较。

	ALFWorld						
方法	**拾取**	**查看**	**清洁**	**加热**	**冷却**	**拾取二物**	**平均**
OPID	92.7	**100.0**	**88.9**	**70.0**	**84.2**	**70.0**	**84.3**
不使用路由	**95.1**	81.8	**88.9**	50.0	**84.2**	65.0	77.5

4.6 消融实验与分析

我们使用 Qwen2.5-3B-Instruct，分别考察分层技能粒度与关键优先路由的贡献。

分层技能的影响。 如表 2 所示，完整的技能层次在两个领域上均取得最佳综合性能。移除回合级技能后，ALFWorld 的平均成绩从 84.3 降至 74.1，WebShop 的成功率从 74.2 降至 67.2，这证实全局流程和失败规避规则提供了重要的默认信号。移除步骤级技能后，ALFWorld 的平均成绩从 84.3 降至 79.1，WebShop 的成功率从 74.2 降至 65.6。这些结果证明了两个技能层级之间的互补性。

关键优先技能路由的影响。 表 3 将 OPID 与一种不使用路由的变体进行比较。该变体将回合级技能应用于每个步骤，并在关键时间步额外加入相应的步骤级技能，从而叠加两种形式的指导。关键优先路由使 ALFWorld 平均成绩提高 +6.8 个百分点（84.3 对 77.5）。这些结果表明，相比直接组合全局和局部指导，选择性地路由最合适的技能粒度更加有效，证明了关键优先路由的重要性。

定性分析。 图 6 展示了一个 ALFWorld 清洁并放置任务。使用 GRPO 训练的智能体在第 4 步试图从台面上拿取一个不存在的锅铲，出现了“目标幻觉”错误。随后，它用勺子代替目标物体，并在将清洁后的锅铲放回餐桌之前就达到了 30 步的上限。相比之下，OPID 遵循连贯的“定位–清洁–放置”流程，并在六步内完成任务。该案例表明，从在策略轨迹中蒸馏分层事后技能，有助于智能体同时学习局部物体落地决策和回合级任务流程，从而减少幻觉动作，并保持朝最终目标推进。

5 结论

本文提出了 OPID，这是一种将在策略智能体的完整轨迹转化为层次化事后监督的技能蒸馏框架。通过从当前策略自身的采样轨迹中提取回合级和步骤级技能，OPID 在保持基于结果

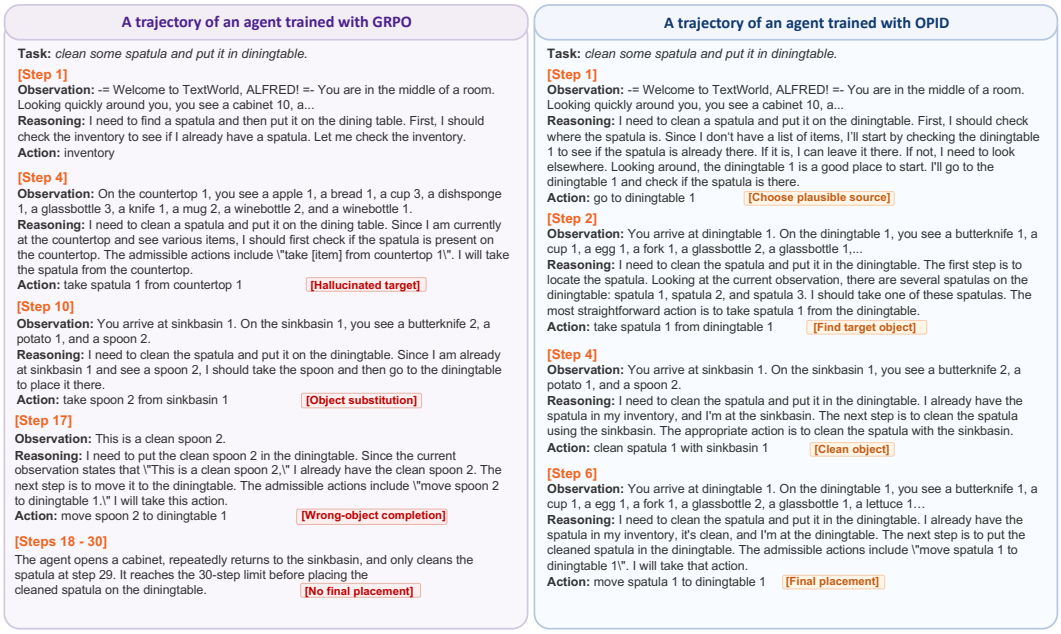


图 6: **ALFWorld 上的定性比较**。对于“清洁一把锅铲并将其放到餐桌上”这一任务，使用 GRPO 训练的智能体臆造了一个不存在的目标物体，用勺子代替锅铲，并且未能在步数限制内完成最终放置。相比之下，OPID 遵循连贯的“定位–清洁–放置”流程，使每个动作都以当前观察为依据，并在六步内完成任务。

的强化学习作为主要目标的同时，提供了稠密且与分布匹配的词元级指导。在具身、网页和基于搜索的智能体基准上的实验表明，OPID 无需在推理时依赖外部技能库、检索或特权上下文，即可改善智能体学习。更广泛地说，我们的结果说明，智能体轨迹不仅是奖励优化所用的样本，也是可复用的决策知识记录，能够被蒸馏回策略之中。

参考文献

Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos, Matthieu Geist, 和 Olivier Bachem. 语言模型的在策略蒸馏：从自行生成的错误中学习. 载于国际学习表征会议, 2024.

Guoxin Chen, Zile Qiao, Xuanzhong Chen, Donglei Yu, Haotian Xu, Xin Zhao, Ruihua Song, Wenbiao Yin, Huifeng Yin, Liwen Zhang, Kuan Li, Minpeng Liao, Yong Jiang, Pengjun Xie, Fei Huang, 和 Jingren Zhou. IterResearch：通过交互扩展重新思考长时程智能体. 载于第十四届国际学习表征会议, 2026.

Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Samuel Stevens, Boshi Wang, Huan Sun, 和 Yu Su. Mind2Web：迈向通用网页智能体. *arXiv* 预印本 *arXiv:2306.06070*, 2023.

Kuofei Fang, Xinyi Che, Haomin Ouyang, Shufan Zhang, Xuehao Wang, Qi Liu, Liyi Liu, Chenqi Zhang, Wenxi Cai, Wenyu Dai, 等. RobotEQ：推动具身人工智能从被动智能迈向主动智能. *arXiv* 预印本 *arXiv:2605.06234*, 2026.

Yuqian Fu, Haohuan Huang, Kaiwen Jiang, Jiacai Liu, Zhuo Jiang, Yuanheng Zhu, 和 Dongbin Zhao. 重新审视在策略蒸馏：经验性失效模式与简单修复方法. *arXiv* 预印本 *arXiv:2603.25562*, 2026.

Yuxian Gu, Li Dong, Furu Wei, 和 Minlie Huang. MiniLLM：大语言模型的知识蒸馏. 载于国际学习表征会议, 2024a.

Yuxian Gu, Li Dong, Furu Wei, 和 Minlie Huang. MiniLLM：大语言模型的知识蒸馏. 载于第十二届国际学习表征会议, 2024b.

Yinghui He, Simran Kaur, Adithya Bhaskar, Yongjin Yang, Jiarui Liu, Narutatsu Ri, Liam Fowl, Abhishek Panigrahi, Danqi Chen, 和 Sanjeev Arora. 零起点自蒸馏：利用自我修订将二元奖励转化为稠密监督. *arXiv* 预印本 *arXiv:2604.12002*, 2026.

Geoffrey Hinton, Oriol Vinyals, 和 Jeff Dean. 蒸馏神经网络中的知识. *arXiv* 预印本 *arXiv:1503.02531*, 2015.

Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, 和 Akiko Aizawa. 构建用于全面评估推理步骤的多跳问答数据集. 载于第 *28* 届国际计算语言学会议论文集, 页 6609–6625, 2020.

Carlos E. Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, 和 Karthik Narasimhan. SWE-bench：语言模型能否解决真实世界的 GitHub 问题？. *arXiv* 预印本 *arXiv:2310.06770*, 2023.

Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, 和 Karthik R Narasimhan. SWE-bench：语言模型能否解决真实世界的 github 问题？. 载于第十二届国际学习表征会议, 2024.

Bowen Jin, Hansi Zeng, Zhenrui Yue, Wang Dong, Hamed Zamani, 和 Jiawei Han. Search-R1：利用强化学习训练大语言模型进行推理并使用搜索引擎. *arXiv* 预印本 *arXiv:2503.09516*, 2025.

Mandar Joshi, Eunsol Choi, Daniel Weld, 和 Luke Zettlemoyer. TriviaQA：面向阅读理解的大规模远程监督挑战数据集. 载于第 *55* 届计算语言学协会年会论文集, 页 1601–1611, 2017.

Jing Yu Koh, Robert Lo, Lawrence Jang, Vikram Duvvur, Ming Chong Lim, Po-Yu Huang, Graham Neubig, Shuyan Zhou, Ruslan Salakhutdinov, 和 Daniel Fried. VisualWebArena：在真实视觉网页任务上评估多模态智能体. *arXiv* 预印本 *arXiv:2401.13649*, 2024.

Solomon Kullback 和 Richard A. Leibler. 论信息与充分性. 数理统计年刊, 22(1):79–86, 1951. doi: 10.1214/aoms/1177729694.

Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, Kristina Toutanova, Llion Jones, Matthew Kelcey, Ming-Wei Chang, Andrew M. Dai, Jakob Uszkoreit, Quoc Le, 和 Slav Petrov. Natural Questions：问答研究基准. 计算语言学协会汇刊, 7:452–466, 2019.

Yaxuan Li, Yuxin Zuo, Bingxiang He, Jinqian Zhang, Chaojun Xiao, Cheng Qian, Tianyu Yu, Huang Gao, Wenkai Yang, Zhiyuan Liu, 和 Ning Ding. 重新思考大语言模型的在策略蒸馏：现象、机制与方法. *arXiv* 预印本 *arXiv:2604.13016*, 2026.

Jianhua Lin. 基于香农熵的散度度量. *IEEE* 信息论汇刊, 37(1):145–151, 1991. doi: 10.1109/18.61115.

Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, 等. AgentBench：将大语言模型作为智能体进行评估. *arXiv* 预印本 *arXiv:2308.03688*, 2023.

Kevin Lu 和 Thinking Machines Lab. 在策略蒸馏. *Thinking Machines Lab*：联结主义, 2025. doi: 10.64434/tml.20251026.

Zhengxi Lu, Zhiyuan Yao, Zhuowen Han, Zi-Han Wang, Jinyang Wu, Qi Gu, Xunliang Cai, Weiming Lu, Jun Xiao, Yueting Zhuang, 和 Yongliang Shen. 自蒸馏智能体强化学习. *arXiv* 预印本 *arXiv:2605.15155*, 2026a.

Zhengxi Lu, Zhiyuan Yao, Jinyang Wu, Chengcheng Han, Qi Gu, Xunliang Cai, Weiming Lu, Jun Xiao, Yueting Zhuang, 和 Yongliang Shen. SKILL0：用于技能内化的上下文智能体强化学习. *arXiv* 预印本 *arXiv:2604.02268*, 2026b.

Junyu Luo, Weizhi Zhang, Ye Yuan, Yusheng Zhao, Junwei Yang, Yiyang Gu, Bohan Wu, Binqi Chen, Ziyue Qiao, Qingqing Long, 等. 大语言模型智能体：方法、应用与挑战综述. *arXiv* 预印本 *arXiv:2503.21460*, 2025.

Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, 和 Hannaneh Hajishirzi. 何时不应信任语言模型：参数化与非参数化记忆有效性研究. 载于第 *61* 届计算语言学协会年会论文集, 页 9802–9822, 2023.

Minjae Oh, Sangjun Song, Gyubin Choi, Yunho Choi, 和 Yohan Jo. 以 KL 求 KL：采用控制变量基线的在策略蒸馏. *arXiv* 预印本 *arXiv:2605.07865*, 2026.

Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A. Smith, 和 Mike Lewis. 测量并缩小语言模型中的组合性差距. 载于计算语言学协会研究成果：*EMNLP 2023*, 页 5687–5711, 2023.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Yang Wu, 等. DeepSeekMath：拓展开放语言模型数学推理的极限. *arXiv* 预印本 *arXiv:2402.03300*, 2024.

Yuhao Shen, Tianyu Liu, Junyi Shen, Jinyang Wu, Quan Kong, Li Huan, 和 Cong Wang. Double：通过双重检索推测并行突破加速极限. *arXiv* 预印本 *arXiv:2601.05524*, 2026.

Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, 和 Matthew Hausknecht. ALFWorld：对齐文本与具身环境以进行交互式学习. *arXiv* 预印本 *arXiv:2010.03768*, 2020.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, 和 Ashish Sabharwal. MuSiQue：通过组合单跳问题构造多跳问题. 计算语言学协会汇刊, 10:539–554, 2022.

Hao Wang, Guozhi Wang, Han Xiao, Yufeng Zhou, Yue Pan, Jichao Wang, Ke Xu, Yafei Wen, Xiaohu Ruan, Xiaoxin Chen, 和 Honggang Qi. Skill-SD：面向多轮大语言模型智能体的技能条件化自蒸馏. *arXiv* 预印本 *arXiv:2604.10674*, 2026.

Jinyang Wu, Mingkuan Feng, Shuai Zhang, Feihu Che, Zengqi Wen, Chonghua Liao, 和 Jianhua Tao. 超越示例：通过蒙特卡洛树搜索实现上下文学习中的高层自动推理范式. *arXiv* 预印本 *arXiv:2411.18478*, 2024.

Jinyang Wu, Shuo Yang, Changpeng Yang, Yuhao Shen, Shuai Zhang, Zhengqi Wen, 和 Jianhua Tao. Spark：通过动态分支实现面向长时程智能体学习的策略感知战略探索. *arXiv* 预印本 *arXiv:2601.20209*, 2026a.

Jinyang Wu, Guocheng Zhai, Ruihan Jin, Yuhao Shen, Zhengxi Lu, Fan Zhang, Haoran Luo, Zheng Lian, Zhengqi Wen, 和 Jianhua Tao. Maestro：利用强化学习编排层次化模型-技能集成. *arXiv* 预印本 *arXiv:2605.22177*, 2026b.

Jinyang Wu, Guocheng Zhai, Ruihan Jin, Jiahao Yuan, Yuhao Shen, Shuai Zhang, Zhengqi Wen, 和 Jianhua Tao. Atlas：编排异构模型与工具以进行多领域复杂推理. *arXiv* 预印本 *arXiv:2601.03872*, 2026c.

Fangzhi Xu, Hang Yan, Qiushi Sun, Jinyang Wu, Zixian Huang, Muye Huang, Jingyang Gong, Zichen Ding, Kanzhi Cheng, Yian Wang, 等. OdysseyArena：面向长时程、主动式和归纳式交互的大语言模型基准评测. *arXiv* 预印本 *arXiv:2602.05843*, 2026.

An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, 等. Qwen2.5 技术报告. *arXiv* 预印本 *arXiv:2412.15115*, 2024.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, 等. Qwen3 技术报告. *arXiv* 预印本 *arXiv:2505.09388*, 2025.

Chenxu Yang, Chuanyu Qin, Qingyi Si, Minghui Chen, Naibin Gu, Dingyu Yao, Zheng Lin, Weiping Wang, Jiaqi Wang, 和 Nan Duan. 自蒸馏 rlvr. *arXiv* 预印本 *arXiv:2604.03128*, 2026.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, 和 Christopher D. Manning. HotpotQA：面向多样且可解释的多跳问答数据集. 载于 *2018* 年自然语言处理经验方法会议论文集, 页 2369–2380, 2018.

Shunyu Yao, Howard Chen, John Yang, 和 Karthik Narasimhan. WebShop：利用落地语言智能体实现可扩展的真实世界网页交互. 载于神经信息处理系统进展, 2022.

Tianzhu Ye, Li Dong, Xun Wu, Shaohan Huang, 和 Furu Wei. 面向语言模型的在策略上下文蒸馏. *arXiv* 预印本 *arXiv:2602.12275*, 2026.

Z.ai. GLM-5.2：为长时程任务而生. https://z.ai/blog/glm-5.2, 6 月 2026. 访问日期：2026-06-22.

Guibin Zhang, Hejia Geng, Xiaohang Yu, Zhenfei Yin, Zaibin Zhang, Zelin Tan, Heng Zhou, Zhongzhi Li, Xiangyuan Xue, Yijiang Li, 等. 面向大语言模型的智能体强化学习全景：综述. *arXiv* 预印本 *arXiv:2509.02547*, 2025.

Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, 和 Aditya Grover. 自蒸馏推理器：面向大语言模型的在策略自蒸馏. *arXiv* 预印本 *arXiv:2601.18734*, 2026.

Shuyan Zhou, Frank F. Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, 等. WebArena：用于构建自主智能体的真实网页环境. *arXiv* 预印本 *arXiv:2307.13854*, 2023.

A 理论分析

本节给出与 OPID 主要设计选择相对应的三个结果。我们首先将所提出的教师优势置于具有代表性的在策略蒸馏目标中加以考察。随后，我们证明它实现了采样词元的反向 KL 更新，刻画以在策略方式收集蒸馏上下文的益处，并在一个自然的专门化假设下论证关键优先路由的合理性。

A.1 符号与代表性的在策略蒸馏目标

A.1.1 符号

令 $i = (\tau, t, \ell)$ 表示响应中的一个有效词元位置。我们将对应的标准自回归上下文记为 $c_i = (h_{\tau,t}, y_{\tau,t,<\ell})$，并将其技能增强后的对应上下文记为 $\widetilde{c}_i$。在每个词元位置，定义

$$b_i(v) \triangleq \pi_{\theta_{\text{old}}}(v \mid c_i), \quad q_i(v) \triangleq \pi_{\theta_{\text{old}}}(v \mid \widetilde{c}_i), \quad p_{\theta,i}(v) \triangleq \pi_\theta(v \mid c_i).$$

其中，b_i 是用于生成响应的行为分布，q_i 是已分离梯度的技能条件教师分布，而 $p_{\theta,i}$ 是在推理时可用的标准上下文下求值的可训练策略。观测词元 $a_i \triangleq y_{\tau,t,\ell}$ 从 b_i 中采样。

我们进一步将词元级对数似然差和策略重要性比定义为

$$\Delta_i(v) \triangleq \log q_i(v) - \log b_i(v), \quad \rho_{\theta,i}(v) \triangleq \frac{p_{\theta,i}(v)}{b_i(v)}. \tag{1}$$

量 $\Delta_i(v)$ 衡量技能增强上下文所引起的词元对数概率变化。特别地，$\Delta_i(v) > 0$ 表明技能条件教师赋予词元 v 的概率高于行为策略。因此，与观测词元对应的 OPID 技能优势为

$$A_i^{\text{skill}} = \Delta_i(a_i).$$

除非另有说明，下文所有期望均在有效响应词元上计算；因此，为简化符号，省略响应掩码。

A.1.2 代表性的在策略蒸馏目标

在策略蒸馏（OPD）在由学生或行为策略生成的自回归上下文上施加教师监督，从而减少蒸馏训练与自由运行推理之间的上下文分布失配 (Agarwal 等, 2024)。上下文生成策略与教师监督的粒度是两个正交的设计选择。在每个在策略上下文上，输出空间的 OPD 目标可分为三种常见监督粒度：全词表、Top-K 和采样词元蒸馏 (Li 等, 2026; Fu 等, 2026)。OPID 属于采样词元类别。

全词表分布匹配。 令 q_i 和 $p_{\theta,i}$ 分别表示自回归上下文 i 上教师和学生的下一词元分布。当完整预测分布可用时，OPD 可以最小化正向 KL、反向 KL 或广义 Jensen–Shannon 散度 (Hinton 等, 2015; Agarwal 等, 2024; Gu 等, 2024b)：

$$\begin{aligned}
\mathcal{L}_{\text{FKL}}(\theta) &= \mathbb{E}_i[D_{\text{KL}}(q_i \| p_{\theta,i})], \\
\mathcal{L}_{\text{RKL}}(\theta) &= \mathbb{E}_i[D_{\text{KL}}(p_{\theta,i} \| q_i)], \\
\mathcal{L}_{\text{JSD}}^{(\alpha)}(\theta) &= \mathbb{E}_i\left[\alpha D_{\text{KL}}(q_i \| m_i^{(\alpha)}) + (1-\alpha) D_{\text{KL}}(p_{\theta,i} \| m_i^{(\alpha)})\right], \\
m_i^{(\alpha)} &= \alpha q_i + (1-\alpha) p_{\theta,i}.
\end{aligned}$$

正向 KL 给出常规的软目标函数，并强调覆盖教师支持的概率质量。反向 KL 则惩罚学生分配给教师不偏好区域的概率，因而通常呈现更强的寻模行为。广义 JSD 将两个模型都与一个混合分布进行比较；当 $\alpha = \frac{1}{2}$ 时，即恢复标准的对称 JSD (Kullback & Leibler, 1951; Lin, 1991)。

Top-K 分布匹配。 Top-K OPD 在受限的局部支撑集上保留分布级监督。常见选择包括由学生选取的支撑集 (Li 等, 2026; Ye 等, 2026) 和由教师选取的支撑集 (Fu 等, 2026)：

$$\begin{aligned} S_{i,p}^{(K)} &\triangleq \text{TopK}(p_{\theta,i}, K), \\ S_{i,q}^{(K)} &\triangleq \text{TopK}(q_i, K), \\ S_i^{(K)} &\in \left\{ S_{i,p}^{(K)}, S_{i,q}^{(K)} \right\}. \end{aligned}$$

对于选定的支撑集 $S_i^{(K)}$，定义受限并重新归一化的分布

$$\begin{aligned} \bar{p}_{\theta,i}^{S_i^{(K)}}(v) &\triangleq \frac{p_{\theta,i}(v)\mathbf{1}\{v \in S_i^{(K)}\}}{\sum_{u \in S_i^{(K)}} p_{\theta,i}(u)}, \\ \bar{q}_i^{S_i^{(K)}}(v) &\triangleq \frac{q_i(v)\mathbf{1}\{v \in S_i^{(K)}\}}{\sum_{u \in S_i^{(K)}} q_i(u)}. \end{aligned}$$

一个具有代表性的截断反向 KL 目标为

$$\begin{aligned} \mathcal{L}_{\text{TopK-RKL}}(\theta) &= \mathbb{E}_i \left[D_{\text{KL}} \left(\bar{p}_{\theta,i}^{S_i^{(K)}} \,\middle\|\, \bar{q}_i^{S_i^{(K)}} \right) \right] \\ &= \mathbb{E}_i \left[\sum_{v \in S_i^{(K)}} \bar{p}_{\theta,i}^{S_i^{(K)}}(v) \log \frac{\bar{p}_{\theta,i}^{S_i^{(K)}}(v)}{\bar{q}_i^{S_i^{(K)}}(v)} \right]. \end{aligned}$$

Top-K 匹配介于单词元监督与全词表监督之间。它在降低计算或通信开销的同时保留多词元信息，但会丢弃所选支撑集之外的概率质量，因此是对完整反向 KL 的一种依赖支撑集的截断近似。

采样词元蒸馏。 在一个固定的在策略上下文上，定义教师–学生对数比代价

$$\delta_i(v) \triangleq \log p_{\theta,i}(v) - \log q_i(v).$$

于是，词元级反向 KL 可以精确写成在学生采样词元上的期望：

$$\begin{aligned} D_{\text{KL}}(p_{\theta,i} \| q_i) &= \mathbb{E}_{a_i \sim p_{\theta,i}} \left[\delta_i(a_i) \right] \\ &= \mathbb{E}_{a_i \sim b_i} \left[\rho_{\theta,i}(a_i) \delta_i(a_i) \right], \qquad \rho_{\theta,i}(a) \triangleq \frac{p_{\theta,i}(a)}{b_i(a)}. \end{aligned}$$

第二个等式要求 $p_{\theta,i} \ll b_i$（支撑覆盖条件）。因此，$\rho_{\theta,i}(a_i)\delta_i(a_i)$ 是每上下文反向 KL 的重要性加权单样本估计量。其得分函数梯度为

$$\nabla_\theta D_{\text{KL}}(p_{\theta,i} \| q_i) = \mathbb{E}_{a_i \sim b_i} \left[\rho_{\theta,i}(a_i) \, \text{sg}[\delta_i(a_i)] \, \nabla_\theta \log p_{\theta,i}(a_i) \right],$$

其中，sg 表示停止梯度。这一联系使得采样词元蒸馏能够利用策略梯度或重要性加权的策略优化机制来实现 (Gu 等, 2024b; Lu & Thinking Machines Lab, 2025; Oh 等, 2026)。与全词表匹配相比，采样词元监督只需要已实现词元的教师概率，但具有更高的 Monte Carlo 方差，且使用的教师分布信息更少。

从裁剪后的 OPID 目标到其未裁剪技能代理目标。 令 $i = (\tau, t, \ell)$ 表示一个有效的轨迹词元位置，并令 ν_b 表示由行为策略所收集轨迹诱导的有效词元位置分布。给定位置 i，观测词元 a_i 从 b_i 中采样。回顾式 1，有

$$\Delta_i(v) = \log q_i(v) - \log b_i(v), \qquad \rho_{\theta,i}(v) = \frac{p_{\theta,i}(v)}{b_i(v)},$$

其中，b_i、q_i 及由此得到的优势在策略更新期间均与梯度分离。采样词元的技能优势为

$$A_i^{\text{skill}}(a_i) = \Delta_i(a_i).$$

完整的 OPID 优势将结果信号与技能信号相结合：

$$A_i^{\text{OPID}}(a_i) = A_i^{\text{ep}} + \lambda_{\text{skill}}\Delta_i(a_i).$$

相应地，实现中采用的裁剪策略损失为

$$\mathcal{L}_{\text{policy}}(\theta) = -\mathbb{E}_{\substack{i\sim\nu_b \\ a_i\sim b_i}}\Big[\min\Big(\rho_{\theta,i}(a_i)A_i^{\text{OPID}}(a_i), \\ \text{clip}(\rho_{\theta,i}(a_i), 1-\epsilon, 1+\epsilon)A_i^{\text{OPID}}(a_i)\Big)\Big].$$

在一个实际生成的轨迹批次中，该期望通过对观测到的有效词元 a_i 取经验平均来实现。

由于 PPO 裁剪是在结果优势与技能优势合并之后应用的，裁剪目标通常无法分解为彼此独立裁剪的结果损失和技能损失。为分离下文研究的技能蒸馏信号，我们因而考虑对应的未裁剪策略代理目标：

$$\mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta) \triangleq -\mathbb{E}_{\substack{i\sim\nu_b \\ a_i\sim b_i}}\left[\rho_{\theta,i}(a_i)A_i^{\text{OPID}}(a_i)\right].$$

与裁剪目标不同，该损失可以精确分解为

$$\mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta) = \mathcal{L}_{\text{ep}}^{\text{unclip}}(\theta) + \mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta),$$

其中

$$\mathcal{L}_{\text{ep}}^{\text{unclip}}(\theta) \triangleq -\mathbb{E}_{\substack{i\sim\nu_b \\ a_i\sim b_i}}\left[\rho_{\theta,i}(a_i)A_i^{\text{ep}}\right]$$

以及

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) \triangleq -\lambda_{\text{skill}}\mathbb{E}_{\substack{i\sim\nu_b \\ a_i\sim b_i}}\left[\rho_{\theta,i}(a_i)\Delta_i(a_i)\right]. \tag{2}$$

式 2 是下一小节分析的技能蒸馏损失。尽管它通过未裁剪代理目标定义，但它刻画了实现中的 PPO 损失在局部由技能诱导的更新。具体而言，令 $\theta_0 = \theta_{\text{old}}$，于是 $p_{\theta_0,i} = b_i$ 且 $\rho_{\theta_0,i}(a) = 1$。由于 1 位于裁剪区间内部，裁剪目标与未裁剪目标在行为策略处具有相同的值和梯度：

$$\begin{aligned}
\mathcal{L}_{\text{policy}}^{\text{clip}}(\theta_0) &= \mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta_0), \\
\nabla_\theta\mathcal{L}_{\text{policy}}^{\text{clip}}(\theta)\Big|_{\theta=\theta_0} &= \nabla_\theta\mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0} \\
&= \nabla_\theta\mathcal{L}_{\text{ep}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0} + \nabla_\theta\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0}.
\end{aligned}$$

因此，$\mathcal{L}_{\text{skill}}^{\text{unclip}}$ 恰好是行为策略附近一阶 PPO 更新中由技能诱导的分量。离开这一区域后，裁剪会通过合并优势的符号将结果信号与技能信号耦合起来，此时未裁剪分解不再能在全局上描述完整的裁剪目标。

A.2 作为相对 KL 代理目标的未裁剪 OPID 技能损失

下面分析式 2 中引入的未裁剪技能蒸馏损失。令 ν_b 表示由行为策略所收集轨迹诱导的有效词元位置分布。在本小节中，轨迹历史、经路由的技能以及对应分布 b_i 和 q_i 均与梯度分离，并在策略更新期间保持固定。

我们假设公共支撑条件

$$p_{\theta,i} \ll b_i \qquad \text{and} \qquad p_{\theta,i} \ll q_i$$

对 ν_b 支撑集中的每个 i 都成立。具有有限对数几率值的标准 softmax 语言模型满足这一条件。

回顾定义

$$\Delta_i(v) \triangleq \log q_i(v) - \log b_i(v), \quad \rho_{\theta,i}(v) \triangleq \frac{p_{\theta,i}(v)}{b_i(v)}.$$

未裁剪 OPID 技能损失为

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) \triangleq -\lambda_{\text{skill}} \mathbb{E}_{\substack{i\sim\nu_b \\ a\sim b_i}} \left[\rho_{\theta,i}(a)\Delta_i(a)\right]. \tag{3}$$

在一个实际生成的轨迹批次中，该期望由观测到的有效词元的经验平均来近似。式 3 中的期望记号为理论分析明确给出了轨迹生成时的词元采样规律。

将相对于行为策略的 KL 和学生–教师反向 KL 损失定义为

$$\mathcal{D}_b(\theta) \triangleq \mathbb{E}_{i\sim\nu_b}\left[D_{\text{KL}}\left(p_{\theta,i}\|b_i\right)\right],$$
$$\mathcal{L}_{\text{RKL}}(\theta) \triangleq \mathbb{E}_{i\sim\nu_b}\left[D_{\text{KL}}\left(p_{\theta,i}\|q_i\right)\right].$$

命题 1 (精确的相对 KL 分解)**.** *在上述假设下，对于每个容许的 θ，*

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) = \lambda_{\text{skill}}\left[\mathcal{L}_{\text{RKL}}(\theta) - \mathcal{D}_b(\theta)\right]. \tag{4}$$

令 $\theta_0 = \theta_{\text{old}}$，并假设对每个 i 都有 $p_{\theta_0,i} = b_i$。则

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta_0) = \lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta_0), \tag{5}$$
$$\nabla_\theta \mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0} = \lambda_{\text{skill}}\ \nabla_\theta \mathcal{L}_{\text{RKL}}(\theta)|_{\theta=\theta_0} \tag{6}$$
$$= -\lambda_{\text{skill}} \mathbb{E}_{\substack{i\sim\nu_b \\ a\sim b_i}} \left[\Delta_i(a)\ \nabla_\theta \log p_{\theta,i}(a)|_{\theta=\theta_0}\right]. \tag{7}$$

证明. 固定一个有效词元位置 i。根据公共支撑假设，并将测度从 b_i 变换为 $p_{\theta,i}$，有

$$\begin{aligned}
&-\lambda_{\text{skill}}\mathbb{E}_{a\sim b_i}\left[\rho_{\theta,i}(a)\Delta_i(a)\right] \\
&= -\lambda_{\text{skill}} \sum_{v\in\mathcal{V}} b_i(v)\frac{p_{\theta,i}(v)}{b_i(v)}(\log q_i(v) - \log b_i(v)) \\
&= \lambda_{\text{skill}} \sum_{v\in\mathcal{V}} p_{\theta,i}(v)(\log b_i(v) - \log q_i(v)).
\end{aligned}$$

在求和项中加上再减去 $\log p_{\theta,i}(v)$，得到

$$\begin{aligned}
&\lambda_{\text{skill}} \sum_{v\in\mathcal{V}} p_{\theta,i}(v)\left[\log\frac{p_{\theta,i}(v)}{q_i(v)} - \log\frac{p_{\theta,i}(v)}{b_i(v)}\right] \\
&= \lambda_{\text{skill}}\left[D_{\text{KL}}(p_{\theta,i}\|q_i) - D_{\text{KL}}(p_{\theta,i}\|b_i)\right].
\end{aligned}$$

对 $i\sim\nu_b$ 取平均，即得式 4。

在 θ_0 处，$p_{\theta_0,i} = b_i$，因此

$$\mathcal{D}_b(\theta_0) = 0.$$

这证明了式 5。此外，$\mathcal{D}_b$ 可微，并在 θ_0 处取得全局最小值，因此

$$\nabla_\theta \mathcal{D}_b(\theta)|_{\theta=\theta_0} = 0.$$

因此，对式 4 求导即可证明式 6。

最后，由于 b_i、q_i 和 Δ_i 均与梯度分离，

$$\nabla_\theta \mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) = -\lambda_{\text{skill}} \mathbb{E}_{\substack{i\sim\nu_b \\ a\sim b_i}} \left[\rho_{\theta,i}(a)\Delta_i(a)\nabla_\theta \log p_{\theta,i}(a)\right].$$

代入 $\rho_{\theta_0,i}(a) = 1$，即得式 7。 □

备注 1 (为何 OPID 技能损失并非直接的反向 KL 损失)**.** *缩放后的直接反向 KL 损失为*

$$\lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta) = \lambda_{\text{skill}}\mathbb{E}_{\substack{i\sim\nu_b \\ v\sim p_{\theta,i}}}\left[\log p_{\theta,i}(v) - \log q_i(v)\right],$$

而 OPID 技能损失可以写为

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) = \lambda_{\text{skill}}\mathbb{E}_{\substack{i\sim\nu_b \\ v\sim p_{\theta,i}}}\left[\log b_i(v) - \log q_i(v)\right].$$

这两个表达式之所以不同，是因为与梯度分离的教师优势以轨迹策略 b_i 为分母，而不是以当前学生 $p_{\theta,i}$ 为分母。重要性加权会将采样分布从 b_i 变为 $p_{\theta,i}$，但不会用 $\log p_{\theta,i}$ 替换 $\log b_i$。因此，

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) - \lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta) = -\lambda_{\text{skill}}\mathcal{D}_b(\theta).$$

由此可见，*OPID* 技能损失是一个精确的相对 *KL* 损失，但只是直接学生–教师反向 *KL* 匹配的局部代理目标。

这一区别也会改变全局最优解。例如，考虑

$$b = \left(\frac{1}{2}, \frac{1}{2}\right), \qquad q = \left(\frac{3}{4}, \frac{1}{4}\right).$$

对于类别分布 $p = (p_1, p_2)$，

$$\frac{\mathcal{L}_{\text{skill}}^{\text{unclip}}(p)}{\lambda_{\text{skill}}} = p_1 \log \frac{2}{3} + p_2 \log 2,$$

它关于 p 是线性的，并且当全部概率质量集中到第一个词元时趋近其下确界。相比之下，直接反向 *KL* 损失仅在 $p = q$ 处取得最小值。因此，不能在全局上将这两个损失视为同一损失。

推论 1 (行为策略附近的一阶紧致性)**.** *假设 $p_{\theta,i}$ 在 θ_0 的一个邻域内二阶连续可微。当 $\delta \to 0$ 时，*

$$\begin{aligned}\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta_0 + \delta) = \lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta_0 + \delta) \\ - \frac{\lambda_{\text{skill}}}{2}\delta^\top F_b \delta + o(\|\delta\|^2),\end{aligned} \tag{8}$$

其中

$$F_b \triangleq \mathbb{E}_{\substack{i\sim\nu_b \\ v\sim b_i}}\left[s_i(v)s_i(v)^\top\right],$$
$$s_i(v) \triangleq \nabla_\theta \log p_{\theta,i}(v)|_{\theta=\theta_0}$$

是对轨迹上下文取平均的行为策略 Fisher 信息。

证明. 根据命题 1，缩放后的反向 KL 损失与 OPID 技能损失之间的差恰为 $\lambda_{\text{skill}}\mathcal{D}_b(\theta)$。相对熵在其参考分布附近的标准局部展开给出

$$\mathcal{D}_b(\theta_0 + \delta) = \frac{1}{2}\delta^\top F_b \delta + o(\|\delta\|^2).$$

将这一展开代入式 4，即得式 8。 □

式 8 精确说明了 OPID 技能损失在何种意义下局部等价于反向 KL 蒸馏。在行为策略处，计入因子 λ_{skill} 后，两个损失具有相同的值与梯度，而它们之间的差是策略位移的二阶量。

推论 2 (匹配的行为 KL 惩罚下的精确恢复)**.** *考虑正则化辅助损失*

$$\mathcal{L}_{\text{aux}}(\theta) \triangleq \mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) + \beta\mathcal{D}_b(\theta). \tag{9}$$

则

$$\mathcal{L}_{\text{aux}}(\theta) = \lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta) + (\beta - \lambda_{\text{skill}})\,\mathcal{D}_b(\theta). \tag{10}$$

特别地，若 $\beta = \lambda_{\text{skill}}$，则

$$\mathcal{L}_{\text{aux}}(\theta) = \lambda_{\text{skill}}\mathcal{L}_{\text{RKL}}(\theta)$$

对每个容许的 θ 都成立。

证明. 将式 4 代入式 9，并合并 $\mathcal{D}_b(\theta)$ 的系数。 □

推论 2 中的精确抵消同时要求：(i) 在普通上下文下求值、相对于同一行为分布 b_i 的 KL 惩罚；以及 (ii) 匹配的系数 $\beta = \lambda_{\text{skill}}$。若 KL 惩罚采用不同的参考分布或不同的系数，则式 10 中会留下相对于行为策略的残余项，因而并不精确等价于直接的学生–教师反向 KL 蒸馏。

与实现中的 PPO 裁剪损失的关系。 命题 1 中的分解精确适用于未裁剪技能损失 $\mathcal{L}_{\text{skill}}^{\text{unclip}}$。在实现的 OPID 目标中，PPO 裁剪应用于合并优势

$$A_i^{\text{OPID}} = A_i^{\text{ep}} + \lambda_{\text{skill}} \Delta_i(a_i),$$

因此，完整的裁剪损失无法在全局上分解为独立裁剪的结果损失和技能损失。

不过，在 $\theta_0 = \theta_{\text{old}}$ 处，有

$$\rho_{\theta_0, i}(a) = 1.$$

由于当 $\epsilon > 0$ 时 1 位于 $[1-\epsilon, 1+\epsilon]$ 内部，裁剪策略损失与未裁剪策略损失在行为策略处具有相同的值和一阶导数：

$$\begin{aligned} \mathcal{L}_{\text{policy}}^{\text{clip}}(\theta_0) &= \mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta_0), \\ \nabla_\theta \mathcal{L}_{\text{policy}}^{\text{clip}}(\theta)\Big|_{\theta=\theta_0} &= \nabla_\theta \mathcal{L}_{\text{policy}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0} \\ &= \nabla_\theta \mathcal{L}_{\text{ep}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0} + \nabla_\theta \mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta)\Big|_{\theta=\theta_0}. \end{aligned}$$

因此，式 6 刻画了局部 PPO 更新中由技能诱导的分量。然而，一旦策略比达到裁剪边界，裁剪就会通过合并优势的符号将结果信号与技能信号耦合起来，此时精确的相对 KL 分解不再适用于完整的裁剪目标。

推论 3 (奖励相同时的非退化词元级信号)**.** *固定一个上下文 i，并使用自由类别对数几率值参数化 $p_i = \text{softmax}(z_i)$。将对应的全动作技能损失定义为*

$$\mathcal{L}_{\text{skill},i}^{\text{unclip}}(z_i) \triangleq -\lambda_{\text{skill}} \sum_{v \in \mathcal{V}} p_i(v) \Delta_i(v).$$

当 $\lambda_{\text{skill}} > 0$ 时，

$$\frac{\partial \mathcal{L}_{\text{skill},i}^{\text{unclip}}}{\partial z_i(v)} = -\lambda_{\text{skill}} p_i(v) \left(\Delta_i(v) - \mathbb{E}_{u \sim p_i}[\Delta_i(u)] \right). \tag{11}$$

当 $p_i = b_i$ 且具有全支撑时，式 11 中的梯度对每个 v 都为零，当且仅当 $q_i = b_i$。

证明. 利用

$$\frac{\partial p_i(u)}{\partial z_i(v)} = p_i(u) \left(\mathbf{1}\{u = v\} - p_i(v) \right),$$

可得

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{skill},i}^{\text{unclip}}}{\partial z_i(v)} &= -\lambda_{\text{skill}} \sum_u \Delta_i(u) p_i(u) \left(\mathbf{1}\{u = v\} - p_i(v) \right) \\ &= -\lambda_{\text{skill}} p_i(v) \Delta_i(v) + \lambda_{\text{skill}} p_i(v) \sum_u p_i(u) \Delta_i(u), \end{aligned}$$

这证明了式 11。

假设 $p_i = b_i$，且对每个 v 都有 $b_i(v) > 0$，同时导数对每个 v 都为零。由于 $\lambda_{\text{skill}} > 0$，可知 $\Delta_i(v)$ 在整个词表上为常数。因此

$$q_i(v) = e^c b_i(v)$$

其中 c 为某个常数。q_i 和 b_i 的归一化意味着 $e^c = 1$，因而 $q_i = b_i$。反之显然成立。 □

推论 3 是一个逐上下文的对数几率值结论。它表明，即使所有采样轨迹获得相同奖励，导致组相对结果优势消失，只要 $q_i \neq b_i$，非平凡的技能条件教师仍会提供词元级学习信号。在共享神经网络参数的情况下，不同上下文的梯度仍可能相互抵消；该结果并不声称汇总后的参数梯度一定非零。

A.3 用于蒸馏的在策略占用度匹配

回顾 ν_b 表示由行为策略所收集轨迹诱导的有效词元位置分布。令 d_b 表示相应的普通自回归上下文 c_i 分布，即由 $i \sim \nu_b$ 诱导的上下文边缘分布。对于任意数据收集策略 μ，令 d_μ 表示类似的上下文分布。

我们将全变差定义为

$$\mathrm{TV}(P,Q) \triangleq \sup_A |P(A) - Q(A)| = \frac{1}{2}\int |\mathrm{d}P - \mathrm{d}Q| \,.$$

下面的结果单独刻画仅改变普通自回归上下文分布的影响。它既适用于非负蒸馏损失，也适用于带符号的代理损失。

命题 2 (在策略占用度匹配)**.** 令 $\ell_\theta : \mathcal{C} \to [m_\ell, M_\ell]$ 为可测的逐上下文损失，其中 $-\infty < m_\ell < M_\ell < +\infty$。则

$$\begin{aligned} &\left|\mathbb{E}_{c\sim d_b}\left[\ell_\theta(c)\right] - \mathbb{E}_{c\sim d_\mu}\left[\ell_\theta(c)\right]\right| \\ &\quad\le (M_\ell - m_\ell)\,\mathrm{TV}(d_b, d_\mu) \\ &\quad\le (M_\ell - m_\ell)\sqrt{\frac{1}{2} D_{\mathrm{KL}}(d_b \| d_\mu)}. \end{aligned} \tag{12}$$

特别地，若 $d_\mu = d_b$，则上下文占用度失配恰好为零。

证明. 定义

$$f_\theta(c) \triangleq \frac{\ell_\theta(c) - m_\ell}{M_\ell - m_\ell}.$$

则 $0 \le f_\theta(c) \le 1$。根据值域在 $[0,1]$ 内的可测函数上全变差的变分刻画，

$$\left|\mathbb{E}_{d_b}[f_\theta] - \mathbb{E}_{d_\mu}[f_\theta]\right| \le \mathrm{TV}(d_b, d_\mu).$$

两边同乘 $M_\ell - m_\ell$，即可证明式 12 中的第一个不等式。第二个不等式由 Pinsker 不等式得到。若 d_b 关于 d_μ 不绝对连续，则 $D_{\mathrm{KL}}(d_b\|d_\mu) = +\infty$，该不等式在扩展实数意义下仍然成立。令 $d_\mu = d_b$，即得最后的结论。 □

例如，命题 2 可应用于逐上下文反向 KL 损失

$$\ell_{\mathrm{RKL},\theta}(c_i) \triangleq D_{\mathrm{KL}}\left(p_{\theta,i} \| q_i\right),$$

它是 OPID 技能更新在局部近似的分布匹配损失。该命题还可应用于带符号的逐上下文 OPID 技能损失的有界版本

$$\begin{aligned} \ell^{\mathrm{unclip}}_{\mathrm{skill},\theta}(c_i) &\triangleq -\lambda_{\mathrm{skill}} \mathbb{E}_{a\sim b_i}\left[\rho_{\theta,i}(a)\Delta_i(a)\right] \\ &= \lambda_{\mathrm{skill}}\left[D_{\mathrm{KL}}\left(p_{\theta,i}\|q_i\right) - D_{\mathrm{KL}}\left(p_{\theta,i}\|b_i\right)\right]. \end{aligned} \tag{13}$$

由于式 13 中的损失带有符号，且对任意概率分布未必一致有界，因此将命题 2 应用于该损失需要一个显式的有界值域条件，例如概率下限、对数比裁剪，或将参数限制在紧邻域内。在适当的矩条件或尾部条件下，也可以得到更一般的版本。

命题 2 只控制普通自回归上下文外层分布的失配。它假设在 d_b 和 d_μ 下求值的是同一个逐上下文损失映射。该命题本身并不控制事后技能、经路由的教师 q_i，或其他也可能随数据收集策略变化的轨迹依赖量的变化。

A.4 关键优先的分层路由

下面形式化说明回合级技能和步骤级技能如何确定 $\mathcal{L}^{\mathrm{unclip}}_{\mathrm{skill}}$ 中使用的、与梯度分离的教师 q_i。

令 $q_i^\star$ 表示词元位置 i 上的理想特权教师。令 q_i^{ep} 和 q_i^{step} 分别表示由回合级技能和步骤级技能诱导的教师。令

$$z_i^\star \in \{0,1\}$$

为预言机关键性指示变量，其中 $z_i^\star = 1$ 表示步骤级教师是合适的专门化教师。分析器的预测为

$$\widehat{z}_i \triangleq \mathbf{1}\{t \in C_\tau\}.$$

关键优先路由规则定义

$$q_i^{\text{route}} \triangleq \widehat{z}_i q_i^{\text{step}} + (1-\widehat{z}_i)\, q_i^{\text{ep}}, \qquad q_i \equiv q_i^{\text{route}}. \tag{14}$$

因此，OPID 技能优势 $\Delta_i(v) = \log q_i(v) - \log b_i(v)$ 中出现的 q_i 正是式 14 中经路由的教师。

用下式衡量两个候选教师的近似误差：

$$\begin{aligned} \mathcal{E}_i^{\text{ep}} &\triangleq D_{\text{KL}}\left(q_i^\star \| q_i^{\text{ep}}\right), \\ \mathcal{E}_i^{\text{step}} &\triangleq D_{\text{KL}}\left(q_i^\star \| q_i^{\text{step}}\right), \\ \mathcal{E}_i^{\text{route}} &\triangleq D_{\text{KL}}\left(q_i^\star \| q_i^{\text{route}}\right). \end{aligned} \tag{15}$$

由于路由决策是硬决策，

$$\mathcal{E}_i^{\text{route}} = \widehat{z}_i \mathcal{E}_i^{\text{step}} + (1-\widehat{z}_i)\, \mathcal{E}_i^{\text{ep}}.$$

命题 3 (路由最优性与检测器错误遗憾)**.** 假设回合级教师和步骤级教师依据预言机关键性标签进行专门化：

$$\begin{aligned} z_i^\star = 1 &\implies \mathcal{E}_i^{\text{step}} \le \mathcal{E}_i^{\text{ep}}, \\ z_i^\star = 0 &\implies \mathcal{E}_i^{\text{ep}} \le \mathcal{E}_i^{\text{step}}. \end{aligned} \tag{16}$$

则逐点有

$$\begin{aligned} \mathcal{E}_i^{\text{route}} = \min &\left\{\mathcal{E}_i^{\text{ep}}, \mathcal{E}_i^{\text{step}}\right\} \\ &+ \mathbf{1}\left\{\widehat{z}_i \neq z_i^\star\right\} \left|\mathcal{E}_i^{\text{ep}} - \mathcal{E}_i^{\text{step}}\right|. \end{aligned} \tag{17}$$

因此，若

$$\left|\mathcal{E}_i^{\text{ep}} - \mathcal{E}_i^{\text{step}}\right| \le \Gamma \tag{18}$$

在 $i \sim \nu_b$ 下几乎必然成立，则

$$\begin{aligned} \mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{route}}\right] \le \min &\left\{\mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{ep}}\right], \mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{step}}\right]\right\} \\ &+ \Gamma \Pr_{i\sim\nu_b}\left(\widehat{z}_i \neq z_i^\star\right). \end{aligned} \tag{19}$$

在关键性检测完全正确时，

$$\widehat{z}_i = z_i^\star \qquad \textit{almost surely},$$

因此

$$\mathcal{E}_i^{\text{route}} = \min\left\{\mathcal{E}_i^{\text{ep}}, \mathcal{E}_i^{\text{step}}\right\}$$

逐点成立，且

$$\mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{route}}\right] \le \min\left\{\mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{ep}}\right], \mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{step}}\right]\right\}.$$

证明. 首先考虑事件 $\widehat{z}_i = z_i^\star$。根据式 16，路由规则会选择近似误差较小的教师。因此

$$\mathcal{E}_i^{\text{route}} = \min\left\{\mathcal{E}_i^{\text{ep}}, \mathcal{E}_i^{\text{step}}\right\}.$$

在该事件上，式 17 中的第二项为零。

在事件 $\widehat{z}_i \neq z_i^\star$ 上，路由规则选择了非专门化教师。相对于预言机选择，它的额外误差恰为

$$\left|\mathcal{E}_i^{\text{ep}} - \mathcal{E}_i^{\text{step}}\right|.$$

这证明了式 17。

取期望可得

$$\begin{aligned} \mathbb{E}_{i\sim\nu_b}\left[\mathcal{E}_i^{\text{route}}\right] = &\mathbb{E}_{i\sim\nu_b}\left[\min\left\{\mathcal{E}_i^{\text{ep}}, \mathcal{E}_i^{\text{step}}\right\}\right] \\ &+ \mathbb{E}_{i\sim\nu_b}\left[\mathbf{1}\left\{\widehat{z}_i \neq z_i^\star\right\} \left|\mathcal{E}_i^{\text{ep}} - \mathcal{E}_i^{\text{step}}\right|\right]. \end{aligned}$$

利用

$$\mathbb{E}[\min\{X, Y\}] \le \min\{\mathbb{E}[X], \mathbb{E}[Y]\}$$

并结合式 18，即可证明式 19。令 $\Pr_{i\sim\nu_b}(\widehat{z}_i \neq z_i^\star) = 0$，即可得到完全正确检测时的结论。 □

命题 3 将关键优先路由背后的两个要求区分开来：教师专门化与关键性检测准确度。在满足专门化条件时，完全正确的检测能够恢复预言机在两个候选教师之间的逐点选择。当检测不完全正确时，额外的教师近似误差由检测器错误概率与两个候选教师误差之差共同控制。

式 15 中的准则衡量候选教师相对于 $q_i^\star$ 的质量。它不同于 $\mathcal{L}_{\text{RKL}}$ 中出现的学生–教师反向 KL 损失 $D_{\text{KL}}(p_{\theta,i}\|q_i)$。因此，若没有额外假设将候选教师的似然比联系起来，就不应将该路由结果解释为 $\mathcal{L}_{\text{RKL}}$ 的直接上界。

A.5 总结

命题 1 分析了 OPID 策略损失中的未裁剪技能分量：

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) = -\lambda_{\text{skill}} \mathbb{E}_{\substack{i\sim\nu_b \\ a\sim b_i}} \left[\rho_{\theta,i}(a)\Delta_i(a)\right].$$

在固定轨迹历史、经路由的技能以及与梯度分离的分布 b_i 和 q_i 条件下，该损失具有如下精确分解：

$$\mathcal{L}_{\text{skill}}^{\text{unclip}}(\theta) = \lambda_{\text{skill}} \left[\mathcal{L}_{\text{RKL}}(\theta) - \mathcal{D}_b(\theta)\right].$$

命题 2 表明，以在策略方式收集普通自回归上下文可消除外层上下文分布失配：当收集分布等于行为策略分布，即 $d_\mu = d_b$ 时，式 12 中的占用度项为零。

命题 3 分析了如何从回合级和步骤级候选教师中选择教师 q_i。在所述专门化假设下，关键优先路由会在检测完全正确时恢复误差较低的候选教师；而在检测不完全正确时，性能下降由下式控制：

$$\Gamma \Pr_{i\sim\nu_b}\left(\widehat{z}_i \neq z_i^\star\right).$$

综合而言，这三个结果表明：

1. 未裁剪 OPID 技能损失是一个精确的相对 KL 损失，并且在行为策略处与缩放后的反向 KL 蒸馏一阶等价；
2. 在策略收集消除了普通自回归上下文外层分布的失配；以及
3. 当候选教师具有专门化能力且关键性检测器准确时，关键优先路由会逼近预言机的候选教师选择。

B 补充实验细节

本节给出正文结果所采用的实验协议。我们按数据集、基线和实现来组织各项细节。

B.1 数据集

表 4 汇总了实验所用的数据集。评估涵盖三个智能体领域：具身推理、网页导航和搜索增强问答。

表 4：智能体基准的详细信息。

领域	基准	训练样本数	测试样本数
具身推理	ALFWorld	2,400	140（已见划分） 134（未见划分）
网页导航	WebShop	2,400	128
搜索增强问答	NQ、TriviaQA、PopQA、HotpotQA、2WikiMultiHopQA、MuSiQue 和 Bamboogle	19,200	51,713

ALFWorld。 ALFWorld (Shridhar 等, 2020) 将基于文本的交互与 ALFRED 家居环境对齐。给定一个自然语言目标和文本观察，智能体必须发出一系列允许的动作来完成任务。我们报告六类任务上的结果：拾取、查看、清洁、加热、冷却和拾取两个物体。

WebShop。 WebShop (Yao 等, 2022) 是一个基于文本的电子商务环境，其中智能体搜索商品、打开商品页面、选择属性，并购买满足自然语言请求的商品。该环境同时提供归一化任务完成得分和二元成功信号；前者会为匹配所请求的属性给出部分得分，后者表示任务是否被准确完成。

搜索增强问答。 遵循 Search-R1 设置 (Jin 等, 2025)，我们在 Natural Questions (Kwiatkowski 等, 2019)、TriviaQA (Joshi 等, 2017)、PopQA (Mallen 等, 2023)、HotpotQA (Yang 等, 2018)、2WikiMultiHopQA (Ho 等, 2020)、MuSiQue (Trivedi 等, 2022) 和 Bamboogle (Press 等, 2023) 上评估搜索增强推理。在此设置中，智能体先与配置好的搜索环境交互，再生成最终答案。

训练数据。 在训练阶段，我们针对每个基准设置分别进行训练。具体而言，我们从 ALFWorld 中采样 2,400 个训练样本，从 WebShop 中采样 2,400 个训练样本，并从搜索增强问答基准中采样 19,200 个训练样本。

B.2 基线

我们将 OPID 与仅使用提示的方法、基于结果的强化学习方法，以及自蒸馏或技能蒸馏变体进行比较。除非明确标有星号，否则所有方法都仅基于普通的环境交互历史进行评估，无法访问技能或任何其他特权上下文。因此，星号表示在验证/测试时可以使用自然语言技能，并不表示采用了不同的主干模型或评估任务。

仅使用提示的方法。

- *Vanilla*。这是未经任何后训练的原始指令微调主干模型。模型只接收标准环境提示，以及环境接口提供的交互历史。
- *Skill-Prompt**。该方法冻结 *Vanilla* 的参数，但在验证/测试上下文中加入与当前任务相关的检索自然语言技能。由于不进行梯度更新，任何提升都完全来自对技能的上下文内使用。

基于结果的强化学习。

- *GRPO* (Shao 等, 2024)。组相对策略优化是一种无需评论器的策略梯度方法：它为每个任务采样一组轨迹，为每条轨迹赋予一个标量结果奖励，并在组内归一化这些奖励以构造相对优势。在本文采用的仅结果信号设置中，一条轨迹内的每个生成词元都继承相同的序列级优势，并使用裁剪后的重要性比率目标更新策略；不使用过程标签或教师生成的词元级目标。
- *Skill-GRPO*。该变体使用与 *GRPO* 相同的组相对结果目标，但在训练轨迹采样和策略更新期间向策略提供与任务相关的自然语言技能。因此，该技能能够塑造探索过程以及获得强化的轨迹。技能会在验证/测试时被移除，因而该基线检验的是技能引导的行为是否已经被吸收到模型参数中，而不仅仅是模型在遵循提示。
- *Skill-GRPO**。该方法的训练方式与 *Skill-GRPO* 相同，但在验证/测试时保留技能上下文。因此，其训练时和测试时的条件保持一致。

自蒸馏与技能蒸馏方法。

- *OPSD* (Zhao 等, 2026)。在策略自蒸馏从同一个底层模型实例化学生和教师，但向二者提供不同的条件上下文。学生从普通任务上下文中在策略采样轨迹，而教师还会接收仅在训练时可用的特权信息，例如经验证的解答或等价的辅助上下文。对于学生自身轨迹的每个前缀，教师重新计算下一词元分布的得分，并通过全词表或采样词元的分布匹配提供稠密的词元级目标。梯度施加于学生一侧，教师分布则被视作停止梯度的目标；教师使用的特权上下文在推理时不可用。
- *GRPO+OPSD*。这是序列级 *GRPO* 损失与词元级 *OPSD* 损失的直接多目标组合。结果项根据环境反馈强化或惩罚完整轨迹，蒸馏项则在各个词元位置提供局部指导。两个损失被简单组合，因此该基线可用于受控检验：在基于结果的强化学习中直接加入稠密自蒸馏是否已经足够。
- *Skill-SD* (Wang 等, 2026)。该方法将自蒸馏适配到多轮智能体任务。已完成的轨迹被总结成紧凑的自然语言技能，记录成功行为、常见失败模式和可复用的高层流程。在训练期间，检索到的技能只对教师分支进行条件化，学生则继续从普通任务提示中生成在策略轨迹；因此，学生必须将教师侧的指导内化，而不能在测试时依赖该技能。
- *RLSD* (Yang 等, 2026)。RLSD 使用特权自教师进行细粒度信用分配，但不直接优化教师–学生分布匹配损失。它将逐词元的教师–学生对数概率差转化为有界权重，用

来调节各词元 GRPO 更新的幅度，而更新的正负和方向仍由环境产生的结果优势决定。因此，特权信息可以指示哪些位置适合进行更大或更小的更新，却不能决定应该强化还是惩罚某个采样词元。在原始方案中，自蒸馏的贡献在训练早期最强，之后按计划逐渐衰减到普通 GRPO，从而将早期稠密指导与稳定的结果优化训练阶段相结合。

- *SDAR* (Lu 等, 2026a)。该方法保留验证器驱动的 GRPO 作为主要优化骨干，并为多轮智能体加入一个单独门控的自蒸馏目标。教师分支接收仅在训练时可用的特权上下文（例如检索技能），并重新计算学生在策略词元的得分；随后，一个平滑、有界的词元级门控制各个教师信号以多大强度进入辅助损失。该门可以利用学生的不确定性和/或分离梯度后的教师–学生对数概率差，对教师的正向认可赋予更高权重，同时柔和减弱可能不可靠的负向拒绝。与 *RLSD* 不同，SDAR 保持 GRPO 优势本身不变，转而调节辅助蒸馏损失；学生在没有特权技能上下文的情况下接受评估。

对于所有复现的后训练基线，我们使用与 OPID 相同的主干模型和环境封装，并在适用情况下保持轨迹采样预算、任务批次、训练步数和评估协议一致。预期差异仅限于优化信号，以及明确说明的技能或其他特权训练上下文的可用性。

B.3 算法与提取技能示例

算法 1 给出了完整的 OPID 训练过程，包括在策略轨迹收集、分层技能提取、关键优先路由、成对评分和裁剪策略优化。表 5 给出了从 ALFWorld、WebShop 和基于搜索的问答任务的成功与失败轨迹中提取的代表性技能。这些示例说明了回合级技能如何捕捉可复用的全局流程，而关键步骤技能则聚焦于影响最终结果的稀疏局部决策。

表 5: **从在策略轨迹中提取的分层技能**。对于每个数据集，我们各展示一条成功轨迹和一条失败轨迹。回合级技能总结可复用的全局行为，而关键步骤技能聚焦于稀疏决策点。步骤索引是从 0 开始的分析器键。

数据集	结果	任务	回合级技能	关键步骤技能
ALFWorld	成功	清洁一个水壶并将其放进橱柜。	流程：首先找到并拿起目标物体，然后移动到清洁处（水槽）清洁它，再前往合适的存放位置（橱柜）；如果橱柜关闭，则将其打开，最后把物体放进去。	**t=0** 直接前往台面或水壶可能所在的表面。 **t=2** 拿到水壶后，立即前往水槽进行清洁。 **t=4** 清洁后前往橱柜（橱柜 1），不要停顿。 **t=6** 如有需要，先打开关闭的橱柜，再把物体放进去。
ALFWorld	失败	将一块干净的肥皂放进推车。	先确认肥皂干净，再将其放进推车。核心错误是忽视清洁要求；警示信号是在未检查或清洁肥皂的情况下反复移动它。	**t=1** 拿起并检查肥皂，确定是否需要清洁。 **t=2** 如果肥皂很脏，先使用水槽或适当工具清洁，再移向推车。
WebShop	成功	请帮我寻找适合敏感肌肤的卸妆产品，款式为 lagom 五层化妆棉，价格低于 40.00 美元。	广泛搜索具体商品名称和关键约束，然后点击第一个匹配的商品结果查看详情，核实属性与价格，再点击“立即购买”完成购买。	**t=1** 首先点击最相关的商品结果（LAGOM 化妆棉），查看其详情页。
WebShop	失败	寻找带钢制框架和储物空间、棕色、带搁板的茶几，价格低于 $110。	核心错误：未确认商品带有钢制框架就进行购买。警示信号：商品标题未提及“钢制框架”；搜索结果包含许多无关商品；商品页面显示了颜色和尺寸筛选项，却没有框架材质。不要依赖部分匹配；完成购买前务必核实所有指定属性，尤其是材质。	**t=1** 点击商品前，检查其标题是否明确提到钢制框架或其他必需属性。 **t=2** 在商品页面上点击“描述”或“特性”，核实钢制框架和搁板尺寸后，再点击“立即购买”。
搜索问答	成功	谁为 Hunter S. Thompson 的小说《恐惧与厌恶在拉斯维加斯》绘制了插图?	流程：首先使用核心实体（作者/书名）进行查询以收集上下文；如果初次搜索未给出直接答案，则专门针对所需属性（插画师）改写查询，并从新结果中提取答案。	**t=1** 如果初次搜索结果未直接回答问题，则改写搜索查询，专门针对缺失的属性（此处为“插图作者”）。
搜索问答	失败	由 Jesse Feras Klaver 领导的政党 GroenLinks 的完整成立日期是什么?	不要忽视关键的时间精度；当任务要求具体日期时，应搜索或提取完整日期，而不只是年份，即使年份最初更为醒目。警示信号：文档包含更精确信息时，却只用年份作答。	**t=2** 从关于 GroenLinks 的文档中提取完整成立日期，而不只是年份。

算法 1 OPID：在策略技能蒸馏

输入： 策略 π_θ，任务集合 $\mathcal{Q}$，分析器 $\mathcal{A}$，技能注入函数 H，组大小 N，技能系数 λ_{skill}，截断参数 ϵ，学习率 η

对于 每轮训练迭代 **执行**
  $\theta_{\text{old}} \leftarrow \theta$
  从 $\mathcal{Q}$ 中采样一批任务提示 $\mathcal{B}$
  对于 每个提示 $q \in \mathcal{B}$ **执行**
    // 在策略采样轨迹组与回合优势
    采样 $\mathcal{G}_q \leftarrow \{\tau^{(1)}, \ldots, \tau^{(N)}\}$，其中 $\tau^{(i)} \sim \pi_{\theta_{\text{old}}}(\cdot \mid q)$
    $\mathbf{r}_q \leftarrow \{R(\tau') \mid \tau' \in \mathcal{G}_q\}$; $\mu_q \leftarrow \text{mean}(\mathbf{r}_q)$; $\sigma_q \leftarrow \text{std}(\mathbf{r}_q)$
    对于 每条轨迹 $\tau \in \mathcal{G}_q$ **执行**
      $A^{\text{ep}}_\tau \leftarrow \big(R(\tau) - \mu_q\big)/\sigma_q$
      // 层次化事后技能提取
      $\big(s^{\text{ep}}_\tau, \{s^{\text{step}}_{\tau,t}\}_{t \in \mathcal{C}_\tau}\big) \leftarrow \mathcal{A}(\tau)$
      // 关键步骤优先的路由与配对评分
      对于 轨迹 τ 中的每个交互步骤 t **执行**
        $s_{\tau,t} \leftarrow \begin{cases} s^{\text{step}}_{\tau,t}, & t \in \mathcal{C}_\tau, \\ s^{\text{ep}}_\tau, & \text{otherwise} \end{cases}$
        $\tilde{h}_{\tau,t} \leftarrow H(h_{\tau,t}, s_{\tau,t})$
        对于 $y_{\tau,t}$ 中掩码为 $m_{\tau,t,\ell}$ 的每个词元 ℓ **执行**
          $\ell^{\text{old}}_{\tau,t,\ell} \leftarrow \log \pi_{\theta_{\text{old}}}(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell})$
          $\ell^{\text{skill}}_{\tau,t,\ell} \leftarrow \log \pi_{\theta_{\text{old}}}(y_{\tau,t,\ell} \mid \tilde{h}_{\tau,t}, y_{\tau,t,<\ell})$
          $A^{\text{skill}}_{\tau,t,\ell} \leftarrow (\ell^{\text{skill}}_{\tau,t,\ell} - \ell^{\text{old}}_{\tau,t,\ell}) m_{\tau,t,\ell}$
          $A^{\text{ep}}_{\tau,t,\ell} \leftarrow A^{\text{ep}}_\tau m_{\tau,t,\ell}$
          $A^{\text{OPID}}_{\tau,t,\ell} \leftarrow A^{\text{ep}}_{\tau,t,\ell} + \lambda_{\text{skill}} A^{\text{skill}}_{\tau,t,\ell}$
        结束 对于
      结束 对于
    结束 对于
  结束 对于
  // 截断策略优化
  对每个有效采样词元 (τ, t, ℓ)，计算
  $\rho_{\tau,t,\ell}(\theta) \leftarrow \exp(\log \pi_\theta(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell}) - \log \pi_{\theta_{\text{old}}}(y_{\tau,t,\ell} \mid h_{\tau,t}, y_{\tau,t,<\ell}))$
  $\mathcal{L}_{\text{policy}}(\theta) \leftarrow -\mathbb{E}_{\tau,t,\ell}\Big[\min\Big(\rho_{\tau,t,\ell}(\theta) A^{\text{OPID}}_{\tau,t,\ell}, \text{clip}(\rho_{\tau,t,\ell}(\theta), 1-\epsilon, 1+\epsilon) A^{\text{OPID}}_{\tau,t,\ell}\Big)\Big]$
  $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}_{\text{policy}}(\theta)$
结束 对于

B.4 实现细节

指标。 对于 ALFWorld，我们计算各任务类型的成功率并报告其宏平均：

$$\text{ALFWorld-Avg} = \frac{1}{6}\sum_{c=1}^{6} \text{SR}_c. \tag{20}$$

对于基于搜索的问答，我们分别计算七个数据集上的答案准确率，并报告不加权宏平均：

$$\text{Search-Avg} = \frac{1}{7}\sum_{d=1}^{7} \text{Acc}_d. \tag{21}$$

对于 WebShop，所报告的得分是环境返回的归一化任务得分均值乘以 100，成功率则是被准确完成的任务所占百分比。

轨迹分析器。 每个在策略回合终止后，我们将任务提示、带步骤索引的观察、策略响应/动作、环境反馈和终止结果序列化成一条有序轨迹记录。随后，基于大语言模型的分析器将该记录映射为一个回合级技能和一组稀疏的关键步骤技能。步骤索引从零开始，与表 5 一致。默认情况下，我们使用 GLM-5.2 (Z.ai, 2026) 作为分析器，温度设为 0.4，最大输出长度设为 4096。对于 ALFWorld 和 WebShop，我们将识别出的关键步骤数上限设为 5；对于基于搜索的问答，则设为 2。

表 6: 强化学习训练超参数。

超参数	取值
训练步数	150
训练批大小	ALFWorld 和 WebShop 为 16；搜索问答为 128
轨迹采样组大小 N	8
学习率	1×10^{-6}
PPO 裁剪参数 ϵ	0.2
技能系数 λ_{skill}	0.001
KL 正则化系数	0.01
最大提示长度	ALFWorld 为 2,048；WebShop 和搜索问答为 4,096
响应长度	512
最大交互步数	ALFWorld 为 30，WebShop 为 15，搜索问答为 4。

主干模型与训练计划。 我们使用 Qwen2.5-3B-Instruct 和 Qwen2.5-7B-Instruct (Yang 等, 2024)，以及 Qwen3-1.7B-Instruct (Yang 等, 2025)。所有模型均训练 150 个更新步。正文所报告的训练批大小在 ALFWorld 和 WebShop 上为 16，在基于搜索的问答上为 128。精确复现所需的其余超参数见表 6。

计算细节。 训练在 8 块 Nvidia A800 80G GPU 上进行。

C 补充结果

C.1 详细样本效率比较

表 7 报告了仅使用部分训练数据时的 ALFWorld 成功率。在所有数据预算下，OPID 均持续优于 GRPO。在低数据量和中等数据量区域，提升尤其显著：使用 60% 的数据时提高 +15.6 个百分点，使用 80% 的数据时提高 +20.3 个百分点。这些结果表明，轨迹衍生的事后技能使 OPID 能够从每次轨迹采样中提取更多监督，从而降低基于结果的强化学习对大量环境交互的依赖。

表 7: **ALFWorld 上的样本效率比较**。我们报告使用不同比例训练数据时的成功率。Δ 行表示 OPID 相对 GRPO 的绝对提升，说明 OPID 尤其能在低数据量和中等数据量区域带来更大收益。

方法	20%	40%	60%	80%	100%
GRPO	27.3	42.2	56.3	58.6	75.0
OPID	36.7	54.7	71.9	78.9	84.3
Δ	+9.4	+12.5	+15.6	+20.3	+9.3

C.2 跨域泛化

表 8 评估了向 ALFWorld 未见划分的迁移。OPID 的平均成功率比 GRPO 高 +7.7 个百分点，在查看和加热任务上的提升尤为明显。这表明 OPID 并非只是拟合观察到的训练轨迹；相反，蒸馏出的回合级流程和步骤级决策规则在未见环境配置下仍然具有价值。

C.3 训练诊断与技能提取模式

图 7–9 为 OPID 训练流水线提供了额外诊断。图 7 报告了在 ALFWorld 上识别出的平均关键步骤数，说明 OPID 以稀疏方式施加步骤级监督，而不是为每个决策分配局部技能。图 8 进一步可视化了训练优势的动态变化，作为正文训练曲线的补充，并展示 OPID 如何在策略优化期间重塑学习信号。图 9 给出了用于将已完成轨迹转化为分层技能的分析器提示。

表 8: **ALFWorld 未见划分上的跨域泛化结果**。我们报告六种未见任务类型上的成功率及其平均值。OPID 的平均成功率高于 GRPO，说明轨迹衍生的技能监督能够迁移到训练环境之外。

	ALFWorld 未见划分						
方法	**拾取**	**查看**	**清洁**	**加热**	**冷却**	**拾取二物**	**平均**
ReAct	17.4	6.7	8.8	7.4	9.1	0.0	8.2
GRPO	73.9	60.0	**82.4**	59.3	72.7	**76.9**	70.9
OPID	**78.3**	**86.7**	**82.4**	**77.8**	**77.3**	69.2	**78.6**
Δ	+4.4	+26.7	+0.0	+18.5	+4.6	-7.7	+7.7

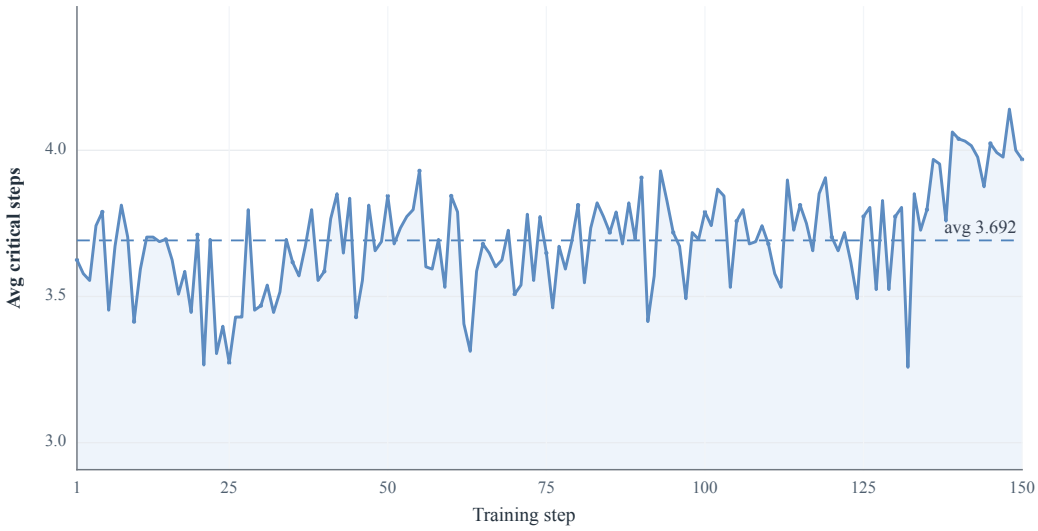


图 7: **ALFWorld 上每个序列的平均关键步骤数**。该曲线给出了分析器在每条轨迹中为步骤级事后技能选出的时间步数量。关键步骤数量相对较少，说明 OPID 有选择地施加局部技能监督，同时将回合级技能作为非关键决策的默认指导。

D 案例研究

图 10–15 给出了来自 ALFWorld、基于搜索的问答和 WebShop 基准的示例。

E 补充讨论

OPID 研究如何将已完成的在策略轨迹复用为长时程智能体强化学习的事后监督。一个自然的下一步是在更广泛的交互环境中评估这一思路；在这些环境中，智能体必须发现潜在规则、维持长期状态，并通过长时间交互进行适应。OdysseyArena (Xu 等, 2026)、AgentBench (Liu 等, 2023)、WebArena (Zhou 等, 2023)、Mind2Web (Deng 等, 2023) 和 VisualWebArena (Koh 等, 2024) 等基准提供了互补的压力测试，超出了本文考虑的具身、购物和搜索设置。这些环境可以检验：当智能体必须处理更长时程、更丰富的界面以及更开放的探索形式时，轨迹衍生的事后技能是否仍然有效。

另一个方向是丰富事后技能的结构。OPID 目前从已完成轨迹中提取回合级和步骤级技能，并根据决策的关键程度对其进行路由。未来工作可以将这种在策略提取与更高层的推理抽象相结合，例如通过搜索发现的推理模式或可复用的思维结构 (Wu 等, 2024)，还可以结合为长时程智能体学习开发的策略感知探索机制 (Wu 等, 2026a; Lu 等, 2026a)。这类扩展或许能



图 8: **OPID 训练期间回合级与技能引导优势信号的幅度**。回合绝对优势衡量由组相对结果奖励产生的平均绝对优势，技能绝对优势则衡量由技能引导的对数概率变化所产生的平均绝对优势。该比较展示了 OPID 如何在整个优化过程中结合稀疏的轨迹级反馈与稠密的技能条件监督。

使智能体跨轨迹聚合技能、识别反复出现的失败模式，并形成更具组合性的行为规则，同时保留 OPID 的关键设计选择：技能用于塑造训练，而不是在推理时作为特权上下文被检索。

最后，OPID 还开辟了若干部署导向的研究方向。由于分析器和技能条件评分仅在训练期间使用，学习到的策略不会产生额外的推理时技能检索成本。尽管如此，训练流水线仍可从更高效的推理与评分机制中受益。DOUBLE (Shen 等, 2026) 等推测式和检索并行解码方法可能降低技能条件蒸馏期间重复进行模型评分的成本。与此同时，将 OPID 扩展到感知更丰富的具身设置，包括 RobotEQ (Fang 等, 2026) 等主动具身智能基准，可以检验事后技能监督能否帮助智能体不仅习得任务完成策略，还习得建立在社会与空间情境上的决策规则。

Analyser Prompt

Analyze the following agent episode and return ONLY valid JSON.

You need to complete all three fields:
1. Write a concise episode_summary.
2. Write one episode_skill that extracts the successful trajectory into workflow: the core decision rule and action ordering that made this trajectory work. / Write one episode_skill that extracts the failed trajectory into avoidance rules: the core mistake and warning signs that agent should avoid.
3. Provide concise, action-oriented decision guidance for at most {max_skill_count} critical step(s) from the candidate set as entries in step_skills; use the full episode to infer the guidance, but phrase each skill as advice the policy can act on at that step.

Important constraints:
- Step indexing is 0-based: step 0 is the first step of the trajectory.
- Use the task description together with the episode context to judge progress and mistakes.
- Use the full episode context to identify what each critical step should have done better.
- Each step_skills value should be one short imperative sentence for the policy at that step.
- Write step_skills as policy-facing guidance, not as retrospective explanation of the trajectory.
- Return only these top-level fields: episode_summary, episode_skill, step_skills.
- The chosen steps are exactly the keys present in step_skills.

Return format:
```
{
    "episode_summary": "string",
    "episode_skill": "string",
    "step_skills": {
        "0": "skill for step 0",
        "2": "skill for step 2"
    }
}
```

Episode context:
- Task description: {task_description}
- episode_success: {outcome_label}
- Candidate step indices: {candidate_step_indices}
- Interaction trajectory: {formatted_episode_steps}

图 9: 分析器的提示。

A trajectory of an agent trained with OPID — ALFWorld

Task: *clean some spatula and put it in diningtable*

[Step 1]
Observation: -= Welcome to TextWorld, ALFRED! =- You are in the middle of a room. Looking quickly around you, you see a cabinet 20, a cabinet 19, a cabinet 18, a cabinet 17, a cabinet 16, a cabinet 15, a cabinet 14, a cabinet 13, a cabinet 12, a cabinet 11, a cabinet 10, a cabinet 9, a cabinet 8, a cabinet 7, a cabinet 6, a cabinet 5, a cabinet 4, a cabinet 3, a cabinet 2, a cabinet 1, a coffeemachine 1, a countertop 2, a countertop 1, a diningtable 2, a diningtable 1, a drawer 6, a drawer 5, a drawer 4, a drawer 3, a drawer 2, a drawer 1, a fridge 1, a garbagecan 1, a microwave 1, a sinkbasin 1, a stoveburner 4, a stoveburner 3, a stoveburner 2, a stoveburner 1, and a toaster 1.
Reasoning: I need to put two winebottle in cabinet. First, I should check where the winebottle are. Let's look around to see if I can find any winebottle. I'll start by checking the diningtables, countertops, and sinkbasin.
Action: go to diningtable 1

[Step 2]
Observation: You arrive at diningtable 1. On the diningtable 1, you see a butterknife 1, a cup 1, a egg 1, a fork 1, a glassbottle 2, a glassbottle 1, a lettuce 1, a mug 1, a pan 1, a pen 3, a pen 2, a pen 1, a peppershaker 1, a saltshaker 2, a saltshaker 1, a soapbottle 1, a spatula 3, a spatula 2, a spatula 1, a spoon 1, and a tomato 1.
Reasoning: I need to clean the spatula and put it in the diningtable. The first step is to locate the spatula. Looking at the current observation, there are several spatulas on the diningtable: spatula 1, spatula 2, and spatula 3. I should take one of these spatulas. The most straightforward action is to take spatula 1 from the diningtable.
Action: take spatula 1 from diningtable 1

[Step 3]
Observation: You pick up the spatula 1 from the diningtable 1.
Reasoning: I need to clean the spatula and put it in the diningtable. I already have the spatula 1 in my inventory. Next, I should clean it. The most straightforward way to clean a spatula is to use the sinkbasin. I will go to the sinkbasin and clean the spatula.
Action: go to sinkbasin 1

[Step 4]
Observation: You arrive at sinkbasin 1. On the sinkbasin 1, you see a butterknife 2, a potato 1, and a spoon 2.
Reasoning: I need to clean the spatula and put it in the diningtable. I already have the spatula in my inventory, and I'm at the sinkbasin. The next step is to clean the spatula using the sinkbasin. The appropriate action is to clean the spatula with the sinkbasin.
Action: clean spatula 1 with sinkbasin 1

[Step 5]
Observation: You clean the spatula 1 using the sinkbasin 1.
Reasoning: I need to put the cleaned spatula in the diningtable. I already have the spatula cleaned in the sinkbasin, so the next step is to go back to the diningtable and put the spatula there. The admissible actions include \"go to diningtable 1\". I will take that action.
Action: go to diningtable 1

[Step 6]
Observation: You arrive at diningtable 1. On the diningtable 1, you see a butterknife 1, a cup 1, a egg 1, a fork 1, a glassbottle 2, a glassbottle 1, a lettuce 1, a mug 1, a pan 1, a pen 3, a pen 2, a pen 1, a peppershaker 1, a saltshaker 2, a saltshaker 1, a soapbottle 1, a spatula 3, a spatula 2, a spoon 1, and a tomato 1.
Reasoning: I need to clean the spatula and put it in the diningtable. I already have the spatula in my inventory, it's clean, and I'm at the diningtable. The next step is to put the cleaned spatula in the diningtable. The admissible actions include \"move spatula 1 to diningtable 1\". I will take that action.
Action: move spatula 1 to diningtable 1

图 10: OPID 在 ALFWorld 示例 1 上的完整轨迹。

A trajectory of an agent trained with OPID — ALFWorld

Task: *put two winebottle in cabinet*

[Step 1]
Observation: -= Welcome to TextWorld, ALFRED! =- You are in the middle of a room. Looking quickly around you, you see a cabinet 20, a cabinet 19, a cabinet 18, a cabinet 17, a cabinet 16, a cabinet 15, a cabinet 14, a cabinet 13, a cabinet 12, a cabinet 11, a cabinet 10, a cabinet 9, a cabinet 8, a cabinet 7, a cabinet 6, a cabinet 5, a cabinet 4, a cabinet 3, a cabinet 2, a cabinet 1, a coffeemachine 1, a countertop 2, a countertop 1, a diningtable 2, a diningtable 1, a drawer 6, a drawer 5, a drawer 4, a drawer 3, a drawer 2, a drawer 1, a fridge 1, a garbagecan 1, a microwave 1, a sinkbasin 1, a stoveburner 4, a stoveburner 3, a stoveburner 2, a stoveburner 1, and a toaster 1.
Reasoning: I need to put two winebottle in cabinet. First, I should check where the winebottle are. Let's look around to see if I can find any winebottle. I'll start by checking the diningtables, countertops, and sinkbasin.
Action: go to diningtable 1
[Step 2]
Observation: You arrive at diningtable 1. On the diningtable 1, you see a bread 1, a butterknife 3, a cellphone 1, a lettuce 1, a spoon 2, a spraybottle 1, and a winebottle 1.
Reasoning: I need to put two winebottle in cabinet. I already see a winebottle 1 on diningtable 1. I should take the winebottle 1 from diningtable 1 and then go to a cabinet to put it in. The admissible actions include "take winebottle 1 from diningtable 1". Let me take the winebottle 1.
Action: take winebottle 1 from diningtable 1
[Step 3]
Observation: You pick up the winebottle 1 from the diningtable 1.
Reasoning: I need to put the winebottle in the cabinet. I already have the winebottle in my inventory, so the next step is to go to a cabinet and put the winebottle inside. The most logical next step is to go to cabinet 1.
Action: go to cabinet 1
[Step 4]
Observation: You arrive at cabinet 1. On the cabinet 1, you see nothing.
Reasoning: I need to put the winebottle in the cabinet. I already have the winebottle in my inventory, and I'm at cabinet 1. The admissible actions include "move winebottle 1 to cabinet 1". I will take that action.
Action: move winebottle 1 to cabinet 1
[Step 5]
Observation: You move the winebottle 1 to the cabinet 1.
Reasoning: I need to put the second winebottle in the cabinet. I already have the first winebottle in the cabinet, so I need to find the second winebottle and put it in the cabinet. The admissible actions include "take winebottle 1 from cabinet 1" and "move winebottle 1 to cabinet 1". Since I already moved the first winebottle to cabinet 1, I need to find the second winebottle. The admissible actions also include "go to diningtable 1" and "go to diningtable 2". I should go to diningtable 2 to check if there is a second winebottle there.
Action: go to diningtable 2
[Step 6]
Observation: You arrive at diningtable 2. On the diningtable 2, you see a apple 1, a bowl 2, a bread 2, a dishsponge 2, a kettle 1, a knife 1, a peppershaker 1, a plate 3, a potato 2, a soapbottle 3, a spatula 1, a spraybottle 2, and a winebottle 3.
Reasoning: I need to put two winebottles in a cabinet. I already have one winebottle (winebottle 1) in cabinet 1. The second winebottle is winebottle 3, which is on diningtable 2. I should take winebottle 3 from diningtable 2 and put it in a cabinet. The admissible actions include "take winebottle 3 from diningtable 2". I will take the winebottle 3 from diningtable 2.
Action: take winebottle 3 from diningtable 2
[Step 7]
Observation: You pick up the winebottle 3 from the diningtable 2.
Reasoning: I need to put the winebottle 3 in the cabinet. I already have winebottle 3 in my inventory, and I need to move it to a cabinet. The most logical next step is to go to cabinet 1 and move the winebottle 3 to it.
Action: go to cabinet 1
[Step 8]
Observation: You arrive at cabinet 1. On the cabinet 1, you see a winebottle 1.
Reasoning: I need to put the winebottle 3 in the cabinet. I already have winebottle 3 in my inventory, and I'm at cabinet 1. The admissible actions include "move winebottle 3 to cabinet 1". I will take that action.
Action: move winebottle 3 to cabinet 1

图 11: OPID 在 ALFWorld 示例 2 上的完整轨迹。

A trajectory of an agent trained with OPID — Search QA

Task: *Do Stanley Tucci and Michael Anderson have the same nationality?*

[Step 1]

Observation: null

Reasoning: null

Action: <search>Do Stanley Tucci and Michael Anderson have the same nationality</search>

[Step 2]

Observation: <information>{"result": "Doc 1: \"Stanley Tucci\"\nawareness to the global refugee crisis. The video, titled \"\"What They Took With Them\"\", has the actors reading a poem, written by Jenifer Toksvig and inspired by primary accounts of refugees, and is part of UNHCR's #WithRefugees campaign, of which also includes a petition to governments to expand asylum to provide further shelter, integrating job opportunities, and education. Stanley Tucci Stanley Tucci (; born November 11, 1960) is an American actor, writer, producer, and film director. He has won three Emmy Awards; two for his performances in \"\"Winchell\"\" and \"\"Monk\"\", and one as a producer of \"\"Park Bench with Steve\nDoc 2: \"Stanley Tucci\"\nfilm. It won him and Tropiano the Independent Spirit Award for Best First Screenplay. He has been nominated three times for Golden Globes, and won twice \u2013 for his title role in \"\"Winchell\"\" (1998), and for his supporting role as Adolf Eichmann in \"\"Conspiracy\"\" (2001), both for HBO films. He also received a Screen Actors Guild Award nomination for \"\"Winchell\"\". He was nominated for Broadway's Tony Award as Best Actor in a Play for his role as Johnny in the 2002 revival of Terrence McNally's \"\"Frankie and Johnny in the Clair de Lune\"\". In 2004, Caedmon Audio released an audiobook\nDoc 3: \"Stanley Tucci\"\nintroduced the couple several years later at her own wedding. Tucci and Blunt married in a civil ceremony in summer 2012, followed by a larger observance at Middle Temple Hall in London on September 29, 2012. The couple live in Barnes, London and have a son, Matteo Oliver (b. January 2015) and a daughter, Emilia Giovanna (b. April 2018). On September 12, 2016, Tucci, as well as Cate Blanchett, Chiwetel Ejiofor, Peter Capaldi, Douglas Booth, Neil Gaiman, Keira Knightley, Juliet Stevenson, Kit Harington, and Jesse Eisenberg, featured in a video from the United Nations' refugee agency UNHCR to help raise\n"}</information>

Reasoning: Based on the provided information, Stanley Tucci is described as an American actor, writer, producer, and film director. However, there is no direct information provided about Michael Anderson's nationality. To determine if they have the same nationality, we would need to know Michael Anderson's nationality.

Action: <search>What is Michael Anderson's nationality</search>

[Step 3]

Observation: <information>{"result": "Doc 1: \"Matt Anderson (volleyball)\"\nMatt Anderson (volleyball) Matthew John Anderson (born 18 April 1987) is an American volleyball player, a member of the United States men's national volleyball team and Russian club Zenit Kazan, a participant of the Olympic Games (2012, 2016), bronze medalist of the 2016 Olympic Games, 2013 NORCECA Champion, a gold medalist of the 2008 Pan American Cup, 2014 World League and 2015 World Cup. Anderson was born in Buffalo, New York to Michael and Nancy Anderson. His father, Michael Anderson, died in January 2010. He has three older sisters named Jennifer, Joelle and Amy and one older brother named Joshua.\nDoc 2: \"Michael Anderson (swimmer)\"\nMichael Anderson (swimmer) Michael Anderson, (born 12 July 1987) is an Australian Paralympic swimmer who has won gold, silver and bronze medals at the three Paralympics from 2008 to 2016. Anderson has nerve damage to his leg caused by meningitis and a hearing impairment. He was born and grew up in Bellingen in the Northern Rivers. He moved to the Gold Coast to study for a Bachelor of Sport Management degree at Griffith University. Anderson made his international debut at the 2005 Deaflympics in Melbourne where he finished sixth in the 50m backstroke. At the 2006 IPC Swimming World Championships\nDoc 3: \"Michael Anderson Pereira da Silva\"\ndebut in a group stage game against Italian team Roma. Most of the autumn and winter 2007 Michael was injured and was undergoing treatment in Brazil, however he has recovered and returned since. On 13 May 2009 the 26-year-old attacking midfield player, changes on loan until 31 December 2009 from Dynamo Kyiv to Botafogo. Michael moved from Kyiv to Portuguesa on 23 May 2011. \"\"according to combined sources on the Flamengo official website and Flaestat\u00edstica.\"\" Michael Anderson Pereira da Silva Michael Anderson Pereira da Silva (born February 16, 1983 in S\u00e3o Caetano do Sul) better known as simply Michael, is\n"}</information>

Reasoning: Based on the provided information, Stanley Tucci is described as an American actor, writer, producer, and film director. Michael Anderson is identified as an Australian Paralympic swimmer. Therefore, they do not share the same nationality.

Action: <answer>No</answer>

图 12: OPID 在基于搜索的问答示例 1 上的完整轨迹。

A trajectory of an agent trained with OPID — Search QA

Task: *What was the name of the best selling book about serial killers that was written by a former chief reporter of national red top newspaper published in the United Kingdom?*

[Step 1]

Observation: null

Reasoning: null

Action: <search>What was the name of the best selling book about serial killers that was written by a former chief reporter of national red top newspaper published in the United Kingdom</search>

[Step 2]

Observation: <information>{"result": "Doc 1: \"Criminal Shadows: Inside the Mind of the Serial Killer\"\nCriminal Shadows: Inside the Mind of the Serial Killer Criminal Shadows: Inside the Mind of the Serial Killer is a book written by English professor of psychology, David V. Canter. It was the winner of two literary awards: the Gold Dagger for Non-Fiction (1994) and the Anthony Award for Best True Crime (1995). A unique insight into some of Britain\u2019s most notorious criminal investigations, this is the account of Professor Canter's experience as Britain\u2019s leading pioneer in the new science of criminal psychological profiling. Canter takes the reader step by step through his development of profiling and through many of\nDoc 2: \"Serial killer\"\nwealth of London, focused the media's attention on the plight of the urban poor and gained coverage worldwide. Jack the Ripper has also been called the most famous serial killer of all time, and his legend has spawned hundreds of theories on his real identity and multiple works of fiction. H. H. Holmes was one of the first documented modern serial killers in the United States, responsible for the death of at least nine victims in the early 1890s. Here as well, the case gained notoriety and wide publicity through possibly sensationalized accounts in William Randolph Hearst's newspapers. At the\nDoc 3: \"My Life Among the Serial Killers\"\nbook. My Life Among the Serial Killers My Life Among the Serial Killers: Inside the Minds of the World's Most Notorious Murderers is a book written by Helen Morrison, M.D and Harold Goldberg. It presents the cases of ten serial killers, and touches on many more. Morrison spent hundreds of hours in face-to-face interviews, over many years, with several of the subjects. She uses the individual stories to explain and put forth her ideas on what makes a serial killer. Morrison begins her story in the early '70s, when psychiatry and law enforcement had a very different view of these\n"}</information>

Reasoning: Based on the provided information, the question is asking for the name of the best-selling book about serial killers written by a former chief reporter of a national red top newspaper in the United Kingdom. The search results provided do not explicitly mention a book that meets all the criteria: 1. It is a best-selling book about serial killers. 2. It was written by a former chief reporter of a national red top newspaper in the United Kingdom. Since the information provided is insufficient to confirm the exact book name, I need to perform a search to find the correct answer.

Action: <search>Best-selling book about serial killers written by a former chief reporter of a national red top newspaper published in the United Kingdom</search>

[Step 3]

Observation: <information>{"result": "Doc 1: \"Serial killer\"\nwealth of London, focused the media's attention on the plight of the urban poor and gained coverage worldwide. Jack the Ripper has also been called the most famous serial killer of all time, and his legend has spawned hundreds of theories on his real identity and multiple works of fiction. H. H. Holmes was one of the first documented modern serial killers in the United States, responsible for the death of at least nine victims in the early 1890s. Here as well, the case gained notoriety and wide publicity through possibly sensationalized accounts in William Randolph Hearst's newspapers. At the\nDoc 2: \"Criminal Shadows: Inside the Mind of the Serial Killer\"\nCriminal Shadows: Inside the Mind of the Serial Killer Criminal Shadows: Inside the Mind of the Serial Killer is a book written by English professor of psychology, David V. Canter. It was the winner of two literary awards: the Gold Dagger for Non-Fiction (1994) and the Anthony Award for Best True Crime (1995). A unique insight into some of Britain\u2019s most notorious criminal investigations, this is the account of Professor Canter's experience as Britain\u2019s leading pioneer in the new science of criminal psychological profiling. Canter takes the reader step by step through his development of profiling and through many of\nDoc 3: \"James Weatherup\"\nEuropean News Agency and sports editor of the London and Surrey Times newspaper.He was head-hunted by a major PR firm in Soho and is now an account director at Keith Bishop Associates in London's West End. James Weatherup After starting out in regional newspapers, he joined the \"\"News of the World,\"\" serving in two stints over 25 years for nine editors. In his first stint he rose to Chief reporter. During this time he co-wrote the best selling book \"\"Inside 25 Cromwell Street\"\" about the serial killers Fred and Rosemary West. He then left for the \"\"Sunday People\"\" in 1999,\n"}</information>

Reasoning: Based on the provided information, the best-selling book about serial killers written by a former chief reporter of a national red top newspaper published in the United Kingdom is likely "Inside 25 Cromwell Street" by James Weatherup. This book is mentioned as co-written with Fred and Rosemary West, and James Weatherup was a former chief reporter for the London and Surrey Times newspaper.

Action: <answer>Inside 25 Cromwell Street</answer>

图 13: OPID 在基于搜索的问答示例 2 上的完整轨迹。

A trajectory of an agent trained with OPID — WebShop

Task: *Find me loose fit, day comfort, hand wash women's tops, tees & blouses with short sleeve, polyester spandex for teen girls with color: a7-blue, and size: medium, and price lower than 40.00 dollars*

[Step 1]

Observation: 'Search'.

Reasoning: I need to find a loose fit, day comfort, hand wash women's tops, tees & blouses with short sleeve, polyester spandex for teen girls with color: a7-blue, and size: medium, with a price lower than 40.00 dollars. The current observation is "Search", so I should perform a search with the appropriate query. The best action is to search for the specific product with the required color, size, and price.

Action: search[a7-blue, medium, polyester spandex, teen girls, color: a7-blue, size: medium, price: <40]

[Step 2]

Observation: 'Back to Search' [SEP] 'Page 1 (Total results: 50)' [SEP] 'Next >' [SEP] 'B09NPML43M' [SEP] 'Womens Short Sleeve Tops, Womens Casual Dandelion Printing T-Shirts Loose O-Neck Blouse Tops Funny Graphic Tee Shirts' [SEP] '$1.01 to $1.74' [SEP] 'B09KLQLLT2' [SEP] 'Long Sleeve Superhero T Shirt Tank Top Mens Compression Shirt Men Workout Fitness Gym Shirt' [SEP] '$19.99' [SEP] 'B09RVF4JP1' [SEP] 'Once Upon A Time Queen Born In 1982 T Shirts It Was Me Tank Top' [SEP] '$19.99' [SEP] 'B08ZRR3DZT' [SEP] 'SheIn Women's Sexy One Shoulder Sleeveless Cutout Mini Club Pencil Bodycon Dress' [SEP] '$19.99 to $27.99' [SEP] 'B07JVVDJ6L' [SEP] 'Canadian Tuxedo T Shirt - Novelty Denim Tux T-Shirt' [SEP] '$19.99' [SEP] 'B09R9YCM6R' [SEP] 'XXBR Summer T-shirts for Mens, Soldier Short Sleeve 3D Street Vintage Printed Shirt Slim Fit Muscle Casual Tee Tops' [SEP] '$8.98 to $11.99' [SEP] 'B01HQTWL6S' [SEP] 'Expression Tees Pug Life Funny Thug Life Unisex Adult Hoodie' [SEP] '$36.99 to $48.99' [SEP] 'B09M63B87V' [SEP] 'YALFJV Women Long Sleeve Crew Neck Side Button T Shirts Tunic Dress Loose Asymmetric Hem Tunic Pullover to Wear with Leggings' [SEP] '$10.71 to $18.34' [SEP] 'B09GLVMLMS' [SEP] 'Anniou Electric Heated Jacket Adjustable Temp USB Heated Coat Winter Hooded Jacket Men Women' [SEP] '$64.99 to $114.99' [SEP] 'B09PL5W9PD' [SEP] 'Women's One Piece Swimsuit Halter Plunge Neck Tummy Control Bathing Suits Push Up Tankini Sets Plus Size Beachwear' [SEP] '$7.8'.

Reasoning: Given the current observation, I need to find a loose fit, day comfort, hand wash women's tops, tees & blouses with short sleeve, polyester spandex for teen girls with color: a7-blue, and size: medium, with a price lower than 40.00 dollars. The current observation shows that the first item on page 1 is "B09NPML43M" with the title "Womens Short Sleeve Tops, Womens Casual Dandelion Printing T-Shirts Loose O-Neck Blouse Tops Funny Graphic Tee Shirts" and a price range of $1.01 to $1.74. Since this item meets all the criteria (color: a7-blue, size: medium, material: polyester spandex, and is a short sleeve top), it is a suitable match for the shopping goal. The best action to take is to click on this item to view it in detail.

Action: click[b09npml43m]

[Step 3]

Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'color' [SEP] 'a1-black' [SEP] 'a1-blue' [SEP] 'a1-gray' [SEP] 'a1-green' [SEP] 'a1-purple' [SEP] 'a1-wine red' [SEP] 'a1-yellow' [SEP] 'a2-blue' [SEP] 'a2-gray' [SEP] 'a2-green' [SEP] 'a2-white' [SEP] 'a2-yellow' [SEP] 'a3-army green' [SEP] 'a3-blue' [SEP] 'a3-gray' [SEP] 'a3-navy' [SEP] 'a3-orange' [SEP] 'a3-wine red' [SEP] 'a4-gray' [SEP] 'a6-black' [SEP] 'a6-blue' [SEP] 'a6-red' [SEP] 'a7-black' [SEP] 'a7-blue' [SEP] 'a7-red' [SEP] 'b15-black' [SEP] 'b15-blue' [SEP] 'b15-red' [SEP] 'b16-black' [SEP] 'b16-blue' [SEP] 'b16-red' [SEP] 'b17-army green' [SEP] 'b17-black' [SEP] 'b17-red' [SEP] 'b17-wine red' [SEP] 'b18-a' [SEP] 'b11-black' [SEP] 'b13-a' [SEP] 'b19-a' [SEP] 'b14-a' [SEP] 'b21-a' [SEP] 'b12-a' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] '3x-large' [SEP] 'Womens Short Sleeve Tops, Womens Casual Dandelion Printing T-Shirts Loose O-Neck Blouse Tops Funny Graphic Tee Shirts' [SEP] 'Price: $1.01 to $1.74' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.

Reasoning: The current observation shows that we are back on Page 1 of the search results, and the options include selecting the color as "a7-blue" and size as "medium". The goal is to find a women's top with color: a7-blue, size: medium, and price lower than 40.00 dollars. We have already clicked on "a7-blue" and are now on the size selection. The next logical step is to click on the size "medium" to continue searching for the desired product.

Action: click[medium]

[Step 4]

Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'color' [SEP] 'a1-black' [SEP] 'a1-blue' [SEP] 'a1-gray' [SEP] 'a1-green' [SEP] 'a1-purple' [SEP] 'a1-wine red' [SEP] 'a1-yellow' [SEP] 'a2-blue' [SEP] 'a2-gray' [SEP] 'a2-green' [SEP] 'a2-white' [SEP] 'a2-yellow' [SEP] 'a3-army green' [SEP] 'a3-blue' [SEP] 'a3-gray' [SEP] 'a3-navy' [SEP] 'a3-orange' [SEP] 'a3-wine red' [SEP] 'a4-gray' [SEP] 'a6-black' [SEP] 'a6-blue' [SEP] 'a6-red' [SEP] 'a7-black' [SEP] 'a7-blue' [SEP] 'a7-red' [SEP] 'b15-black' [SEP] 'b15-blue' [SEP] 'b15-red' [SEP] 'b16-black' [SEP] 'b16-blue' [SEP] 'b16-red' [SEP] 'b17-army green' [SEP] 'b17-black' [SEP] 'b17-red' [SEP] 'b17-wine red' [SEP] 'b18-a' [SEP] 'b11-black' [SEP] 'b13-a' [SEP] 'b19-a' [SEP] 'b14-a' [SEP] 'b21-a' [SEP] 'b12-a' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] '3x-large' [SEP] 'Womens Short Sleeve Tops, Womens Casual Dandelion Printing T-Shirts Loose O-Neck Blouse Tops Funny Graphic Tee Shirts' [SEP] 'Price: $1.01 to $1.74' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.

Reasoning: Looking at the current observation, the agent is on the "Back to Search" page, and the goal is to find a women's top with color: a7-blue, size: medium, and price lower than 40.00. The agent has already clicked on "medium" and is now on the color selection. The most relevant product that matches the criteria is "B09NPML43M" with color "a7-blue" and size "medium". The agent should click on "a7-blue" to select the color and then click on "medium" to select the size.

Action: click[a7-blue]

[Step 5]

Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'color' [SEP] 'a1-black' [SEP] 'a1-blue' [SEP] 'a1-gray' [SEP] 'a1-green' [SEP] 'a1-purple' [SEP] 'a1-wine red' [SEP] 'a1-yellow' [SEP] 'a2-blue' [SEP] 'a2-gray' [SEP] 'a2-green' [SEP] 'a2-white' [SEP] 'a2-yellow' [SEP] 'a3-army green' [SEP] 'a3-blue' [SEP] 'a3-gray' [SEP] 'a3-navy' [SEP] 'a3-orange' [SEP] 'a3-wine red' [SEP] 'a4-gray' [SEP] 'a6-black' [SEP] 'a6-blue' [SEP] 'a6-red' [SEP] 'a7-black' [SEP] 'a7-blue' [SEP] 'a7-red' [SEP] 'b15-black' [SEP] 'b15-blue' [SEP] 'b15-red' [SEP] 'b16-black' [SEP] 'b16-blue' [SEP] 'b16-red' [SEP] 'b17-army green' [SEP] 'b17-black' [SEP] 'b17-red' [SEP] 'b17-wine red' [SEP] 'b18-a' [SEP] 'b11-black' [SEP] 'b13-a' [SEP] 'b19-a' [SEP] 'b14-a' [SEP] 'b21-a' [SEP] 'b12-a' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] '3x-large' [SEP] 'Womens Short Sleeve Tops, Womens Casual Dandelion Printing T-Shirts Loose O-Neck Blouse Tops Funny Graphic Tee Shirts' [SEP] 'Price: $1.01 to $1.74' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.

Reasoning: Given the current observation, the agent is on the "Back to Search" page, and the goal is to find a women's top with color a7-blue, size medium, and price lower than 40.00 dollars. The agent has already clicked on "medium" and "a7-blue", but the product is still displayed as the same item. Since the product is already shown as a7-blue and medium, the best action is to click on "buy now" to complete the purchase.

Action: click[buy now]

图 14: OPID 在 WebShop 示例 1 上的完整轨迹。

A trajectory of an agent trained with OPID — WebShop

Task: *Find me men's sleep & lounge with long sleeve, elastic waistband for daily wear with color: multi 4, and size: large, and price lower than 60.00 dollars*

[Step 1]
Observation: 'Search'.
Reasoning: I need to find men's sleep & lounge with long sleeve, elastic waistband for daily wear, color: multi 4, size: large, and price lower than 60.00 dollars. The current observation is 'Search', so I should perform a search with the appropriate query. The best query to use is: ***men's sleep & lounge long sleeve elastic waistband daily wear color multi 4 size large price: <60"** This query includes all the required criteria: - Men's sleep & lounge - Long sleeve - Elastic waistband - Daily wear - Color: multi 4 - Size: large - Price: lower than 60.00 I will now perform the search with this query.
Action: search[mens sleep & lounge long sleeve elastic waistband daily wear color multi 4 size large price: <60]

[Step 2]
Observation: 'Back to Search' [SEP] 'Page 1 (Total results: 50)' [SEP] 'Next >' [SEP] 'B09ND8P2QR' [SEP] 'InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant' [SEP] '$43.59' [SEP] 'B09ND9DP7J' [SEP] 'InterestPrint Gold Horse Pattern Men's 2-Piece Sleepwear Set, Long Sleeve Shirt with Pants Loungewear' [SEP] '$43.59' [SEP] 'B09Q5ZHRVM' [SEP] 'Yinimo Mens Gym Shorts Fashionable Loose Beach Drawstring Turkey Print Beach Cool Shorts' [SEP] '$19.19' [SEP] 'B09QW2HQRK' [SEP] 'CandyMan Lace Pajama and Lounge Pants for Men' [SEP] '$31.0 to $69.0' [SEP] 'B09S3BN15C' [SEP] 'Mens Linen Shirt,Men's Striped Shirts Casual Short Sleeve Button Down Shirts Regular Fit Hawaiian Shirts Beach Tees Tops' [SEP] '$3.78 to $11.38' [SEP] 'B09HGFV91W' [SEP] 'ZHDD Tops for Mens, Men's Knight Punk Vintage Style Long Sleeve Asymmetric Hem Cowl Neck Teen Boys Gothic Pullover' [SEP] '$4.98 to $7.99' [SEP] 'B09HX5CD2D' [SEP] 'CSU Cleveland State University Vikings Property Fleece Drawstring Shorts Heather Charcoal' [SEP] '$39.95' [SEP] 'B09R9YCM6R' [SEP] 'XXBR Summer T-shirts for Mens, Soldier Short Sleeve 3D Street Vintage Printed Shirt Slim Fit Muscle Casual Tee Tops' [SEP] '$8.98 to $11.99' [SEP] 'B09M63B87V' [SEP] 'YALFJV Women Long Sleeve Crew Neck Side Button T Shirts Tunic Dress Loose Asymmetric Hem Tunic Pullover to Wear with Leggings' [SEP] '$10.71 to $18.34' [SEP] 'B09QQP3356' [SEP] 'HAUKLIE Men's Sports Waffle Ribbed Polo Shirts Summer Short Sleeve Cotton Muscle Quarter-Zip Henley T-Shirt Tunics Tops' [SEP] '$10.99'.
Reasoning: Given the current observation, I need to find a men's sleep & lounge with long sleeve, elastic waistband for daily wear, color: multi 4, size: large, and price lower than 60.00 dollars. From the observations, the relevant product that matches the criteria is: - **B09ND8P2QR**: "InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant" with a price of **$43.59**. This item meets all the criteria: - It is a men's sleep & lounge. - It has a long sleeve. - It has an elastic waistband. - It is color: multi 4. - It is size: large. - It is priced under **$60.00**. Therefore, the best action is to **click on this product** to view it in detail.
Action: click[b09nd8p2qr]

[Step 3]
Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] 'color' [SEP] 'multi 1' [SEP] 'multi 10' [SEP] 'multi 2' [SEP] 'multi 3' [SEP] 'multi 4' [SEP] 'multi 5' [SEP] 'multi 6' [SEP] 'multi 7' [SEP] 'multi 8' [SEP] 'multi 9' [SEP] 'InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant' [SEP] 'Price: $43.59' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.
Reasoning: The current observation shows that we are back on Page 1 of the search results, and the options include selecting the size as "large" and color as "multi 4". The goal is to find a men's sleep & lounge with long sleeve, elastic waistband, color: multi 4, size: large, and price lower than 60.00 dollars. We have already clicked on "B09ND8P2QR" (the product "InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant") and are now looking to select the size and color. The most appropriate action is to click on the size "large" to proceed with the search.
Action: click[large]

[Step 4]
Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] 'color' [SEP] 'multi 1' [SEP] 'multi 10' [SEP] 'multi 2' [SEP] 'multi 3' [SEP] 'multi 4' [SEP] 'multi 5' [SEP] 'multi 6' [SEP] 'multi 7' [SEP] 'multi 8' [SEP] 'multi 9' [SEP] 'InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant' [SEP] 'Price: $43.59' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.
Reasoning: The current observation shows that we are back to the search page, and the options include selecting the size as "large" and color as "multi 4". The goal is to find a men's sleep & lounge with long sleeve, elastic waistband, color: multi 4, and size: large, with a price lower than $60.00. We have already clicked on "large" and are now looking for the color "multi 4". The best action is to click on "multi 4" to select the color.
Action: click[multi 4]

[Step 5]
Observation: 'Back to Search' [SEP] '< Prev' [SEP] 'size' [SEP] 'small' [SEP] 'medium' [SEP] 'large' [SEP] 'x-large' [SEP] 'xx-large' [SEP] 'color' [SEP] 'multi 1' [SEP] 'multi 10' [SEP] 'multi 2' [SEP] 'multi 3' [SEP] 'multi 4' [SEP] 'multi 5' [SEP] 'multi 6' [SEP] 'multi 7' [SEP] 'multi 8' [SEP] 'multi 9' [SEP] 'InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant' [SEP] 'Price: $43.59' [SEP] 'Rating: N.A.' [SEP] 'Description' [SEP] 'Features' [SEP] 'Reviews' [SEP] 'Buy Now'.
Reasoning: Given the current observation, the agent is on the "Back to Search" page, and the goal is to find a men's sleep & lounge with long sleeve, elastic waistband for daily wear with color: multi 4 and size: large, with a price lower than $60. The agent has already clicked on "large" and "multi 4", but the product is still shown as "InterestPrint Deer and Stars Men's Loungewear Pajama Sets - Long Sleeve Tee and Jogger Pant" with a price of $43.59. Since the product is already matching the size and color, the best action is to click on "buy now" to complete the purchase.
Action: click[buy now]

图 15: OPID 在 WebShop 示例 2 上的完整轨迹。