SAF-OPD：用于在线策略蒸馏的稳定优势融合

Yifan Ding[1,2]*, Xincheng Wei[2,3]*, Yoshua Y. Li[2]*†
Ziheng Li[2], Yuquan Lu[2], Siyu Zhang[2]
Dongsheng Ma[2,4], Rongxiang Weng[2], Xunliang Cai[2], Yun Chen[1]†
[1]上海财经大学 [2]美团，LongCat 团队
[3]香港中文大学（深圳） [4]北京大学
dingyii2002@gmail.com, yoshua_li@meituan.com, yunchen@sufe.edu.cn

摘要

可验证奖励强化学习（RLVR）将单个响应级奖励广播给每个词元，而在线策略蒸馏（OPD）则借助更强的教师模型对每个词元评分，以获得稠密优势，但其性能上限受教师质量制约，也会抑制超越教师的探索。二者的互补性使 RLVR 与 OPD 的结合颇具潜力，但我们发现，以固定系数融合两种优势会因两类校准偏差而引发熵坍缩：一是**量级失配**，即词元级 OPD 优势可能激增至远超有界 RLVR 优势的水平，从而淹没后者的信号；二是**时序失配**，即持续施加全强度 OPD 会不断将学生模型拉向教师模型，并限制超越教师所需的探索。我们提出稳定优势融合框架 SAF，该框架仅对 OPD 优势施加一个轻量级四阶段流程来解决这两个问题：以先稀疏化后压缩的机制控制量级，并以先预热后退火的机制控制时序；各阶段均可独立启停，且增加的开销可以忽略不计。我们以 GRPO 实例化 RLVR，并使用 Qwen3-1.7B/4B/8B 在七个数学推理与代码生成基准上评估 SAF：SAF 避免了熵坍缩，并持续优于固定系数的 GRPO+OPD 融合，在全部六种模型–领域设置上的综合得分提升了 0.51–2.70%，同时实现了更稳定的训练。

1 引言

随着可验证奖励强化学习（RLVR）的发展，大语言模型（LLM）在数学和代码生成等复杂推理任务上展现出卓越能力 Zhang et al. [2025]。在 RLVR 算法中，组相对策略优化（GRPO） Shao et al. [2024], Guo et al. [2025] 是一种应用广泛且具有代表性的实现：它使用基于规则的验证器对每次采样轨迹评分，再在对应采样组内归一化该分数，得到单个响应级优势 A_i^{GRPO}，并将其等同地广播给该采样轨迹中的每个词元；本文采用 GRPO 作为 RLVR 的具体实现。这种广播使 GRPO 简洁却也较为粗粒度：A_i^{GRPO} 将每个词元都视为对结果负有同等责任，因此，一段冗长的正确推导及其中唯一的决定性步骤会获得相同的信用。与之不同，在线策略蒸馏（OPD）借助更强的教师模型对学生生成的每个词元评分，提供词元级优势向量 $A_{i,t}^{\mathrm{OPD}} = \log \pi_T(y_{i,t} \mid s_{i,t}) - \log \pi_\theta(y_{i,t} \mid s_{i,t})$；该向量在每次更新时重新计算，为学生尚无法独立解决的问题提供相对于教师的稠密反馈 Agarwal et al. [2024], Gu et al. [2024], Liu et al. [2026]。然而，仅使用 OPD 也存在互补性的弱点：由于 $A_{i,t}^{\mathrm{OPD}}$ 完全依据教师自身的词元级似然定义，无论教师本身是否正确，它都会奖励对教师分布的匹配，因此，除非显式重塑奖励以外推并超越教师，否则其性能上限会隐式地受教师质量限制 Yang et al. [2026a]；在缺少真实响应级验证器奖励时，持续匹配教师也不会产生超越教师的探索压力，而独立验证的 RLVR 奖励能够直接提供这种压力 Cui et al. [2025a]。由于 RLVR 提供稀疏但经过验证的信号，OPD 提供稠密但相对于教师的信号，二者在构造上似乎天然互补，由此推动了越来越多的研究通过固定混合系数直接相加两种优势来融合它们 Wang et al. [2026a], MiMo Core Team [2026]。

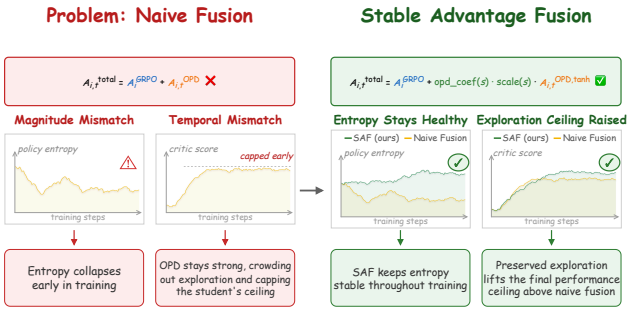


图 1 | 固定系数融合与 SAF 的对比。SAF 分别以专门的控制机制应对 OPD 优势的量级失配与时序失配，从而避免熵坍缩、保留探索能力并提升最终性能。

*同等贡献。
†通讯作者。

然而，将这种融合视为简单的加法组合，掩盖了两项之间的一个基本不对称性。A_i^{GRPO} 是每次采样轨迹对应的单个标量，由有界的响应级验证器奖励在其采样组内归一化一次得到，因此其量级具有自校准性 Shao et al. [2024]。相比之下，$A_{i,t}^{\text{OPD}}$ 是在每次更新时由对数概率差重新计算的词元级量。它的量级不受组相对归一化的约束，个别词元上可能出现较大数值，而这正是 OPD 类系统中奖励尖峰、长度膨胀等训练病态的一个已知来源 Wang et al. [2026b], Xing et al. [2026], Zhao et al. [2026], Luo et al. [2026]。尽管该差值本身能够忠实反映局部的师生差异 Liu et al. [2026]，固定融合系数却无法根据学生与教师之间不断变化的距离来调整该信号的贡献：即使一种优势每次采样轨迹仅归一化一次，而另一种优势未经归一化且需在线重新估计，它仍隐式假设两种优势在每个词元和每个训练步骤上始终处于可比尺度。本文探究这一假设是否成立；若不成立，又应如何在放弃这一假设后融合两种优势。

作为初步研究，我们采用最简单的选择来实例化这一方案，即固定融合 A_i^{GRPO} 与 $A_{i,t}^{\text{OPD}}$，并发现上述不对称并非只是理论上的顾虑：它会在实践中破坏训练稳定性。策略熵在训练早期坍缩，此后一直维持低位；这一失效模式被广泛认为会阻碍探索并限制 RLVR 的最终准确率 Cui et al. [2025a]。学生模型也会被过度拉向教师模型，而且后期准确率会在低于更合理受控融合所能达到的水平处进入平台期（第 4.4 节）。通过诊断这一失效现象，我们将其归因于两种相互独立但同时存在的校准偏差，而单个固定系数无法同时解决二者。第一种是**量级失配**：与有界且经过组归一化的 A_i^{GRPO} 不同，词元级 $A_{i,t}^{\text{OPD}}$ 无界且呈重尾分布，这与已有报告一致，即不受约束的师生对数比信号可能在个别词元上骤增至极端量级 Zhao et al. [2026]；因此，少数词元携带的优势可能远大于任何 RLVR 项，并在数值上主导融合更新。第二种是**时序失配**：全强度教师指导的价值不会在整个训练过程中保持不变，因为一旦学生模型已经内化了教师所能提供的大部分知识，继续施加全强度 OPD 指导便会过度约束策略并限制其性能上限。两种失配作用于不同轴向，一种针对词元级尺度，另一种针对训练时间上的调度，因此仅重新调节该系数无法解决任一问题；第 4.4 节给出了支撑这一诊断的完整实验证据。

受上述诊断启发，我们提出稳定优势融合（SAF）：不再调节单个全局系数，而是分别为**量级失配**与**时序失配**配备一种专门机制。对于量级失配，词元级量级控制器会对每个响应内的经验 OPD 优势分布进行稀疏化并加以限制，使重尾词元无法再主导更新。对于时序失配，训练阶段控制器会跟踪在线师生 KL 散度，检测 OPD 信号何时已经发挥完作用，并相应地对其全局系数进行退火，从而只在全强度指导仍有价值时施加该指导。与采用固定系数的 RLVR+OPD 基线相比，SAF 不引入额外模型或辅助损失，只需对采样得到的 OPD 优势施加轻量级变换；第 3 节将详述四个组成阶段，以及如何将其组合为完整的融合规则。

我们的贡献总结如下。

- 我们指出了有界且仅归一化一次的 RLVR 优势与无界且在线重新计算的 OPD 优势之间的基本不对称性，并证明以固定系数融合二者会使这种不对称表现为两种相互关联但彼此不同的校准偏差：一种出现在词元级量级上，另一种出现在训练时序调度上；仅调节系数无法解决其中任何一种偏差。

- 我们提出 SAF，这是一条轻量级的四阶段优势融合流程：以先稀疏化后压缩的机制控制量级，并以先预热后退火的机制控制时序。每个阶段均可独立启停，而且退火时长是相对于观测到的预热终点确定的，而非预先固定。

- 我们采用 GRPO 作为 RLVR 的具体实现，并使用 Qwen3-8B、Qwen3-4B 和 Qwen3-1.7B 在七个数学推理与代码生成基准上开展了广泛实验。结果表明，SAF：1）在全部六种模型–领域设置中，综合得分均优于固定系数的 GRPO+OPD，增幅为 0.51–2.70%；2）正如训练动态分析所示，能够有效避免固定系数融合引发的熵坍缩，在整个训练过程中保留策略的探索能力，从而提高最终任务性能的上限。

2 相关工作

2.1 RLVR 与粗粒度信用分配

可验证奖励强化学习（RLVR）利用无需评论器、经过组归一化且广播至每个词元的响应级优势来训练 LLM 推理，最常见的实现是 GRPO Shao et al. [2024], Guo et al. [2025], Schulman et al. [2017]；Dr.GRPO、DAPO 和 GSPO 等后续工作改进了这一标量的归一化、裁剪或重要性加权，却仍保留其粗粒度特性 Liu et al. [2025], Yu et al. [2025], Zheng et al. [2025]。在采样轨迹所含信息最少时，这种粒度的限制恰恰最为严重：对于采样组中极少出现正确响应的困难问题，每个词元都会获得同一个接近于零的优势，因此，学生最需要改进之处反而几乎得不到 GRPO 信号。过程奖励模型以及基于熵或不确定性的重加权直接针对这一粒度问题，但它们依赖学生模型内部的信号，因而无法为学生尚不能解决的问题提供指导 Lightman et al. [2023], Wang et al. [2024], Cui et al. [2025a]。

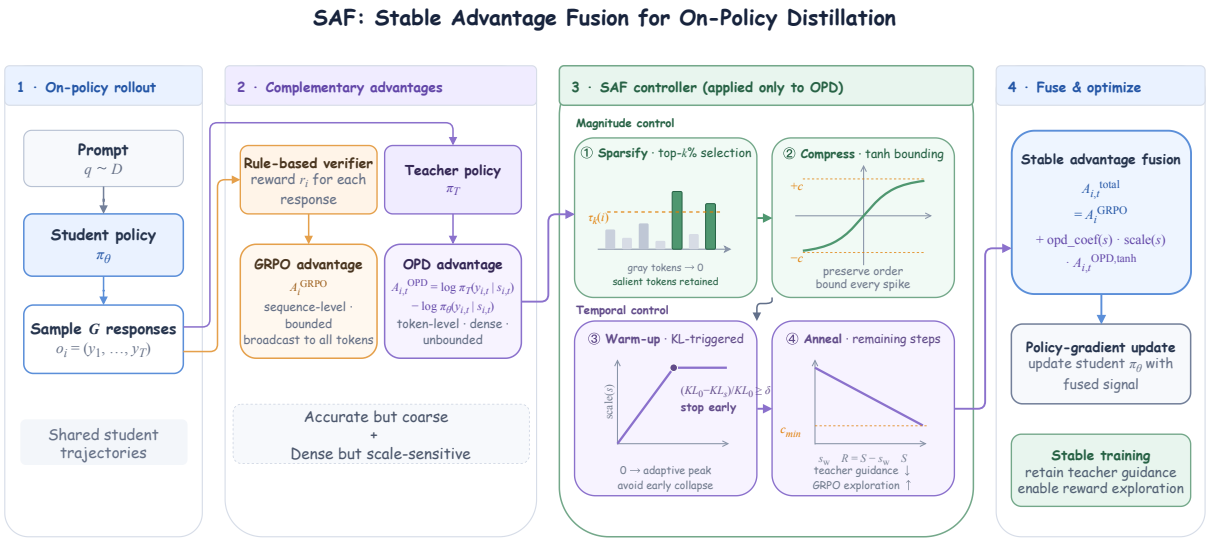


图 2 | SAF 概览。SAF 仅通过四个阶段修改 OPD 分支，随后再将其加入保持不变的 GRPO 优势，以进行策略梯度更新。

2.2 在线策略蒸馏及其与 RLVR 的结合

与针对固定教师目标的离线蒸馏不同 Hinton et al. [2015], Kim and Rush [2016]，在线策略蒸馏（OPD）利用教师模型给出的词元概率对学生生成的轨迹评分，从而减小训练–生成失配，并实现稠密的词元级反馈 Agarwal et al. [2024], Gu et al. [2024]；如今，它已成为一种常见的后训练阶段 Song and Zheng [2026], Zhang [2026]。本文采用其采样词元变体，以较低成本获得单个词元估计 Ko et al. [2024]。一类研究在存在师生失配时单独约束该信号，包括将蒸馏限制在可靠状态、使散度适应局部不确定性、放松严格模仿、将监督转移至中间表示，或降低估计器方差；G-OPD 则重新将 OPD 解释为受 KL 约束的 RL Zhong et al. [2026], Jin et al. [2026], Ko et al. [2026], Xing et al. [2026], Wang et al. [2026b], Yang et al. [2026a,b], Oh et al. [2026]。然而，这些工作都没有将 OPD 与 RLVR 信号结合。另一类研究融合 OPD 与 RLVR，却没有解决由此产生的校准偏差：KDRL 对两项损失求和 Xu et al. [2025]，MiMo-V2-Flash 则以固定强度将词元级师生优势加入 GRPO 优势 MiMo Core Team [2026]；正是这种固定系数融合所引发的熵坍缩构成了本文的研究动机（第 1 节）。RLSD、SDAR 等方法不再局限于固定系数，但它们只通过粗粒度的响应级统计量对整个 OPD 项进行门控或调度 Yang et al. [2026c], Liu et al. [2026], Lu et al. [2026], Tan et al. [2026], Pan et al. [2026], Wang et al. [2026c]；其中没有任何方法相对于 A_i^{GRPO} 限制单个词元的 OPD 优势，因此在粗粒度门控后，重尾量级仍可能占据主导。SAF 则为每种失配配备粒度与之匹配的机制：限制每个词元的影响，并依据在线师生 KL 散度而非响应级统计量自适应调整 OPD 强度。

3 方法

3.1 预备知识：优势融合问题

给定提示 q，GRPO 从采样策略中采样一组 G 个响应 $\{o_1, \ldots, o_G\}$，并使用基于规则的验证器为每个响应分配单个标量奖励。该奖励依据组内自身统计量进行归一化，得到响应级优势 A_i^{GRPO}，再将其等同地广播给响应 o_i 中的每个词元。因此，A_i^{GRPO} 有界且经过验证，却不包含 o_i 内究竟哪个词元对结果起到决定作用的信息。与此同时，OPD 在学生生成的轨迹上最小化从学生策略 π_θ 到教师策略 π_T 的反向 KL 散度，其中 $s_{i,t} = (\boldsymbol{x}_i, \boldsymbol{y}_{i,<t})$ 表示词元上下文。根据近期 OPD 系统采用的下一词元近似 MiMo Core Team [2026], Yang et al. [2026a]，将其与策略梯度形式对比，可以将词元级对数概率差的负值确定为 OPD 优势：

$$A_{i,t}^{\text{OPD}} = \log \pi_T(y_{i,t} \mid s_{i,t}) - \log \pi_\theta(y_{i,t} \mid s_{i,t}), \tag{1}$$

因此，当教师为某个词元分配的概率高于学生时，该词元获得正优势，反之则获得负优势。与 A_i^{GRPO} 不同，$A_{i,t}^{\text{OPD}}$ 会在每个词元 t 上独立重新计算，因而其量级不受任何组相对归一化的约束。

值得注意的是，G-OPD Yang et al. [2026a] 从理论上表明，OPD 是稠密 KL 约束 RL 的一个特例；在这一视角下，$A^{\text{OPD}}_{i,t}$ 本身就是一种隐式奖励。这使 A^{GRPO}_{i} 与 $A^{\text{OPD}}_{i,t}$ 得以作为同一 RL 形式下的两种奖励信号，并为将二者相加形成单个融合优势提供了依据。

我们的目标是为策略梯度更新构造一个融合信号 $A^{\text{total}}_{i,t}$，该信号需要：（i）限制任一词元的 $A^{\text{OPD}}_{i,t}$ 所产生的绝对影响，防止其在数值上淹没序列级 A^{GRPO}_{i}；（ii）在训练过程中自适应调整 OPD 贡献的整体强度。SAF 仅对 $A^{\text{OPD}}_{i,t}$ 应用四个可独立启停的阶段来满足这两项要求，同时保持 A^{GRPO}_{i} 不变：第 3.2 节介绍量级控制器（先进行前 $k\%$ 稀疏化，再进行有界 tanh 压缩），第 3.3 节介绍时序控制器（先进行 KL 触发的预热，再进行线性退火），第 3.4 节则将四个阶段组合为完整的融合规则。

3.2 量级控制：先稀疏化后压缩

按照第 3.1 节确定 $A^{\text{OPD}}_{i,t}$ 后，仍有一个问题尚待解决：它的词元级量级不受约束。由于该量是根据对数概率差在每个词元上独立重新计算的，少数词元可能产生比 A^{GRPO}_{i} 高出一个数量级的值；一旦将其纳入 $A^{\text{total}}_{i,t}$，寥寥几个词元便可能主导整个序列的梯度。为此，我们设置了一个稀疏化阶段来移除显著性较低的词元，以及一个压缩阶段来限制其余词元的量级。

阶段 1：前 $k\%$ 稀疏化。 如图 3（第 4.4 节）所示，$|A^{\text{OPD}}_{i,t}|$ 的经验分布高度集中在零附近，只有少数词元呈现出明显更大的量级。因此，对于每个序列 i，我们仅保留量级超过该序列内 $(1-k\%)$ 分位数的词元，并将其余词元置零：

$$M_{i,t} = \mathbf{1}\big[|A^{\text{OPD}}_{i,t}| \geq \tau_k(i)\big]\,,$$

其中，$\tau_k(i)$ 是序列 i 上 $\{|A^{\text{OPD}}_{i,t}|\}$ 的 $(1-k\%)$ 分位数，k 为超参数（`topk_percent`）。由此得到过滤后的信号 $A^{\text{OPD, top-}k\%}_{i,t} = M_{i,t} \cdot A^{\text{OPD}}_{i,t}$。由于 $\tau_k(i)$ 针对每个序列重新计算，过滤器会适应该序列自身的 OPD 量级分布，而非应用单个全局阈值；设置 $k = 100$ 将完全禁用过滤，因此该阶段严格涵盖未过滤信号这一情形。

阶段 2：有界 tanh 压缩。 即使阶段 1 已经移除了显著性最低的词元，保留下来的词元在量级上仍可能存在显著差异，并且偶尔会出现极端离群值。我们可以选择将过滤后的信号通过一种有界且尺度可调的变换：

$$A^{\text{OPD,tanh}}_{i,t} = c\,\tanh\!\left(A^{\text{OPD, top-}k\%}_{i,t}\right), \tag{2}$$

其中，c 是可调系数。由于 tanh 将 $\mathbb{R}$ 映射至 $(-1,1)$，无论压缩前的量级如何，压缩后的信号都会被限制在 $(-c,c)$ 内；同时，该变换在原点附近仍近似线性，因此能够保留中小量级信号之间的相对次序。该阶段以逐元素方式执行，增加的开销可以忽略不计，并且能够独立关闭。这两个阶段共同约束量级失配：阶段 1 根据词元相对于其所在序列的显著性，决定哪些词元参与贡献；阶段 2 则决定任一保留词元所能产生的贡献有多大。

3.3 时序控制：先预热后退火

另一个独立的问题是，$A^{\text{OPD}}_{i,t}$ 的适当强度会随训练过程而变化。从第一次更新开始便以全强度注入该信号，可能导致策略熵过早坍缩 Cui et al. [2025a]；而在学生吸收了教师的大部分指导后仍维持这一强度，则可能将策略锁定在教师行为上，挤压 GRPO 的探索空间，甚至从整体上破坏生成稳定性 Luo et al. [2026]。因此，我们首先令 OPD 强度从零开始线性提升，并允许观测到的师生 KL 降幅提前终止这一预热过程；随后，在剩余步骤中线性降低 OPD 系数，使 GRPO 逐步重新取得主导权。

阶段 3：KL 触发的预热。 我们使用一个随全局步骤 s 线性增大的因子缩放阶段 2 的输出：

$$\text{scale}(s) = \min\!\left(\frac{s}{S_{\text{warmup}}}, 1.0\right),$$

其中，S_{warmup} 是最大预热时长。我们并非只依赖预先指定的步骤预算，而是监控从学生到教师的反向 KL 散度的采样词元估计；该估计是在用于策略优化的同一批学生生成响应上计算的（附录 C）。令 KL_0 表示预热开始时的估计值，KL_s 表示步骤 s 时的取值，一旦满足

$$\frac{KL_0 - KL_s}{KL_0} \geq \delta, \qquad \delta > 0,$$

就提前终止预热，并将 $\text{scale}(s)$ 冻结在当前值。这一提前停止准则使用观测到的学生到教师采样反向 KL 的下降幅度，而非固定步骤数，来确定线性提升何时停止，因为不同模型和任务所需的下降幅度存在显著差

Method	Mathematical Reasoning					Code Generation			
	AIME-24	AIME-25	HMMT25-Feb	HMMT25-Nov	Avg.	HumanEval+	MBPP+	LiveCodeBench	Avg.
Teacher: Qwen3-30B-A3B-Instruct-2507	73.65	61.98	43.85	57.81	59.32	82.93	78.31	45.00	68.75
Student: Qwen3-8B									
Base	26.56	21.25	11.35	9.79	17.24	80.49	72.49	23.71	58.90
GRPO-only	61.15	49.06	28.65	37.50	44.09	81.10	**72.22**	28.85	60.72
OPD-only	59.58	50.52	27.60	40.73	44.61	**84.15**	71.96	33.29	63.13
GRPO+OPD (fixed)	60.83	**51.25**	28.44	**43.33**	45.96	78.66	71.69	34.86	61.74
SAF (ours)	**64.79**	**51.25**	**30.00**	41.67	**46.93**	81.10	71.69	**37.43**	**63.41**
Student: Qwen3-4B									
Base	23.02	21.88	11.67	9.17	16.44	79.27	63.49	24.57	55.78
GRPO-only	58.96	50.62	30.10	37.60	44.32	80.49	68.78	32.14	60.47
OPD-only	57.81	51.56	29.38	37.71	44.12	78.66	69.31	30.71	59.56
GRPO+OPD (fixed)	57.19	51.98	29.90	**38.44**	44.38	79.88	66.14	33.86	59.96
SAF (ours)	**60.21**	**53.96**	**31.15**	38.23	**45.89**	**82.93**	**70.63**	**34.43**	**62.66**
Student: Qwen3-1.7B									
Base	12.81	10.83	5.94	3.54	8.28	60.98	54.23	15.14	43.45
GRPO-only	36.25	31.35	17.19	16.88	25.42	65.24	53.70	17.57	45.50
OPD-only	35.10	28.54	15.83	16.35	23.96	**70.73**	**58.73**	25.86	**51.77**
GRPO+OPD (fixed)	34.79	29.69	17.50	16.56	24.64	70.12	56.08	**26.43**	50.88
SAF (ours)	**36.67**	**31.98**	**18.02**	**19.27**	**26.49**	**70.73**	57.14	26.29	51.39

表 1 | 数学推理与代码生成结果。所有数值均为准确率（%）。在每个模型规模和每一列中，最佳结果以粗体表示，次佳结果以下划线表示。

异。它还能防止过度模仿：教师自身的能力并非没有上限，其词元级评分也可能存在校准偏差 Yang et al. [2026a]；因此，一旦学生已经弥合了大部分可达到的差距，延长全强度指导主要会增加拟合教师错误的风险，而非带来更多收益。

阶段 4：在剩余步骤中线性退火。 令 S 表示总训练预算，s_{w} 表示预热自然结束或由 KL 触发条件提前结束时的步骤。我们在 s_{w} 处启动局部计数器 $t_{\mathrm{a}} = 0$，并在此后的每次更新后将其递增；对于剩余预算 $R = S - s_{\mathrm{w}}$，将 OPD 系数定义为

$$\mathrm{opd_coef}(s) = \begin{cases} 1, & s < s_{\mathrm{w}}, \\ c_{\min} + (1 - c_{\min}) \left(1 - \dfrac{t_{\mathrm{a}}}{R}\right), & s \geq s_{\mathrm{w}}, \end{cases} \tag{3}$$

其中，$0 \leq t_{\mathrm{a}} \leq R$，$c_{\min}$ 是保留少量 OPD 贡献的下限。因此，退火会在预热结束时从系数 1 开始，并在最后一个步骤达到 $c_{\min}$；由 KL 更早触发终止会增大 R，使衰减更加平缓。禁用预热时，我们设置 $s_{\mathrm{w}} = 0$，并在全部训练预算范围内进行退火。

3.4 整体融合与实现

依次组合四个阶段（阶段 1 → 阶段 2 → 阶段 3 → 阶段 4），即可得到最终的融合优势

$$A_{i,t}^{\mathrm{total}} = A_i^{\mathrm{GRPO}} + \mathrm{opd_coef}(s) \cdot \mathrm{scale}(s)\, A_{i,t}^{\mathrm{OPD,tanh}}. \tag{4}$$

被禁用的各阶段都会退化为恒等映射；禁用全部四个阶段后，即恢复固定融合 $A_i^{\mathrm{GRPO}} + A_{i,t}^{\mathrm{OPD}}$。因此，SAF 仅修改优势融合步骤，不会引入额外模型、损失或前向传播：阶段 1 为每个序列计算一个分位数，阶段 3 存储 KL_0 以计算 $(KL_0 - KL_s)/KL_0$，时序控制器则只维护 s_{w} 和 t_{a}。因此，SAF 可以作为即插即用的替代方案，嵌入现有 GRPO+OPD 训练循环。

4 实验

4.1 实验设置

模型与训练。 我们在基于 verl Sheng et al. [2025] 的 GRPO+OPD 流水线中实现 SAF，将学生模型初始化为 Qwen3-8B、Qwen3-4B 或 Qwen3-1.7B，并采用 Qwen3-30B-A3B-Instruct-2507 作为教师模型 Yang et al. [2025]，由其提供计算 $A_{i,t}^{\mathrm{OPD}}$ 所需的逐词元对数概率。给定规模下的所有方法均采用相同的初始化、教师模型和训练数据：数学任务使用 57K 道难度 ≥ 6 的 DeepMath He et al. [2025] 问题，代码任务使用包含 25K 道问题的 Eurus-RL-Code 数据集 Cui et al. [2025b]；学生模型以同策略方式生成回答，可验证奖励驱动 GRPO 信号，教师评分驱动 OPD 信号。OPD-only 使用一套专用的蒸馏配置，而其余方法共享另一套配置（附录 A）。我们将 SAF 与四个对照方法进行比较：未经训练的 **Base** 模型；**GRPO-only**（移除 $A_{i,t}^{\mathrm{OPD}}$）；

OPD-only（移除 A_i^{GRPO}）；以及 **GRPO+OPD (fixed)**，该方法将 OPD 系数固定为 1，并禁用 SAF 的控制机制。除非另有说明，SAF 采用 $k = 20$、$c = 0.1$、$S_{\text{warmup}} = 100$、$\delta = 0.2$ 和 $c_{\text{min}} = 0$。

评测。 我们在 AIME24 AI-MO [2024]、AIME25 OpenCompass [2025] 和 HMMT25（2 月与 11 月）Balunović et al. [2025] 上评测数学推理能力，并在 HumanEval+、MBPP+ Liu et al. [2023] 和 LiveCodeBench（v6，2025 年 2 月 ∼5 月）Jain et al. [2024] 上评测代码生成能力。数学答案使用 `Math-Verify`[1] 验证，代码则使用基准提供的单元测试评分；我们报告每个领域内的非加权平均值。完整的解码和采样设置见附录 A。

4.2 主要结果

表 1 表明，在两个领域和三种模型规模上，SAF 相较固定系数融合都能稳定提升综合得分。在数学推理任务上，相较 GRPO+OPD (fixed)，SAF 在 Qwen3-8B、Qwen3-4B 和 Qwen3-1.7B 上分别提升 0.97%、1.51% 和 1.85%。在代码生成任务上，相应的增益分别为 1.67%、2.70% 和 0.51%。在六种模型–领域设置上取平均后，SAF 达到 49.46%，分别比 GRPO+OPD (fixed)、GRPO-only 和 OPD-only 高 1.54%、2.71% 和 1.60%。这些稳定的综合增益表明，控制 OPD 信号比完全舍弃该信号或始终以全强度注入该信号更有效。

这些提升覆盖面广，但并不均匀。Qwen3-8B SAF 在七个基准中的四个上取得最佳成绩（或并列最佳），在数学和代码任务上的领域平均值分别比 GRPO-only 高 2.84% 和 2.69%；MBPP+ 是一个例外，SAF 落后于 GRPO-only 和 OPD-only，但差距不超过 0.53%，同时其平均表现仍优于固定融合。Qwen3-4B SAF 在七个基准中的六个上取得最佳成绩，在数学和代码任务上分别比 GRPO-only 提升 1.57% 和 2.19%。对于 Qwen3-1.7B，SAF 在七个基准中的五个上取得最佳成绩或并列最佳，并在数学和代码任务上分别比 GRPO-only 提升 1.07% 和 5.89%；在 1.7B 代码任务上，OPD-only 取得最高平均值（51.77%），其次是 SAF（51.39%），而 SAF 仍比固定融合高 0.51%。这些例外清楚表明，SAF 能在综合层面稳定优于固定融合，但并非在每种规模的每项基准上都胜过所有基线。

4.3 消融实验

接下来，我们在相同的 300 步预算下考察具有代表性的 Qwen3-4B 数学推理训练。表 2 显示，仅使用量级控制的表现与固定融合相近（44.35% 对 44.38%），而在缺少完整时序控制器的情况下加入预热同样不够充分（44.07%）。这并不否定 top-k 过滤和 tanh 压缩的必要性：图 3 和附录 D 直接揭示了这些操作所调控的近零集中质量和极端逐词元量级。相反，这说明仅纠正量级失配不足以提升最终准确率。启用退火后，平均值升至 45.23%。在完整 SAF 配置下，所选阈值 $\delta = 0.2$ 达到 45.89%，而将其增大到 $\delta = 0.3$ 时仅为 44.51%。由于更大的 δ 要求 KL 出现更大幅度的下降后预热才会结束，因此，将 δ 从 0.2 提高到 0.3 会延长全强度 OPD 指导，但准确率反而降低 1.38%；这一现象与学生模型逐渐接近一个并非总是正确的教师模型所能提供的能力上限相一致，因而继续追随教师主要只会强化教师自身的错误。这支持选择 $\delta = 0.2$。因此，证据支持二者发挥互补作用：top-k 过滤和 tanh 压缩使 OPD 信号适合参与融合，而时序控制器则决定该信号应在何时以及以多大强度影响优化。完整 SAF 配置分别比固定融合和仅使用量级控制的变体提升 1.51% 和 1.54%。

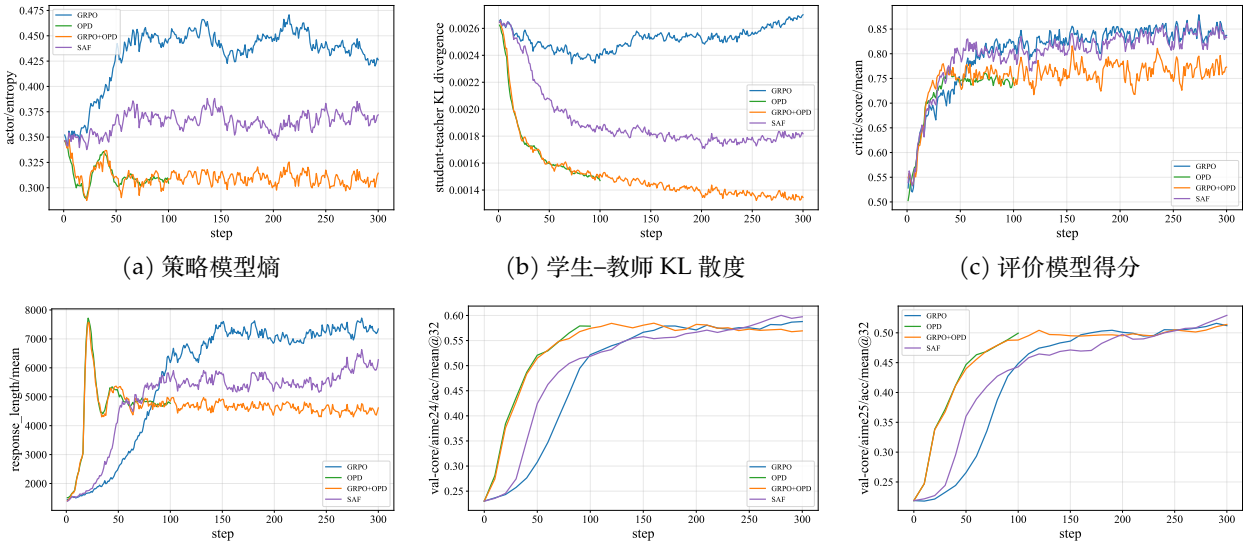
Configuration	AIME-24	AIME-25	HMMT25-Feb	HMMT25-Nov	Avg.
GRPO+OPD (fixed)	57.19	51.98	29.90	**38.44**	44.38
+ top-k and tanh (fixed weight)	58.75	50.94	30.10	37.60	44.35
+ warm-up (no annealing)	58.96	51.46	29.69	36.15	44.07
+ annealing	59.27	52.60	**31.25**	37.81	45.23
SAF ($\delta = 0.2$, selected)	**60.21**	**53.96**	31.15	38.23	**45.89**
SAF ($\delta = 0.3$)	58.75	52.81	29.38	37.08	44.51

表 2 | Qwen3-4B 数学推理经过 300 个训练步骤后的代表性 SAF 消融结果。

4.4 训练动态分析

本小节报告启发 SAF 设计的初步研究（第 1 节）：我们在 Qwen3-4B 数学推理任务上实现固定融合 $A_i^{\text{GRPO}} + A_{i,t}^{\text{OPD}}$，诊断其导致训练不稳定的原因，并通过原始 OPD 优势分布及其产生的优化轨迹追踪由此造成的量级失配和时序失配，随后分析在这两种失配均得到控制后，SAF 为何能够优于该融合方法。

[1] https://github.com/huggingface/Math-Verify



(a) 策略模型熵　(b) 学生–教师 KL 散度　(c) 评价模型得分

(d) 回答长度　(e) AIME-24 准确率　(f) AIME-25 准确率

图 4 | Qwen3-4B 在数学推理任务上经过 300 个优化步骤的训练动态：(a) 策略模型熵，(b) 学生–教师 KL 散度，(c) 评价模型平均得分，(d) 平均回答长度，(e) AIME-24 准确率，以及 (f) AIME-25 准确率。这些曲线比较了相同任务设置下的 GRPO、OPD、固定系数 GRPO+OPD 和 SAF。

OPD 优势分布。 我们首先量化阶段 1–2 所要调控的 $A_{i,t}^{\mathrm{OPD}}$ 与 A_i^{GRPO} 之间的量级失配。图 3 将 Qwen3-4B 前十个训练步骤中收集的 $|A_{i,t}^{\mathrm{OPD}}|$ 分箱统计，附录 D 则报告另外五个步骤中的代表性逐词元数值。两种视角都呈现相同模式：绝大多数词元携带的优势接近于零，而少数词元的优势则高出一至两个数量级。具体而言，附录 D 中检查的 180 个绝对值最大的 OPD 词元，其绝对值无一例外都超过所属序列的 GRPO 优势绝对值；OPD 的极值达到 20.3585，而同时出现的最大 GRPO 优势绝对值仅为 2.4749。在固定融合下，尽管两种优势名义上以 1:1 加权，这类词元仍会在数值上主导其整个序列的更新。该分布构成了第 3.2 节所引入的逐序列 top-k% 过滤和有界 tanh 压缩的依据。

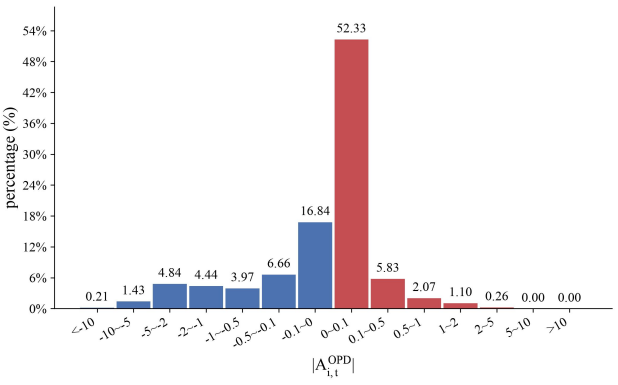


图 3 | Qwen3-4B 在数学推理任务前 10 个训练步骤中收集的逐词元 OPD 优势绝对值 $|A_{i,t}^{\mathrm{OPD}}|$ 的经验分布。

四种机制下的训练动态。 接下来，我们比较这种量级失配如何传播至优化过程。图 4 通过五项诊断指标追踪 Qwen3-4B 在数学推理任务上采用 GRPO、OPD、固定系数 GRPO+OPD 和 SAF 时历经 300 个优化步骤的表现：策略模型熵、学生–教师 KL 散度、评价模型得分、回答长度和验证准确率。固定系数融合迅速将策略模型熵从约 0.35 降至 0.30 并维持在这一水平附近，同时还将学生–教师 KL 降至四种机制中的最低水平；这与未经调控、呈重尾分布的 OPD 词元反复将学生模型拉向教师模型的现象一致。未接收教师信号的 GRPO-only 位于另一个极端：其熵升至 0.42 以上，KL 则始终最高。SAF 介于两种极端之间，将熵维持在约 0.35–0.38 的中间水平，并逐步降低 KL，但不会像固定融合那样紧密地跟随教师；这与第 3.3 节中将量级控制与先预热后退火的调度相结合所要达到的效果一致。

训练动态与任务性能的联系。 这种中间机制带来了可衡量的下游收益，而非仅仅增加了随机性。SAF 的评价模型得分迅速恢复并最终达到约 0.84，接近表现最强的 GRPO 轨迹；固定融合则在较低的约 0.77 处进入平台期。回答长度呈现相应模式：经历共同的早期瞬态变化后，固定融合稳定在约 4.5k 个词元，而 SAF 继续生成约 5.3k–6.2k 个词元的回答，既避免了低熵固定融合策略下的短回答状态，又未扩展到 GRPO 约 7k 个词元的回答长度。验证准确率呈现相同的排序：SAF 在训练后期持续提升，并且最终在 AIME-24（约 0.59 对 0.57）和 AIME-25（约 0.53 对 0.51）上都高于

固定融合。值得注意的是，固定融合最紧密地跟随教师模型（KL 最低），但最终准确率最低且最早进入平台期，因此，更紧密的模仿并未转化为更好的性能；这与教师模型只是一个并不完美的代理相一致，因为长时间进行全强度模仿会过拟合这一代理，而非可验证奖励。综合来看，这些诊断指标支持同一种解释：未经调控的全强度蒸馏以牺牲熵、回答长度并使准确率更早进入平台期为代价来降低 KL；相比之下，SAF 的控制机制既保留了足以稳定训练的教师指导，又为持续进行奖励驱动的探索留下空间。我们将此分析视为诊断性分析；表 2 分离了各组件的因果贡献，附录 B 则报告了与这一诊断一致的额外参数空间证据。

4.5 跨规模与跨领域分析

在涵盖 Qwen3-8B、Qwen3-4B 和 Qwen3-1.7B 的全部六种模型–领域设置中，SAF 相较固定融合的优势始终存在，增益范围为 0.51% 至 2.70%。这种增益并不局限于某一种容量机制：在数学推理任务上，随着学生模型缩小，优势幅度单调增大（8B 为 0.97%，4B 为 1.51%，1.7B 为 1.85%）；这一结果与较小的学生模型在得到控制后会更多依赖信息更密集的 OPD 信号相一致。在代码生成任务上，该模式并非单调变化—4B 时最大（2.70%），8B 时仍较为显著（1.67%），1.7B 时最小（0.51%，此时 OPD-only 已是最强基线）—这表明规模会与领域交互，而非仅作为单一的难度维度。结合消融实验，这些结果表明，在不同模型规模和任务领域中，对有界逐词元蒸馏信号实施时序控制均有益；但我们不会据此声称该方法对未经测试的教师模型、超参数或本文所研究的 1.7B–8B 范围之外的规模具有稳健性。

5 结论

本文研究了如何融合回答级 GRPO 优势与逐词元 OPD 优势，同时避免二者中的任何一方使另一方失稳。朴素的固定系数求和存在量级失配，即逐词元 OPD 优势的峰值远超有界 GRPO 优势；同时还存在时序失配，即随着学生模型逐渐收敛于教师模型，全强度指导的价值会发生漂移。SAF 通过一个四阶段、可切换的流水线同时解决这两个问题：该流水线将先进行 top-k 稀疏化、再进行 tanh 压缩的量级控制，与先预热、后退火的时序控制相结合，且不增加任何辅助模型、教师查询或损失项。在采用 Qwen3-8B、Qwen3-4B 和 Qwen3-1.7B 的数学推理与代码生成任务上，SAF 在全部六种设置中均比固定系数 GRPO+OPD 提升 0.51–2.70%；尽管固定系数基线最紧密地跟随教师模型，SAF 仍避免了该基线出现的早期熵坍缩和最低准确率平台。因此，稀疏的可验证奖励与密集的代理信号之间的融合不应简化为单一混合系数，而应在训练过程中分别控制信号的量级与可信度。

参考文献

Kaiyan Zhang, Yuxin Zuo, Bingxiang He, Youbang Sun, Runze Liu, Che Jiang, Yuchen Fan, Kai Tian, Guoli Jia, Pengfei Li, Yu Fu, Xingtai Lv, Yuchen Zhang, Sihang Zeng, Shang Qu, Haozhan Li, Shijie Wang, Yuru Wang, Xinwei Long, Fangfu Liu, Xiang Xu, Jiaze Ma, Xuekai Zhu, Ermo Hua, Yihao Liu, Zonglin Li, Huayu Chen, Xiaoye Qu, Yafu Li, Weize Chen, Zhenzhao Yuan, Junqi Gao, Dong Li, Zhiyuan Ma, Ganqu Cui, Zhiyuan Liu, Biqing Qi, Ning Ding, and Bowen Zhou. 大型推理模型强化学习综述，2025. URL https://arxiv.org/abs/2509.08827.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. DeepSeekMath：推动开放语言模型的数学推理极限，2024. URL https://arxiv.org/abs/2402.03300.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, Runxin Xu, Ruoyu Zhang, Shirong Ma, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z. F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Hanwei Xu, Honghui Ding, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jingchang Chen, Jingyang Yuan, Jinhao Tu, Junjie Qiu, Junlong Li, J. L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaichao You, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Liang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Mingxu Zhou, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qiushi Du, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, R. J. Chen, R. L. Jin, Ruyi Chen, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shengfeng Ye, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, S. S. Li, Shuang Zhou, Shaoqing Wu, Tao Yun, Tian Pei, Tianyu Sun, T. Wang, Wangding Zeng, Wen Liu, Wenfeng Liang, Wenjun Gao, Wenqin Yu, Wentao Zhang, W. L. Xiao, Wei An, Xiaodong Liu, Xiaohan Wang, Xiaokang Chen, Xiaotao Nie, Xin Cheng, Xin Liu, Xin Xie, Xingchao Liu, Xinyu Yang, Xinyuan Li, Xuecheng Su, Xuheng Lin, X. Q. Li, Xiangyue Jin, Xiaojin Shen, Xiaosha Chen, Xiaowen Sun, Xiaoxiang Wang, Xinnan Song, Xinyi Zhou,

Xianzu Wang, Xinxia Shan, Y. K. Li, Y. Q. Wang, Y. X. Wei, Yang Zhang, Yanhong Xu, Yao Li, Yao Zhao, Yaofeng Sun, Yaohui Wang, Yi Yu, Yichao Zhang, Yifan Shi, Yiliang Xiong, Ying He, Yishi Piao, Yisong Wang, Yixuan Tan, Yiyang Ma, Yiyuan Liu, Yongqiang Guo, Yuan Ou, Yuduan Wang, Yue Gong, Yuheng Zou, Yujia He, Yunfan Xiong, Yuxiang Luo, Yuxiang You, Yuxuan Liu, Yuyang Zhou, Y. X. Zhu, Yanping Huang, Yaohui Li, Yi Zheng, Yuchen Zhu, Yunxian Ma, Ying Tang, Yukun Zha, Yuting Yan, Z. Z. Ren, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhicheng Ma, Zhigang Yan, Zhiyu Wu, Zihui Gu, Zijia Zhu, Zijun Liu, Zilin Li, Ziwei Xie, Ziyang Song, Zizheng Pan, Zhen Huang, Zhipeng Xu, Zhongyu Zhang, and Zhen Zhang. DeepSeek-R1 通过强化学习激励大语言模型推理。 *Nature*, 645(8081):633–638, 2025. ISSN 1476-4687. doi: 10.1038/s41586-025-09422-z. URL http://dx.doi.org/10.1038/s41586-025-09422-z.

Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos, Matthieu Geist, and Olivier Bachem. 语言模型的在线策略蒸馏：从自身生成的错误中学习，2024. URL https://arxiv.org/abs/2306.13649.

Yuxian Gu, Li Dong, Furu Wei, and Minlie Huang. MiniLLM：大语言模型的知识蒸馏。载于第十二届学习表征国际会议，2024. URL https://openreview.net/forum?id=5h0qf7IBZZ.

Yifeng Liu, Shiyuan Zhang, Yifan Zhang, and Quanquan Gu. 自蒸馏策略梯度，2026. URL https://arxiv.org/abs/2606.04036.

Wenkai Yang, Weijie Liu, Ruobing Xie, Kai Yang, Saiyong Yang, and Yankai Lin. 超越教师学习：基于奖励外推的广义在线策略蒸馏。*arXiv* 预印本 *arXiv:2602.12125*，2026a.

Ganqu Cui, Yuchen Zhang, Jiacheng Chen, Lifan Yuan, Zhi Wang, Yuxin Zuo, Haozhan Li, Yuchen Fan, Huayu Chen, Weize Chen, et al. 推理语言模型强化学习的熵机制，2025a. URL https://arxiv.org/abs/2505.22617.

Chen Wang, Zhaochun Li, Jionghao Bai, Yining Zhang, Hexuan Deng, Ge Lan, and Yue Wang. 面向大语言模型后训练的蒸馏强化学习，2026a. URL https://arxiv.org/abs/2607.17247.

MiMo Core Team. MiMo-V2-Flash 技术报告，2026. URL https://arxiv.org/abs/2601.02780.

Rui Wang, Hongru Wang, Yi Chen, Boyang Xue, Tianqing Fang, Wenhao Yu, and Kam-Fai Wong. 揭秘在线策略蒸馏：作用、病理与调控，2026b. URL https://arxiv.org/abs/2607.13399.

Xingrun Xing, Haoqing Wang, Boyan Gao, Ziheng Li, and Yehui Tang. 信赖域在线策略蒸馏，2026. URL https://arxiv.org/abs/2606.01249.

Anhao Zhao, Junlong Tong, Yingqi Fan, Ping Nie, Wenjie Li, and Xiaoyu Shen. PowerOPD：利用有界幂变换稳定在线策略蒸馏，2026. URL https://arxiv.org/abs/2606.17199.

Feng Luo, Yu-Neng Chuang, Guanchu Wang, Zicheng Xu, Xiaotian Han, Tianyi Zhang, and Vladimir Braverman. 揭秘 OPD：大语言模型的长度膨胀与稳定策略，2026. URL https://arxiv.org/abs/2604.08527.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 近端策略优化算法，2017. URL https://arxiv.org/abs/1707.06347.

Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. 理解类 R1-Zero 训练：批判性视角，2025. URL https://arxiv.org/abs/2503.20783.

Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. DAPO：大规模开源大语言模型强化学习系统，2025. URL https://arxiv.org/abs/2503.14476.

Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, et al. 组序列策略优化，2025. URL https://arxiv.org/abs/2507.18071.

Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. 让我们逐步验证，2023. URL https://arxiv.org/abs/2305.20050.

Peiyi Wang, Lei Li, Zhihong Shao, R. X. Xu, Damai Dai, Yifei Li, Deli Chen, Y. Wu, and Zhifang Sui. Math-Shepherd：无需人工标注逐步验证并强化大语言模型，2024. URL https://arxiv.org/abs/2312.08935.

Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 神经网络中的知识蒸馏，2015. URL https://arxiv.org/abs/1503.02531.

Yoon Kim and Alexander M. Rush. 序列级知识蒸馏，2016. URL https://arxiv.org/abs/1606.07947.

Mingyang Song and Mao Zheng. 大语言模型在线策略蒸馏综述，2026. URL https://arxiv.org/abs/2604.00626.

Bowen Zhang. 在线策略蒸馏的公式驱动综述与研究议程，2026. URL https://arxiv.org/abs/2606.22793.

Jongwoo Ko, Sungnyun Kim, Tianyi Chen, and Se-Young Yun. DistillM：迈向面向大语言模型的精简蒸馏，2024. URL https://arxiv.org/abs/2402.03898.

Qiyong Zhong, Mao Zheng, Mingyang Song, Xin Lin, Jie Sun, Houcheng Jiang, Xiang Wang, and Junfeng Fang. SOD：面向小语言模型智能体的逐步在线策略蒸馏。*arXiv* 预印本 *arXiv:2605.07725*，2026.

Woogyeol Jin, Taywon Min, Yongjin Yang, Dennis Wei, Yi Zhou, Swanand Ravindra Kadhe, Nathalie Baracaldo, and Kimin Lee. 语言模型的熵感知在线策略蒸馏，2026. URL https://arxiv.org/abs/2603.07079.

Jongwoo Ko, Sara Abdali, Young Jin Kim, Tianyi Chen, and Pashmina Cameron. 通过宽松在线策略蒸馏高效扩展推理能力，2026. URL https://arxiv.org/abs/2603.11137.

Shenzhi Yang, Guangcheng Zhu, Bowen Song, Haobo Wang, Mingxuan Xia, Xing Zheng, Yingfan Ma, Zhongqi Chen, Weiqiang Wang, Junbo Zhao, and Gang Chen. OPRD：在线策略表征蒸馏，2026b. URL https://arxiv.org/abs/2606.06021.

Minjae Oh, Sangjun Song, Gyubin Choi, Yunho Choi, and Yohan Jo. 用 KL 换 KL：采用控制变量基线的在线策略蒸馏，2026. URL https://arxiv.org/abs/2605.07865.

Hongling Xu, Qi Zhu, Heyuan Deng, Jinpeng Li, Lu Hou, Yasheng Wang, Lifeng Shang, Ruifeng Xu, and Fei Mi. KDRL：通过统一知识蒸馏与强化学习对推理大语言模型进行后训练，2025. URL https://arxiv.org/abs/2506.02208.

Chenxu Yang, Chuanyu Qin, Qingyi Si, Minghui Chen, Naibin Gu, Dingyu Yao, Zheng Lin, Weiping Wang, Jiaqi Wang, and Nan Duan. 自蒸馏 RLVR，2026c. URL https://arxiv.org/abs/2604.03128.

Zhengxi Lu, Zhiyuan Yao, Zhuowen Han, Zi-Han Wang, Jinyang Wu, Qi Gu, Xunliang Cai, Weiming Lu, Jun Xiao, Yueting Zhuang, and Yongliang Shen. 自蒸馏智能体强化学习，2026. URL https://arxiv.org/abs/2605.15155.

Qitai Tan, Zefang Zong, Yang Li, and Peng Chen. ATOD：面向多轮自主智能体的退火式轮次感知在线策略蒸馏，2026. URL https://arxiv.org/abs/2606.27814.

Leyi Pan, Shuchang Tao, Yunpeng Zhai, Lingzhe Zhang, Zhaoyang Liu, Bolin Ding, Aiwei Liu, and Lijie Wen. RLCSD：基于对比式在线策略自蒸馏的强化学习，2026. URL https://arxiv.org/abs/2606.11709.

Jiaxuan Wang, Xuan Ouyang, Zhiyu Chen, Yulan Hu, Zheng Pan, Xin Li, and Lan-Zhe Guo. TRACE：通过词元路由的自在线策略对齐在关键位置蒸馏，2026c. URL https://arxiv.org/abs/2605.10194.

Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. HybridFlow：灵活高效的 RLHF 框架。载于第二十届欧洲计算机系统会议论文集，第 1279–1297 页。ACM，2025. doi: 10.1145/3689031.3696075.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 技术报告，2025. URL https://arxiv.org/abs/2505.09388.

Zhiwei He, Tian Liang, Jiahao Xu, Qiuzhi Liu, Xingyu Chen, Yue Wang, Linfeng Song, Dian Yu, Zhenwen Liang, Wenxuan Wang, et al. DeepMath-103K：用于推进推理的大规模、高难度、去污染且可验证的数学数据集。*arXiv* 预印本 *arXiv:2504.11456*，2025.

Ganqu Cui, Lifan Yuan, Zefan Wang, Hanbin Wang, Wendi Li, Bingxiang He, Yuchen Fan, Tianyu Yu, Qixin Xu, Weize Chen, et al. 通过隐式奖励进行过程强化。*arXiv* 预印本 *arXiv:2502.01456*，2025b.

AI-MO. Aime 2024. https://huggingface.co/datasets/AI-MO/aimo-validation-aime, 2024.

OpenCompass. Aime 2025. https://huggingface.co/datasets/opencompass/AIME2025, 2025.

Mislav Balunović, Jasper Dekoninck, Ivo Petrov, Nikola Jovanović, and Martin Vechev. MathArena：在无污染数学竞赛上评估大语言模型，2025. URL https://matharena.ai/.

Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang, and Lingming Zhang. ChatGPT 生成的代码真的正确吗？对用于代码生成的大语言模型的严格评测。载于第三十七届神经信息处理系统大会，2023. URL https://openreview.net/forum?id=1qvx610Cu7.

Naman Jain, King Han, Alex Gu, Wen-Ding Li, Fanjia Yan, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. LiveCodeBench：对用于代码的大语言模型进行整体且无污染的评测。*arXiv* 预印本 *arXiv:2403.07974*，2024.

Yuchen Cai, Ding Cao, Liang Lin, Chunxi Luo, Xin Xu, Kai Yang, Weijie Liu, Saiyong Yang, Tianxiang Zhao, Guangzhong Sun, Guiquan Liu, and Junfeng Fang. 学会预见：揭示在线策略蒸馏的解锁效率，2026. URL https://arxiv.org/abs/2605.11739.

A 详细实验设置

我们使用 Qwen3-30B-A3B-Instruct-2507 作为教师模型，并以 Qwen3-8B、Qwen3-4B 或 Qwen3-1.7B 初始化学生模型。数学训练使用经过筛选的 DeepMath 子集，其中包含 57K 道难度等级不低于 6 的题目；代码训练则使用包含 25K 道题目的 Eurus-RL-Code 数据集。当最终数学答案正确或所有代码单元测试均通过时，基于规则的验证器赋予奖励 1，否则赋予 0。学生回答采用同策略采样，教师模型逐词元为这些相同的回答评分，而不生成单独的轨迹。

基于 GRPO 的方法。 对于给定的学生模型规模和领域，纯 GRPO、GRPO+OPD（固定）和 SAF 使用相同的优化与采样配置，只有优势构造方式不同。我们在数学任务上将这些方法优化 300 步，在代码任务上优化 200 步。表 3 列出了它们共用的超参数。

Hyperparameter	Mathematics	Code
Train batch size	128	128
Micro batch size	128	128
Responses per prompt (G)	8	8
Maximum prompt length	2,048	2,048
Maximum response length	16,384	8,192
Rollout temperature	1.0	1.0
Rollout top-p	1.0	1.0
Actor learning rate	1×10^{-6}	1×10^{-6}
Optimization steps	300	200
Actor KL-loss coefficient	0.0	0.0

表 3 | 基于 GRPO 的方法所用训练超参数：纯 GRPO、GRPO+OPD（固定）和 SAF。

纯 OPD。 纯 OPD 对数学推理和代码生成使用不同配置，汇总见表 4。两个领域均采用 1,024 的批大小、每个提示一次学生模型采样，以及 1×10^{-6} 的学习率。我们在数学任务上将纯 OPD 优化 100 步，在代码任务上优化 50 步；对应的最大回答长度分别为 16,384 和 8,192 个词元。

Hyperparameter	Mathematics	Code
Batch size	1,024	1,024
Responses per prompt	1	1
Maximum prompt length	2,048	2,048
Maximum response length	16,384	8,192
Rollout temperature	1.0	1.0
Rollout top-p	1.0	1.0
Learning rate	1×10^{-6}	1×10^{-6}
Optimization steps	100	50

表 4 | 纯 OPD 用于数学推理和代码生成的训练超参数。

优势配置。 对于纯 GRPO，我们将 OPD 项设为零；对于纯 OPD，我们将验证器导出的 GRPO 优势设为零。GRPO+OPD（固定）使用单位 OPD 系数，对应于 1:1 融合 $A_i^{\mathrm{GRPO}} + A_{i,t}^{\mathrm{OPD}}$，并禁用 SAF 的全部四项控制。完整 SAF 从相同的单位系数出发，并应用表 5 中的设置。每个回答均独立重新计算 top-k 阈值。预热最多持续 100 个优化步骤；当学生—教师 KL 的相对下降达到 0.2 时，也可能提前结束。预热后，局部退火计数器覆盖所有剩余步骤，因此 OPD 系数会在特定领域训练预算结束时降至零，而不是采用单独调节的衰减时长。

评测设置。 对每个模型，我们使用 1.0 的温度、1.0 的 top-p 和 16,384 个词元的最大生成长度，但 HumanEval+ 与 MBPP+ 使用贪心解码。在每个数学基准（AIME-24、AIME-25、HMMT25-Feb 和 HMMT25-Nov）上，我们为每道题采样 32 个解，并报告各次采样的平均准确率；而在 LiveCodeBench v6（2025 年 2 月至 5 月）上，我们为每道题采样四个解并报告 pass@1，即只要至少一个采样解通过，就将该题计为已解决。数学答案由 Math-Verify 检查，代码提交则由基准提供的单元测试评分。Base、所有基线及 SAF 均固定采用这些解码和评分设置。

Hyperparameter	Value
Per-response retention ratio k	20%
tanh compression coefficient c	0.1
Maximum warm-up steps S_{warmup}	100
Relative KL-drop threshold δ	0.2
Initial OPD coefficient	1.0
Annealing floor $c_{\min}$	0.0
Annealing duration	Remaining training steps

表 5 | 所选 SAF 配置的方法特定超参数。

计算基础设施。 所有实验均在一个节点上运行，该节点配备 8×NVIDIA H200 GPU（每个 GPU 具有 140GB HBM3e 显存，采用 Hopper 架构）、96 个物理 CPU 核心（184 个逻辑核心）以及 1.5TB 系统内存。

B 训练动态：参数空间补充分析

第 4.4 节基于熵、学生—教师 KL、评判模型得分、回答长度和验证准确率，报告了 Qwen3-4B 在数学推理任务上采用 GRPO、OPD、固定系数 GRPO+OPD 和 SAF 训练时的优化轨迹（图 4）。本附录从更具探索性的参数空间视角补充分析相同的训练方案。

参数空间更新几何（补充）。 第 4.4 节中的诊断均在优势信号或训练曲线上计算。作为一项额外且更具探索性的证据，我们还检查了表 3 和表 4 所报告的相同纯 GRPO 与纯 OPD 检查点产生的参数空间更新矩阵 $\Delta W^{(t)} = W^{(t)}_{\text{trained}} - W_{\text{base}}$；分析限定于前 300 个优化步骤，并采用逐层 SVD。图 5 汇总了在前 100 个共同优化步骤内计算的三个量（纯 OPD 在数学任务上训练 100 步，并在这一时域保存检查点）：(a) 各方法更新矩阵的平均稳定秩 $\|\Delta W\|_F^2/\|\Delta W\|_{\text{op}}^2$，(b) 两种方法左奇异子空间（输出/“写入”方向）的重叠，以及 (c) 两种方法右奇异子空间（输入/“读取”方向）的重叠。与第 4.4 节赋予两种信号的定性作用一致，在整个时域内，OPD 更新的稳定秩显著低于 GRPO，这表明其更新能量更集中于少数方向，而 GRPO 更新保持相对更高的秩且更为分散。两种方法的更新还从相似的输入子空间读取（右奇异子空间重叠较高），却写入大体不同的输出子空间（左奇异子空间重叠明显较低）；这表明 GRPO 与 OPD 会关注重叠的输入特征，但会将策略推向不同方向。我们将其作为参数几何层面的补充性探索观察来报告，而非直接支持 SAF 优势层设计的证据；SAF 的量级控制或时序控制均不是依据该分析构建的，关于更新矩阵几何与优势融合设计之间联系的严格研究留待未来工作 Cai et al. [2026]。

指标定义。 下面精确定义本附录所用的四个量（稳定秩、左/右奇异子空间重叠以及两种权重漂移统计量）。所有量均从逐步更新矩阵 $\Delta W_\ell^{(t)} = W^{(t)}_{\text{trained},\ell} - W^0_\ell$ 逐层计算，其中 ℓ 表示给定 Transformer 层中的一个 2D 权重矩阵（`q/k/v/o_proj` 或 `gate/up/down_proj`），W^0_ℓ 是对应的基座模型权重。每个 $\Delta W_\ell^{(t)}$ 均通过（经济型）奇异值分解被分解为 $\Delta W_\ell^{(t)} = U_\ell^{(t)}\Sigma_\ell^{(t)}(V_\ell^{(t)})^\top$，其奇异值为 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0$（$r = \min(m,n)$）；$\|\Delta W\|_F = \|\boldsymbol{\sigma}\|_2 = \left(\sum_i \sigma_i^2\right)^{1/2}$ 表示 Frobenius 范数，$\|\Delta W\|_{\text{op}} = \sigma_1$ 表示算子（谱）范数。$U_\ell^{(t)}$ 的列张成更新的输出（“写入”）子空间，$(V_\ell^{(t)})^\top$ 的行张成更新的输入（“读取”）子空间。

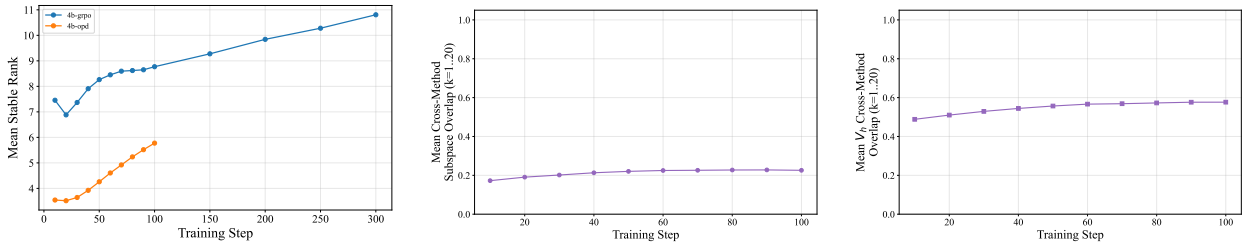
*稳定秩。*对于单个矩阵，稳定秩是按能量加权的有效维数

$$\text{StableRank}\big(\Delta W_\ell^{(t)}\big) = \frac{\|\Delta W_\ell^{(t)}\|_F^2}{\|\Delta W_\ell^{(t)}\|_{\text{op}}^2} = \frac{\sum_{i=1}^r \sigma_i^2}{\sigma_1^2} \in [1, r], \tag{5}$$

当所有更新能量都集中在首个奇异方向时，该值等于 1；当能量均匀分布在所有方向时，该值等于 r。图 5(a) 中的曲线针对每种方法，在给定步骤上对所有 2D 权重矩阵的该值取平均。

*跨方法子空间重叠。*令 $U^{(t)}_{X,k} \in \mathbb{R}^{m\times k}$（相应地，$V^{(t)}_{X,k} \in \mathbb{R}^{n\times k}$）收集方法 $X \in \{\text{GRPO}, \text{OPD}\}$ 在步骤 t 对同一层更新矩阵的前 k 个左（相应地，右）奇异向量，其中始终取 k=20。两种方法输出子空间之间的 Grassmann 式重叠定义为其交叉投影的平均奇异值，

$$\text{Overlap}_U(t) = \frac{1}{k}\sum_{j=1}^{k} s_j\Big(\big(U^{(t)}_{\text{GRPO},k}\big)^\top U^{(t)}_{\text{OPD},k}\Big) \in [0,1], \tag{6}$$



(a) 稳定秩　(b) 输出子空间重叠　(c) 输入子空间重叠

图 5 | Qwen3-4B 在数学推理上的纯 GRPO 与纯 OPD 检查点的参数空间更新几何补充分析：(a) 更新矩阵的平均稳定秩，(b) 两种方法的输出（左奇异）子空间重叠，以及 (c) 输入（右奇异）子空间重叠。

其中 $s_j(\cdot)$ 表示第 j 个奇异值；$\mathrm{Overlap}_U(t) \approx 1$ 表明两种方法写入几乎相同的输出方向，而 $\mathrm{Overlap}_U(t) \approx 0$ 表明输出子空间（近似）正交。输入子空间重叠 $\mathrm{Overlap}_V(t)$ 的定义完全相同，只需用 $V_{X,k}^{(t)}$ 替换 $U_{X,k}^{(t)}$。在绘制图 5(b)–(c) 之前，这两个量都先在各层及每层内的二维权重矩阵上取平均。

权重漂移。以 $\theta_\ell^{(t)}$ 表示步骤 t 时第 ℓ 层展平后的参数向量，以 θ_ℓ^0 表示其基座模型对应向量，则图 6 所报告的绝对 L2 漂移为

$$\|\Delta W_\ell^{(t)}\|_2 = \left\|\theta_\ell^{(t)} - \theta_\ell^0\right\|_2, \tag{7}$$

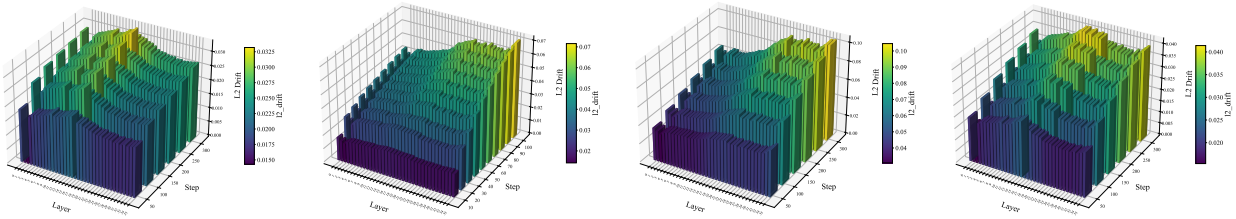
而图 7 所报告的尺度归一化相对漂移为

$$\frac{\|\Delta W_\ell^{(t)}\|_2}{\|W_\ell^0\|_2 + \epsilon} = \frac{\left\|\theta_\ell^{(t)} - \theta_\ell^0\right\|_2}{\left\|\theta_\ell^0\right\|_2 + \epsilon}, \tag{8}$$

其中 $\epsilon = 10^{-8}$ 用于防止除零。当一层包含多个具名参数张量（例如分立的 `q/k/v/o_proj` 矩阵）时，层级取值是该层各参数张量上对应指标的算术平均值。

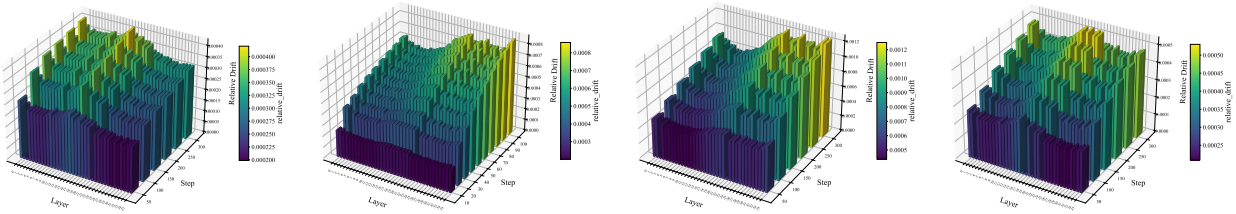
四种训练方案的逐层权重漂移（补充）。 为进一步说明上述更新矩阵几何的背景，图 6 使用与图 4 相同的 Qwen3-4B 数学推理检查点，将正文比较的四种训练方案——纯 GRPO、纯 OPD、固定系数 GRPO+OPD 和 SAF——在各层、各步骤上的 L2 权重漂移 $\|\Delta W_\ell^{(t)}\|_2$ 可视化。每个曲面都以 Transformer 层索引和优化步骤为横轴展示漂移量；请注意，各面板的 z 轴和步骤轴范围不同，因为纯 GRPO、固定融合和 SAF 展示的是完整的 300 步预算，而纯 OPD 展示的是自身完整的 100 步训练时域。纯 GRPO 逐渐累积漂移，直到约第 300 步才达到最大值，其量级（峰值 ≈ 0.03）远低于其他方案。相比之下，纯 OPD 每步漂移得快得多，仅用 100 步便达到相当或更大的量级（峰值 ≈ 0.07），这与其在每次更新中接受更密集的词元级监督一致。固定系数 GRPO+OPD 叠加了两种效应：由于它在每一步都将全强度 OPD 引导施加于 GRPO 更新之上，其漂移增长最快，并在第 300 步达到四种方案中的最大量级（峰值 ≈ 0.10），且集中于较后层。SAF 采用第 3 节所述的相同量级控制和时序退火；尽管训练步数相同，其漂移（峰值 ≈ 0.04）仍显著小于固定融合，但高于纯 GRPO。这表明 SAF 的控制器会抑制、但不会消除不受约束的蒸馏信号所诱发的过度参数移动。该模式与图 4 已讨论的熵及学生—教师 KL 轨迹一致，并提供了额外的参数空间视角：OPD 信号最缺乏控制的方案（固定融合）在参数空间中的漂移也最大，而 SAF 控制器会约束该漂移但不会将其完全压制。与图 5 一样，我们将其作为补充性探索观察来报告，而非 SAF 设计据以推导的机制。

四种训练方案的逐层相对权重漂移（补充）。 图 6 中的绝对 L2 漂移受各层参数量影响，使得单一方案内的跨层比较不够直接。作为补充的尺度归一化视角，图 7 报告了相同四种方案及检查点的相对权重漂移 $\|\Delta W_\ell^{(t)}\|_2/(\|W_\ell^0\|_2 + \epsilon)$。按基座参数范数归一化可消除层大小的混杂影响，并得到一幅与图 6 一致但更清晰的图景：纯 GRPO 在整个训练过程中始终最保守，其层平均相对漂移从第 50 步的约 2.3×10^{-4} 上升到第 300 步的约 3.6×10^{-4}（增至 $1.6\times$）。纯 OPD 再次表现出最快的逐步增长，从第 10 步的约 2.2×10^{-4} 增至第 100 步的约 6.8×10^{-4}（只用三分之一步数便增至 $3.2\times$），其最大相对漂移集中于最深层（例如第 35 层）。固定系数 GRPO+OPD 同时达到最快增长率和最大最终量级，在第 300 步时层平均相对漂移达到约 1.0×10^{-3}（相较第 10 步增至 $4.8\times$），同样集中于较后层。SAF 呈现非常接近的定性形状，但相较固定融合整体受到压缩：尽管相较自身第 10 步也有相近的 $4.1\times$ 相对增长，到第 300 步时却仅达到约 4.6×10^{-4}。这从尺度归一化角度确认，SAF 控制器所约束的是参数移动的量级，而不只是其层间分布。



(a) 纯 GRPO　(b) 纯 OPD　(c) 固定 GRPO+OPD　(d) SAF（本文方法）

图 6 | Qwen3-4B 在数学推理上的四种训练方案随 Transformer 层（x 轴）和优化步骤（y 轴）变化的逐层 L2 权重漂移 $\|\Delta W_\ell^{(t)}\|_2$：(a) 纯 GRPO，(b) 纯 OPD，(c) 固定系数 GRPO+OPD，以及 (d) SAF。



(a) 纯 GRPO　(b) 纯 OPD　(c) 固定 GRPO+OPD　(d) SAF（本文方法）

图 7 | 与图 6 相同的四种训练方案及检查点随 Transformer 层（x 轴）和优化步骤（y 轴）变化的逐层相对权重漂移 $\|\Delta W_\ell^{(t)}\|_2/(\|W_\ell^0\|_2+\epsilon)$：(a) 纯 GRPO，(b) 纯 OPD，(c) 固定系数 GRPO+OPD，以及 (d) SAF。

C　学生—教师 KL 的计算

时序控制器使用采样词元来估计从学生策略 π_θ 到教师策略 π_T 的反向 KL 散度。该估计在用于策略优化的相同学生生成回答上计算，从而避免在每个回答位置对整个词表进行 KL 评估。令 $s_{i,t}=(\boldsymbol{x}_i,\boldsymbol{y}_{i,<t})$ 表示回答 i 在词元 t 处的上下文。对于采样词元 $y_{i,t}$，我们首先计算经过截断的教师到学生对数概率比

$$d_{i,t}=\mathrm{clip}\big(\log\pi_T(y_{i,t}\mid s_{i,t})-\log\pi_\theta(y_{i,t}\mid s_{i,t}),\\ -20,20\big). \tag{9}$$

随后，我们遵循低方差 k_3 估计器，将词元级贡献定义为

$$\widehat{D}_{i,t}=\mathrm{clip}(\exp(d_{i,t})-d_{i,t}-1,-10,10)\,. \tag{10}$$

若不截断，式 10 将化为非负估计器 $r-\log r-1$，其中 $r=\pi_T(y_{i,t}\mid s_{i,t})/\pi_\theta(y_{i,t}\mid s_{i,t})$。在 $y_{i,t}\sim\pi_\theta(\cdot\mid s_{i,t})$ 下，其期望等于 $D_{\mathrm{KL}}(\pi_\theta(\cdot\mid s_{i,t})\,\|\,\pi_T(\cdot\mid s_{i,t}))$。截断操作是实现中的保护措施，用于防止数值溢出和有限样本中的极端贡献。

令 $m_{i,t}\in\{0,1\}$ 为回答掩码，用于排除提示和填充位置。我们采用词元均值聚合有效词元的贡献：

$$KL_s=\frac{\sum_{i,t}m_{i,t}\widehat{D}_{i,t}}{\sum_{i,t}m_{i,t}}. \tag{11}$$

该标量以 `actor/kl_loss` 记录。在我们的配置中，`use_kl_loss=True` 启用其计算，而 `kl_loss_coef=0` 则阻止它向策略模型目标贡献额外的 KL 正则项。因此，它仅作为可观测的学生—教师对齐统计量。预热控制器将其初始值记录为 KL_0，并在第 3.3 节的提前停止准则中使用相对下降量 $(KL_0-KL_s)/KL_0$。

D　词元级原始信号分析

本附录考察前五个连续训练步骤中的两种未经处理的训练优势。我们沿用第 3.1 节的记号：$A_{i,t}^{\mathrm{OPD}}=\log\pi_T(y_{i,t}\mid s_{i,t})-\log\pi_\theta(y_{i,t}\mid s_{i,t})$ 表示词元级 OPD 优势，A_i^{GRPO} 表示回答 i 的所有词元共享的回答级 GRPO 优势。这两个量分别对应实现字段 `raw_opd` 和 `raw_grpo`。

对于每个训练步骤，我们选择三个具有代表性的回答：**(a)** A_i^{GRPO} 最负的回答（错误），**(b)** A_i^{GRPO} 接近零的回答（中性/混合），以及 **(c)** A_i^{GRPO} 最正的回答（正确）。对于每个回答，我们报告 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 个位置、用于提供局部上下文的前 15 个回答词元，以及在全部回答词元上计算的汇总统计量。在每个回答块中，两个词元级表格沿横轴排列词元位置，后接一个紧凑的汇总表。

D.1 训练步骤 1

(a) 回答 189（$A_i^{\text{GRPO}} = -2.4749$，**错误，3148 个词元**）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	189	346	540	641	847	946	994	1383	1847	3091	3092	3134
Token	`several`	`2`	`will`	`term`	`E`	`7`	`cancel`	`}`	`\`	`Now`	`take`	`---↩↩`
$A_{i,t}^{\text{OPD}}$	-13.7876	-17.4881	-10.5098	-13.9257	-14.4314	-9.0760	-8.5954	-10.7748	-9.3498	-10.9243	-10.2098	-8.9048

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`the`	`infinite`	`product`	`:↩↩`	`$$`	`↩`	`\`	`prod`	`_{`	`n`	`=`	`2`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0004	-4.6245	+0.0068	+0.0007	+0.0000	+0.0005	+0.0000	+0.0000	+0.0019	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000

汇总（3148 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.2594	-2.4749
std	+1.2329	0.0000
min	-17.4881	-2.4749
max	+5.6796	-2.4749

(b) 回答 0（$A_i^{\text{GRPO}} = +0.3536$，**中性，363 个词元**）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	66	92	94	107	110	120	132	136	177	258	347	362
Token	`find`	`This`	`an`	`exponential`	`**`	`$`	`over`	`real`	`variables`	`our`	`Final`	`<|im_end|>`
$A_{i,t}^{\text{OPD}}$	-8.4885	-6.3400	-6.1097	-5.9964	-8.8939	-8.1489	-6.5749	-10.1239	-7.3847	-5.4155	-9.6873	-5.2518

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`joint`	`density`	`function`	`:↩↩`	`$$`	`↩`	`f`	`(x`	`,`	`y`	`,`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0001	+0.0139	-0.0141	+0.1487	-1.6046	+0.0000	-2.2116	+0.0000	+0.0000	+0.0000	+0.0001	-1.1151	+0.0000	+0.0000

汇总（363 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.5425	+0.3536
std	+1.6162	0.0000
min	-10.1239	+0.3536
max	+1.8588	+0.3536

(c) 回答 135（$A_i^{\text{GRPO}} = +2.4749$，**正确，695 个词元**）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	23	89	183	219	224	247	248	259	274	327	356	636
Token	`**`	`function`	`equal`	`}`	`since`	`**`	`zero`	`(g`	`permutation`	`Half`	`number`	`Final`
$A_{i,t}^{\text{OPD}}$	-7.6053	-8.7120	-10.3569	-11.7299	-6.7478	-8.6477	-11.7095	-8.4914	-8.5523	-7.0024	-14.7974	-9.8838

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`determine`	`whether`	`the`	`following`	`statement`	`is`	`**`	`true`	`for`	`all`	`$`
$A_{i,t}^{\text{OPD}}$	+0.0001	+0.0002	+0.4287	+0.0065	+0.0016	+0.0023	+0.0028	+0.3882	+0.0249	+0.0000	-1.9667	+0.0000	+0.0067	+0.0000	-0.6986

汇总（**695** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.3897	+2.4749
std	+1.5458	0.0000
min	-14.7974	+2.4749
max	+1.9325	+2.4749

D.2 训练步骤 2

(a) 回答 **8**（$A_i^{\text{GRPO}} = -2.4749$，错误，**733** 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 **12** 项：

Position	68	118	137	160	249	287	289	498	554	571	719	721
Token	`term`	`(`	`}↩`	`\`	`1`		`+`		`Therefore`	`Then`	`---↩↩`	`Final`
$A_{i,t}^{\text{OPD}}$	-7.2954	-9.7388	-7.1736	-11.2268	-17.9447	-16.4380	-10.4996	-15.2381	-8.4721	-8.6563	-9.9507	-10.2704

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`evaluate`	`the`	`limit`	`:↩↩`	`$$`	`↩`	`\`	`lim`	`_{`	`n`	`\`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0008	+0.1321	+0.0000	+0.0027	+0.0053	+0.0085	+0.0053	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	-3.3742

汇总（**733** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.4116	-2.4749
std	+1.7312	0.0000
min	-17.9447	-2.4749
max	+2.5161	-2.4749

(b) 回答 **4**（$A_i^{\text{GRPO}} = +0.3536$，中性，**602** 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 **12** 项：

Position	318	334	359	379	432	447	477	497	571	574	587	590
Token	`$↩↩`	`1`	`looks`	`+`	`approx`	`Thus`	`Therefore`	`$↩↩`	`Therefore`	`final`	`---`	`Final`
$A_{i,t}^{\text{OPD}}$	-10.7052	-6.9898	-7.0174	-9.4997	-7.7371	-12.4224	-11.3634	-7.8916	-10.2927	-9.2755	-7.8828	-8.2090

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`evaluate`	`the`	`limit`	`:↩↩`	`$$`	`↩`	`\`	`lim`	`_{`	`n`	`\`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0008	+0.1333	+0.0000	+0.0027	+0.0052	+0.0150	+0.0053	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	-4.1184

汇总（**602** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.4214	+0.3536
std	+1.6275	0.0000
min	-12.4224	+0.3536
max	+2.0158	+0.3536

(c) 回答 **37**（$A_i^{\text{GRPO}} = +2.4749$，正确，**1383** 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 **12** 项：

Position	148	154	205	329	336	528	530	650	713	749	814	991
Token	`space`	`can`	`F`	`measurable`	`also`	`can`	`associated`	`However`	`This`	`power`	`can`	`Since`
$A_{i,t}^{\text{OPD}}$	-8.0621	-7.8963	-10.5909	-20.3585	-13.4059	-12.1148	-8.4644	-9.0888	-7.9808	-10.7333	-11.8686	-12.1417

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`find`	`the`	`**`	`card`	`inality`	`**`	`of`	`the`	`set`	`of`	`**`
$A_{i,t}^{\text{OPD}}$	+0.0015	+0.0082	+0.0010	+0.0000	+0.0779	+0.0001	+0.0004	-0.0000	+0.0000	+0.0007	-0.0001	+0.0000	+0.0019	+0.0000	-0.0332

汇总（**1383** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.4614	+2.4749
std	+1.5323	0.0000
min	-20.3585	+2.4749
max	+2.5852	+2.4749

D.3 训练步骤 3

(a) 回答 152（$A_i^{\text{GRPO}} = -2.4749$，错误，**1033** 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 **12** 项：

Position	42	231	318	416	450	457	546	559	881	940	946	985
Token	`(`	`+`	`\`	`very`	`approx`	`So`	`left`	↩	`Take`	`<`	`So`	`something`
$A_{i,t}^{\text{OPD}}$	-12.3997	-6.8740	-7.9706	-8.4695	-10.7473	-8.2718	-7.1454	-7.7500	-7.3970	-7.7376	-12.9474	-9.0241

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`recursive`	`sequence`	`defined`	`by`	`:↩↩`	`$$`	↩	`b`	`_`	`1`	`=`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0002	+0.0028	+0.0797	+0.2692	+0.0007	-2.8324	+0.2013	+0.0022	+0.0273	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000

汇总（**1033** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.2942	-2.4749
std	+1.2957	0.0000
min	-12.9474	-2.4749
max	+2.9957	-2.4749

(b) 回答 2（$A_i^{\text{GRPO}} = -0.3536$，中性，**552** 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 **12** 项：

Position	6	54	87	206	227	261	280	311	362	422	519	551
Token	`(`	`to`	`important`	`is`	`subset`	`is`	`subset`	`The`	`-`	`ring`	`Conclusion`	`<|im_end|>`
$A_{i,t}^{\text{OPD}}$	-7.2268	-7.1247	-6.3155	-9.5342	-7.9704	-7.0191	-16.1068	-9.0377	-8.4210	-6.8585	-9.7430	-9.3995

回答的前 **15** 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`**`	`local`	`(`	`not`	`No`	`ether`	`ian`	`)`	`domain`	`**`	`$`
$A_{i,t}^{\text{OPD}}$	+0.0001	+0.0000	+0.0256	+0.1121	+0.3423	+0.0000	-7.2268	+0.0141	-4.0181	+0.0000	+0.0000	-1.3005	+0.0001	-0.0074	-0.0000

汇总（**552** 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.4796	-0.3536
std	+1.6198	0.0000
min	-16.1068	-0.3536
max	+2.2114	-0.3536

(c) 回答 16（$A_i^{\text{GRPO}} = +2.4749$，正确，921 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	118	155	173	259	283	577	594	708	712	765	874	901
Token	`such`	`solutions`	`pairs`	`unity`	`only`	`Now`	`the`	`the`	`:↩↩`	`This`	`So`	`---↩↩`
$A_{i,t}^{\text{OPD}}$	-6.7144	-6.9551	-15.1645	-7.5274	-6.8762	-6.7637	-5.8708	-7.6130	-11.5820	-7.2075	-8.5703	-8.0519

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`**`	`con`	`gr`	`u`	`ence`	`equation`	`**`	`:↩↩`	`$$`	`↩`	`x`
$A_{i,t}^{\text{OPD}}$	+0.0000	-0.0002	-3.5894	+0.2090	-1.3109	-0.0987	+0.0000	+0.0000	+0.0000	-0.0027	-0.0141	-0.0475	-0.0001	+0.0000	+0.0000

汇总（921 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.3583	+2.4749
std	+1.3354	0.0000
min	-15.1645	+2.4749
max	+3.4178	+2.4749

D.4 训练步骤 4

(a) 回答 34（$A_i^{\text{GRPO}} = -2.4749$，错误，1397 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	26	112	129	212	217	319	580	1041	1283	1311	1329	1396
Token	`$`	`b`	`for`	`:↩↩`	`+`	`expression`	`=`	`}↩`	`/`	`/`	`Thus`	`<|im_end|>`
$A_{i,t}^{\text{OPD}}$	-9.9835	-12.5009	-15.3752	-12.1700	-12.9890	-11.4401	-11.1801	-13.6017	-9.9589	-12.8283	-11.2880	-10.1182

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`sequence`	`$(`	`a`	`_n`	`)`	`_{`	`n`	`\`	`ge`		`1`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0001	+0.0000	+0.0983	+0.0002	+0.0564	+0.0000	+0.0000	+0.0052	+0.0000	+0.0000	+0.0005	+0.0000	-0.1782	+0.0000

汇总（1397 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.3822	-2.4749
std	+1.5979	0.0000
min	-15.3752	-2.4749
max	+4.9387	-2.4749

(b) 回答 21（$A_i^{\text{GRPO}} = +0.3536$，中性，1023 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	232	345	391	401	441	513	547	589	889	917	947	951
Token	`f`	`Ideal`	`ann`	`dimension`	`nil`	`Coordinate`	`f`	`elements`	`So`	`These`	`Step`	`Conclusion`
$A_{i,t}^{\text{OPD}}$	-8.2226	-11.8967	-9.0663	-8.3018	-8.8799	-8.2837	-10.0756	-9.4204	-9.2330	-11.6286	-8.6771	-12.8161

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`determine`	`the`	`**`	`dimension`	`**`	`of`	`the`	`quotient`	`ring`	`↩`	`$$`
$A_{i,t}^{\text{OPD}}$	+0.0002	+0.0001	+0.6647	+0.0000	+0.0742	+0.0000	+0.1900	+0.0000	+0.3095	+0.0122	+0.0000	+0.0892	+0.0000	+0.5187	-0.0000

汇总（1023 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.5035	+0.3536
std	+1.5621	0.0000
min	-12.8161	+0.3536
max	+2.1031	+0.3536

(c) 回答 52（$A_i^{\text{GRPO}} = +2.4749$，正确，2310 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	64	365	449	859	863	935	1095	1466	1707	1771	1819	2214
Token	`.↩`	`T`	`T`	`\`	`-`	`tr`	`first`	`^n`	`maximum`	`---↩↩`	`triangle`	`Final`
$A_{i,t}^{\text{OPD}}$	-14.9193	-8.8550	-10.1490	-14.4367	-10.2472	-10.0332	-8.7231	-10.6075	-9.5449	-8.4645	-10.9428	-10.9494

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`a`	`linear`	`operator`	`$`	`T`	`:`	`\`	`ell`	`^`	`2`	`\`	`rightarrow`
$A_{i,t}^{\text{OPD}}$	+0.0002	+0.0000	+0.0229	+0.0025	+0.0516	+0.0000	+0.0006	+0.0000	+0.1267	+0.0000	+0.0000	+0.0000	+0.0000	+0.0007	-3.0091

汇总（2310 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.3849	+2.4749
std	+1.3496	0.0000
min	-14.9193	+2.4749
max	+4.1275	+2.4749

D.5 训练步骤 5

(a) 回答 93（$A_i^{\text{GRPO}} = -2.4749$，错误，1616 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	111	118	284	287	293	319	461	522	578	587	1342	1448
Token	`(`	`a`	`stretch`	`plane`	`each`	`.↩↩`	`no`	`f`	`This`	`function`	`If`	`conclusion`
$A_{i,t}^{\text{OPD}}$	-10.7766	-10.9075	-10.9272	-8.3615	-9.5392	-8.6375	-8.6105	-8.3328	-7.7441	-8.6470	-10.8534	-8.9139

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`:↩↩`	`>`	`If`	`$`	`f`	`(x`	`,`	`y`	`)`	`=`		`0`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0000	+0.0658	-4.9537	+0.0067	+0.1240	-0.0001	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000

汇总（1616 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.4781	-2.4749
std	+1.4702	0.0000
min	-10.9272	-2.4749
max	+5.1961	-2.4749

(b) 回答 1（$A_i^{\text{GRPO}} = +0.3536$，中性，546 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	21	115	117	153	177	220	244	279	395	444	458	489
Token	`asked`	`Consider`	`Equation`	`A`	`So`	`\`	`that`	`that`	`$`	`$`	`Conclusion`	`:↩↩`
$A_{i,t}^{\text{OPD}}$	-6.6305	-8.5071	-5.7975	-10.1694	-5.5674	-4.6801	-6.9888	-5.6696	-4.6985	-7.5715	-6.0161	-7.9329

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`given`	`the`	`matrix`	`equation`	`:↩↩`	`$$`	`↩`	`A`	`^`	`2`	`+`	`A`	`=`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0001	-0.2871	-0.1381	+0.2385	+0.0001	-0.0001	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000	+0.0000

汇总（546 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.2358	+0.3536
std	+1.1496	0.0000
min	-10.1694	+0.3536
max	+2.7361	+0.3536

(c) 回答 55（$A_i^{\text{GRPO}} = +2.4749$，正确，2845 个词元）

按位置排序的 $|A_{i,t}^{\text{OPD}}|$ 最大的 12 项：

Position	590	826	969	1012	1452	1625	1709	2074	2440	2738	2837	2844
Token	`y`	`0`	`=`	`Int`	`which`	`]`	`=`	`$`	`-`	`Each`	`The`	`<|im_end|>`
$A_{i,t}^{\text{OPD}}$	-7.7754	-8.1879	-8.0133	-14.2993	-7.8828	-7.1504	-7.6268	-9.1528	-6.9237	-9.4345	-10.6689	-8.4856

回答的前 15 个词元（含上下文）：

Position	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Token	`We`	`are`	`asked`	`to`	`evaluate`	`the`	`double`	`integral`	`:↩↩`	`$$`	`↩`	`\`	`i`	`int`	`_E`
$A_{i,t}^{\text{OPD}}$	+0.0000	+0.0001	+0.3269	+0.0000	+0.0115	+0.0001	+0.1603	+0.0000	-0.7045	-0.0000	+0.0000	+0.0004	+0.0000	+0.0000	+0.0022

汇总（2845 个词元）：

Stat.	$A_{i,t}^{\text{OPD}}$	A_i^{GRPO}
mean	-0.2342	+2.4749
std	+1.0454	0.0000
min	-14.2993	+2.4749
max	+3.8790	+2.4749

跨回答观察。 在上述 15 个代表性回答中（五个连续步骤各取三个回答），所报告的 180 个最高量级词元位置无一例外地满足 $|A_{i,t}^{\text{OPD}}| > |A_i^{\text{GRPO}}|$。例如，所报告的 OPD 极值达到 20.3585，而这些回答中 GRPO 优势的最大绝对值为 2.4749。因此，在固定 1:1 融合中，只要某个显著 OPD 词元处于活跃状态，其贡献就可能大幅超过验证器导出的回答级贡献，并在局部主导融合更新。该选定词元分析证实了量级失配在不同回答类型及连续步骤中的存在与持续性；它并不声称完整批次中的大多数词元都具有较大取值，因为图 3 反而表明，大多数原始 OPD 值集中在零附近。零附近的大量取值与少数占主导地位的活跃词元共同说明，应先进行稀疏化，再对保留值施加有界压缩。