MirroS

代码即世界：
通过智能体发现面向物理推理的可执行世界表征

MirroS 技术报告

摘要

物理理解与推理依赖于构建紧凑且具有泛化能力的世界表征。尽管现代视觉语言模型能够识别并解释多种物理事件，但它们往往缺乏对底层机制的显式表征，例如物体状态、物理参数和支配系统演化的动力学，而这些表征是可靠推理世界如何演化以及如何响应干预所必需的。本文提出 **Code-as-World**，这是一种通过可执行世界表征来表示物理世界的范式。Code-as-World 将物理组成、动态演化和视觉外观表达为可执行代码，从而为物理世界提供紧凑、具有定量依据且可控的抽象。为了从自然语言描述或真实世界视频等多模态观测中构建此类表征，我们受溯因推理启发，开发了一个智能体发现循环。在该循环中，智能体提出、执行、渲染、验证并迭代改进可执行世界假设。作为一项具体应用，我们利用经过验证的可执行世界，为视觉语言模型的定量物理推理训练提供可规模化的物理监督。实验表明，Code-as-World-VL 在 QuantiPhy 上取得了最先进的性能，并超越了领先的闭源模型，展现出可执行世界表征作为物理智能可规模化基础的潜力。

日期： 2026 年 9 月 6 日

博客： https://mirros.ai/blog/representing-physical-world

代码： https://github.com/mirros-lab/code-as-world

项目主页： https://mirros-lab.github.io/code-as-world

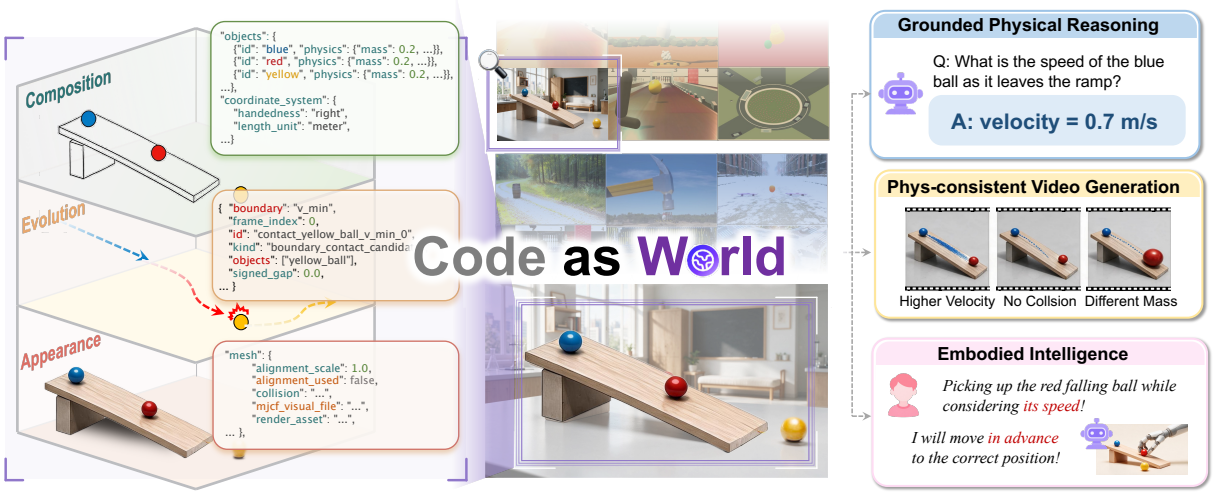


图 1 Code-as-World 将物理世界表征为可执行代码，以支持物理智能。

目录

1 引言 **3**

2 探索物理世界表征 **3**

3 以代码表征世界：可执行世界表征 **4**
3.1 具体实现 . . . 5

4 世界表征的智能体发现 **5**
4.1 证据构建 . . . 5
4.2 智能体发现循环 . . . 6
4.3 评估 . . . 6
4.3.1 实验设置 . . . 6
4.3.2 定性分析 . . . 7
4.3.3 智能体发现循环 . . . 7
4.4 局限性 . . . 8

5 应用：学习定量物理推理 **8**
5.1 问题形式化 . . . 8
5.2 图像空间测量基础 . . . 10
5.3 基于已验证可执行世界的世界空间物理标定 . . . 10
5.4 评估 . . . 10
5.4.1 实验设置 . . . 10
5.4.2 图像空间测量 . . . 12
5.4.3 定量物理推理 . . . 12
5.5 局限性 . . . 12

6 相关工作 **13**

7 结论 **13**
7.1 更广泛的物理现象 . . . 13
7.2 更广泛的物理能力 . . . 14

附录 **21**

A 数据集详情 **21**
A.1 图像空间数据集 . . . 21
A.2 世界空间可执行世界数据集 . . . 21

B 实验规程 **21**
B.1 可执行世界的保真度与真实感评估 . . . 21
B.2 可执行引擎配置 . . . 22
B.3 图像空间测量评估 . . . 23
B.4 世界空间 QuantiPhy 评估 . . . 23
B.5 推理模型设置 . . . 23

C 补充实验 **24**
C.1 文本驱动的仿真到真实评估 . . . 24
C.2 补充智能体发现循环实验 . . . 24
C.3 图像空间测量结果 . . . 24
C.4 数据来源消融 . . . 26

1 引言

"朋友，一切看得见的事物，都不过是纸板面具。" — Herman Melville，《*白鲸*》，第 36 章

理解物理世界并对其进行推理，是智能的重要标志 [1]。人类能够理解陌生的物理情境，并在不同情境间迁移知识；他们借助物体、质量、运动、重力和摩擦等概念进行推理，而非记忆孤立的观测。因此，*泛化*是物理智能的一个决定性特征：从一种情境中获得的知识，在物体、配置或观测发生变化时仍应有用。这种泛化要求构建*表征* [2]，将感官经验的复杂性压缩为紧凑的抽象，刻画世界中存在什么、世界如何演化，以及哪些因素决定其行为。

由此引出了一个根本问题：需要何种形式的表征，才能刻画、理解物理世界并对其进行推理？现代视觉语言模型 [3–6] 为描述物理世界提供了强大的接口。通过在大规模图像—文本和视频—文本数据上训练，它们能够识别物体、叙述运动，并用语言解释广泛的物理现象。然而，描述一种现象并不等同于还原产生该现象的机制 [7]。物理智能要求推理超越可见的观测，深入系统的结构，包括其物体状态 [8–10]、物理参数 [11]、支配其演化的动力学 [9, 10, 12]，以及对干预的响应 [9, 13, 14]。这一区别形成了根本性的*现象—机制二分*：现象描述发生了什么，而机制解释为何发生，并预测不同条件下会发生什么。

本文提出 **Code-as-World**，这是一种通过代码表示物理世界的新范式。Code-as-World 不将世界仅通过像素 [15, 16]、潜在特征 [17, 18] 或自然语言描述 [19, 20] 来表示，而是将世界中与任务相关的结构表达为可执行代码，规定其物理组成、动态演化和视觉外观。代码为物理世界提供了*紧凑且具有定量依据的抽象*：物体及其关系能够以组合方式组织，同时显式保留状态、物理参数和支配其演化的动力学。因此，代码既保留了物理推理所需的机制结构，又抽象掉了单次观测中的偶然细节。

然而，从不完整观测中获得此类表征，本质上是一个逆问题。从日心说到 Newton 定律，科学发现通常通过溯因推理 [21] 推进：在遵循简洁性原则的同时，搜索能够最佳解释证据的假设，从而由带噪且不完整的观测还原物理机制。受这一过程启发，我们将世界表征构建表述为一个**智能体发现循环**，而非单次预测问题 [22]。代码*可执行且天然适用于智能体*的特性，使智能体能够将每个表征视作可检验的世界假设：给定自然语言描述或真实视频等多模态证据，智能体先提出一个可执行世界假设，在模拟器中将其实例化并执行，渲染其预测的观测，然后利用已有证据进行验证。二者之间的差异被反馈用于修正假设，形成"提出—实例化—执行—渲染—验证"循环，逐步搜索与观测一致的可执行世界。

作为一项具体应用，我们将得到的可执行世界用作**定量物理推理** [11] 的物理监督。在这类任务中，视觉语言模型必须从单目视频中推断物体尺寸、位移、速度和加速度等可测量的量。与语义层面的物理问答 [10] 不同，这些任务要求模型将视觉证据与其背后世界的度量状态联系起来。我们结合测量监督与从经过验证的可执行世界中获得的物理监督，训练了视觉语言模型系列 Code-as-World-VL。所得模型显著提升了定量物理推理能力：Code-as-World-VL-9B 相比参数规模大得多的模型（包括 Gemini-3.1-Flash [3]），在 QuantiPhy [11] 上取得了更优表现。Code-as-World-VL-27B 进一步超越了 9B 版本及所有参与评估的基线模型。这些结果表明，可执行世界表征能够提供可规模化的监督，帮助视觉模型建立对物理机制的理解。

综上，我们的贡献如下：

- **可执行世界表征**。通过对现有物理世界表征的专门讨论，我们提出 Code-as-World，将与任务相关的物理世界表示为涵盖物理组成、动态演化和视觉外观的可执行代码。
- **智能体发现循环**。我们将世界表征构建过程表述为智能体发现问题，并开发了"提出—实例化—执行—渲染—验证"循环，迭代搜索与语言或视觉证据一致的世界表征。
- **面向视觉语言模型的物理监督**。我们利用经过验证的可执行世界，为定量物理推理提供可规模化的监督。Code-as-World-VL 取得了显著提升，在 QuantiPhy 上达到最先进的性能，超越了领先的闭源模型。

2 探索物理世界表征

物理理解 [1, 9–11, 23] 最终取决于模型编码世界所采用的表征。现有方法从多个角度探索了这一问题，包括像素级预测、几何重建和基于语言的抽象。这些范式各自刻画了物理世界的重要方面，但任何一种都无法单独提供同时支持语义理解、结构组合和时序预测的完整表征。

像素。 对物理世界建模的一种自然方法，是直接从视觉观测中学习。视频生成模型通过根据过去的帧预测未来观测来学习时间动态，生成结果日益逼真且多样 [15, 16, 24–26]。然而，仅预测观测并不要求模型显式表示视觉变化的底层原因。如果模型只优化未来像素预测，它就无须区分场景变化究竟由相机运动

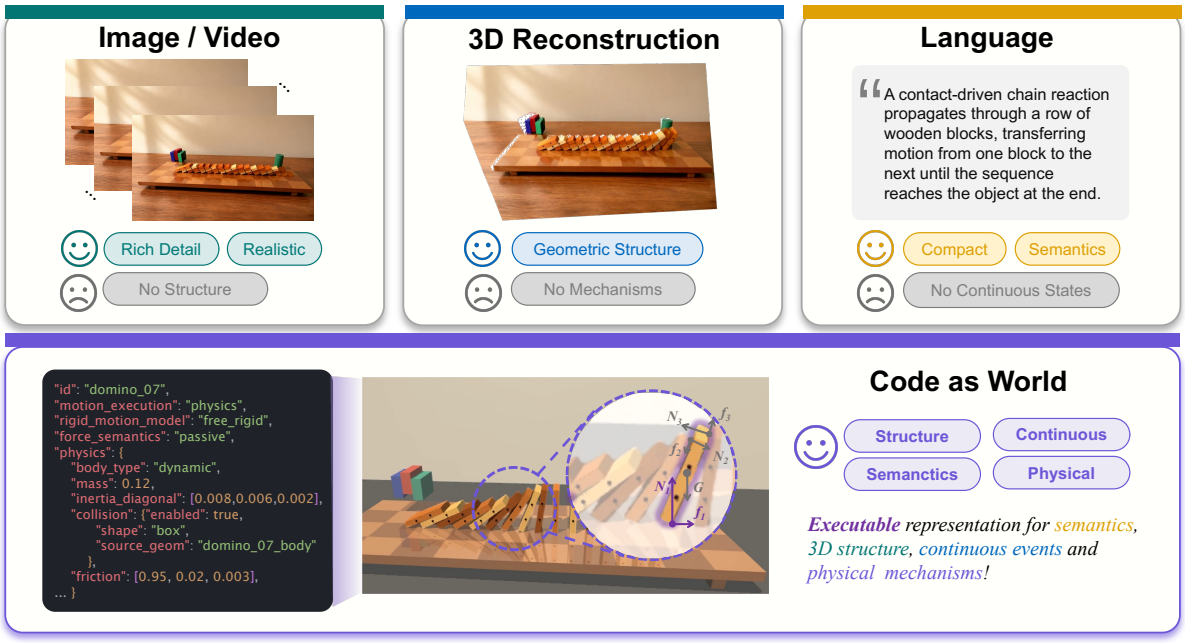


图 2 **不同物理世界表征的比较。**像素保留了丰富的视觉细节，却缺乏显式结构，使观测的底层原因存在歧义；三维表征刻画几何结构，却不一定揭示物理机制；语言提供紧凑的语义抽象，却缺乏表达连续物理状态所需的精度。代码将世界表达为抽象、具有定量依据且可执行的表征，从而与这些表征形成互补。

还是物体运动引起，也无须区分物体是暂时被遮挡还是已经消失。因此，只要能够生成视觉上合理的未来，多种相互矛盾的内部解释就可能达到相似的预测准确率。

这种歧义限制了物理推理。具有物理意义的表征必须解耦生成观测的各类因素，包括持续保持的物体身份、物理状态转移、交互和视角变化。视觉上合理的未来，并不一定是物理上正确的未来 [27, 28]。

三维。 另一类研究关注重建，包括三维重建 [29–32]、逆向图形学 [33–36] 和动态场景表征 [37–42]。通过要求模型恢复几何、视角和外观，基于重建的方法对信息保留施加了强约束，并在场景建模方面展现出卓越能力。

然而，可重建性并不必然意味着可解释性。潜在表征可能忠实地复现观测，却同时将持久结构、动态变量和外观因素纠缠在一起。恢复物体的三维几何并不能解释其物理行为，例如它为何会在支撑被移除后下落，或它如何与其他物体交互。重建能够保留信息，却不会自动揭示支配世界演化的因果因素。

自然语言。 语言为物理世界提供了另一种强大的抽象 [43–45]。通过将视觉观测转化为说明、描述或推理轨迹，基于语言的表征能够捕捉紧凑、可组合且可跨情境迁移的高层概念，以支持推理。例如，“一个人拿起一只杯子”这样的描述保留了实体、动作和语义关系，同时舍弃了无关的视觉细节。

然而，语言在表达物理状态的连续性和定量性方面存在固有限制。精确几何、轨迹、接触关系和物理参数，很难通过少量离散词元精确编码。语言提供了有效的语义接口，却无法提供完整的物理状态表征。

这些视角揭示了互补的优势 [46]：像素保留丰富细节，三维表征保留几何结构，语言则捕捉语义抽象。然而，物理智能可能需要一种更好地整合这些能力的表征：像语言一样表达语义，像重建一样具有结构，并像生成模型一样能够建模时间演化。这种表征不应仅仅描述或复现世界，而应显式刻画产生观测的实体、状态和机制。

3 以代码表征世界：可执行世界表征

本文提出 Code-as-World ，这是一种通过代码表示物理世界的范式。

代码 为世界提供结构化且可组合的抽象：它显式表示实体、关系、物理参数，以及作为状态操作的事件，同时抽象掉单次观测中的偶然细节。这种表征将物理过程的底层结构化状态，与用于观测这些过程的连续外观分离。前者为推理提供可组合性、可编辑性和显式约束，后者则保留难以显式编码的丰富视觉细

节和不确定性。通过执行与渲染，代码能够生成与所表示世界一致的观测；其中，物理等价性——即世界组成、约束和演化的一致性——优先于像素级复现。

3.1 具体实现

为将这一范式实例化，我们开发了一种可执行世界表征（EWR）的具体实现，并将其与对物理模拟引擎的程序化调用相结合。图 13 展示了该表征及其模拟接口的一个示例。

具体而言，EWR p 在概念上由三个组成部分构成：

$$p = (\mathcal{C}, \mathcal{E}, \mathcal{A}) \in \mathcal{P}_{\text{exec}}, \tag{1}$$

其中，$\mathcal{P}_{\text{exec}}$ 表示有效可执行世界的空间。这三个组成部分共同规定了世界包含什么、如何演化，以及呈现何种外观。

物理组成。 $\mathcal{C}$ 描述世界中存在的事物，以及其中实体相对稳定的物理属性。它包括场景中的物体、它们的几何形状、度量尺寸，以及质量、摩擦和重力等物理属性。地面、桌子和墙壁等环境结构同样被表示为静态物理实体，使其能够参与支撑、接触和碰撞。这一组成部分定义了物理过程中涉及的持久实体，以及这些过程得以展开的基本条件。

动态演化。 $\mathcal{E}$ 描述世界如何随时间展开。它包括物体初始状态、状态随时间的变化、关键事件，以及模拟持续时间。给定动态演化部分，世界的物理组成可被展开为完整的状态轨迹，并在执行过程中产生接触、碰撞、速度变化和终止条件等事件。

视觉外观。 $\mathcal{A}$ 描述物理世界如何被观测和呈现。它包括相机参数、背景、材质、光照、输出帧率、分辨率，以及渲染或视频生成配置。这一组成部分不改变底层物理过程，但决定了物理轨迹如何在视觉上呈现。参与支撑或碰撞的环境元素属于物理组成，而仅提供视觉上下文的背景和外观因素属于视觉外观。

这一实现通过可执行且可控的接口呈现所表示的世界。EWR 的不同组成部分可以被独立检查、修改和执行：可以改变某个物体、物理参数、动态条件或相机设置，同时保留其余结构。这类可执行表征为下游推理、模拟、验证和数据生成提供了基础。

4 世界表征的智能体发现

尽管 Code-as-World 为物理世界提供了结构化的表征空间，但从局部、异构的观测中恢复这种表征仍然具有挑战性。为应对这一挑战，Code-as-World 将世界表征建模为智能体发现过程，而非直接预测问题。给定文本描述、真实视频等多模态证据，发现智能体构建语义或视觉约束，并通过统一的*提出假设–实例化–执行–渲染–验证*循环，迭代搜索与输入证据一致的 EWR。得到的表征将底层物理机制外显为智能体可以直接查询、干预和验证的接口，从而支持物理数据生成、定量监督、可验证奖励构建，以及更广泛的下游物理推理。

4.1 证据构建

给定输入 ξ 及其所属模态 m，智能体在进入发现循环之前，首先通过专用的证据适配器构建该模态特有的证据 η。文本和视频输入由不同的适配器处理，分别转换为语义或视觉证据，用于约束同一个 EWR 空间。

文本驱动的世界构建。 智能体从输入文本中提取明确的实体、空间关系、物理事件和预期结果，并将其组织为结构化语义证据。由于文本描述通常无法完整确定几何形状、物理参数或相机配置，智能体结合物理先验与合理的默认条件，初始化一个可执行世界假设，再通过仿真和语义验证逐步完善这一假设。对于第 5 节所述的下游应用，在获得可执行世界后，我们利用视频生成模型进行仿真到现实的迁移，丰富物体、材质、背景和光照。生成的视频具有更强的视觉真实感，同时仍与底层物理轨迹和世界状态保持一致。

视频驱动的世界抽象。 给定真实视频，智能体提取深度图、实例掩码和物体轨迹，作为世界构建与验证的视觉证据。深度图约束场景的空间结构和相对距离，掩码确定物体边界和几何范围，轨迹则捕捉时间上的对应关系及图像平面内的运动。对于分割出的每个场景物体，智能体进一步利用三维物体生成模型 [47]

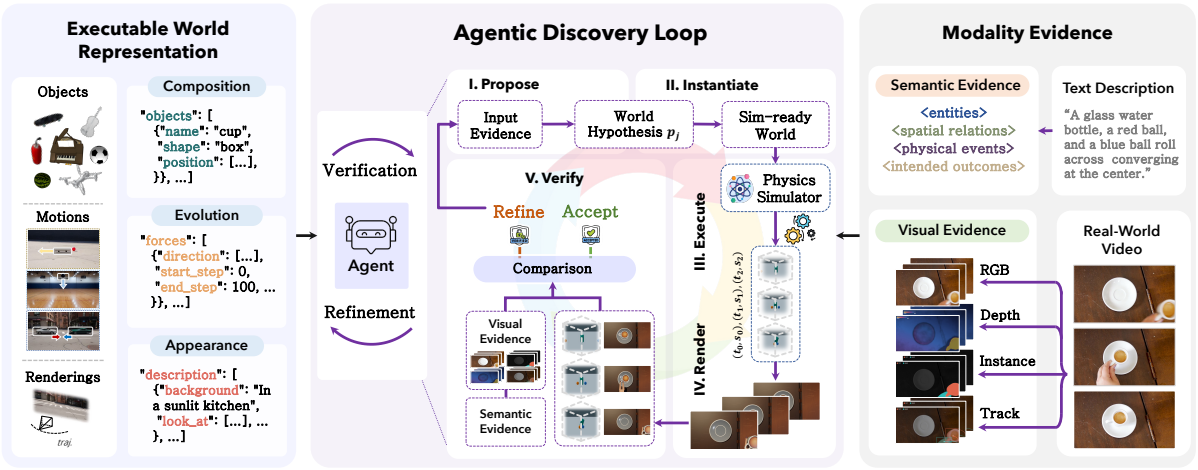


图 3 可执行世界表征的智能体发现循环。给定文本提示或真实视频，模态专用处理器将输入转换为语义或视觉证据。随后，统一的提出假设–实例化–执行–渲染–验证循环从物理组成、动态演化和视觉外观三个方面优化可执行世界表征。

构建对应网格。随后，它将这些网格与深度、跟踪证据相结合，恢复物体的空间位置、尺度和动态状态，从而构建可执行的三维场景。每个候选 EWR 的仿真展开结果都会被投影回输入视角，并根据其与观测到的几何形状、深度、掩码和轨迹的一致性进行迭代优化。

4.2 智能体发现循环

给定模态特有的证据 η，发现智能体提出初始 EWR，并通过*多轮提出假设–实例化–执行–渲染–验证*循环逐步完善它，在可执行假设空间中搜索最能解释输入证据、同时尽可能简约的 EWR。算法 1 总结了智能体发现循环的完整流程。

在每轮迭代中，智能体提出或更新 EWR $p = (\mathcal{C}, \mathcal{E}, \mathcal{A})$，其依据包括 η、当前假设以及上一轮迭代的结构化反馈 Δ。随后，EWR 被实例化为符合特定仿真器接口、可直接供仿真器使用的参数 θ，由仿真器执行并生成完整的状态轨迹 τ。该轨迹显式记录物体状态、接触、碰撞和事件结果，使世界假设具有可以直接检查的时序与因果后果。

随后，智能体将 τ 渲染为预测的视觉观测。对于视频输入，它还会将仿真状态投影为深度图、实例掩码和图像平面轨迹。在验证阶段，系统在选定的关键帧上比较预测证据与输入证据。对于文本输入，验证器主要评估语义和物理约束；对于视频输入，则联合比较 RGB 外观、深度、掩码和轨迹。各帧的差异被汇总为 Δ，指导智能体在下一轮迭代中对相关组件进行局部修改。当当前 EWR 能够充分且简约地解释输入时，循环终止。否则，优化会持续到迭代预算耗尽，此时该假设被拒绝。

4.3 评估

4.3.1 实验设置

数据来源与筛选。 对于文本驱动的构建，语言描述由大语言模型生成，随后由人工标注者审核。对于视频驱动的抽象，我们通过以运动为重点的筛选流程，从 WISA-80K [48] 中选取候选观测。首先保留元数据表明包含明显刚体运动或碰撞类交互的片段，并移除混合了不相关物理现象的片段。随后剔除相机平移或旋转明显、物体运动不足、剪辑严重或物理事件不完整的视频。剩余片段经过人工审核，以检查时间连续性、物体可见性，以及是否适合进行可执行重建。

处理工具。 对于每个保留的视频，SAM3 [49] 提供实例掩码和图像平面轨迹，VGGT-Omega [50] 估计场景深度和相机几何，SAM3D [47] 提供物体几何形状。这些观测约束智能体发现循环；生成的世界只有在能够渲染并与源视频进行验证时才会被保留。对于这两种输入模态，Code-as-World 均使用同一个仿真接口生成同步的视频和物理状态。

评估协议与指标。 我们对视频驱动的世界重建进行最多 $K = 5$ 轮智能体发现，并在相同评估预算下，将迭代优化与单次生成及 Best-of-5 采样进行比较。视觉对齐度和物体 IoU [51] 分别衡量输入视频与仿真重建

算法 1 可执行世界表征的智能体发现

Require: Input evidence ξ; LLM A; iteration budget K

Notation. η denotes the preprocessed evidence. The current EWR is $p = (\mathcal{C}, \mathcal{E}, \mathcal{A})$, while θ denotes its simulator-ready instantiation and τ its executed world-state trajectory. The structured trace z records the hypotheses and verification outcomes produced during discovery.

Ensure: An evidence-supported EWR p, or rejection, together with trace z

if ξ is a text specification **then**
  $m \leftarrow$ text; $\eta \leftarrow \text{InterpretText}(A, \xi)$ ▷ 语义证据
else if ξ is a video **then**
  $m \leftarrow$ video; $D \leftarrow \text{Depth}(\xi)$; $M \leftarrow \text{Segment}(\xi)$; $Q \leftarrow \text{Track}(\xi)$ ▷ 视觉证据
  $\eta \leftarrow (\xi, D, M, Q)$
end if
$p \leftarrow \emptyset$; $\Delta \leftarrow \emptyset$; $z \leftarrow \emptyset$
for $k = 1$ to K **do**
  $p \leftarrow \text{ModifyEWR}(A, \eta, p, \Delta)$ ▷ 提出假设 | 更新
  $\theta \leftarrow \text{CompileEWR}(p)$ ▷ 实例化
  $\tau \leftarrow \text{RunSimulation}(\theta)$ ▷ 执行
  $\hat{X} \leftarrow \text{Render}(\tau, \theta)$; $(\hat{D}, \hat{M}, \hat{Q}) \leftarrow \text{Project}(\tau, \theta)$ ▷ 渲染与投影
  $\hat{\eta} \leftarrow (\hat{X}, \hat{D}, \hat{M}, \hat{Q})$
  $F \leftarrow \text{SelectFrames}(m, \eta)$; $\Delta \leftarrow \emptyset$ ▷ 验证
  for all $f \in F$ **do**
    $\delta \leftarrow \text{CompareAndDiagnose}(A, \hat{\eta}[f], \eta)$
    $\Delta \leftarrow \Delta \oplus \delta$
  end for
  $z \leftarrow z \oplus \text{RecordRound}(k, p, \tau, \Delta)$
  if $\text{Accept}(A, p, \Delta)$ **then**
    return (p, z)
  end if
end for
return $(\textsc{Reject}, z)$

结果之间的全视频视觉一致性和物体区域重叠程度。受 [52, 53] 启发，我们采用 Traj-ADE、Velocity-ADE 和准确率 @2%D，分别衡量物体位置误差、帧间位移误差，以及误差位于 $0.02D$ 范围内的有效观测百分比；所有距离均以画面对角线长度 D 归一化。

4.3.2 定性分析

我们从文本和视频两种输入出发，评估 Code-as-World 所整理数据的质量。图 6 和图 7 展示了两种模态的代表性输入与输出。这些示例表明，Code-as-World 既能将语义描述转化为以物理机制为依据的视频，也能从真实视觉观测中恢复可执行世界。

除解释已观测证据之外，Code-as-World 还将恢复的可执行世界作为可编辑程序开放出来，以支持可控生成。如图 4 所示，我们可以在改变物理量或初始条件后重新仿真一个世界。例如，改变保龄球的初始速度方向会产生不同的轨迹。我们也可以调整相机配置，从全局视角或任一汽车的视角渲染同一次碰撞。我们的内部视频生成模型将每个修改后的仿真展开结果渲染为真实感视频，同时保留指定的物理演化和视角。将世界编辑与外观合成分离，便可生成连贯的反事实视频，而无须为每个变体重新进行重建。

4.3.3 智能体发现循环

为评估智能体发现循环的有效性，我们将最大循环轮数设为 $K = 5$，比较不同轮数下的视频驱动世界重建结果。候选选择与优化由 Code-as-World 中的验证器驱动，而结果通过未包含在验证信号中的独立指标衡量。所有报告指标均比较输入视频与重建 EWR 的仿真渲染结果。图 5 展示了各项指标随循环轮数的变化。每条实线均从第一轮的单次生成结果开始，随后连接第二至第五轮中连续四次智能体发现循环更新的结果。灰色虚线表示 Best-of-5 参考结果。在这些优化过程中，静态质量和大多数运动保真度指标总体上均有所改善。在相同的五次评估预算下，智能体发现循环在大多数方面优于 Best-of-5，表明其计算资源利用效率高于独立采样。

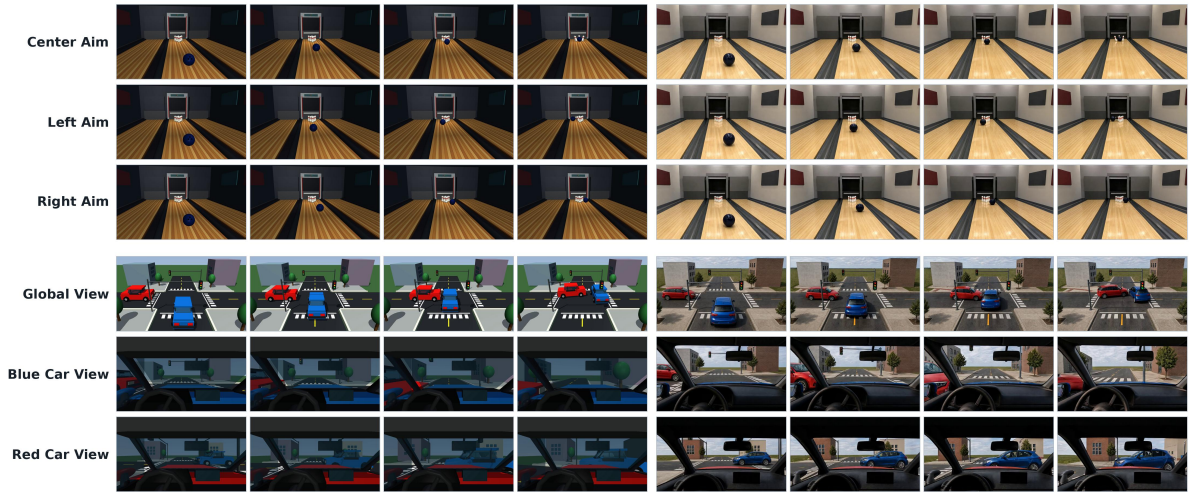


图 4 利用 Code-as-World 进行可控的重新仿真。每行左侧四列展示修改后的仿真展开结果，右侧四列展示其真实感视频中在时间上对齐的对应帧。

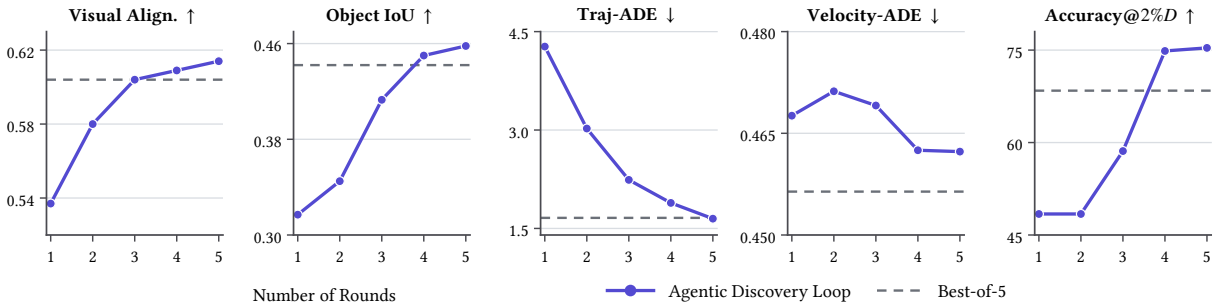


图 5 不同循环轮数下的智能体发现。实线连接单次生成结果与第二至第五轮的智能体循环结果。灰色虚线表示独立采样的 Best-of-5 结果。在相同的五次评估预算下，智能体循环在视觉对齐度、物体 IoU、Traj-ADE 和准确率 @2%D 上表现更优。其中，D 表示画面对角线长度。Traj-ADE 的单位为 %D，Velocity-ADE 的单位为 %D/步，准确率以 2%D 为阈值计算。

4.4 局限性

现实世界环境高度复杂，当前仿真器无法忠实涵盖全部物理条件。即便看似简单的刚体运动，也可能对地形、接触几何、材料属性或其他潜在因素的微小变化十分敏感。当底层过程超出仿真器的建模范围时，智能体发现循环可能收敛到局部合理的 EWR，却无法恢复对该物理过程在机制层面准确的解释。

5 应用：学习定量物理推理

作为 Code-as-World 的一项具体下游应用，我们研究视觉语言模型中的定量物理推理 [11]。语义层面的物理问答往往可以依靠视觉模式或常识先验解决，而这项任务要求 VLM 从单目视频的像素观测中推断隐含的物理量，例如物体在现实世界中的尺寸、速度和加速度。然而，真实世界视频很少提供此类底层物理量的标注。Code-as-World 通过提供经过验证、能够显式给出物理状态和轨迹的可执行世界，解决这一根本挑战，从而支持规模化的物理监督。

5.1 问题形式化

给定单目视频 V 和定量物理问题 q，模型预测数值答案 $\hat{y} = f_\theta(V, q) \in \mathbb{R}$。问题指定目标物体、相关时间戳、待查询物理量（例如尺寸、速度或加速度），以及像素空间或世界空间中的输出单位。对于世界空间查询，问题还会额外提供一个已知世界空间数值为 ρ 的参考量，以实现度量标定。

视频提供像素空间中的测量结果，但不会直接揭示其在世界空间中的尺度。令 y^{pix} 和 ρ^{pix} 分别表示以像素为单位的目标测量值和参考测量值。遵循 QuantiPhy [11]，我们将相对尺度估计为 $\gamma = \frac{\rho}{\rho^{\text{pix}}}$，并以

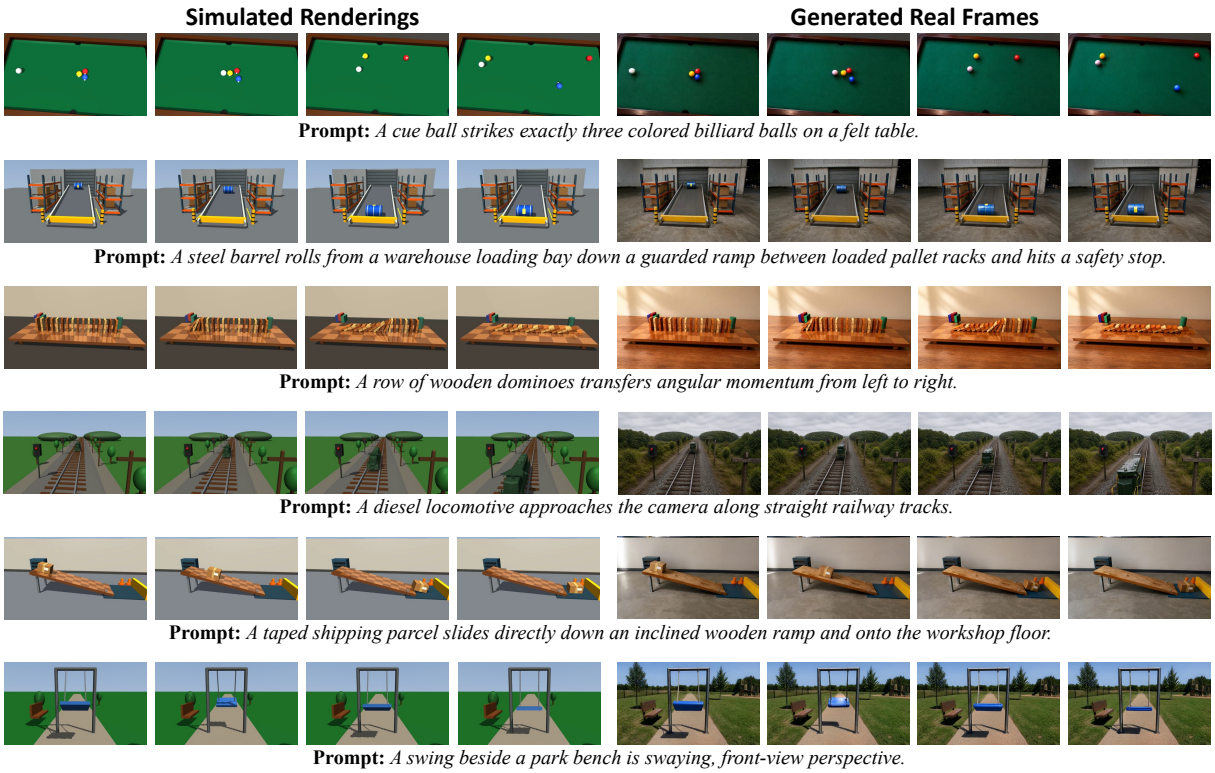


图 6 **文本驱动构建的可视化结果**：从可执行仿真到真实感视频。对于每个示例，左侧展示依据文本描述生成的仿真展开结果中的对应帧，右侧展示视频生成模型合成的最终视频中的对应帧。仿真到现实的转换引入了丰富多样的物体、材质、背景和纹理，同时保留了可执行世界所编码的运动轨迹与物理演化。

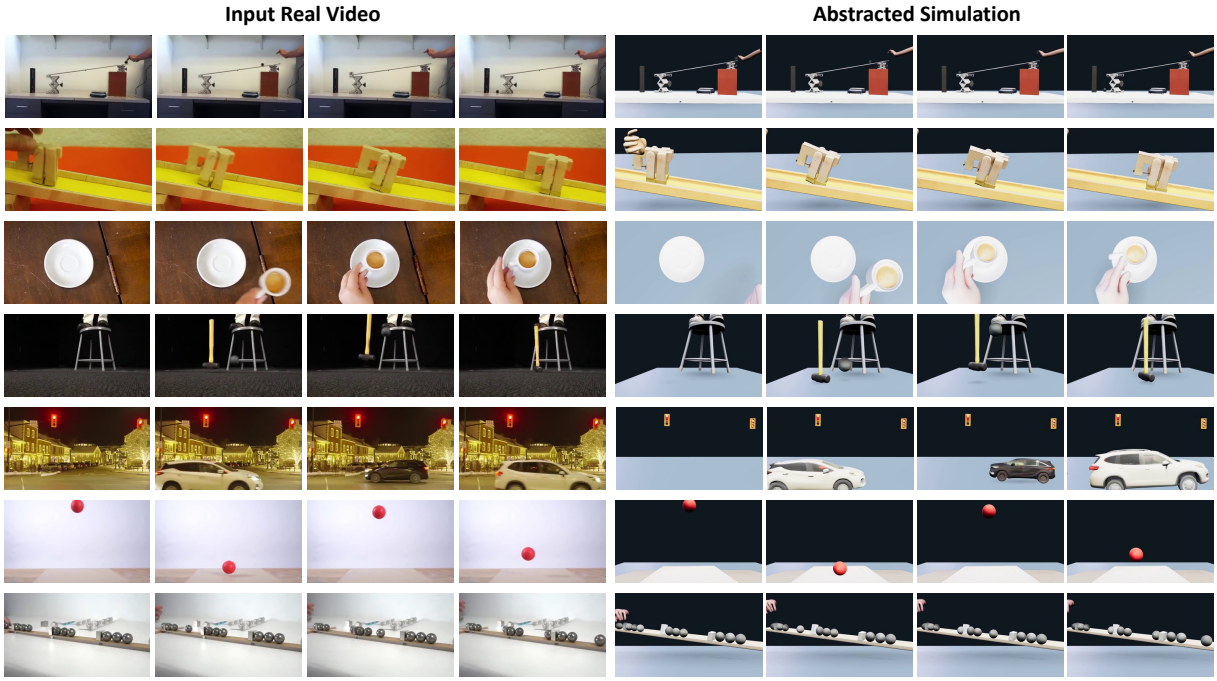


图 7 **视频驱动抽象的可视化结果**：从真实视频到可执行仿真。对于每个示例，左侧展示输入真实视频中的对应帧，右侧展示抽象得到的可执行世界的对应仿真展开结果。恢复的仿真与观测到的场景组成、物体运动和物理交互相一致，将底层物理机制刻画为连贯、可执行的过程。

$y = \gamma y^{\text{pix}}$ 作为世界空间物理量的真实答案。同样的标定方式可将尺寸、位移、速度和加速度的像素测量值转换为世界单位。在三维场景中，深度信息提供额外的几何线索，帮助建立图像空间测量值与对应世界空间物理量之间的联系。

5.2 图像空间测量基础

定量物理推理需要以可靠的图像空间测量为基础 [54, 55]。我们将现有视觉数据集中的边界框、掩码和物体轨迹转换为定量问答对，以构建像素级监督。这些问题涉及物体的空间范围、位置、位移、速度和加速度，无须进行世界空间标定。具体而言，对于物体轨迹 $\{\mathbf{c}_t\}_{t=1}^{T}$，若其采样间隔为 Δt，则位移、速度和加速度计算如下：

$$\mathbf{d} = \mathbf{c}_{t_2} - \mathbf{c}_{t_1}, \qquad \mathbf{v}_t = \frac{\mathbf{c}_{t+1} - \mathbf{c}_{t-1}}{2\Delta t}, \qquad \mathbf{a}_t = \frac{\mathbf{c}_{t+1} - 2\mathbf{c}_t + \mathbf{c}_{t-1}}{\Delta t^2}, \tag{2}$$

其中，t_1 和 t_2 是位移问题指定的时间戳。物体的空间范围和位置直接从边界框或掩码中读取，运动量则由轨迹导出。

我们在由此得到的像素级数据集 $\mathcal{D}_{\text{pix}}$ 上，对模型进行监督微调：

$$\mathcal{L}_{\text{pix}} = -\mathbb{E}_{(V,q,y)\sim\mathcal{D}_{\text{pix}}} \log \pi_\theta(y \mid V, q). \tag{3}$$

这一阶段训练模型定位、测量和跟踪物体，为后续世界空间物理推理提供视觉基础。

5.3 基于已验证可执行世界的世界空间物理标定

在建立图像空间测量基础后，我们进一步利用经过验证的可执行世界构建物理监督。每个 EWR 都提供同步的视频和仿真状态轨迹，记录物体几何、相机参数、时间戳以及随时间变化的物理状态。这使得我们能够直接生成具有精确世界空间标签的定量问答对。具体而言，我们从这些记录中采样目标物体、相关时间戳、物理量和所要求的世界单位，并可选地提供一个已知世界空间数值的参考量作为尺度先验。答案 y 直接从同一个 EWR 中获得：物体尺寸从场景几何中读取，位移、速度和加速度则根据状态轨迹计算。只有当问题的目标物体、时间范围及可选参考量在对应观测中均有效时，该问题才会被保留，形成 VQA 训练样本 (V, q, y)。文本驱动和视频驱动的可执行世界使用相同格式，分别构成 $\mathcal{D}_{\text{text}}$ 和 $\mathcal{D}_{\text{video}}$，再合并为统一的世界级训练数据。

我们使用组相对策略优化（GRPO） [56, 57]，在这些可执行世界样本上优化模型。奖励将经过尺度归一化的数值准确性与单位正确性、回答格式的辅助奖励相结合：

$$r_{\text{num}} = \exp\left(-\frac{|\hat{y} - y|}{|y| + \epsilon}\right), \qquad r = r_{\text{num}} + \lambda_u r_{\text{unit}} + \lambda_f r_{\text{fmt}}. \tag{4}$$

这两类可执行世界监督具有互补优势。文本驱动的世界提供完全可观测的仿真器状态和数值精确的物理监督，视频驱动的世界则更贴近真实观测的外观与运动分布。因此，联合训练能够同时结合精确的物理监督与面向真实世界视频的视觉泛化能力。

5.4 评估

5.4.1 实验设置

模型与训练。 我们使用八张 NVIDIA H100 GPU，按照第 5 节描述的两阶段课程，训练用于受控比较、直接输出答案的 Code-as-World-VL 4B 和 9B 变体。第一阶段通过监督微调建立图像空间测量能力；第二阶段将 GRPO [57] 应用于由文本驱动和视频驱动的可执行世界生成的世界级 VQA。我们将第一阶段结束后的检查点称为*图像空间*变体，将完成两个阶段后的检查点称为 Code-as-World-VL-4B 和 Code-as-World-VL-9B。为检验这一框架能否扩展至更大规模的推理模型，我们还训练了 Code-as-World-VL-27B（推理版），它会在最终答案之前生成思维链推理。在训练和评估期间，所有变体均从每段视频中均匀采样 16 帧，并保持时间顺序。附录 B.5 给出了 27B 模型的独立协议。

训练与评估数据。 我们的图像空间监督由四个指代表达数据集——RefCOCO [54]、RefCOCO+ [54]、RefCOCOg [72] 和 RefCLEF [73]——以及 GOT-10K [74] 构建。指代表达数据集提供自然语言描述和真

表 1 **定量物理推理结果**。我们报告 QuantiPhy-validation 中 2S、2D、3S 和 3D 子集上的 MRA，以及这些子集的宏平均值。4B 和 9B 变体直接输出答案，而 27B 推理变体仅对其推理轨迹之后输出的答案进行评分。各行按模型系列分组，Code-as-World-VL 变体以紫色突出显示。

Models	Size	Kinematic Categories				Average Score
		2S	2D	3S	3D	
Proprietary models						
Gemini-3.1 Flash [3]	–	49.4	47.5	**61.4**	61.1	54.8
ChatGPT-5.1 [58]	–	**56.9**	34.6	45.6	56.4	48.4
Gemini-2.5 Pro [59]	–	45.9	38.6	40.7	60.2	46.4
Gemini-2.5 Flash [59]	–	42.8	31.9	47.0	54.7	44.1
Grok 4.1 (Fast Reasoning) [60]	–	23.4	30.5	46.3	46.8	36.8
ChatGPT-5 [61]	–	32.2	24.6	35.6	38.1	32.6
ChatGPT-5 Pro [61]	–	16.2	22.7	20.2	18.9	19.5
Open-weight models						
Qwen3-VL-32B-Instruct [62]	32B	38.1	39.7	39.8	43.0	40.2
InternVL-3.5-30B [63]	30B	33.1	33.0	31.4	44.7	35.5
Qwen3-VL-8B-Instruct [62]	8B	17.2	27.6	36.0	48.3	32.3
Qwen3.5-4B [6]	4B	26.6	35.7	19.8	41.3	31.2
InternVL-3.5-8B [63]	8B	26.9	23.2	38.4	31.7	30.0
Qwen3-VL-2B-Instruct [62]	2B	25.0	28.6	16.0	39.1	27.2
Phi-4-Multimodal-Instruct [64]	5.6B	26.6	26.5	31.6	23.8	27.1
SmolVLM-Instruct [65]	0.26B	30.0	21.4	22.8	33.0	26.8
Qwen3.5-2B [6]	2B	28.7	29.7	17.9	25.9	25.6
InternVL-3.5-2B [63]	2B	24.4	22.7	15.3	34.9	24.3
Molmo-7B [66]	7B	13.8	20.3	19.1	41.7	23.7
CogVLM2 Video [67]	12B	18.1	16.8	16.3	24.0	18.8
VILA-7B [68]	7B	14.4	19.5	8.8	30.4	18.3
Phi-3-Mini-128K-Instruct [69]	3.8B	14.7	12.4	21.6	19.6	17.1
MiniCPM-V 4.5 [70]	8B	27.5	33.2	0.0	0.0	15.2
LLaVA-13B [71]	13B	11.2	10.8	8.1	21.9	13.0
Ours						
Code-as-World-VL-4B	**4B**	45.4	55.4	45.8	56.0	50.6
Code-as-World-VL-9B	**9B**	55.0	52.9	55.6	58.1	55.4
Code-as-World-VL-27B (Reasoning)	**27B**	48.7	**62.4**	60.5	**62.8**	**58.6**

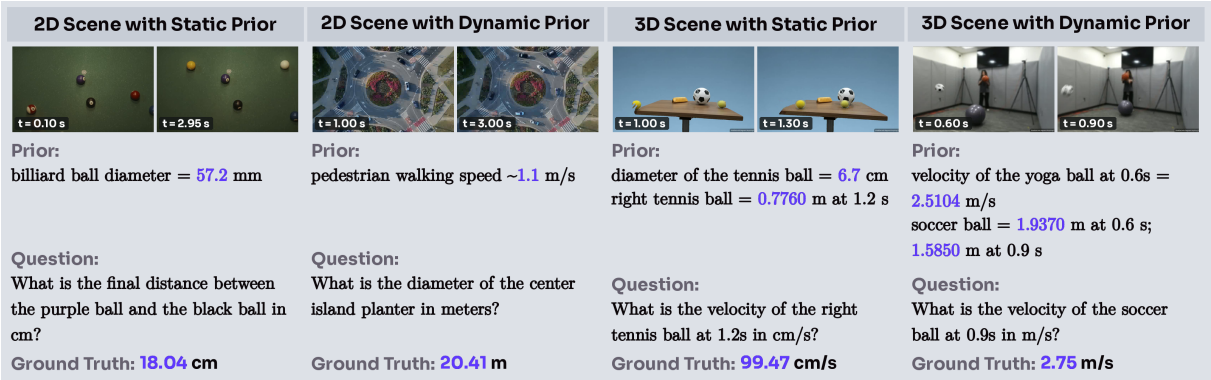


图 8 定量物理推理示意。输入包含一段视频和一个问题。对于三维场景，额外的深度先验提供空间上下文。模型需要依据视频预测答案。示例改编自 [11]。

实边界框，我们据此生成有关被指代物体原始像素宽度、高度、对角线长度的问题，以及要求给出其边界框坐标的定位问题。GOT-10K 提供视频中密集的物体轨迹，我们据此在随机采样的时间戳上构建有关目标物体图像空间范围、速度和加速度的问题，以及指定时间戳的视频定位问题。我们的世界级监督包含由 Code-as-World 生成的文本驱动和视频驱动的可执行世界，可从中导出同步的视频、物理状态和世界级 VQA 样本。我们使用对应的留出数据集开展像素级评估，并使用开源的 QuantiPhy-validation 数据集 [11] 评估具有实际度量单位的物理推理。

指标。 对于图像空间测量，我们在 RefCOCO、RefCOCO+、RefCOCOg、RefCLEF 和 GOT-10K 五个数据集上进行评估。对于每个数据集，通过比较模型以像素为单位的数值答案与对应的真实像素量，计算平均相对准确率（MRA）[75]。四个指代表达数据集评估物体的空间范围，GOT-10K 则评估物体的空间范围和运动量。对于世界空间中的 QuantiPhy 评估，我们在开源的 QuantiPhy-validation 数据集 [11] 上评估具有实际度量单位的物理推理，并依据其公开的真实数值答案计算 MRA。我们还按照官方协议报告 2S、2D、3S 和 3D 子集的结果。

5.4.2 图像空间测量

如表 3 所示，4B 和 9B 图像空间变体尽管模型规模较小，仍取得了出色的图像平面测量表现。完整的 Code-as-World-VL 模型在每项基准上都进一步超越对应的图像空间变体，表明世界空间训练保留并增强了底层的图像空间定位与测量能力。附录 B.3 提供了更多评估细节和完整结果。

5.4.3 定量物理推理

QuantiPhy 评估模型能否利用物理先验，对单目视频证据进行标定，以世界单位估计物体的尺寸、位移、速度和加速度。我们遵循官方协议，在相同的视频输入和问题格式下比较所有模型。

如表 1 所示，在直接输出答案的受控比较中，Code-as-World-VL 展现了出色的定量物理推理能力。Code-as-World-VL-4B 显著优于参数规模更大的开放权重基线，并能与领先的闭源系统保持竞争力；Code-as-World-VL-9B 则在直接输出答案的变体中取得了最佳平均表现。它在各基准子集上的稳定优势表明，性能提升并不局限于特定物理量或场景配置。Code-as-World-VL 能够更可靠地将视觉测量与实际尺度及运动相联系，体现了可执行世界监督对于通用视频定量推理的价值。

为进一步验证这种物理推理能力，我们训练了规模更大、具备推理能力的 Code-as-World-VL-27B，它会在输出最终标量答案之前展示测量与标定的推理轨迹。如表 1 所示，该模型超越了直接输出答案的 9B 变体以及最强的闭源基线。由于模型规模和回答协议同时发生了变化，我们将 27B 的结果视为框架能够扩展至更大推理模型的证据，而非对单独引入推理所产生效果的受控估计。图 10 通过 QuantiPhy 示例展示了这一过程，附录 B.5 则详述了推理模型的设置。图 9 进一步总结了规模扩展趋势：平均 MRA 从直接输出答案的 4B 变体到 9B 变体逐步提高，并在具备推理能力的 27B 模型上达到最高值。

5.5 局限性

本节的实证研究存在两项主要局限。首先，QuantiPhy 只评估物理理解中的有限子集，主要关注在运动较受约束的条件下，对尺寸、位移、速度和加速度进行单目尺度标定。因此，它仅涵盖现实世界物理现

象的一小部分。自然场景可能包含相机运动、旋转、形变、遮挡、接触、碰撞、摩擦、流体、刚体交互，以及长时间跨度的多物体动力学。

其次，Code-as-World-VL 目前从经过验证的可执行世界所提供的监督中学习，但尚未将智能体发现过程本身内化。换言之，模型接受的是世界表征与验证结果的训练，而假设构建、仿真、诊断和迭代修正仍发生在模型外部。将物理推理拓展至更广泛的机制，并将这一发现循环转化为模型的原生能力，是未来研究的重要方向。

6 相关工作

物理理解与推理。 对物理智能的探索已经涵盖了日益丰富的物理世界推理形式。空间推理关注从视觉观测中恢复几何结构和物体之间的关系 [75–77]。在空间结构之外，物理问答研究模型能否根据图像和视频理解物体属性、交互及可测量的物理量，并对其进行推理 [9–11, 23, 78]。另一类工作研究直觉物理，评估模型能否超越表层视觉相关性，获得类似人类对物体恒存性、动力学和物理合理性的预期 [79, 80]。交互式物理环境也日益被用于研究智能体能否通过行动与干预，运用物理知识解决新任务 [1, 81–84]。尽管取得了这些进展，现有方法仍主要通过特定任务的输出评估物理理解，而对物理实体、状态和机制的底层表征仍大多是隐式的。

以代码作为世界表征。 代码已成为表示可执行世界的一种有前景的媒介。在虚拟环境中，近期工作探索了面向交互式智能体的基于代码的世界模型，其中程序充当环境的可执行引擎，能够通过交互进行生成、修改和评估 [85–87]。除虚拟世界外，研究者也探索了用于物理内容创建与模拟的基于代码的表征。在物体层面，近期基准研究了通过代码生成三维资产和程序化物体 [88, 89]；在场景层面，程序化表征已被用于描述可编辑的三维环境和室内场景 [90–93]。这些方法展示了代码在提供结构化、可组合和可编辑表征方面的优势，但它们主要关注静态场景结构。更新的工作通过可执行模拟和具备物理感知能力的推理，将代码驱动的表征扩展至物理动力学 [94–96]。然而，这些方法尚未解决一个更根本的问题：如何从真实世界观测中抽象出物理机制，并将其转化为可执行表征。

智能体优化与发现。 智能体系统的近期进展探索了智能体如何通过迭代提出、评估和改进外部产物，自主发现更优的解决方案。编程智能体已经展示出通过进化搜索和自动评估发现改进算法的能力 [22]；类似思想还被扩展到学术实验自动化 [97]、机器人可复用技能发现 [98]，以及视觉环境可执行表征生成 [91, 93]。这些方法表明，智能体能够从执行预定义流程，进一步转向主动搜索更符合任务目标的产物。我们的工作在物理世界表征这一背景下呼应了该趋势：将可执行世界假设作为有待发现的产物，并通过模拟以及与语言或视觉证据的对照验证，对其进行迭代改进。

7 结论

物理理解不只需要预测或描述观测，还需要能够刻画世界如何组成、演化以及被操控的底层机制的表征。本文提出 Code-as-World，探索将可执行世界表征作为连接视觉观测与基于机制的推理的桥梁。通过将结构化代码表征与不断演进的智能体发现过程相结合，Code-as-World 使智能体能够针对观测到的物理世界构建、验证并改进可执行假设。我们进一步表明，这些经过验证的可执行世界能够为视觉语言模型的定量物理推理训练提供可规模化的物理监督。我们的结果表明，可执行代码表征为实现更显式、可验证且具有更强泛化能力的物理智能提供了一个有前景的方向。

7.1 更广泛的物理现象

我们当前的实现主要关注刚体动力学，但 Code-as-World 范式并不局限于某一种物理领域。代码具有足够的表达能力，可以为流体 [99, 100]、布料及其他可变形体 [101, 102]、燃烧 [103, 104]、断裂 [105]、弹性与塑性 [106, 107]，以及气体动力学 [108] 的专用模拟器提供统一接口，从而有望将图形学与计算物理领域数十年的进展引入物理智能。核心挑战在于将这种表达能力转化为实际可用的能力：编程智能体必须学会正确调用和组合各类模拟引擎，同时发现过程必须从观测中提取信息足够充分的证据，并在不同物理领域中验证候选世界。因此，拓展可执行表征及其证据验证机制，是未来工作的一个重要方向。

7.2 更广泛的物理能力

除当前用作定量物理推理的结果监督来源之外，通过代码表示物理世界还为物理智能开启了若干更广泛的方向：

- **通用且具有物理依据的物理推理**：Code-as-World 为实体、状态、关系和动力学提供结构化表征，使监督能够超越稀疏的问答目标。未来工作可以探索如何利用可执行世界训练模型，使其能够将实体与观测建立对应、推断物理关系、模拟可能的交互，并对照显式世界状态验证自身的推理 [1, 85, 86]。
- **物理一致的视频生成**：可执行世界表征为视频生成器提供持久状态，显式维持物体身份、几何和时间演化。通过将世界动力学与视觉渲染分离 [109]，未来系统有望实现更连贯的长时程生成、可控干预，以及更好的物理一致性。
- **审慎规划的具身交互**：可执行世界表征可能支持一种类似系统 2 的具身智能形式。在这种形式下，智能体构建显式世界模型，对可能的未来进行推理，并在执行前审慎权衡候选动作，而非仅依赖反应式策略 [110]。通过为被动观测、模拟环境和真实世界交互提供共享抽象，这些表征能够将一种情境中获得的物理知识迁移到另一种情境，为突破直接真实世界经验的限制、实现可规模化的具身学习提供路径。

作者

Hanyang Wang, Yimo Cai, Weiliang Chen, Jiawei Chi, Haowen Sun, Qiyu Dai, Yi-Hsin Hung, Xingzhuo Guo, Jinshan Ren, Runmao Yao, Ziwei Liu, Mingsheng Long, Yueqi Duan, Jun Gao, Jiangran Lyu, Fangfu Liu, Jialong Wu[†]

所属机构

MirroS，清华大学，北京大学，南洋理工大学

[†]项目负责人。

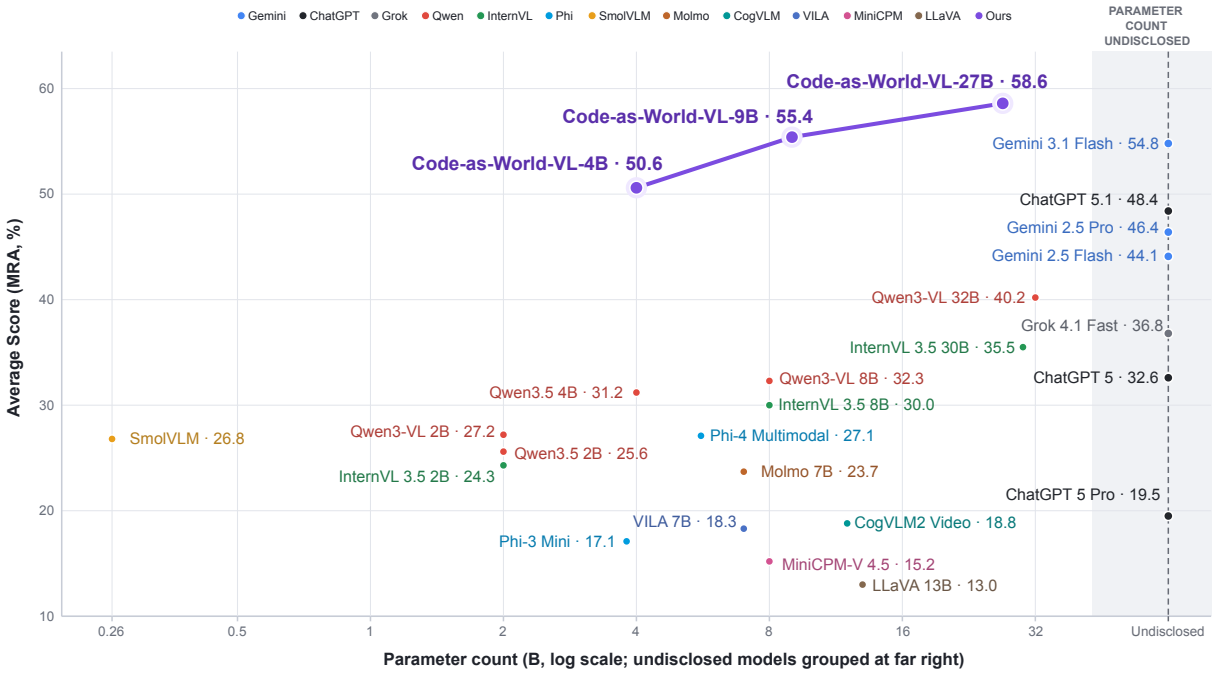
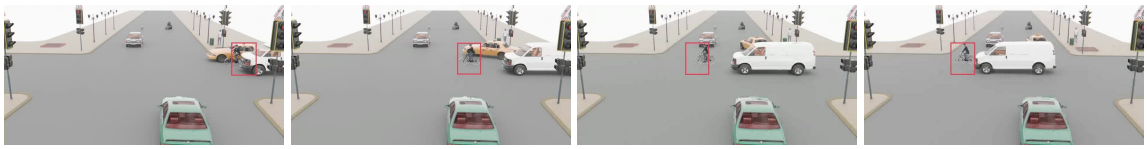


图 9 **QuantiPhy** 上的参数规模扩展结果。未公开参数量的模型统一列在最右侧。



$t = 0.1\,\mathrm{s}$ $t = 0.9\,\mathrm{s}$ $t = 1.7\,\mathrm{s}$ $t = 2.1\,\mathrm{s}$

Prior: Bicycle-camera distances are $d = 23.5534\,\mathrm{m}$ at $0.58\,\mathrm{s}$ and $d = 23.2262\,\mathrm{m}$ at $1.58\,\mathrm{s}$.
Question: What is the average speed of the bicycle in m/s?

`<think>` **(abridged).**
1. **Identify the motion.** The bicycle moves from right to left.
2. **Compute the radial component.** $v_r = |23.2262 - 23.5534|/(1.58 - 0.58) = 0.33\,\mathrm{m/s}$.
3. **Track and calibrate.** The lateral track is about 210 pixels/s; mean depth $\bar{z} \approx 23.4\,\mathrm{m}$ gives $v_\perp \approx 5.5$–$6.8\,\mathrm{m/s}$.
4. **Check.** Since $v_r \ll v_\perp$, the total speed is about $6\,\mathrm{m/s}$.
`</think>`

Predicted Answer: 6 m/s **GT:** 5.33 m/s **MRA:** 0.8



$t = 1.1\,\mathrm{s}$ $t = 1.4\,\mathrm{s}$ $t = 1.7\,\mathrm{s}$ $t = 2.0\,\mathrm{s}$

Prior: Billiard-ball diameter = 57.2 mm.
Question: What is the white ball's average velocity from 1.00 to 2.00 s in cm/s?

`<think>` **(abridged).**
1. **Locate the target.** Track the white ball (red boxes) across the table.
2. **Measure in Image-Space.** Its center displacement over 1.00 s is approximately 248 pixels; the ball spans about 53 pixels.
3. **Calibrate to World-Space.** The 57.2-mm diameter gives the local scale; perspective-normalized displacement yields $v \approx 26.8\,\mathrm{cm/s}$.
4. **Check.** The direction and nearly constant track agree with the observed roll.
`</think>`

Predicted Answer: 26.8 cm/s **GT:** 26.82 cm/s **MRA:** 1.0

图 10 **Code-as-World-VL-27B** 在 **QuantiPhy** 上的推理过程。上下展示了两个代表性案例：可执行世界中的自行车示例，以及来自 `internet_0027` 的真实视频台球示例。红框标出选定帧中的目标物体。节选的推理轨迹保留了关键的图像空间测量和世界空间标定步骤。

参考文献

[1] A. Bakhtin, L. van der Maaten, J. Johnson, L. Gustafson, 和 R. Girshick. “Phyre：物理推理的新基准”. 载于: *神经信息处理系统进展* 32 (2019).

[2] Y. Bengio, A. Courville, 和 P. Vincent. “表征学习：综述与新视角”. 载于: *IEEE 模式分析与机器智能汇刊* 35.8 (2013), 页 1798–1828.

[3] Google DeepMind. *Gemini 3.1 Flash-Lite*. 技术报告. https://storage.googleapis.com/deepmind-media/Model-Cards/Gemini-3-1-Flash-Lite-Model-Card.pdf. Google DeepMind, 2025.

[4] B. Seed. “Seed2. 0 模型卡：面向真实世界复杂性的智能前沿”. 载于: *arXiv 预印本 arXiv:2607.00248* (2026).

[5] K. Team, T. Bai, Y. Bai, Y. Bao, S. Cai, Y. Cao, 等. “Kimi k2. 5：视觉智能体智能”. 载于: *arXiv 预印本 arXiv:2602.02276* (2026).

[6] Qwen Team. *Qwen3.5：迈向原生多模态智能体*. 2 月 2026.

[7] P. Machamer, L. Darden, 和 C. F. Craver. “关于机制的思考”. 载于: *科学哲学* 67.1 (2000), 页 1–25.

[8] Y. Li, Q. Gao, T. Zhao, B. Wang, H. Sun, H. Lyu, 等. “多模态语言模型中的核心知识缺陷”. 载于: *arXiv 预印本 arXiv:2410.10855* (2024).

[9] K. Yi, C. Gan, Y. Li, P. Kohli, J. Wu, A. Torralba, 和 J. B. Tenenbaum. “Clevrer：用于视频表征与推理的碰撞事件”. 载于: *arXiv 预印本 arXiv:1910.01442* (2019).

[10] W. Chow, J. Mao, B. Li, D. Seita, V. C. Guizilini, 和 Y. Wang. “PhysBench：评测并增强视觉语言模型对物理世界的理解”. 载于: *第 13 届国际学习表征会议*. 2025.

[11] L. Puyin, T. Xiang, E. Mao, S. Wei, X. Chen, A. Masood, L. Fei-Fei, 和 E. Adeli. “Quantiphy：评估视觉语言模型物理推理能力的定量基准”. 载于: *IEEE/CVF 计算机视觉与模式识别会议论文集*. 2026, 页 33174–33184.

[12] H. Sun, Q. Gao, H. Lyu, D. Luo, Y. Li, 和 H. Deng. “探究大型视觉语言模型的力学推理能力”. 载于: *arXiv 预印本 arXiv:2410.00318* (2024).

[13] D. Luo, Y. Li, M. Wang, T. Zhao, B. Wang, S. Wang, 等. “视觉语言模型无法推理物理变换”. 载于: *arXiv 预印本 arXiv:2603.07109* (2026).

[14] L. M. Schulze Buschoff, E. Akata, M. Bethge, 和 E. Schulz. “多模态大语言模型的视觉认知”. 载于: *自然 · 机器智能* 7.1 (2025), 页 96–106.

[15] T. Brooks, B. Peebles, C. Holmes, W. DePue, Y. Guo, L. Jing, 等. “作为世界模拟器的视频生成模型”. 载于: (2024).

[16] T. Seedance, D. Chen, L. Chen, X. Chen, Y. Chen, Z. Chen, 等. “Seedance 2.0：推进面向世界复杂性的视频生成”. 载于: *arXiv 预印本 arXiv:2604.14148* (2026).

[17] M. Assran, A. Bardes, D. Fan, Q. Garrido, R. Howes, M. Muckley, 等. “V-jepa 2：自监督视频模型实现理解、预测与规划”. 载于: *arXiv 预印本 arXiv:2506.09985* (2025).

[18] O. Siméoni, H. V. Vo, M. Seitzer, F. Baldassarre, M. Oquab, C. Jose, 等. “Dinov3”. 载于: *arXiv 预印本 arXiv:2508.10104* (2025).

[19] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, 等. “从自然语言监督中学习可迁移的视觉模型”. 载于: *国际机器学习会议*. PmLR. 2021, 页 8748–8763.

[20] H. Liu, C. Li, Q. Wu, 和 Y. J. Lee. “视觉指令微调”. 载于: *神经信息处理系统进展* 36 (2023), 页 34892–34916.

[21] J. R. Josephson 和 S. G. Josephson. *溯因推理：计算、哲学与技术*. 剑桥大学出版社, 1996.

[22] A. Novikov, N. Vũ, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner, 等. “Alphaevolve：用于科学与算法发现的编码智能体”. 载于: *arXiv 预印本 arXiv:2506.13131* (2025).

[23] F. Zhou, J. Huang, J. Li, D. Ramanan, 和 H. Shi. *PAI-Bench：物理人工智能的综合基准*. 2025. arXiv: 2512.01989 [cs.CV].

[24] J. Wu, S. Yin, N. Feng, X. He, D. Li, J. Hao, 和 M. Long. “ivideogpt：交互式 videogpt 是可扩展的世界模型”. 载于: *神经信息处理系统进展* 37 (2024), 页 68082–68119.

[25] S. Huang, J. Wu, Q. Zhou, S. Miao, 和 M. Long. “Vid2world：将视频扩散模型打造为交互式世界模型”. 载于: *arXiv 预印本 arXiv:2505.14357* (2025).

[26] W. Chen, H. Sun, J. Gao, J. Chi, H. Wang, Q. Dai, 等. “HarnessEval-W：以智能体实现视觉世界评估”. 载于: *arXiv 预印本 arXiv:2608.16859* (2026).

[27] B. Kang, Y. Yue, R. Lu, Z. Lin, Y. Zhao, K. Wang, G. Huang, 和 J. Feng. “视频生成距离世界模型还有多远：物理定律视角”. 载于: *arXiv 预印本 arXiv:2411.02385* (2024).

[28] S. Motamed, L. Culp, K. Swersky, P. Jaini, 和 R. Geirhos. “生成式视频模型理解物理原理吗？”. 载于: *2026 年 IEEE/CVF 计算机视觉应用冬季会议（WACV）*. IEEE. 2026, 页 948–958.

[29] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, 和 R. Ng. “Nerf：将场景表征为神经辐射场以实现视图合成”. 载于: *ACM 通讯* 65.1 (2021), 页 99–106.

[30] B. Kerbl, G. Kopanas, T. Leimkühler, 和 G. Drettakis. “用于实时辐射场渲染的三维高斯泼溅”. 载于: *ACM 图形学汇刊* 42.4 (7 月 2023).

[31] S. Wang, V. Leroy, Y. Cabon, B. Chidlovskii, 和 J. Revaud. “DUSt3R：让三维几何视觉变得简单”. 载于: *CVPR*. 2024.

[32] J. Wang, M. Chen, N. Karaev, A. Vedaldi, C. Rupprecht, 和 D. Novotny. “VGGT：基于视觉几何的 Transformer”. 载于: *IEEE/CVF 计算机视觉与模式识别会议论文集*. 2025.

[33] M. Boss, R. Braun, V. Jampani, J. T. Barron, C. Liu, 和 H. Lensch. “Nerd：从图像集合中进行神经反射率分解”. 载于: *IEEE/CVF 国际计算机视觉会议论文集*. 2021, 页 12684–12694.

[34] J. Gao, C. Gu, Y. Lin, Z. Li, H. Zhu, X. Cao, L. Zhang, 和 Y. Yao. “可重光照的三维高斯：通过 BRDF 分解与光线追踪实现逼真的点云重光照”. 载于: *欧洲计算机视觉会议*. Springer. 2024, 页 73–89.

[35] Y. Jiang, J. Tu, Y. Liu, X. Gao, X. Long, W. Wang, 和 Y. Ma. “Gaussianshader：利用反射表面着色函数的三维高斯泼溅”. 载于: *2024 年 IEEE/CVF 计算机视觉与模式识别会议（CVPR）*. IEEE. 2024, 页 5322–5332.

[36] X. Zhang, P. P. Srinivasan, B. Deng, P. Debevec, W. T. Freeman, 和 J. T. Barron. “NeRFactor：未知光照下形状与反射率的神经分解”. 载于: *ACM 图形学汇刊* 40.6 (12 月 2021), 页 1–18. DOI: 10.1145/3478513.3480496.

[37] A. Pumarola, E. Corona, G. Pons-Moll, 和 F. Moreno-Noguer. “D-NeRF：动态场景的神经辐射场”. 载于: *IEEE/CVF 计算机视觉与模式识别会议论文集*. 2021.

[38] K. Park, U. Sinha, P. Hedman, J. T. Barron, S. Bouaziz, D. B. Goldman, R. Martin-Brualla, 和 S. M. Seitz. “HyperNeRF：面向拓扑变化神经辐射场的高维表征”. 载于: *ACM 图形学汇刊* 40.6 (12 月 2021).

[39] Z. Yang, X. Gao, W. Zhou, S. Jiao, Y. Zhang, 和 X. Jin. “用于高保真单目动态场景重建的可变形三维高斯”. 载于: *2024 年 IEEE/CVF 计算机视觉与模式识别会议（CVPR）*. IEEE. 2024, 页 20331–20341.

[40] G. Wu, T. Yi, J. Fang, L. Xie, X. Zhang, W. Wei, W. Liu, Q. Tian, 和 X. Wang. “用于实时动态场景渲染的四维高斯泼溅”. 载于: *2024 年 IEEE/CVF 计算机视觉与模式识别会议（CVPR）*. IEEE. 2024, 页 20310–20320.

[41] Z. Yang, H. Yang, Z. Pan, 和 L. Zhang. “利用四维高斯泼溅实现实时逼真动态场景表征与渲染”. 载于: *国际学习表征会议（ICLR）*. 2024.

[42] Y. Duan, F. Wei, Q. Dai, Y. He, W. Chen, 和 B. Chen. “4D-Rotor 高斯泼溅：迈向动态场景的高效新视角合成”. 载于: *SIGGRAPH 会议论文集*. 2024.

[43] J. Berg, C. Zhu, Y. Bao, I. Durugkar, 和 A. Gupta. “语义世界模型”. 载于: *arXiv 预印本 arXiv:2510.19818* (2025).

[44] D. Chen, T. Moutakanni, W. Chung, Y. Bang, Z. Ji, A. Bolourchi, 和 P. Fung. “利用视觉语言世界模型进行推理式规划”. 载于: *arXiv 预印本 arXiv:2509.02722* (2025).

[45] Q. Han, K. Hu, L. Qiu, C. Wu, 和 K. He. *VISTA：用于交互世界推理的视觉运行框架*. 8 月 2026.

[46] J. Wu, X. Zhang, H. Yuan, X. Zhang, T. Huang, C. He, 等. “视觉生成通过多模态世界模型解锁类人推理”. 载于: *arXiv 预印本 arXiv:2601.19834* (2026).

[47] X. Chen, F.-J. Chu, P. Gleize, K. J. Liang, A. Sax, H. Tang, 等. “Sam 3d：将图像中的任意对象三维化”. 载于: *arXiv 预印本 arXiv:2511.16624* (2025).

[48] J. Wang, A. Ma, K. Cao, J. Zheng, J. Feng, Z. Zhang, W. Pang, 和 X. Liang. “Wisa：用于物理感知文生视频的世界模拟器助手”. 载于: *神经信息处理系统进展* 38 (2026), 页 5388–5416.

[49] N. Carion, L. Gustafson, Y.-T. Hu, S. Debnath, R. Hu, D. Suris, 等. “Sam 3：通过概念分割万物”. 载于: *arXiv 预印本 arXiv:2511.16719* (2025).

[50] J. Wang, M. Chen, S. Zhang, N. Karaev, J. Schönberger, P. Labatut, 等. “VGGT-Omega”. 载于: *arXiv 预印本 arXiv:2605.15195* (2026).

[51] F. Perazzi, J. Pont-Tuset, B. McWilliams, L. Van Gool, M. Gross, 和 A. Sorkine-Hornung. “视频对象分割的基准数据集与评估方法”. 载于: *IEEE 计算机视觉与模式识别会议论文集*. 2016, 页 724–732.

[52] A. Gupta, J. Johnson, L. Fei-Fei, S. Savarese, 和 A. Alahi. “Social gan：利用生成对抗网络生成符合社会规范的轨迹”. 载于: *IEEE 计算机视觉与模式识别会议论文集*. 2018, 页 2255–2264.

[53] W. Jiang, E. Trulls, J. Hosang, A. Tagliasacchi, 和 K. M. Yi. “Cotr：用于跨图像匹配的对应关系 Transformer”. 载于: *IEEE/CVF 国际计算机视觉会议论文集*. 2021, 页 6207–6217.

[54] L. Yu, P. Poirson, S. Yang, A. C. Berg, 和 T. L. Berg. “对指代表达中的上下文建模”. 载于: *欧洲计算机视觉会议（ECCV）*. Springer. 2016, 页 69–85.

[55] Z. Peng, W. Wang, L. Dong, Y. Hao, S. Huang, S. Ma, 和 F. Wei. “Kosmos-2：将多模态大语言模型锚定于世界”. 载于: *arXiv 预印本 arXiv:2306.14824* (2023).

[56] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, 等. “Deepseekmath：突破开放语言模型的数学推理极限”. 载于: *arXiv 预印本 arXiv:2402.03300* (2024).

[57] D. Guo, D. Yang, H. Zhang, J. Song, P. Wang, Q. Zhu, 等. “Deepseek-r1：通过强化学习激发大语言模型的推理能力”. 载于: *arXiv 预印本 arXiv:2501.12948* (2025).

[58] OpenAI. *GPT-5.1：更智能、更善于对话的 ChatGPT*. https://openai.com/index/gpt-5-1/. 访问日期：2026-07-29. 11 月 2025.

[59] G. Comanici, E. Bieber, M. Schaekermann, I. Pasupat, N. Sachdeva, I. Dhillon, 等. “Gemini 2.5：通过高级推理、多模态、长上下文与下一代智能体能力拓展前沿”. 载于: *arXiv 预印本 arXiv:2507.06261* (2025).

[60] xAI. *Grok 4.1 模型卡*. 模型卡. 访问日期：2026-07-29. xAI, 11 月 2025.

[61] OpenAI. *GPT-5 系统卡*. 系统卡. 访问日期：2026-07-29. OpenAI, 8 月 2025.

[62] S. Bai, Y. Cai, R. Chen, K. Chen, X. Chen, Z. Cheng, 等. “Qwen3-vl 技术报告”. 载于: *arXiv 预印本 arXiv:2511.21631* (2025).

[63] W. Wang, Z. Gao, L. Gu, H. Pu, L. Cui, X. Wei, 等. “Internvl3. 5：提升开源多模态模型的通用性、推理能力与效率”. 载于: *arXiv 预印本 arXiv:2508.18265* (2025).

[64] A. Abouelenin, A. Ashfaq, A. Atkinson, H. Awadalla, N. Bach, J. Bao, 等. “Phi-4-mini 技术报告：通过 LoRA 混合构建紧凑而强大的多模态语言模型”. 载于: *arXiv 预印本 arXiv:2503.01743* (2025).

[65] A. Marafioti, O. Zohar, M. Farré, M. Noyan, E. Bakouch, P. Cuenca, 等. “Smolvlm：重新定义小型高效多模态模型”. 载于: *arXiv 预印本 arXiv:2504.05299* (2025).

[66] M. Deitke, C. Clark, S. Lee, R. Tripathi, Y. Yang, J. S. Park, 等. “Molmo 与 pixmo：面向先进视觉语言模型的开放权重与开放数据”. 载于: *计算机视觉与模式识别会议论文集*. 2025, 页 91–104.

[67] W. Hong, W. Wang, M. Ding, W. Yu, Q. Lv, Y. Wang, 等. “Cogvlm2：用于图像与视频理解的视觉语言模型”. 载于: *arXiv 预印本 arXiv:2408.16500* (2024).

[68] J. Lin, H. Yin, W. Ping, P. Molchanov, M. Shoeybi, 和 S. Han. “Vila：论视觉语言模型的预训练”. 载于: *IEEE/CVF 计算机视觉与模式识别会议论文集*. 2024, 页 26689–26699.

[69] M. Abdin, S. A. Jacobs, A. A. Awan, J. Aneja, A. Awadallah, H. H. Awadalla, 等. “Phi-3 技术报告：在手机本地运行的高能力语言模型”. 载于: *ArXiv* abs/2404.14219 (2024).

[70] T. Yu, Z. Wang, C. Wang, F. Huang, W. Ma, Z. He, 等. “Minicpm-v 4.5：通过架构、数据与训练方案打造高效多模态大语言模型”. 载于: *arXiv 预印本 arXiv:2509.18154* (2025).

[71] H. Liu, C. Li, Q. Wu, 和 Y. J. Lee. “视觉指令微调”. 载于: *神经信息处理系统进展* 36 (2023), 页 34892–34916.

[72] J. Mao, J. Huang, A. Toshev, O. Camburu, A. L. Yuille, 和 K. Murphy. “无歧义对象描述的生成与理解”. 载于: *IEEE 计算机视觉与模式识别会议（CVPR）论文集*. 2016, 页 11–20.

[73] S. Kazemzadeh, V. Ordonez, M. Matten, 和 T. Berg. “ReferItGame：指代自然场景照片中的对象”. 载于: *2014 年自然语言处理经验方法会议（EMNLP）论文集*. 2014, 页 787–798.

[74] L. Huang, X. Zhao, 和 K. Huang. “GOT-10k：用于真实环境中通用对象跟踪的大规模高多样性基准”. 载于: *IEEE 模式分析与机器智能汇刊* 43.5 (2019), 页 1562–1577.

[75] J. Yang, S. Yang, A. W. Gupta, R. Han, L. Fei-Fei, 和 S. Xie. “在空间中思考：多模态大语言模型如何观察、记忆与回忆空间”. 载于: *计算机视觉与模式识别会议论文集*. 2025, 页 10632–10643.

[76] D. Wu, F. Liu, Y.-H. Hung, 和 Y. Duan. “Spatial-mllm：提升多模态大语言模型的视觉空间智能能力”. 载于: *神经信息处理系统进展* 38 (2026), 页 13569–13597.

[77] F. Liu, D. Wu, J. Chi, Y. Cai, Y.-H. Hung, X. Yu, 等. “Spatial-TTT：利用测试时训练实现流式视觉空间智能”. 载于: *arXiv 预印本 arXiv:2603.12255* (2026).

[78] F. Liu, H. Wang, S. Yao, S. Zhang, J. Zhou, 和 Y. Duan. “Physics3d：通过视频扩散学习三维高斯的物理属性”. 载于: *arXiv 预印本 arXiv:2406.04338* (2024).

[79] R. Riochet, M. Y. Castro, M. Bernard, A. Lerer, R. Fergus, V. Izard, 和 E. Dupoux. “Intphys：视觉直觉物理推理的框架与基准”. 载于: *arXiv 预印本 arXiv:1803.07616* (2018).

[80] F. Bordes, Q. Garrido, J. T. Kao, A. Williams, M. Rabbat, 和 E. Dupoux. “Intphys 2：评测复杂合成环境中的直觉物理理解”. 载于: *arXiv 预印本 arXiv:2506.09849* (2025).

[81] X. Xu, P. Bu, Y. Wang, B. F. Karlsson, Z. Wang, T. Song, 等. “DeepPHY：评测智能体式视觉语言模型的物理推理能力”. 载于: *AAAI 人工智能会议论文集*. 卷 40. 40. 2026, 页 34160–34168.

[82] C. Xue, V. Pinto, C. Gamage, E. Nikonova, P. Zhang, 和 J. Renz. “以 Phy-Q 衡量物理推理智能”. 载于: *自然 · 机器智能* 5.1 (2023), 页 83–93.

[83] Y. Wu, M. Song, Y. Lan, L. Wang, Z. Hu, Y. Xiao, 等. “从感知到行动：视觉推理的交互式基准”. 载于: *arXiv 预印本 arXiv:2602.21015* (2026).

[84] R. Yao, K. Hu, Y. Cao, R. Wang, S. Tian, Z. Cao, 等. “Apple-pi：评测借助视频思考以迈向基于定律的物理智能”. 载于: *arXiv 预印本 arXiv:2607.16401* (2026).

[85] W. Lehrach, D. Hennes, M. Lazaro-Gredilla, X. Lou, C. Wendelken, Z. Li, 等. “用于通用游戏游玩的代码世界模型”. 载于: *国际学习表征会议*. 卷 2026. 2026, 页 133870–133927.

[86] S. Rodionov. “编码智能体时代面向 ARC-AGI-3 的可执行世界模型”. 载于: *通用人工智能国际会议*. Springer. 2026, 页 198–210.

[87] H. Tang, D. Key, 和 K. Ellis. “Worldcoder：基于模型的大语言模型智能体，通过编写代码与环境交互构建世界模型”. 载于: *神经信息处理系统进展* 37 (2024), 页 70148–70212.

[88] Y. Zheng 和 F. Bordes. “Voxelcodebench：评测通过代码生成进行的三维世界建模”. 载于: *arXiv 预印本 arXiv:2604.02580* (2026).

[89] Y. Gao, L. Shu, G. Ye, X. Xiong, A. Makadia, M. Guo, L. Itti, 和 J. Chen. “3DCodeBench：评测智能体通过代码进行的程序化三维建模”. 载于: *arXiv 预印本 arXiv:2606.01057* (2026).

[90] Y. Zhang, Z. Li, M. Zhou, S. Wu, 和 J. Wu. “场景语言：用程序、词语与嵌入表征场景”. 载于: *2025 年 IEEE/CVF 计算机视觉与模式识别会议（CVPR）*. IEEE. 2025, 页 24625–24634.

[91] P. Wang, Y. Wang, L. Li, Z. Yang, K. Q. Lin, Y. Li, 和 Y. Cheng. “SceneCode：用于包含关节对象的可编辑室内场景的可执行世界程序”. 载于: *arXiv 预印本 arXiv:2605.19587* (2026).

[92] Y. Yang, Z. Luo, W. Gan, J. Hao, J. Lu, J. Yan, Z. Lyu, 和 X. Xu. “Code-as-Room：通过智能体代码合成从俯视图像生成三维房间”. 载于: *arXiv 预印本 arXiv:2605.18451* (2026).

[93] S. Yin, J. Ge, Z. Z. Wang, C. Wang, X. Li, M. J. Black, T. Darrell, A. Kanazawa, 和 H. Feng. “通过交错式多模态推理实现将视觉视为逆向图形学的智能体”. 载于: *arXiv 预印本 arXiv:2601.11109* (2026).

[94] J. Liang, M. Ku, K.-H. Hui, P. Nie, 和 W. Chen. “VisPhyWorld：通过代码驱动的视频重建探究物理推理”. 载于: *arXiv 预印本 arXiv:2602.13294* (2026).

[95] Ž. Kovačič 和 K. Ellis. “MPMWorlds：用于推断与外推物理动力学的物质点法仿真”. 载于: *arXiv 预印本 arXiv:2606.01538* (2026).

[96] T. Xie, P. Wang, Y. Qian, Y. Wang, R. Ma, Y. Tai, 等. “PhysCodeBench：评测通过自纠正多智能体迭代改进实现的三维场景物理感知符号仿真”. 载于: *arXiv 预印本 arXiv:2604.23580* (2026).

[97] A. Karpathy. *autoresearch*. https://github.com/karpathy/autoresearch. 2026.

[98] R. Lu, Y. Wu, E. Kou, L. Fu, W. Xiao, A. Mandlekar, 等. “ASPIRE：面向机器人学的智能体技能发现”. 载于: *arXiv 预印本 arXiv:2607.00272* (2026).

[99] J. Stam. “稳定流体”. 载于: *第 26 届计算机图形学与交互技术年会论文集*. SIGGRAPH ’99. 美国: ACM 出版社/Addison-Wesley 出版公司, 1999, 页 121–128. DOI: 10.1145/311535.311548.

[100] Q. Dai, X. Ni, qianfan Shen, W. Chen, B. Chen, 和 M. Chu. “RainyGS：利用基于物理的高斯泼溅高效合成雨景”. 载于: *IEEE/CVF 计算机视觉与模式识别会议（CVPR）论文集*. 6 月 2025.

[101] D. Baraff 和 A. Witkin. “布料仿真中的大步长方法”. 载于: *第 25 届计算机图形学与交互技术年会论文集*. SIGGRAPH ’98. 美国纽约州纽约市: 美国计算机协会, 1998, 页 43–54. DOI: 10.1145/280814.280821.

[102] R. Narain, A. Samii, 和 J. F. O’brien. “用于布料仿真的自适应各向异性重网格化”. 载于: *ACM 图形学汇刊（TOG）* 31.6 (2012), 页 1–10.

[103] D. Q. Nguyen, R. Fedkiw, 和 H. W. Jensen. “基于物理的火焰建模与动画”. 载于: *第 29 届计算机图形学与交互技术年会论文集*. 2002, 页 721–728.

[104] Q. Shen, N. Tao, Q. Dai, T. Chen, M. Qin, Y. Zhang, M. Chu, W. Chen, 和 B. Chen. “FieryGS：利用融合物理的高斯泼溅合成真实场景中的火焰”. 载于: *第 14 届国际学习表征会议*. 2026.

[105] J. F. O’brien 和 J. K. Hodgins. “脆性断裂的图形建模与动画”. 载于: *第 26 届计算机图形学与交互技术年会论文集*. 1999, 页 137–146.

[106] D. Terzopoulos, J. Platt, A. Barr, 和 K. Fleischer. “弹性可变形模型”. 载于: *第 14 届计算机图形学与交互技术年会论文集*. 1987, 页 205–214.

[107] G. Irving, J. Teran, 和 R. Fedkiw. “用于稳健大变形仿真的可逆有限元”. 载于: *2004 年 ACM SIGGRAPH/Eurographics 计算机动画研讨会论文集*. 2004, 页 131–140.

[108] R. P. Fedkiw, T. Aslam, B. Merriman, 和 S. Osher. “处理多材料流界面的无振荡欧拉方法（虚拟流体法）”. 载于: *计算物理学杂志* 152.2 (1999), 页 457–492.

[109] H. A. Alhaija, J. Alvarez, M. Bala, T. Cai, T. Cao, L. Cha, 等. “Cosmos-transfer1：利用自适应多模态控制进行条件世界生成”. 载于: *arXiv 预印本 arXiv:2503.14492* (2025).

[110] P. Intelligence, B. Ai, A. Amin, R. Aniceto, A. Balakrishna, G. Balke, 等. “pi0.7：具有涌现能力的可引导通用机器人基础模型”. 载于: *arXiv 预印本 arXiv:2604.15483* (2026).

[111] J. Y. Lim, R. Shah, Z. Ikram, S. Yu, H. Ma, T.-Y. Leong, 和 D. Liu. “JEDI：用于在线基于模型的强化学习的联合嵌入扩散世界模型”. 载于: *arXiv 预印本 arXiv:2605.13013* (2026).

[112] A. Bardes, Q. Garrido, J. Ponce, X. Chen, M. Rabbat, Y. LeCun, M. Assran, 和 N. Ballas. “V-jepa：用于视觉表征学习的潜在视频预测”. 载于: (2024).

[113] K. Allen, C. Doersch, G. Zhou, M. Suhail, D. Driess, I. Rocco, 等. “用于评估生成视频的直接运动模型”. 载于: *arXiv 预印本 arXiv:2505.00209* (2025).

[114] C. Doersch, P. Luc, Y. Yang, D. Gokay, S. Koppula, A. Gupta, 等. “Bootstap：用于任意点跟踪的自举训练”. 载于: *亚洲计算机视觉会议*. Springer. 2024, 页 483–500.

[115] E. Todorov, T. Erez, 和 Y. Tassa. “MuJoCo：用于基于模型的控制的物理引擎”. 载于: *2012 年 IEEE/RSJ 智能机器人与系统国际会议*. IEEE. 2012, 页 5026–5033. DOI: 10.1109/IROS.2012.6386109.

[116] T. Wan, A. Wang, B. Ai, B. Wen, C. Mao, C.-W. Xie, 等. “Wan：开放且先进的大规模视频生成模型”. 载于: *arXiv 预印本 arXiv:2503.20314* (2025).

[117] Z. Jiang, Z. Han, C. Mao, J. Zhang, Y. Pan, 和 Y. Liu. “Vace：一体化视频创作与编辑”. 载于: *IEEE/CVF 国际计算机视觉会议论文集*. 2025, 页 17191–17202.

附录

A 数据集详情

本节补充介绍第 5.4.1 节概述的数据集。图像空间数据集提供直接的图像平面测量监督，而 Code-as-World 可执行世界数据集则从经过验证的 EWR 中提供同步视频、物理状态和世界空间视觉问答样本。

A.1 图像空间数据集

图像来源。 我们基于 RefCOCO 和 RefCOCO+ [54]、RefCOCOg [72] 以及 RefCLEF [73] 构建图像样本。每条标注都将一个自然语言指代表达与一个真实边界框关联起来。我们根据边界框坐标构造关于物体宽度、高度、对角线长度及其在图像平面中的相对位置的问题。我们保留原始的定位任务作为辅助监督，要求模型返回所指物体的边界框。

视频来源。 GOT-10K [74] 为被跟踪物体提供密集的逐帧边界框。我们从每段视频中均匀采样 16 个按时间排序的帧，并利用边界框的中心和尺寸构建以像素为单位的物体大小、位移、速率和加速度问题。此外，我们还根据采样的边界框构建针对特定时间戳的定位问题。每个问题都包含一段对被跟踪物体的简短语义描述，以明确指定目标。

统计信息。 移除图像与评估数据重叠的样本后，图像空间训练集包含 73,335 个问答对。其中，46,763 个来自 GOT-10K：包括 20,858 个速率样本、8,399 个速度样本、12,169 个加速度样本、3,995 个定位样本和 1,342 个尺寸相关样本。其余 26,572 个样本来自上述四个指代表达数据集，包括 16,989 个定位样本和 9,583 个尺寸相关样本。

A.2 世界空间可执行世界数据集

Code-as-World 可执行世界数据集统一了根据经审核的语言规格描述和真实视频观测构建的世界空间监督。该数据集包含 1,585 个文本驱动和 988 个视频驱动的视觉问答样本。

B 实验规程

B.1 可执行世界的保真度与真实感评估

我们从三个互补维度评估可执行世界：与原始观测的一致性、对物体运动的保持程度，以及与真实视频分布的接近程度。

视觉对齐。 对于帧 t，令 M_t 和 $\widehat{M}_t$ 分别表示观测物体掩码的并集和渲染物体掩码的并集。轮廓分量是二者的交并比，$s_t^{\mathrm{sil}} = |M_t \cap \widehat{M}_t| / |M_t \cup \widehat{M}_t|$；当两个掩码均为空时，其值为一。令 z_t 和 $\hat{z}_t$ 分别为观测深度图和渲染深度图，I_t 和 $\hat{I}_t$ 分别为对应的 8 位 RGB 帧。考虑像素 p 所属的掩码重叠区域 $\Omega_t = M_t \cap \widehat{M}_t$，令 Ω_t^{dep} 表示观测深度和渲染深度均为有限值且观测深度为正的像素子集，令 Ω_t^{rgb} 表示 Ω_t 中有效的 RGB 像素。我们计算绝对相对深度误差的中位数和归一化 RGB 误差：

$$e_t^{\mathrm{dep}} = \operatorname*{median}_{p \in \Omega_t^{\mathrm{dep}}} \frac{|\hat{z}_t(p) - z_t(p)|}{\max(|z_t(p)|, 10^{-6})}, \qquad e_t^{\mathrm{rgb}} = \operatorname*{mean}_{p \in \Omega_t^{\mathrm{rgb}}} \frac{\|\hat{I}_t(p) - I_t(p)\|_1}{3 \times 255}. \tag{5}$$

对应的相似度为 $s_t^{\mathrm{dep}} = (1 + e_t^{\mathrm{dep}})^{-1}$ 和 $s_t^{\mathrm{rgb}} = \max(0, 1 - e_t^{\mathrm{rgb}})$。定义有效分量集合 $\mathcal{A}_t$：该集合始终包含 sil；包含 dep 的充要条件为 $\Omega_t^{\mathrm{dep}} \neq \emptyset$；包含 rgb 的充要条件为 $\Omega_t^{\mathrm{rgb}} \neq \emptyset$。若 T 为原始评估帧的数量，则视觉对齐得分为有效分量权重重新归一化后逐帧得分在整个视频上的均值：

$$\mathrm{VA} = \frac{1}{T} \sum_{t=1}^{T} \frac{\sum_{c \in \mathcal{A}_t} w_c s_t^c}{\sum_{c \in \mathcal{A}_t} w_c}, \qquad (w_{\mathrm{sil}}, w_{\mathrm{dep}}, w_{\mathrm{rgb}}) = (0.60, 0.25, 0.15). \tag{6}$$

因此，在重新归一化权重之前，我们会省略不可用的深度或 RGB 分量，而轮廓分量在每一帧中始终有效。

物体交并比。 令 $M_{t,o}$ 和 $\widehat{M}_{t,o}$ 分别表示物体 o 在帧 t 中的观测掩码和渲染掩码。我们计算

$$\mathrm{IoU}_{t,o} = \frac{|M_{t,o} \cap \widehat{M}_{t,o}|}{|M_{t,o} \cup \widehat{M}_{t,o}|}, \tag{7}$$

并将其在所有已标注物体与帧配对上的均值报告为物体交并比。当两个掩码均为空时，我们将交并比设为一。渲染的可见性通过最终场景的深度缓冲确定，从而避免将被遮挡的几何体视为额外可见区域而加以惩罚。视觉对齐得分和物体交并比越高，表明视觉一致性越好 [51]。

轨迹保真度。 对于一个物体，令 $\mathbf{p}_t$ 表示其在采样帧 t 中由仿真器给出的真实图像平面中心，令 $\hat{\mathbf{p}}_t$ 表示 CoTracker 在待评估视频中对该中心的估计。仿真器渲染视频及其仿真到真实视频均从 $\mathbf{p}_0$ 初始化，并与同一条真实轨迹进行比较。对于每段视频，我们均匀采样 16 帧，并在跟踪前将其宽度调整为 512。对于宽度为 W、高度为 H 的帧，令 $D = \sqrt{W^2 + H^2}$ 表示其对角线长度。为使记号简洁，$\langle \cdot \rangle$ 表示在所有有效物体与采样帧上的均值，不包含初始化帧；对于速度，它表示在有效连续帧对上的均值。遵循标准轨迹误差评估方法 [52, 53]，我们定义

$$\text{Traj-ADE} = \frac{100}{D} \left\langle \|\hat{\mathbf{p}}_t - \mathbf{p}_t\|_2 \right\rangle, \tag{8}$$

$$\text{Velocity-ADE} = \frac{100}{D} \left\langle \|(\hat{\mathbf{p}}_t - \hat{\mathbf{p}}_{t-1}) - (\mathbf{p}_t - \mathbf{p}_{t-1})\|_2 \right\rangle, \tag{9}$$

$$\text{Accuracy@2\%D} = 100 \left\langle \mathbb{1}[\|\hat{\mathbf{p}}_t - \mathbf{p}_t\|_2 \le 0.02D] \right\rangle, \tag{10}$$

轨迹平均位移误差（Traj-ADE）以 $\%D$ 为单位报告，速度平均位移误差（Velocity-ADE）以 $\%D$/步为单位报告。我们保留绝对图像位置，不减去初始跟踪偏移。在数据集级别的结果中，每个可执行世界具有相同权重；首先对同一世界的各个仿真到真实变体取均值，再计算最终的跨世界均值。

JEDi 指标。 JEDi [111] 利用 V-JEPA [112] 视频特征衡量视频在分布层面的真实感。令 $\{\mathbf{z}_i^r\}_{i=1}^n$ 表示真实参考视频的特征，$\{\mathbf{z}_j^c\}_{j=1}^m$ 表示候选视频的特征。设特征维度为 d，二次多项式核为 $k(\mathbf{u}, \mathbf{v}) = (\mathbf{u}^\top \mathbf{v}/d)^2$，我们报告有偏最大均值差异：

$$\text{JEDi} = 100 \left[\frac{1}{n^2} \sum_{i,i'} k(\mathbf{z}_i^r, \mathbf{z}_{i'}^r) + \frac{1}{m^2} \sum_{j,j'} k(\mathbf{z}_j^c, \mathbf{z}_{j'}^c) - \frac{2}{nm} \sum_{i,j} k(\mathbf{z}_i^r, \mathbf{z}_j^c) \right]. \tag{11}$$

JEDi 越低，表明候选视频分布与真实参考分布越接近。

TRAJAN 指标。 TRAJAN [113] 单独衡量运动真实感。我们使用 BootsTAPIR [114] 提取点轨迹，通过 TRAJAN TrackAutoEncoder 对其编码，并将得到的 128×64 潜在表征展平为一个 8192 维特征。对于每组特征，我们估计样本均值和无偏样本协方差 (μ, Σ)。给定真实视频和候选视频各自的 (μ_r, Σ_r) 和 (μ_c, Σ_c)，报告的距离为

$$\text{TRAJAN} = \|\mu_r - \mu_c\|_2^2 + \mathrm{Tr}\left(\Sigma_r + \Sigma_c - 2 \left(\Sigma_r^{1/2} \Sigma_c \Sigma_r^{1/2} \right)^{1/2} \right). \tag{12}$$

TRAJAN 越低，表明与真实视频运动统计特征的一致性越好。这里，Tr 表示矩阵的迹，每个矩阵平方根均为主半正定平方根。

B.2 可执行引擎配置

我们使用 MuJoCo [115] 作为构建和执行 EWR 的仿真平台。在该平台内，我们支持两种可互换的执行引擎。动画引擎通过随时间变化的位姿和轨迹从运动学层面描述运动，着重刻画什么在运动以及如何运动；物理引擎则描述力学物体及其相互作用，并根据力、接触和约束等属性推导运动。两种引擎均实现相同的可执行世界接口，因此能够独立于输入证据接入智能体发现过程，从而根据所需的运动控制方式和物理细节，灵活搭配证据与引擎。正文使用视频证据和动画引擎展示智能体发现过程，而第 C.1 节报告使用视频证据与物理引擎的结果。在仿真之后，我们使用 Wan2.2-VACE [116, 117] 和一个内部视频生成模型，对渲染视频执行以真实感为目标的重渲染阶段。该阶段以仿真器渲染结果为条件，在保持可执行轨迹展开过程的场景结构和时序动态的同时，提高照片级真实感。

B.3 图像空间测量评估

图像空间评估将直接测量与世界空间标定分开考察。对于一个轴对齐边界框 $B_t = (x_t^{\min}, y_t^{\min}, x_t^{\max}, y_t^{\max})$，其宽度、高度和对角线长度分别为

$$w_t = x_t^{\max} - x_t^{\min}, \qquad h_t = y_t^{\max} - y_t^{\min}, \qquad \ell_t = \sqrt{w_t^2 + h_t^2}. \tag{13}$$

对于视频，令 $\mathbf{c}_t$ 表示均匀采样时间戳处被跟踪边界框的中心，采样间隔为 Δt。我们通过中心差分计算图像平面速度和加速度：

$$\mathbf{v}_t = \frac{\mathbf{c}_{t+1} - \mathbf{c}_{t-1}}{2\Delta t}, \qquad \mathbf{a}_t = \frac{\mathbf{c}_{t+1} - 2\mathbf{c}_t + \mathbf{c}_{t-1}}{\Delta t^2}. \tag{14}$$

标量速率和加速度目标取对应向量的模。我们仅在所需边界框均有效的时间戳处生成问题。目标值始终以原始像素、像素每秒或像素每二次方秒为单位；不提供物体尺寸先验或世界单位尺度。

标量预测使用式 (15) 评估，采用相同的解析方式和相对误差计算方法。我们在每个基准内分别对样本级平均相对准确率（MRA）取均值，得到表 3 中报告的五个数据集得分。定位输出单独解析为边界框；表中报告的标量 MRA 不包含定位样本。

B.4 世界空间 QuantiPhy 评估

我们在开源 QuantiPhy 验证集 [11] 上进行评估。该验证集包含 159 个定量问答对，其真实答案公开可见。每个样本都提供一段单目视频、一个问题和一项物理先验，模型须据此推断一个世界空间标量。我们遵循官方的分类与评估规程。

运动学类别。 报告的四个子集分别记为 2S、2D、3S 和 3D。数字表示空间设定：2 表示平面运动学，3 表示考虑深度的三维设定。字母表示所提供源先验的类型：S 表示静态量，例如物体尺寸；D 表示动态量，例如速度或加速度。被询问的目标量本身既可以是静态的，也可以是动态的；子集归属由源先验和空间设定共同决定。

平均相对准确率。 我们使用平均相对准确率（MRA）[75]。对于样本 i，令 $\hat{y}_i$ 表示模型的原始响应。评估器将其解析为标量，并通过取绝对值统一其符号：$\tilde{y}_i = |\,\mathrm{parse}(\hat{y}_i)|$。给定真实值 $y_i > 0$，相对误差为 $r_i = |\tilde{y}_i - y_i|/y_i$。令 $\Theta = \{0.1, 0.2, \ldots, 0.9, 0.95\}$，样本级得分为

$$\mathrm{MRA}_i = \frac{1}{|\Theta|} \sum_{\theta \in \Theta} \mathbb{1}[r_i < 1 - \theta]\,. \tag{15}$$

因此，一个预测会在十个逐渐收紧的相对误差阈值上分别计分。无法解析为有限数值的响应不满足任何阈值，得分为零。

我们分别在 2S、2D、3S 和 3D 各子集内对样本级 MRA 取均值。总体得分为这四个子集得分的非加权宏平均，而不是按样本数量加权的平均值。正文中展示的所有 MRA 值均乘以 100。

B.5 推理模型设置

范围与输入。 Code-as-World-VL-27B（推理）是一个独立的、采用结果监督的推理变体，并非 4B/9B 直接回答模型受控比较中的第三个比较点。它与直接回答模型接收相同的 16 个按时间排序的帧、问题、单位以及基准提供的物理先验。对于需要考虑深度的问题，它还接收相同的、由基准提供的深度上下文。在测试时，它无法访问用于生成数据的 EWR、仿真器状态、物体轨迹、外部工具、检索或真实测量值。

训练规程。 27B 变体采用 GRPO 优化，训练数据为从经过验证的可执行世界构建并合并的文本驱动与视频驱动世界空间问题。每个提示词生成 16 条轨迹；全局更新批大小为 16，优化器采用 AdamW，学习率为 5×10^{-6}，权重衰减为 0.01，预热步数为五步，参数精度为 bfloat16。我们启用模型的中等推理强度思考模式，且不施加 KL 惩罚。奖励解析器丢弃推理轨迹，仅根据最终数值答案计算 MRA。没有任何过程标签或奖励监督轨迹内容，因此推理训练仍以结果为依据。

响应格式。 系统提示词提供起始的 `<think>` 标签，并要求模型用 `</think>` 结束推理轨迹，然后仅在一行中输出一个标量及所要求的单位。在轨迹内部，完整的解答可以识别目标和时间戳、获取图像空间测量值、处理深度和透视关系，并将测量值标定为世界空间量。该轨迹采用自由形式，并非一系列分别接受监督的字段。图 10 展示了本文所报告模型生成的一条代表性轨迹。

表 2 文本驱动的仿真到真实视频生成的分布真实感与运动保真度。真实感指标以留出的真实视频作为参考分布，而运动指标则将 CoTracker 的估计轨迹与仿真器提供的真实轨迹进行比较。

	Distributional Realism		Motion Fidelity		
Video Type	**JEDi MMD** ↓	**TRAJAN Fréchet** ↓	**Traj-ADE** ↓ (%D)	**Velocity-ADE** ↓ (%D/step)	**Accuracy@2%D** ↑ (%)
Simulator Render	3.000	406.872	1.682	0.404	78.81
Sim-to-Real Video	1.484	185.321	1.677	0.472	77.49

推理与解析。 对于表 1 中的结果，我们评估训练至第 60 步的模型。对每个 QuantiPhy 样本采样一个响应，温度设为 1.0，核采样参数为 $p = 0.95$，响应长度上限为 6,144 个词元。表中的各子集 MRA 及其非加权宏平均均来自此次第 60 步验证运行。我们不使用自一致性、多数投票、N 选优或工具调用。评估器仅取最后一个 `</think>` 标签之后的文本，并提取其中的第一个标量；若输出为简短的单行直接答案，也可作为回退形式接受，而未闭合的多行推理轨迹则无法解析，得分为零。因此，数值评估器始终无法看到推理轨迹内部的数字。

C 补充实验

C.1 文本驱动的仿真到真实评估

在确认 EWR 能够忠实解释其输入之后，我们进一步评估它能否生成既具有真实感又具有可靠标注的视频，结果见表 2。对于文本驱动的世界，仿真器提供精确的状态、轨迹和物理标签，而视频生成器应在不改变这些信息的前提下提升视觉真实感。因此，我们从分布真实感和运动保真度两个维度评估仿真到真实生成。

生成的视频在整体视频特征分布和运动特征分布上均更接近真实视频，同时保留了与原始仿真器渲染视频相当的运动一致性。因此，仿真到真实生成改善了视觉外观，而没有实质性改变 EWR 所指定的物理演化。综合来看，这两项评估首先确认了可执行表征仍忠实于其源证据，随后表明它能够生成具有真实感的观测，同时保持仿真器所导出状态与标签的可靠性。

C.2 补充智能体发现循环实验

为评估迭代发现能否在主要分析所用的动画引擎之外仍然有效，我们使用附录 B.2 中描述的物理引擎重复实验。如图 11 所示，性能在五轮发现过程中持续改善：视觉对齐、物体交并比以及阈值为 2%D 的准确率均上升，而轨迹平均位移误差和速度平均位移误差均下降。到第五轮时，智能体发现循环在全部五项指标上也优于相同预算下的 5 选优基线，表明其迭代收益在不同的可执行引擎下仍然存在。

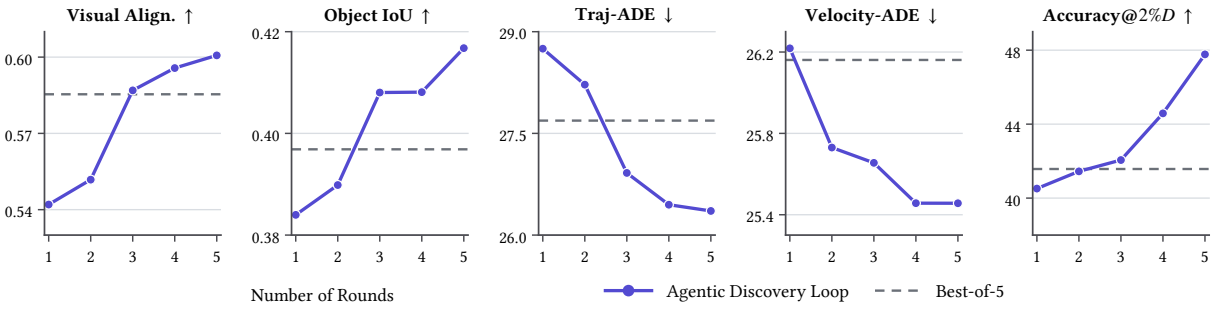


图 11 **使用物理引擎的智能体发现。**实线曲线报告五轮迭代发现的性能，灰色虚线表示同样五次评估预算下的 5 选优结果。视觉对齐、物体交并比及阈值为 2%D 的准确率越高越好；轨迹平均位移误差和速度平均位移误差越低越好。

C.3 图像空间测量结果

我们在四个指代表达数据集和 GOT-10K 上，将 Code-as-World-VL 与开放权重模型进行比较。这些基准涵盖图像中的物体尺寸与定位，以及视频中的物体尺寸与运动。表 3 报告定量比较结果。图 12 展示了定位、长度、速率和加速度的代表性预测，作为表 3 定量结果的补充。在所示样本中，Code-as-World-VL 能够识别指定目标并给出接近真实值的测量结果，而对比模型则表现出更大的定位或数值误差。

表 3 像素级测量评估。指代表达数据集评估图像中的物体尺寸，而 GOT-10K 评估视频中的物体尺寸和运动。图像空间变体仅采用第一阶段训练；完整的 Code-as-World-VL 模型还额外接受可执行世界强化学习。

Models	Size	RefCOCO†	RefCOCOg†	RefCOCO+†	RefCLEF†	GOT-10K*
Open-weight models						
Qwen3-VL-32B-Instruct [62]	32B	49.1	40.3	44.9	32.5	15.8
Qwen3.5-27B [6]	27B	47.0	44.8	46.8	31.6	6.1
Qwen3.5-9B [6]	9B	38.6	33.0	38.6	37.8	15.9
MiniCPM-V 4.5 [70]	8B	55.6	53.2	54.1	38.6	15.9
InternVL-3.5-8B [63]	8B	36.4	30.9	35.2	24.2	14.4
Qwen3-VL-8B-Instruct [62]	8B	43.4	43.0	41.8	40.0	18.9
Qwen3.5-4B [6]	4B	28.6	26.1	30.4	20.9	3.0
InternVL-3.5-4B [63]	4B	36.9	32.5	35.9	27.5	8.4
Ours						
Code-as-World-VL-4B (Image-Space)	**4B**	56.1	51.6	56.2	31.2	18.7
Code-as-World-VL-4B	**4B**	62.9	60.2	63.3	39.8	20.5
Code-as-World-VL-9B (Image-Space)	**9B**	63.7	61.1	61.5	47.2	20.1
Code-as-World-VL-9B	**9B**	**68.3**	**65.6**	**66.4**	**61.9**	**26.6**

图像空间变体建立了可靠的视觉定位和像素级测量能力，为后续世界空间学习提供感知基础。加入世界空间监督后，完整的 4B 和 9B 模型在全部五个图像空间基准上均优于各自对应的图像空间变体。因此，两个训练阶段相互促进：图像空间监督使物理推理以可观测测量为基础，而世界空间监督则将物理一致性反馈给定位和定量测量。

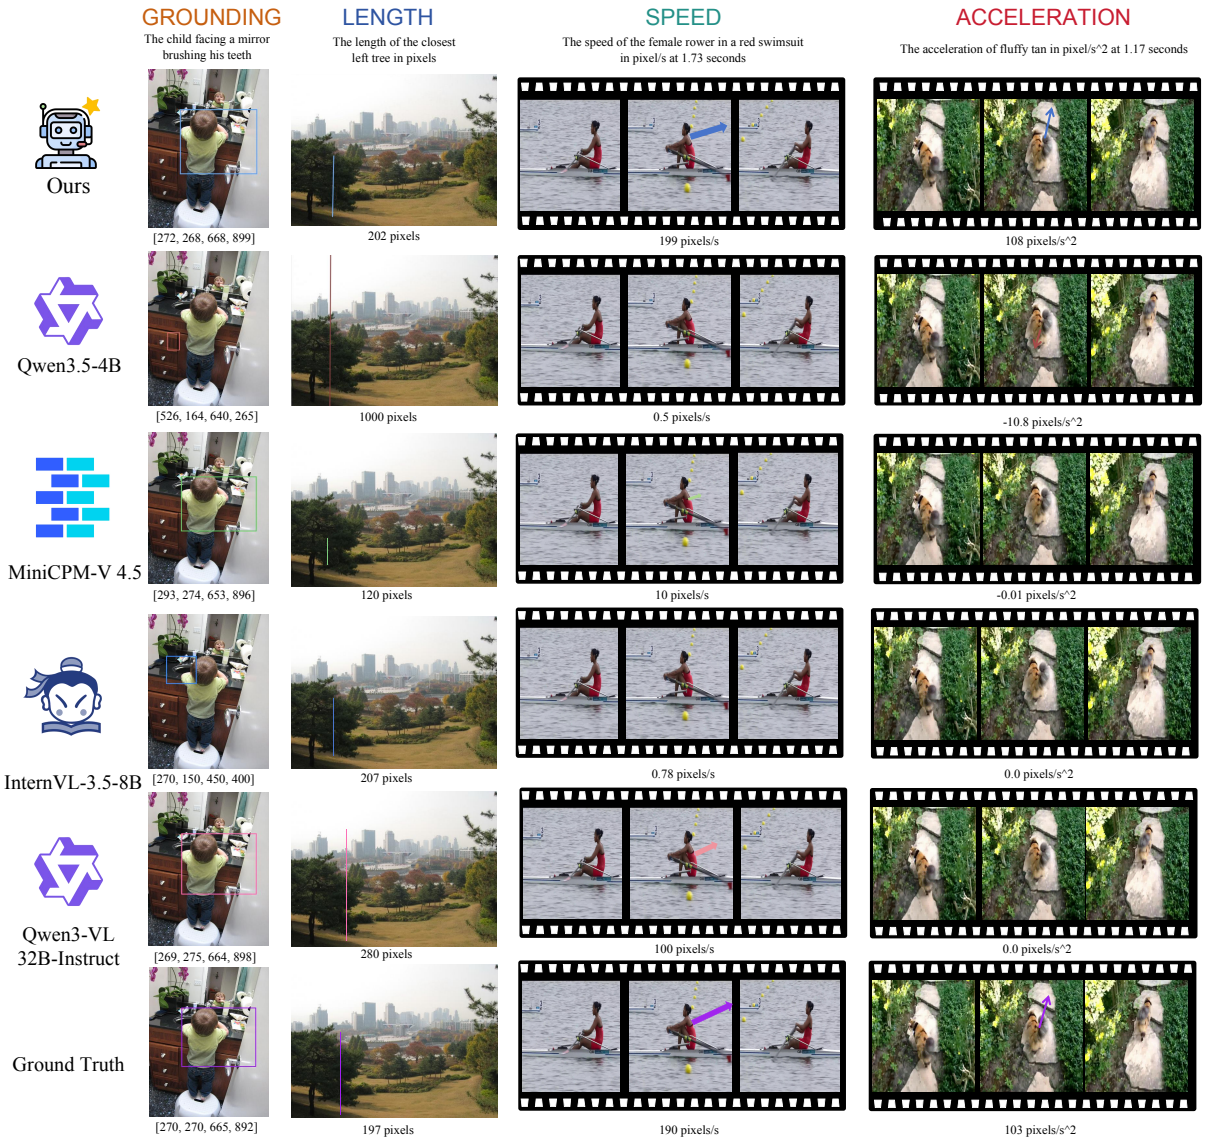


图 12 图像空间定位与测量的定性比较。四列分别评估目标定位、物体长度、速率和加速度。所有数值量均以问题指定的像素空间单位表示。

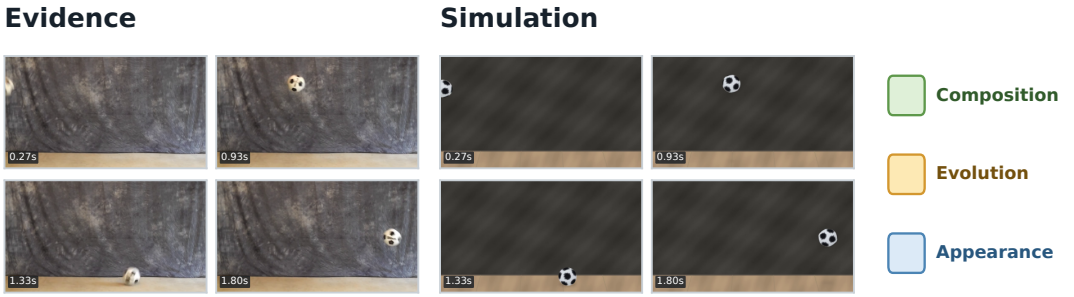
C.4 数据来源消融

我们对两阶段课程中的三类数据来源进行消融：图像空间测量数据 $\mathcal{D}_{\text{pix}}$、文本驱动的可执行世界 $\mathcal{D}_{\text{text}}$，以及视频驱动的可执行世界 $\mathcal{D}_{\text{video}}$。我们在紧凑的 4B 和 9B 模型上开展此项消融。所有变体首先使用 $\mathcal{D}_{\text{pix}}$ 建立图像空间测量能力，随后单独或联合引入两类世界空间数据来源。

表 4 数据来源消融。针对两阶段课程中的三类数据来源，我们报告各 QuantiPhy 子集上的 MRA 及其宏平均。

Training Variants	Size	$\mathcal{D}_{\text{pix}}$	$\mathcal{D}_{\text{text}}$	$\mathcal{D}_{\text{video}}$	2S	2D	3S	3D	Avg.
Image-Space Only	4B	✓			45.3	45.1	31.6	54.6	44.2
+ Text-Driven Worlds	4B	✓	✓		47.5	49.4	40.0	57.0	48.5
+ Video-Driven Worlds	4B	✓		✓	42.2	52.7	46.5	49.8	47.8
Full Code-as-World-VL	4B	✓	✓	✓	45.4	**55.4**	45.8	56.0	50.6
Image-Space Only	9B	✓			44.3	51.9	51.4	60.0	50.9
+ Text-Driven Worlds	9B	✓	✓		47.2	48.1	53.5	61.1	52.5
+ Video-Driven Worlds	9B	✓		✓	43.1	50.5	**57.4**	**61.5**	53.1
Full Code-as-World-VL	9B	✓	✓	✓	**55.0**	52.9	55.6	58.1	**55.4**

如表 4 所示，加入任意一种世界空间数据来源都能提升 4B 图像空间模型的性能，结合两种来源则达到最佳平均得分 50.6，体现了二者的互补收益。在更大规模模型上也存在相同趋势，完整的 9B 模型从 50.9 提升至 56.8。综合来看，这些结果表明，在图像空间定位之外，精确的仿真器监督与真实视频对齐提供了互补信号。



scene.json

```
{
  "schema_version": 1,
  "coordinate_system": {"handedness": "right",
    "up_axis": "y", "length_unit": "meter"},
  "camera": {
    "model": "perspective",
    ...
    "binding": {"frame_count": 60,
      "image_size": [280, 504],
      ...
      "source_image_size": [1080, 1920]}
  },
  ...
  "execution_mode": "physics",
  "collision_objects": ["ball", "floor"],
  "expected_collisions": true,
  "external_wrenches": [],
  "contact_events": [
    {"frame_index": 14, "time_seconds": 0.533133,
      "objects": ["ball", "floor"],
      ...
      "kind": "native_contact"},
    {"frame_index": 40, "time_seconds": 1.400667,
      "objects": ["ball", "floor"],
      ...
      "kind": "native_contact"}
  ],
  ...
  "objects": [
    {
      "id": "ball", "semantic_label": "\u8db3\u7403",
      "role": "dynamic_rigid",
      "motion_execution": "physics",
      "extent": [0.2196042402061299,
        0.2196042402061299, 0.2196042402061299],
      "mesh": {"primitive_type": "sphere",
        "procedural_primitive": true,
        ...
        "appearance": "soccer_panels"},
      "initial_state": {
        "position": [-1.563215794156141,
          0.8104922155577554, -2.43124233553216666],
        ...
        "linear_velocity": [1.3552338287520653,
          -0.6983782887575889, 0.00507999744185685],
        "angular_velocity": [0.0, 0.0, 0.0]
      },
      "physics": {
        "body_type": "dynamic", "collision": {
          "shape": "sphere", "radius": 0.10980212010306495},
        "friction": 0.0, "mass": 3.6768789664225365,
        ...
        "restitution": 0.8059094118124696
      }
      ...
    },
    {
      "id": "floor", "semantic_label": "\u5730\u9762",
      "role": "static_rigid",
      "extent": [2.222890615463257,
        0.030757149681448936, 0.31273001432418823],
      ...
      "physics": {"body_type": "fixed",
        "collision": {"shape": "oriented_box_proxy"},
        ...
        "friction": 0.0, "restitution": 0.1}
    }
  ],
  ...
  "relations": [
    {"subject": "ball", "object": "floor",
      "type": "above", "confidence": 0.98}
  ],
  "rendering": {
    "background_kind": "synthetic",
    ...
    "preview_video": "renders/final_simulation.mp4"
  },
  "simulator": {
    "backend": "mujoco", "integrator": "implicitfast",
    "gravity": [0.0,
      -9.228704973337999, 0.0],
    "time_step": 0.001, "solver_iterations": 100
    ...
  },
  ...
  "timeline": {
    "fps": 29.969730572122224, "frame_count": 60,
    "time_basis": "source PTS seconds"
  }
  ...
}
```

simulation_sdk.py

```
...
557     scene = {
558         "schema_version": 1,
559         # Object-level execution is semantic; all numeric
    fitting remains SDK-owned.
560         "execution_mode": effective_mode,
561         "physics_recovered": False,
562         "expected_collisions": expected_collisions,
563         "collision_objects": collision_objects,
564         "coordinate_system": {
565             "handedness": "right",
566             "up_axis": "y",
567             "length_unit": "meter" if scale_status ==
    "metric" else "scene_unit",
568             "scale_status": scale_status,
569         },
570         "timeline": timeline,
571         "camera": {
572             "model": "perspective",
573             "trajectory": _relative(camera_path, run_root),
574             "binding": _load_camera_trajectory(camera_path),
575         },
576         "objects": objects,
577         "relations": relations,
578         "simulator": {
579             "backend": "mujoco",
580             "time_step": _positive_number(
581                 request["parameters"].get("time_step", 1.0 /
    240.0), "time_step"
582             ),
583             "gravity": gravity.tolist(),
584             "gravity_units": "m/s2" if scale_status ==
    "metric" else "scene_units/s2",
585             "scene_path": _relative(xml_path, run_root),
586         },
587         "ground": ground,
588         "boundaries": environment["boundaries"] if
    environment is not None else {},
589         "tracking_source": _relative(poses_path, run_root),
590         "trajectory_source": _relative(poses_path,
    run_root),
...
12399     (
12400         optimized_objects,
12401         optimized_boundaries,
12402         optimized_wrenches,
12403         gravity_scale,
12404     ) = _apply_scene_parameter_vector(
12405         original,
12406         original_boundaries,
12407         original_wrenches,
12408         specs,
12409         best_values,
12410         normal,
12411     )
12412     scene["objects"] = optimized_objects
12413     scene["boundaries"] = optimized_boundaries
12414     scene["external_wrenches"] = optimized_wrenches
12415     optimized_gravity = (base_gravity *
    gravity_scale).astype(float).tolist()
12416     scene["simulator"]["gravity"] = optimized_gravity
12417     final_parameters = copy.deepcopy(dict(mjcf_parameters))
12418     final_parameters["gravity"] = optimized_gravity
...
```

图 13 一个具体的 EWR 代码与仿真接口。视频驱动的场景被编码为结构化的 `scene.json` 规格描述，其中包含场景组成、演化、外观、物理参数、关系、仿真器配置和时间线。仿真器软件开发工具包（SDK）在 MuJoCo 中实例化并执行该规格描述，上方逐帧对齐的证据与仿真输出展示了所得到的重建结果。